

Comparación de arquitecturas

Fernando Nelson Candia Aroni


31 de Agosto de 2026

Dataset de evaluación

Ventana de espectrograma de 3 s → **cajas tiempo–frecuencia** con etiqueta especie/tipo de llamada (**25 clases**, 8 especies).

Split	Ventanas	Cajas
train	21 966	27 022
val	9 446	10 090
test	8 007	7 985


- Partición **por grabación**: ninguna ventana de test viene de un audio visto en entrenamiento.
- Acierto con $\text{IoU} \geq 0,5$; el uso previsto es **pre-anotación**, así que el recall pesa más que la precisión.



Borde desplazado

IoU 0.66


IoMin 0.80



Encuadre laxo

IoU 0.61


IoMin 1.00



Silaba dentro de frase


IoU 0.10

IoMin 1.00



— anotación - - - predicción

El Desbalance de clases



- as/hc (aullido de *Alouatta*) aporta **2 023** cajas de test; sb/sc sólo **37**. Un factor de 55.
- Ocho clases tienen menos de 100 cajas de test.
- Las llamadas **largas y tonales** abundan; los *squeaks* y *chirps* de decenas de milisegundos son minoría y son, además, los más difíciles de encuadrar.

Este reparto es el que explica el piso por clase que aparece en los resultados: no es sólo un problema de modelo.

Arquitecturas comparadas

	Faster R-CNN	DETR ts5	DETR ts10	YOLO26
Backbone	ResNet-50	AST	AST	CSP propio
Preentrenamiento	COCO	AudioSet	AudioSet	COCO
Parámetros	43,4 M	89,6 M	89,6 M	10,0 M
entrenables	43,4 M	3,1 M	3,1 M	10,0 M
Cajas candidatas	RPN + 100	64 queries	64 queries	300 (end-to-end)
Entrada	$3 \times 416 \times 1024$	$1 \times 128 \times 331$	$1 \times 128 \times 331$	$3 \times 512 \times 512$
Tokens / resolución	—	$12 \times 64 \cdot 47$ ms	$12 \times 32 \cdot 94$ ms	—
Elección del <i>best</i>	F3 (val)	F3 (val)	F3 (val)	mAP@0,5:0,95

Lo que está igualado para los cuatro

Mismas ventanas y mismo split · score $\geq 0,5$ · IoU $\geq 0,5$ · supresión de anidadas a 0,3 · tope de 64 detecciones por ventana · box_score_thresh 0,001 · una sola implementación de las métricas. **No** está igualada la receta de entrenamiento: cada framework corre con la suya, y YOLO26 elige su *checkpoint* con otro criterio.

Resultados

		Recall	Precisión	F3	mAP@0,5	mAP@0,5:0,95
Faster R-CNN	val	0,770	0,500	0,731	0,474	0,205
	test	0,777	0,499	0,736	0,487	0,211
DETR ts5	val	0,694	0,532	0,674	0,362	0,136
	test	0,694	0,517	0,671	0,373	0,143
DETR ts10	val	0,677	0,521	0,657	0,357	0,138
	test	0,682	0,499	0,658	0,347	0,138
YOLO26	val	0,533	0,819	0,552	0,531	0,263
	test	0,532	0,805	0,550	0,520	0,264

Punto de operación (F3)

Faster R-CNN > DETR ≫ YOLO26

Curva completa (mAP)


YOLO26 > Faster R-CNN ≫ DETR

val → test

sin caída: máx. 0,007 de recall

Faster R-CNN gana el recall en 24 de 25 clases; la mAP baja de los DETR (0,14) delata un encuadre flojo.

Recall-precisión



Tres modelos no dominados; elegir entre ellos es una decisión de uso, no de calidad:

- **Faster R-CNN** — máximo recall (0,777): 2 cajas revisadas por llamada recuperada, y casi nada se pierde.
- **DETR ts5** — intermedio, con sólo **3,1 M** de parámetros entrenables.
- **YOLO26** — máxima precisión (0,805) con 10 M de parámetros; deja fuera casi la mitad de las llamadas.

DETR ts10 está dominado por ts5: menos recall y menos precisión. Es lo único que la ablación descarta sin ambigüedad. Con F3 — el criterio de la tesis, $\text{recall} \times 9$ — el orden es Faster R-CNN, DETR, YOLO26.

Limitaciones de cada enfoque

Faster R-CNN — el mejor hoy

- Precisión 0,499: la mitad de lo que propone se descarta a mano.
- Entrena sus 43,4 M de parámetros desde COCO: no aprovecha ningún preentrenamiento de audio.
- mAP@0,5:0,95 de 0,211: el encuadre sigue flojo.

DETR (AST congelado) — la arquitectura propia

- 3,1 M entrenables: recall competitivo, pero mAP la mitad que la de Faster R-CNN.
- Su recall por clase sigue al soporte ($\rho = 0,56$): las clases raras no llegan a aprenderse.
- Bajar el paso de 10 a 5 cuesta $4\times$ y devuelve $+0,012$ de recall.

YOLO26 — el más barato

- Recall 0,532: 13 de 25 clases por debajo de 0,35.
- Su *checkpoint* se eligió por mAP@0,5:0,95, no por F3: el punto de operación está sin calibrar, es un piso.
- Sin preentrenamiento de audio.

Transversal — lo que no sostiene ningún número

- **Una sola semilla** por corrida: diferencias menores a $\sim 0,01$ de mAP no se separan del ruido.
- Ablación incompleta: falta el paso 2, la rama `logmel` y el *fine-tune* del AST. El PCEN aún no es un número.
- **EAT + DINO** implementado y verificado, pero sin entrenar.

Gracias