

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS E INGENIERÍA



**Detección de vocalizaciones de primates
neotropicales mediante cajas tiempo–frecuencia
para la pre-anotación asistida de grabaciones de
monitoreo acústico pasivo**

Tesis para obtener el título profesional de
Ingeniero Informático que presenta:

Fernando Nelson Candia Aroni

Asesor:

Dr. Edwin Rafael Villanueva Talavera

Lima, 2026

Índice general

1. Generalidades	2
1.1. Problemática	2
1.1.1. Recolección de datos acelerada	2
1.1.2. Análisis lento e inconsistente	4
1.1.3. Investigaciones anteriores	4
1.1.4. Vacío y contribución	5
1.2. Árbol de problemas	7
1.2.1. Condiciones subyacentes	8
1.2.2. Problema central	8
1.2.3. Causas	9
1.2.4. Efectos	11
1.3. Objetivos	12
1.3.1. Objetivo general	12
1.3.2. Objetivos específicos	13
1.4. Resultados esperados	13
1.4.1. OE1: Protocolo y conjunto de datos curado	13
1.4.2. OE2: Detector y evaluación	15
1.4.3. OE3: Cobertura, carga de revisión y análisis de discrepancias	17
1.5. Trazabilidad	20
1.6. Métodos y procedimientos	21
1.6.1. Metodología CRISP-DM	21
1.6.2. Herramientas	26
1.6.3. Procedimientos y reproducibilidad	26
2. Marco Referencial	29
2.1. Marco Teórico	29
2.1.1. Formulación del problema de detección	29
2.1.2. El espectrograma y la asimetría de sus ejes	32
2.1.3. Detección de objetos sobre audio	33
2.2. Marco Conceptual	34
2.2.1. Paisaje sonoro	34
2.2.2. Eventos acústicos	35
2.2.3. Representaciones tiempo–frecuencia	36

2.2.4.	Detección de eventos sonoros	37
2.2.5.	Clasificación jerárquica	40
2.2.6.	Anotaciones inconsistentes	41
3.	Estado del Arte	44
3.1.	Metodología de la revisión	44
3.1.1.	Objetivos y preguntas de revisión	44
3.1.2.	Estrategia de búsqueda	45
3.1.3.	Criterios de inclusión y exclusión	45
3.2.	Resultados de la revisión	47
3.2.1.	P1: Estrategias de detección tiempo–frecuencia	47
3.2.2.	P2: Clasificación jerárquica fina	48
3.2.3.	P3: Mitigación de ruido y variabilidad entre sensores	48
3.2.4.	P4: Conjuntos de datos y aumento de datos	49
3.2.5.	P5: Transferencia de aprendizaje	49
4.	Curación del Conjunto de Datos (OE1)	52
4.1.	Análisis del conjunto original	52
4.1.1.	Material recibido y formato	52
4.1.2.	Defectos detectados	53
4.1.3.	Composición del conjunto curado	55
4.1.4.	Geometría de los eventos	57
4.1.5.	Sílabas y frases	58
4.2.	Protocolo de curación y estandarización (RE1.1)	60
4.2.1.	Carga y consolidación	60
4.2.2.	Normalización de etiquetas	61
4.2.3.	Saneamiento geométrico	62
4.2.4.	Vocabulario cerrado y selección del subconjunto	63
4.3.	Particionado y ventaneo (RE1.2)	64
4.3.1.	Partición por archivo de grabación	64
4.3.2.	El ventaneo y lo que le cuesta a las llamadas largas	67
4.3.3.	Densidad de eventos por ventana	69
4.3.4.	Representación y normalización de las cajas	70
4.4.	Balance del conjunto de experimento	72
4.5.	Ficha del conjunto derivado (RE1.3)	73
5.	Detección, Evaluación y Utilidad Operativa (OE2 y OE3)	75
5.1.	Arquitectura propuesta y línea base (RE2.1)	75
5.2.	Pipeline de entrenamiento e inferencia (RE2.2)	78
5.3.	Protocolo de evaluación	78
5.4.	Resultados (RE2.3)	78
5.4.1.	Configuraciones comparadas	79
5.4.2.	Desempeño al punto de operación declarado	79

5.4.3.	Confianza calibrada y comparación a carga igual	80
5.4.4.	Lectura por clase	82
5.4.5.	Qué establece esta comparación	84
5.5.	Exportación a Raven (RE2.4)	87
5.6.	Publicación del código y del modelo (RE2.5)	87
5.7.	Protocolo de evaluación operativa (RE3.1)	87
5.8.	Cobertura frente a carga de revisión (RE3.2)	87
5.9.	Taxonomía de discrepancias (RE3.3)	87
5.10.	Validación experta (RE3.4, condicional)	87
A.	Plan del Proyecto	90
A.1.	Justificación y viabilidad	90
A.1.1.	Justificación	90
A.1.2.	Beneficios esperados	90
A.1.3.	Viabilidad técnica	91
A.1.4.	Viabilidad temporal	91
A.1.5.	Viabilidad económica	91
A.2.	Definición y alcance del proyecto	91
A.2.1.	Alcance	91
A.2.2.	Entregables y criterios de aceptación	92
A.2.3.	Exclusiones	92
A.2.4.	Limitaciones y restricciones	92
A.3.	Planificación del proyecto	94
A.3.1.	Estructura de desglose del trabajo	94
A.3.2.	Cronograma	96
A.3.3.	Estimación de costos	96
A.3.4.	Lista de recursos	96
A.3.5.	Gestión de riesgos	98

Índice de figuras

1.1. Ejemplo de anotación tiempo–frecuencia en Raven.	3
1.2. Tres formas de salida de un evento sonoro.	5
1.3. Árbol de problemas.	7
1.4. Material recibido por especie.	9
1.5. Fases de CRISP-DM del proyecto.	23
1.6. Criterio de IoU.	26
2.1. Segmentación tiempo–frecuencia	30
2.2. Cadena de la señal.	34
2.3. Compromiso STFT.	37
2.4. Escala mel.	37
2.5. PCEN frente a log-mel.	38
4.1. Archivo de anotaciones de Raven	52
4.2. Raven con una grabación anotada	53
4.3. Etiquetas únicas encontradas en la columna de especie.	54
4.4. Etiquetas únicas encontradas en la columna de tipo de llamada.	54
4.5. Advertencias emitidas durante la carga automatizada de las grabaciones.	54
4.6. Grabación con corrupción leve	55
4.7. Grabación con corrupción severa	55
4.8. Galería de llamadas.	56
4.9. Geometría de las clases	58
4.10. Duración frente a ancho de banda	59
4.11. Anidamiento frase-sílaba.	60
4.12. Pipeline de curación.	61
4.13. Anotaciones por par	65
4.14. Partición por grabación.	67
4.15. Efecto del ventaneo.	69
4.16. Ventana de entrenamiento	71
4.17. Coordenadas de la caja.	71
4.18. Cajas por clase y partición	72
4.19. Cajas anotadas por ventana	73
5.1. Arquitectura propuesta.	75
5.2. Pirámide multiescala.	76

5.3. Capa del decodificador.	76
5.4. Muestreo deformable.	77
5.5. Pipeline de entrenamiento.	77
5.6. Emparejamiento húngaro.	77
5.7. Pipeline de inferencia.	78
5.8. Umbral de confianza.	78
5.9. Detecciones cualitativas.	87
5.10. Matriz de confusión.	88
5.11. Distribución de IoU.	88
5.12. Ablación acumulada.	89
5.13. Línea de tiempo de detecciones.	89
5.14. Previsualización de la tabla de Raven.	89
A.1. EDT en árbol.	94

Índice de tablas

1.1. Resumen por especie	3
1.2. Vacío del problema	6
1.3. Disponibilidad en Xeno-canto	6
1.4. IOV de OE1	14
1.5. IOV de OE2	16
1.6. IOV de OE3	18
1.7. Taxonomía de discrepancias	20
1.8. Trazabilidad del planteamiento	21
1.9. Fases de CRISP-DM y objetivos	22
1.10. Métricas de evaluación	25
1.11. Stack técnico: pipeline	27
1.12. Stack técnico: desarrollo	28
2.1. Arquitecturas frente a requisitos	39
2.2. Especies de primates consideradas en el proyecto	41
2.3. Repertorio por especie	42
3.1. Cadenas de búsqueda	45
3.2. Criterios de inclusión y exclusión	46
4.1. Composición del vocabulario curado por especie	56
4.2. Variación de tamaño de las llamadas anotadas	57
4.3. Clases del subconjunto de experimento	66
4.4. Composición de las particiones tras el ventaneo	67
4.5. Efecto del ventaneo sobre las clases largas	68
4.6. Parámetros de preprocesamiento	70
5.1. Configuraciones comparadas	79
5.2. Resultados al punto de operación	80
5.3. Cobertura a carga igual	81
5.4. Recall por clase	83
A.1. Criterios de aceptación	93
A.2. EDT del proyecto	95
A.3. Costos de equipos y hardware	96

A.4. Capital intelectual	96
A.5. Costos de software y servicios	97
A.6. Costos indirectos	97
A.7. Resumen de costos	97
A.8. Riesgos del proyecto	99

Capítulo 1

Generalidades

1.1. Problemática

1.1.1. Recolección de datos acelerada

El monitoreo acústico pasivo (PAM) consiste en dejar grabadoras autónomas en el campo y registrar el sonido del ecosistema de forma continua. Frente a otros métodos de muestreo, los sensores acústicos no son invasivos, suelen ser omnidireccionales y ofrecen un área de detección mayor y menos restricciones taxonómicas que las cámaras trampa (Gibb et al., 2018). Permiten muestrear durante periodos largos con poco esfuerzo manual, lo que aumenta la probabilidad de detectar especies raras o poco vocales (Gibb et al., 2018), justamente el caso de los primates neotropicales de la Amazonía peruana, difíciles de observar de forma directa.

La aparición de sensores de bajo costo y código abierto está ampliando rápidamente el acceso a estas tecnologías y permite desplegar redes multisensor a escala (Gibb et al., 2018). El costo de grabar y almacenar cayó lo suficiente como para hacer viable la captura continua de audio (Stowell, 2022). El conjunto sobre el que trabaja esta tesis lo ilustra: 3 355 grabaciones de ocho especies de primates, con una duración acumulada de 32,69 horas, de las cuales 2 820 grabaciones (26,36 horas) cuentan con anotaciones expertas. La composición por especie se detalla en la Tabla 1.1. Sobre ese material, el protocolo de curación del Capítulo 4 deja 19 042 anotaciones utilizables: es la magnitud que conviene retener para contrastarla, más adelante, con lo disponible públicamente.




Figura 1.1: Ejemplo de anotación tiempo–frecuencia en Raven.

Tabla 1.1: Resumen por especie

Especie (código)	Total		Con anotaciones	
	N.º	Horas	N.º	Horas
Mono ardilla boliviano (SB)	290	3,08	256	2,79
Mono aullador (AS)	808	7,57	779	7,27
Capuchino de cabeza grande (SM)	659	6,13	582	5,31
Mono nocturno (AA)	116	1,10	83	0,78
Mono araña peruano (AC)	561	6,07	383	3,62
Capuchino de cabeza chata (CC)	16	0,11	7	0,04
Tití de Toppin (PT)	375	3,35	320	2,82
Tamarino de Weddell (LW)	530	5,28	410	3,71
Total	3 355	32,69	2 820	26,36

1.1.2. Análisis lento e inconsistente

El cuello de botella habitual es la falta de tiempo-persona de analistas entrenados (Stowell, 2022), y recolectar anotaciones es el principal cuello de botella para construir estos métodos (Nguyen Hong Duc et al., 2021). El trabajo se hace a mano. El analista abre cada grabación, inspecciona el espectrograma, dibuja un recuadro alrededor de cada vocalización y le asigna una etiqueta. En detección de eventos sonoros, recolectar etiquetas fuertes a gran escala consume mucho tiempo, y en la mayoría de los casos varios trabajadores se reparten las anotaciones para construir un solo conjunto de datos (Koga et al., 2024).

Ese reparto introduce un segundo problema ya que la anotación manual es subjetiva, y resulta difícil cuantificar los sesgos ligados al nivel de conocimiento del analista (Gibb et al., 2018); estudios recientes muestran que la tarea genera errores específicos de cada anotador (Nguyen Hong Duc et al., 2021). Al comparar varios anotadores sobre el mismo audio, las etiquetas fuertes presentan variaciones grandes tanto en el tipo de evento como en los tiempos de inicio y fin, hasta el punto de que determinar una etiqueta única resulta difícil (Koga et al., 2024). En bioacústica marina, Leroy et al. (2018) encontraron menos del 50 % de acuerdo entre dos analistas, y también un acuerdo pobre de un mismo analista al anotar dos veces el mismo segmento.

La variación temporal en las etiquetas fuertes es inevitable, y afecta tanto al entrenamiento del modelo como a la evaluación de su desempeño (Koga et al., 2024). Esto significa que en proyectos donde se aplica PAM, una gran parte del audio queda sin anotar y las etiquetas anotadas son inconsistentes.

1.1.3. Investigaciones anteriores

Los sistemas más difundidos clasifican segmentos de duración fija. BirdNET identifica cientos de especies de aves puntuando ventanas cortas de audio (Kahl et al., 2021) y, en un caso más cercano al de esta tesis, HOWLish detecta aullidos de lobo con una precisión de 0,006 bajo un desbalance extremo, y aun así reduce unas 15 veces el tiempo del operador frente a anotar todo a mano (Campos et al., 2025). Ese resultado es relevante porque muestra que, cuando un humano revisa la salida, aceptar precisión baja a cambio de recall alto es una estrategia válida. Su limitación es la forma del resultado: una probabilidad por segmento, no un evento delimitado.

Una segunda línea sí devuelve eventos. Los *sound event bounding boxes* formalizan cada predicción como una cuádrupla de clase, tiempo de inicio, tiempo de fin y una puntuación global de confianza (Ebberts et al., 2024). Es un evento con extensión propia, pero esa extensión existe solo sobre el eje temporal.

La tercera línea trata el espectrograma como una imagen. La idea de partida es que los eventos acústicos se manifiestan como patrones bidimensionales de tiempo y frecuencia, con texturas y estructuras geométricas propias, análogos a los objetos que aparecen en imágenes naturales (Pham et al., 2018). El trabajo más cercano al de esta tesis es NBM, que publica anotaciones precisas de tiempo y frecuencia recolectadas por decenas de aficionados a las aves en Francia, junto con un modelo de detección de objetos de dos etapas adaptado a datos de audio (Airale et al., 2025).




Figura 1.2: Tres formas de salida de un evento sonoro.

1.1.4. Vacío y contribución

El vacío tiene dos ejes, y esta tesis se sitúa en el cruce (Tabla 1.2).

Tabla 1.2: Vacío del problema

	Tarea madura: detección temporal	Tarea poco explorada: cajas tiempo–frecuencia
Dominio con recursos (aves, mamíferos marinos, cánidos)	BirdNET, SEBB, YOHO	NBM (Airale et al., 2025), YOLOv5 en focas barbudas (Escobar-Amado et al., 2024)
Dominio sin recursos (primates neotropicales)	Heinicke et al. (2015), primates africanos	Vacío: esta tesis

Eje de dominio. Los sistemas maduros existen para aves, lobos y mamíferos marinos. Para primates neotropicales de la Amazonía no hay un conjunto público con anotaciones tiempo–frecuencia. La Tabla 1.3 lo documenta sobre el repositorio abierto de grabaciones de fauna más utilizado: para las ocho especies objetivo, Xeno-canto contiene 32 grabaciones en primer plano y poco más de una hora de audio en total, tres especies no tienen ninguna grabación, y ninguna de las disponibles incluye anotaciones tiempo–frecuencia.

Tabla 1.3: Disponibilidad de grabaciones de las especies objetivo en Xeno-canto

Especie	Grabaciones (primer plano)	Duración total
<i>Alouatta sara</i>	8	41:14
<i>Plecturocebus toppini</i>	13	19:20
<i>Ateles chamek</i>	4	03:42
<i>Saimiri boliviensis</i>	4	02:28
<i>Aotus azarae</i>	3	02:18
<i>Cebus cuscinus</i>	0	N/D
<i>Leontocebus weddelli</i>	0	N/D
<i>Sapajus apella macrocephalus</i>	0	N/D
Total	32	69:02

Consulta realizada el 19 de agosto de 2026 sobre el nombre científico de cada especie (Vellinga, 2026).

Eje de tarea. El vacío tampoco es solo de dominio. La investigación existente ha pasado por alto en gran medida el rango de frecuencia de los eventos; el SED temporal descarta información codificada en el dominio frecuencial, y por eso la detección precisa

de cajas tiempo–frecuencia puede asistir al investigador humano. Pese a esa relevancia, sigue siendo un área en gran medida inexplorada (Zhu and Sato, 2025).

En el cruce de ambos ejes se sitúa esta tesis, que desarrolla un protocolo de curación y estandarización sobre las anotaciones producidas por el equipo de investigación, y un detector que devuelve cajas tiempo–frecuencia con especie, tipo de llamada y confianza, concebido como herramienta de pre-anotación asistida.

1.2. Árbol de problemas

El árbol se estructura siguiendo el heurístico de análisis causa–efecto propuesto por Veselý (2008), y sirve de puente entre la brecha operativa descrita en la sección anterior y los objetivos de la investigación. Organiza el área temática en causas, problema central y efectos para ordenar el trabajo posterior, sin cuantificar las relaciones entre sus elementos.

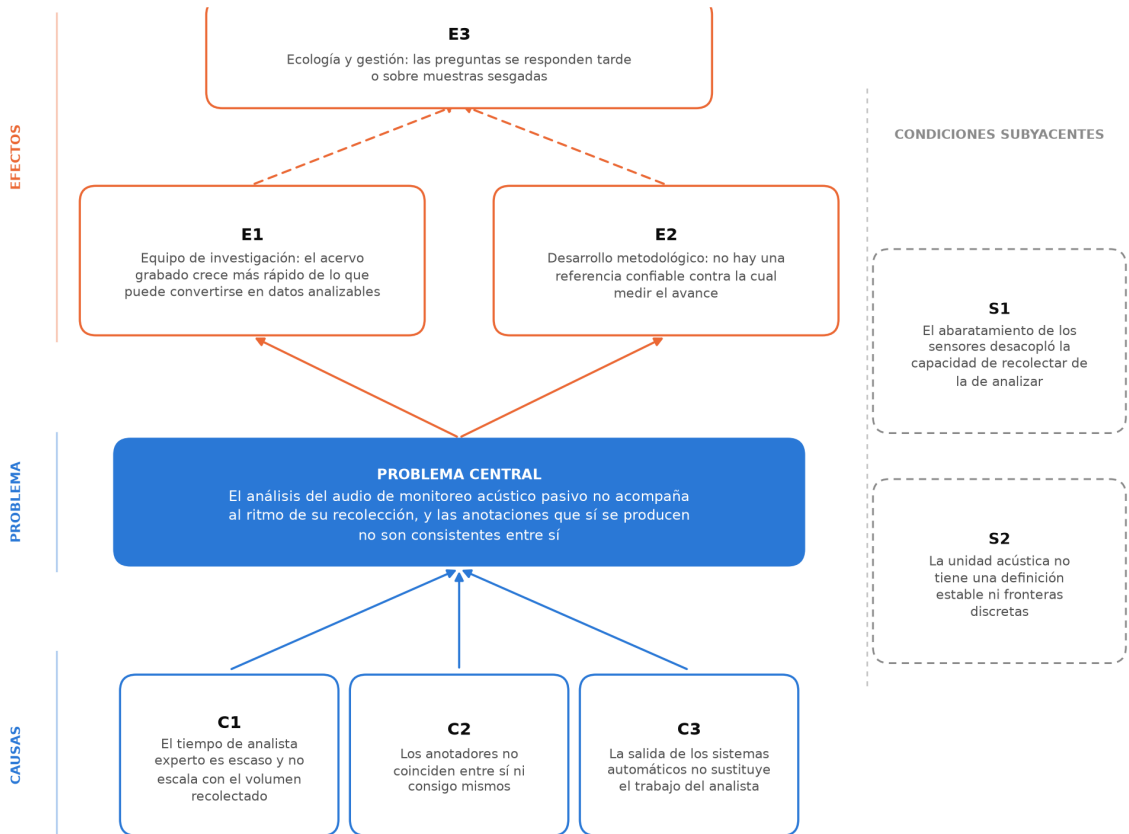


Figura 1.3: Árbol de problemas.

1.2.1. Condiciones subyacentes

Dos condiciones enmarcan el problema sin ser causas sobre las que esta tesis pueda actuar. Se consignan aparte, siguiendo la recomendación de Veselý (2008) de ubicar fuera del eje causal aquello sin lo cual el problema no existiría o existiría de otra forma.

S1: Grabar se volvió barato, pero analizar no

Los sensores de bajo costo permiten desplegar redes de muchos micrófonos a escala (Gibb et al., 2018). La condición no es negativa en sí misma; es la que vuelve visible y creciente la distancia entre lo que se graba y lo que se llega a revisar.

S2: La unidad acústica no tiene una definición estable ni fronteras discretas

Las unidades acústicas pueden estar jerárquicamente anidadas, de modo que una secuencia de unidades puede considerarse ella misma una unidad y ser reemplazada por una etiqueta; se organizan en notas, trinos, sílabas, frases, motivos y cantos, y las definiciones de unidad varían ampliamente entre investigadores, incluso dentro de un mismo grupo taxonómico (Kershenbaum et al., 2016). A ello se suma que las unidades producidas por animales exhiben variación graduada en sus rasgos, mientras que la mayoría de métodos analíticos asume categorías discretas (Kershenbaum et al., 2016). La indefinición de granularidad es, entonces, anterior al anotador y no se resuelve entrenándolo mejor. Esta condición es la que justifica, más adelante, una curación metodológica explícita en lugar de una corrección de las anotaciones recibidas.

1.2.2. Problema central

El análisis del audio de monitoreo acústico pasivo no acompaña al ritmo de su recolección, y las anotaciones que sí se producen no son consistentes entre sí.

El enunciado tiene deliberadamente dos predicados, porque el problema tiene dos dimensiones que ninguna de las dos agota por separado: un déficit de *caudal* (se anota mucho menos de lo que se graba) y un déficit de *consistencia* (lo que se anota no obedece a un criterio único). Un planteamiento que solo recogiera el primero dejaría sin cubrir la causa C2 y el efecto E2; uno que solo recogiera el segundo no explicaría todo el audio que queda sin anotar.

Del lado de la recolección, el despliegue a escala es hoy accesible (S1). Del lado del análisis, la gran cantidad de audio que se acumula hace que un cuello de botella común sea la falta de tiempo-persona de analistas entrenados (Stowell, 2022). Conforme escala el número de grabadoras desplegadas, detectar señales acústicas en los paisajes sonoros registrados se vuelve un obstáculo logístico que limita la escalabilidad de los estudios de PAM (Campos et al., 2025).




Figura 1.4: Material recibido por especie.

1.2.3. Causas

C1: Hay pocas horas de analista experto disponibles

Los eventos sonoros requieren que un experto los anote con las etiquetas correctas, y ese tiempo experto suele escasear; la restricción se siente tanto en distinciones categóricas finas como en el monitoreo a gran escala, donde el volumen de datos excede con mucho las horas-persona disponibles (Stowell, 2022). En detección de eventos sonoros, recolectar etiquetas fuertes a gran escala consume mucho tiempo, y por eso varios trabajadores se reparten las anotaciones para construir un solo conjunto de datos (Koga et al., 2024). El reparto entre anotadores es la respuesta habitual a esta restricción, y es también el punto donde C1 y C2 se encuentran: alivia el caudal a costa de multiplicar los criterios en juego.

C2: Inconsistencia entre anotadores y dentro de un mismo anotador

La tarea es subjetiva y genera errores específicos de cada anotador (Nguyen Hong Duc et al., 2021), y los sesgos ligados al nivel de conocimiento del analista son difíciles de

cuantificar (Gibb et al., 2018). La magnitud está medida: menos del 50 % de acuerdo entre analistas, y acuerdo pobre de un mismo analista consigo mismo (Leroy et al., 2018); con 20 anotadores por clip, las etiquetas fuertes presentan variaciones grandes en tipo de evento y en tiempos de inicio y fin (Koga et al., 2024). Estudios previos no han encontrado soluciones suficientes, y la variación afecta tanto el entrenamiento como la evaluación (Koga et al., 2024).

Interesa subrayar que este desacuerdo es una propiedad medible de la tarea y no un defecto individual corregible: descansa sobre S2, que fija su piso. Reducirlo a cero no es un objetivo alcanzable, y cualquier propuesta metodológica debe trabajar con él en lugar de suponerlo ausente.

C3: La salida de los sistemas automáticos no sustituye el trabajo del analista

La automatización sería la vía natural para aliviar C1, pero su producto actual no es un reemplazo directo del insumo que el analista necesita. Esto ocurre por dos motivos distintos, uno de representación y otro de cobertura.

En cuanto a la representación, los sistemas basados en segmentos fijos entregan una probabilidad asociada a una rejilla, no un evento con extensión propia: BirdNET divide las grabaciones en fragmentos de 3 s y almacena las probabilidades por especie de cada segmento (Kahl et al., 2021), y HOWLish segmenta en ejemplos de 0,96 s y promedia las predicciones con una ventana móvil (Campos et al., 2025). Los sistemas que sí entregan eventos delimitados los definen solo sobre el eje temporal, sea como cuádruplas de clase, onset, offset y confianza (Ebbers et al., 2024), sea regresando los puntos de inicio y fin de cada clase (Venkatesh et al., 2022). La frecuencia, sin embargo, aporta información que el biólogo usa: las cajas predichas llevan información estadística embebida sobre la vocalización, como su duración, ancho de banda y frecuencia central (Escobar-Amado et al., 2024).

En cuanto a la cobertura, aun cuando la precisión es alta, los métodos del estado del arte fallan con regularidad al distinguir llamadas tenues, transitorias o parcialmente enmascaradas, produciendo tasas altas de falsos negativos (Gibb et al., 2018). Una salida automática incompleta no descarga al analista: lo obliga a revisar igual.

1.2.4. Efectos

Los efectos se organizan por actor afectado, siguiendo el criterio que Veselý (2008) ilustra en su tercer ejemplo, en lugar de asignar un efecto a cada causa. E1 y E2 son efectos directos; E3 se deriva de ambos.

E1: Para el equipo de investigación, el material grabado crece más rápido de lo que puede analizarse

El volumen de datos excede con mucho las horas-persona disponibles (Stowell, 2022), y la detección de señales en los paisajes sonoros registrados se convierte en un obstáculo logístico conforme escalan los despliegues (Campos et al., 2025). El efecto práctico es que el esfuerzo y el gasto de despliegue quedan inmovilizados en material sin procesar, y que la porción del material efectivamente anotada responde a la disponibilidad del analista antes que a un criterio de muestreo.

E2: Para el desarrollo metodológico, no hay una referencia confiable contra la cual medir el avance

La variación en las etiquetas fuertes no solo afecta el entrenamiento del modelo, sino que tiene un impacto significativo sobre la evaluación de su desempeño (Koga et al., 2024). En el terreno de las cajas tiempo–frecuencia, Zhu and Sato (2025) observan desplazamientos relativamente grandes de las cajas predichas frente a las anotadas, y concluyen que las fronteras de los eventos son borrosas y difíciles de determinar, por lo que fijar un umbral de IoU bajo es razonable. A la heterogeneidad se suma un faltante no aleatorio: las llamadas tenues o enmascaradas escapan a los métodos automáticos (Gibb et al., 2018), de modo que los eventos ausentes de la referencia son sistemáticamente los más difíciles. La consecuencia es que las cifras de desempeño reportadas son difíciles de comparar entre trabajos y tienden a describir mejor las condiciones fáciles que el problema completo.

E3: Para la ecología y la gestión, las preguntas se responden tarde o sobre muestras sesgadas

Efecto indirecto, derivado de E1 y E2. El PAM es cada vez más adecuado para programas de monitoreo orientados a objetivos, cuyos protocolos deben ser estandarizables, escalables y financieramente sostenibles (Gibb et al., 2018); sus beneficios incluyen el muestreo continuo con poco esfuerzo manual y una mayor probabilidad de detectar

especies raras o poco vocales (Gibb et al., 2018). Cuando el análisis no acompaña a la recolección, esas ventajas no se materializan: la ventaja de detección de lo raro se pierde por E1, y la confianza en lo que se reporta se erosiona por E2. En primates, Heinicke et al. (2015) ya habían señalado el costo de esta brecha al evaluar un sistema de monitoreo acústico en un ambiente de selva altamente ruidoso.

1.3. Objetivos

1.3.1. Objetivo general

OG. Desarrollar y evaluar un sistema de pre-anotación asistida que proponga cajas tiempo–frecuencia con especie y tipo de llamada sobre grabaciones de PAM de primates amazónicos, con el fin de maximizar la cobertura de eventos anotados bajo una carga de revisión acotada.

El encuadre asistido cuenta con respaldo en la literatura. La inteligencia artificial no reemplaza la experiencia, y conforme estos sistemas se estandarizan asumen el papel de pares expertos con quienes se consulta y debate, sin desplazar el rol del experto ni el del trabajo colaborativo (Stowell, 2022). También tiene precedente cuantificado en primates. Heinicke et al. (2015) evaluaron un sistema de monitoreo acústico para cuatro especies de primates en el ambiente altamente ruidoso del Parque Nacional Tai, y reportan que, pese a una precisión aparentemente baja, la inversión de tiempo para remover manualmente los falsos positivos de la salida del sistema fue de apenas 3–5 % comparada con la de un humano recolectando y procesando los datos de vocalización.

El mismo patrón se repite fuera de primates, y lo hace con una distinción que este objetivo general adopta de forma deliberada. HOWLish recupera el 81,3 % de los eventos de aullido observados y ofrece una reducción de 15 veces en el tiempo del operador frente a la detección totalmente manual, y su tubería redujo 22 veces el volumen de datos que un operador debía procesar manualmente (Campos et al., 2025). Son dos cifras de naturaleza distinta: la primera es una medida de tiempo humano y exige cronometrar a una persona; la segunda es una cantidad contable que se deriva de la propia salida del sistema. Por eso el enunciado habla de *carga* de revisión y no de tiempo de revisión: la carga —cuántas propuestas hay que inspeccionar y cuánto audio puede omitirse por completo— es la magnitud que este trabajo puede medir sobre su

propio conjunto de prueba, sin depender de la disponibilidad de un revisor externo. El dato de Heinicke et al. (2015) conserva su lugar como motivación, pues muestra que el encuadre asistido es rentable en primates y en selva ruidosa, pero no como indicador.

El enunciado fija además el compromiso que el sistema asume de antemano: priorizar la cobertura aceptando falsos positivos. Ese sesgo no es una concesión sino una decisión con precedente cuantificado, ya que HOWLish resulta útil operando con una precisión de 0,006 bajo desbalance extremo (Campos et al., 2025). Su contrapartida es que la carga generada por ese sesgo debe quedar acotada y reportada, y de eso se ocupa OE3.

1.3.2. Objetivos específicos

Cada objetivo específico responde a una de las tres causas del árbol: OE1 a la inconsistencia del etiquetado (C2), OE2 a la forma de la salida (C3) y OE3 a la escasez de horas de analista (C1).

OE1. Definir un protocolo de curación y estandarización, y aplicarlo sobre las anotaciones entregadas por el equipo de investigación para construir un conjunto de datos consistente de cajas tiempo–frecuencia etiquetadas por especie y tipo de llamada.

OE2. Implementar y evaluar un detector que reciba un espectrograma y devuelva cajas tiempo–frecuencia con especie, tipo de llamada y confianza, comparándolo con una línea base establecida.

OE3. Caracterizar el comportamiento operativo del detector sobre un conjunto de prueba independiente, cuantificando la cobertura de las anotaciones de referencia, la carga de revisión asociada y la naturaleza de sus discrepancias.

1.4. Resultados esperados

1.4.1. OE1: Protocolo y conjunto de datos curado

Las grabaciones y las anotaciones primarias provienen del equipo de investigación. La contribución de esta tesis es la normalización, el particionado y la caracterización del conjunto derivado, no la anotación original.

RE1.1. Protocolo documentado: vocabulario cerrado de clases, mapa de sinónimos, reglas de descarte y criterio de partición. Las definiciones de unidad y las etiquetas semánticas varían ampliamente entre investigadores (Kershenbaum et al., 2016),

Tabla 1.4: Resultados esperados, medios de verificación e indicadores objetivamente verificables de OE1

RE	Resultado	Medio de verificación	Indicador objetivamente verificable (IOV)
RE1.1	Protocolo de curación y estandarización documentado.	Documento del protocolo.	Define la normalización de columnas y etiquetas, el mapa de sinónimos, el descarte de ruido y cajas degeneradas, la corrección de pares imposibles, el recorte al límite de Nyquist y el tratamiento de registros fuera de vocabulario.
RE1.2	Conjunto acústico curado y particionado para el experimento.	Directorio <code>data/processed/</code> : etiquetas, metadatos y tres archivos <code>.pt</code> .	Los archivos procesados cargan sin error; <code>meta.json</code> registra la semilla, el criterio de selección, las exclusiones, la etiqueta usada y la normalización; el código divide por archivo de grabación con proporciones 60/22,5/17,5 y no por ventanas aisladas.
RE1.3	Ficha del conjunto derivado.	Capítulo de curación, README y metadatos del conjunto.	Describe las ocho especies, el vocabulario, la composición, el desbalance, el diccionario de campos, el ventaneo de 3 s con salto de 1,5 s, la normalización log-mel, las exclusiones y las limitaciones conocidas.

lo que justifica cerrar el vocabulario, y los protocolos de monitoreo deben ser estandarizables (Gibb et al., 2018).

RE1.2. Conjunto curado y particionado por archivo de grabación, sin solapamiento entre particiones. La variación en las etiquetas fuertes impacta la evaluación (Koga et al., 2024), por lo que una partición que no infle artificialmente el resultado es condición para que las cifras sean interpretables.

RE1.3. Ficha del conjunto derivado: composición, desbalance, sesgos conocidos y limitaciones. Pese a la importancia de los datos para el aprendizaje automático, no existe un proceso estandarizado para documentar conjuntos de datos; las *datasheets* proponen documentar motivación, composición, proceso de recolección y usos recomendados, con el potencial de aumentar la transparencia y la rendición de cuentas (Gebru et al., 2021). La ficha distingue dos capas: el conjunto primario, producido por el equipo de investigación, y el conjunto derivado, producido por esta tesis.

La decisión de excluir las clases de frase se apoya directamente en Kershenbaum et al. (2016): las unidades pueden estar jerárquicamente anidadas, de modo que una secuencia de unidades puede considerarse ella misma una unidad, y un detector de conjunto plano no puede representar esa relación.

1.4.2. OE2: Detector y evaluación

RE2.1. Documento de diseño: arquitectura propuesta y línea base, con justificación de ambas. Los eventos se manifiestan como patrones bidimensionales con texturas y estructuras geométricas propias, análogos a los objetos de imágenes naturales (Pham et al., 2018), y detectar un objeto implica tanto afirmar que una clase está presente como localizarla, localización que se representa típicamente mediante una caja delimitadora (Lin et al., 2014). La brecha de modalidad entre imagen y audio justifica sustituir los *backbones* preentrenados en imágenes (Zhu and Sato, 2025). Como precedentes de detección bidimensional en bioacústica se consideran Escobar-Amado et al. (2024) y Airale et al. (2025), y como línea base sobre espectrogramas, González et al. (2025).

Tabla 1.5: Resultados esperados, medios de verificación e indicadores objetivamente verificables de OE2

RE	Resultado	Medio de verificación	Indicador objetivamente verificable (IOV)
RE2.1	Diseño experimental, arquitectura propuesta y línea base.	Documento de diseño y módulo de arquitecturas.	Especifica la arquitectura AST-Deformable-DETR implementada, con dimensión 128, 64 consultas y 3 niveles, sus hiperparámetros, y define la comparación con las líneas base declaradas.
RE2.2	Pipeline reproducible de entrenamiento, evaluación e inferencia.	Scripts de datos, entrenamiento, evaluación e inferencia; módulos de <code>src/pipelines/</code> ; <code>pyproject.toml</code> y manual técnico.	El pipeline genera los splits procesados, entrena desde un conjunto de configuración, evalúa un checkpoint y ejecuta inferencia sobre un WAV; las dependencias y comandos de ejecución están declarados.
RE2.3	Informe comparativo de resultados.	Informe de experimentación y archivos de métricas.	Reporta, como mínimo, recall, precisión, F1, IoU medio, AP a IoU 0,25 y 0,5, recall por clase y matriz de confusión; separa detección, encuadre y clasificación y justifica la selección del modelo.
RE2.4	Modelo final cargable y demostración funcional.	Checkpoint <code>.pth</code> , <code>labels.json</code> y ejecución de <code>src/infer.py</code> .	El checkpoint se carga sin claves incompatibles y la inferencia sobre un WAV produce un archivo tabulado con las columnas de Raven, incluidas coordenadas tiempo–frecuencia, especie, tipo de llamada y puntuación.
RE2.5	Código y modelo disponibles en un repositorio.	Repositorio de control de versiones.	La URL del repositorio permite localizar el código de curación, entrenamiento, evaluación e inferencia, junto con las instrucciones de ejecución y los artefactos del modelo final que se hayan decidido publicar.

RE2.2. Pipeline reproducible de entrenamiento, evaluación e inferencia. La pirámide multiescala corrige que las arquitecturas de tipo ViT y AST produzcan representaciones de escala única (Zhu and Sato, 2025).

RE2.3. Informe de evaluación desagregado en detección, encuadre y clasificación, con comparación contra la línea base. Un umbral de IoU bajo es razonable cuando las fronteras de los eventos son borrosas (Zhu and Sato, 2025), y el sesgo hacia el recall se justifica por el fallo sistemático de los métodos automáticos ante llamadas tenues o enmascaradas (Gibb et al., 2018).

RE2.4. Modelo final y exportador a tabla de selección de Raven. Las cajas llevan información estadística embebida útil para el analista, como la duración, el ancho de banda y la frecuencia central (Escobar-Amado et al., 2024).

RE2.5. Repositorio público con código y pesos del modelo.

El contraste que sostiene RE2.4 es directo: BirdNET y HOWLish entregan probabilidad por segmento (Kahl et al., 2021; Campos et al., 2025), los *sound event bounding boxes* y YOHO entregan límites temporales (Ebberts et al., 2024; Venkatesh et al., 2022), y esta tesis entrega la tupla completa de tiempo, frecuencia, especie, tipo de llamada y confianza.

1.4.3. OE3: Cobertura, carga de revisión y análisis de discrepancias

OE3 mide la utilidad operativa del sistema con magnitudes que se calculan sobre el propio conjunto de prueba. Ninguno de sus tres resultados comprometidos depende de cronometrar a un revisor externo, y el cuarto se declara condicional justamente porque sí depende de él.

RE3.1. Protocolo de evaluación operativa, redactado y fechado antes de ejecutar la evaluación: material de prueba, punto de operación y criterio con que se elige, umbral de emparejamiento, supresión de no máximos entre ventanas, agregación por archivo y taxonomía de discrepancias, siguiendo el marco de tubería para identificación automatizada de sonidos (Gibb et al., 2018). Fijarlo de antemano impide elegir a posteriori el umbral o la métrica que mejor favorezcan al resultado ya obtenido.

Tabla 1.6: Resultados esperados, medios de verificación e indicadores objetivamente verificables de OE3

RE	Resultado	Medio de verificación	Indicador objetivamente verificable (IOV)
RE3.1	Protocolo de evaluación operativa.	Documento del protocolo, fechado antes de ejecutar la evaluación.	Especifica el subconjunto de prueba particionado por archivo y sin solapamiento, el punto de operación y el criterio con que se elige, el umbral IoU 0,5 de emparejamiento, la supresión de no máximos entre ventanas, el procedimiento de agregación por archivo y las cuatro categorías de la taxonomía de discrepancias.
RE3.2	Curva de cobertura frente a carga de revisión.	Informe de evaluación operativa, archivos de métricas y medición de inferencia.	Reporta la curva completa de cobertura (<i>recall</i> por evento a IoU 0,5) frente a propuestas por hora de audio; el punto de operación elegido junto con su criterio; el cociente FP/TP; la fracción de audio sin ninguna propuesta como reducción de volumen; y el costo de inferencia en minutos de GPU por hora de audio. No fija un porcentaje de ahorro antes de medirlo.
RE3.3	Taxonomía geométrica de discrepancias.	Informe de análisis, tablas de distribución y panel de espectrogramas.	Distribuye las predicciones de alta confianza entre las cuatro categorías de la Tabla 1.7; caracteriza la categoría D por banda de frecuencia, duración y puntuación frente a la distribución de los eventos anotados de cada clase; e incluye ejemplos visuales representativos de cada categoría sobre el espectrograma.
RE3.4	Validación experta de la categoría abierta (<i>condicional</i>).	Informe de validación, sujeto a la disponibilidad del equipo de investigación.	Si se concreta: resuelve una muestra de predicciones de categoría D entre evento omitido por la referencia y falso positivo genuino, y estima el acuerdo entre el modelo y el criterio experto. Su ausencia no compromete el cumplimiento de OE3.

RE3.2. Curva de cobertura frente a carga de revisión, en lugar de una única cifra cronometrada. La curva expresa qué fracción de las anotaciones de referencia recupera el sistema en función de cuántas propuestas por hora de audio se pide inspeccionar, y sobre ella se elige el punto de operación: el umbral que maximiza la cobertura sujeto a un techo de propuestas por hora. El punto de operación deja así de ser una constante heredada y pasa a ser una decisión justificada. Las cinco magnitudes que se reportan —cobertura, propuestas por hora, FP/TP, reducción de volumen y costo de inferencia— se computan íntegramente sobre la partición de prueba. El precedente metodológico directo es la reducción de 22 veces en el volumen de datos que un operador debía procesar manualmente (Campos et al., 2025), indicador que ese trabajo deriva de la salida del sistema y no de un cronómetro; el mismo trabajo sostiene el compromiso de cobertura sobre precisión al resultar útil operando con una precisión de 0,006 bajo desbalance extremo. El dato de tiempo de Heinicke et al. (2015) queda como motivación del encuadre asistido, no como indicador de este resultado.

Si el calendario lo permite, se añade una medición cronometrada sobre una muestra pequeña revisada por el propio autor, declarada de forma explícita como cota ilustrativa y no como validación experta.

RE3.3. Taxonomía geométrica de las discrepancias entre las predicciones de alta confianza y las anotaciones de referencia, según la Tabla 1.7. Las tres primeras categorías se resuelven sin consultar a nadie, porque quedan determinadas por la relación geométrica entre la caja predicha y una caja anotada que sí existe: son modos de error del modelo operando sobre eventos presentes en la referencia. Los dos que documenta Zhu and Sato (2025) —una caja anotada detectada como varias, y varias detectadas como una— corresponden a la categoría B, y la borrosidad de las fronteras del evento que ese mismo trabajo describe es lo que hace necesaria la categoría A.

Solo la categoría D queda abierta, y se caracteriza estadísticamente en lugar de dejarse sin resolver: se compara la distribución de banda de frecuencia, duración y puntuación de esas predicciones contra la de los eventos anotados de cada clase. Si se parecen geoméricamente a los eventos anotados y se concentran en las bandas correctas, eso constituye un *indicio* —no una prueba— de que la referencia omite

eventos. Que tal indicio sea plausible tiene respaldo: los métodos automáticos fallan con llamadas tenues o enmascaradas (Gibb et al., 2018), lo que implica la existencia de eventos válidos fuera del *ground truth*, y la variabilidad intra-analista (Leroy et al., 2018) apunta en la misma dirección desde el lado humano.

RE3.4. Validación experta de una muestra de predicciones de categoría D, para resolver si son eventos omitidos por la referencia o falsos positivos genuinos, y estimar el acuerdo entre el modelo y el criterio experto. Se declara **condicional**, sujeto a la disponibilidad del equipo de investigación. Su función en el documento es doble: proteger el cierre de la tesis, que no queda supeditado a la agenda de un tercero, y dejar preparado el resultado adicional si esa disponibilidad se concreta.

Tabla 1.7: Taxonomía geométrica de las discrepancias de alta confianza

Tipo	Discrepancia	Definición	¿Resoluble sin experto?
A	Encuadre	Solapa con una anotación de la misma clase, pero con IoU inferior al umbral de emparejamiento.	Sí
B	Unidad	Varias predicciones sobre una misma anotación, o una predicción sobre varias anotaciones: división y fusión.	Sí
C	Clase	Encuadre correcto sobre una anotación, con etiqueta de especie o de tipo de llamada incorrecta.	Sí
D	Región sin anotación	No solapa con ninguna caja anotada. Puede ser un evento omitido por la referencia o un falso positivo genuino.	No

Limitación declarada. Sin revisión experta, las predicciones de alta confianza situadas en regiones sin anotación (tipo D) no pueden clasificarse de forma concluyente entre eventos omitidos por la referencia y falsos positivos genuinos. Esta tesis las caracteriza geométricamente y las reporta como una cantidad acotada, dejando su resolución como trabajo futuro condicionado a la disponibilidad del equipo de investigación.

1.5. Trazabilidad

La relación entre las causas del problema, sus efectos y los productos comprometidos se resume en la Tabla 1.8. En la práctica, OE1 aborda la heterogeneidad del etiquetado,

OE2 la representación funcional de los eventos, y OE3 la utilidad operativa del sistema dentro del flujo de trabajo del analista. OE3 sigue atacando C1, la escasez de horas de analista, pero lo hace midiendo cuánto trabajo se evita y no cuánto tiempo tarda alguien en hacerlo.

Tabla 1.8: Trazabilidad entre causas, efectos, objetivos y resultados esperados

Causa	Efecto	Objetivo	Resultados esperados
C1: Velocidad	E1	OE3	RE3.1, RE3.2, RE3.3 y RE3.4 (condicional)
C2: Consistencia	E2	OE1	RE1.1, RE1.2, RE1.3
C3: Forma de la salida	E1, E2	OE2	RE2.1, RE2.2, RE2.3, RE2.4, RE2.5
E1, E2	E3	OG	Sistema de pre-anotación asistida integrado

1.6. Métodos y procedimientos

1.6.1. Metodología CRISP-DM

El desarrollo se organiza siguiendo CRISP-DM (*Cross-Industry Standard Process for Data Mining*), un marco iterativo, independiente de la industria y de la herramienta, que proporciona una hoja de ruta general para proyectos de minería de datos (Chapman et al., 2000). Su estructura cíclica, desde la comprensión del problema hasta el despliegue de la solución, se ajusta a un proyecto de investigación aplicada en el que la comprensión de los datos, la experimentación con modelos y la evaluación continua se realimentan entre sí. La Tabla 1.9 resume la correspondencia entre las seis fases, los objetivos específicos y los capítulos de este documento.

Fase 1: Comprensión del negocio o de la investigación.

Convierte el conocimiento del dominio y los objetivos del proyecto en una definición formal del problema de minería de datos (Chapman et al., 2000). Esa traducción es el contenido de las secciones anteriores de este capítulo: la brecha operativa se estructura como árbol de problemas y de ahí derivan el objetivo general, los objetivos específicos y los resultados esperados. Los criterios de éxito son a la vez técnicos, relacionados con el desempeño en detección, encuadre y clasificación, y operativos, vinculados con la

Tabla 1.9: Fases de CRISP-DM y objetivos

Fase	Contenido en este proyecto	Objetivo	Capítulo
1. Comprensión del negocio	Árbol de problemas, objetivos y criterios de éxito	N/A	1
2. Comprensión de los datos	Análisis exploratorio y verificación de calidad de las anotaciones recibidas	OE1	4
3. Preparación de datos	Curación, vocabulario cerrado, particionado y ventaneo	OE1	4
4. Modelado	Detector de cajas tiempo–frecuencia y línea base	OE2	5
5. Evaluación	Métricas por eje, discrepancias y carga de revisión	OE2, OE3	5
6. Despliegue	Inferencia por lotes y exportación a tabla de selección de Raven	OE2	5

cobertura alcanzada y con la carga de revisión que genera alcanzarla, como recomienda el marco para asegurar que el resultado sea útil y no solo correcto.

Fase 2: Comprensión de los datos.

Los datos primarios son grabaciones en formato WAV muestreadas a 44,1 kHz, capturadas con dispositivos AudioMoth y entregadas por el equipo de investigación junto con sus anotaciones. Cada especie llega en una carpeta con grabaciones de duración heterogénea y un archivo de texto delimitado por tabulaciones producido con Raven Pro, en el que cada fila registra tiempo de inicio y fin, frecuencia mínima y máxima, amplitud, calidad, etiqueta de especie y etiqueta de tipo de llamada. La fase comprende el análisis exploratorio visualización de espectrogramas, distribución de clases, distribución de duraciones y rangos de frecuencia, junto con la verificación de calidad de los archivos de audio corruptos, errores tipográficos y etiquetas inconsistentes. El Capítulo 4 desarrolla ambos.

Fase 3: Preparación de datos.

Comprende la limpieza y normalización de etiquetas sobre un vocabulario cerrado, el preprocesamiento del audio, el cálculo de la representación tiempo–frecuencia, la segmentación de las grabaciones largas en ventanas de duración fija con solapamiento, y el aumento de datos mediante adición de ruido de fondo del propio entorno, desplazamiento




Figura 1.5: Fases de CRISP-DM del proyecto.

de tono, estiramiento temporal y enmascaramiento de bloques de tiempo o frecuencia sobre el espectrograma. Aquí se resuelve la comparación entre log-mel y PCEN anunciada en la sección 2.2.3, bajo el criterio allí declarado.

Fase 4: Modelado.

La forma de la salida no está en discusión: el sistema debe emitir la tupla completa de la ecuación (2.1), y esa exigencia excluye de antemano toda arquitectura cuya cabeza produzca una probabilidad por trama o por segmento. Lo que se compara, por tanto, no son familias de arquitectura sino configuraciones que sí satisfacen la exigencia: la arquitectura propuesta sobre un extractor de audio con cabeza de detección, en sus dos pasos temporales, y dos líneas base de detector sobre espectrogramas, un detector de una etapa (González et al., 2025) y uno de dos etapas con propuestas de región.

La regla de decisión se fija antes de entrenar: gana la configuración con mayor valor de la métrica principal definida en la Fase 5, medida sobre la partición de *validación*; la partición de prueba se reserva para reportar el desempeño de la configuración ya elegida y no participa de la elección. La implementación se realiza en PyTorch con código modular, separando la definición de la arquitectura, el bucle de entrenamiento y las utilidades.

Fase 5: Evaluación.

Los modelos entrenados se evalúan sobre la partición de prueba y los resultados se leen contra los criterios de éxito de la Fase 1. El análisis no se agota en una cifra agregada: identifica qué clases se detectan mejor y peor, qué tipos de error predominan, entre ellos la confusión entre especies acústicamente próximas, los falsos positivos por ruido y los errores de localización en tiempo o en frecuencia, y acompaña las cifras con ejemplos visualizados sobre el espectrograma.

Reportar varias métricas sin jerarquía permitiría elegir a posteriori la que favorezca al modelo preferido. Para evitarlo, la Tabla 1.10 asigna a cada una un rol fijado de antemano.

La **métrica principal** es el *recall* a nivel de evento *agnóstico a la clase*, con un umbral de IoU bidimensional de 0,5 y un umbral de confianza de 0,5. Que sea agnóstico a la clase no es un descuido: la sección 4.1.4 muestra que la geometría separa especies pero no tipos de llamada dentro de una misma especie, de modo que localizar y etiquetar son problemas de dificultad distinta, y mezclarlos en una sola cifra oculta cuál de los dos falla. El *recall* manda porque el sistema es de pre-annotación asistida y un humano revisa su salida.

El **criterio de selección de *checkpoint*** es una $F\text{-}\beta$ con $\beta = 3$, que pondera el *recall* nueve veces más que la precisión, y es la traducción operativa del requisito enunciado con el objetivo general: perder una vocalización cuesta más que revisar un falso positivo. Para que ese sesgo no degenera en proponer indiscriminadamente, junto a él se reporta el cociente **FP/TP al punto de operación**, que es literalmente la carga de revisión que el experto asume por cada acierto y la magnitud que conecta esta fase con OE3.

El umbral de confianza de 0,5 que fija la métrica principal es un punto de comparación común entre configuraciones, no el punto de operación definitivo del sistema. Ese último se elige en OE3 barriendo el umbral y leyendo la curva de cobertura frente a propuestas por hora de audio, de modo que la comparación entre modelos y la decisión operativa quedan separadas.

El encuadre se puntúa aparte, con el IoU medio sobre los pares ya emparejados y la precisión media a varios umbrales de IoU. El barrido incluye umbrales bajos porque las fronteras del evento son borrosas incluso entre anotadores (Zhu and Sato, 2025), de

modo que exigir un solapamiento alto mediría el acuerdo con un borde que el propio anotador no reproduce.

Tabla 1.10: Métricas de evaluación y rol asignado a cada una

Métrica	Definición	Rol
<i>Recall</i> por evento, agnóstico a la clase	Proporción de eventos anotados recuperados por alguna predicción cuyo solapamiento con la caja anotada supera IoU 0,5, al umbral de confianza 0,5. No exige que la clase sea correcta.	Principal
F- β con $\beta = 3$	Media armónica ponderada de precisión y <i>recall</i> que pesa el segundo nueve veces más que la primera.	Selección de <i>checkpoint</i>
FP/TP al punto de operación	Falsos positivos por cada verdadero positivo: la carga de revisión que el experto asume por cada acierto.	Costo de revisión (OE3)
IoU medio del encuadre	Solapamiento medio entre la caja predicha y la anotada, sobre los eventos ya emparejados. Mide encuadre, no detección.	Encuadre
Precisión media a varios umbrales de IoU	Precisión media agnóstica a la clase, evaluada en un barrido de umbrales de solapamiento desde exigencias laxas hasta estrictas.	Encuadre
Acierto sobre pares emparejados	Exactitud de la etiqueta de especie y tipo de llamada, condicionada a que la detección sea correcta.	Clasificación
Desempeño por clase	<i>Recall</i> individual para cada par de especie y tipo de llamada, con la causa atribuida a cada caída.	Diagnóstico

Fase 6: Despliegue.

En un proyecto de investigación el despliegue consiste en aplicar el modelo final a un volumen de grabaciones que no participaron del entrenamiento ni de la evaluación, y en producir con ellas tablas de anotación automáticas que el analista pueda abrir directamente en Raven. El artefacto es un *pipeline* de inferencia que recibe un directorio de audio, aplica exactamente el mismo preprocesamiento del entrenamiento, obtiene las predicciones crudas, ejecuta el posprocesamiento y escribe la tabla de selección en el formato esperado.




Figura 1.6: Criterio de IoU.

1.6.2. Herramientas

Cada herramienta se justifica por el requisito que satisface y por la alternativa que se descarta, no por sus virtudes generales. La Tabla 1.11 recoge las que intervienen en el recorrido del dato y la Tabla 1.12 las que sostienen el desarrollo. Donde no hay alternativa real, se dice.

1.6.3. Procedimientos y reproducibilidad

Las fases anteriores describen qué se hace con los datos y por qué. Esta subsección recoge únicamente lo operativo que no pertenece a ninguna fase en particular porque atraviesa todas: cómo se custodia el material, cómo se registran los experimentos y qué garantiza que un número reportado pueda volver a obtenerse.

Custodia del material primario. Los audios y sus anotaciones se mantienen bajo una estructura de directorios fija que no se edita nunca a mano. Toda transformación se produce por script a partir de ella y escribe en un directorio derivado distinto. Esa separación es la que permite reconstruir el conjunto de trabajo desde cero cada vez que el protocolo de curación cambia, y la que impide que una corrección puntual quede sin registro.

Registro de experimentos. Cada corrida queda asociada a un identificador de configuración y a un *commit* del repositorio. El bucle de entrenamiento registra los hiperparámetros, guarda *checkpoints* de forma periódica y evalúa sobre validación a intervalos fijos. Los scripts de evaluación son independientes de los de entrenamiento:

Tabla 1.11: Herramientas del *pipeline*, de la curación a la inferencia

Herramienta	Función en el <i>pipeline</i>	Por qué esta y no la alternativa
Python 3.12	Lenguaje de todo el sistema	R y MATLAB carecen de implementaciones de referencia de detectores de objetos, que es el componente que no se va a reimplementar
Pandas	Consolidación, limpieza y particionado de las anotaciones tabulares	Procesar los archivos de Raven con scripts <i>ad hoc</i> no deja registro reproducible de qué filas se descartaron y por qué
NumPy	Representación en memoria del audio y de las cajas antes de pasar a tensores	Sin alternativa práctica: es la interfaz común entre SoundFile, PyTorch y Matplotlib
SoundFile y soxr	Lectura por bloques de las grabaciones y remuestreo a 44,1 kHz	Permiten leer solo la ventana pedida de un archivo de una hora, en lugar de cargarlo entero en memoria
torchaudio	Cálculo del espectrograma mel que consume el modelo	Librosa devuelve arreglos de NumPy y obligaría a convertir en cada lote; aquí la transformada entrega tensores que el PCEN entrenable recibe directamente
PyTorch	Definición, entrenamiento y evaluación del detector	Las implementaciones de referencia de detectores están mayoritariamente en PyTorch, y portarlas a otro marco no se justifica
Transformers	Carga del <i>backbone</i> AST preentrenado en AudioSet	Entrenar un transformador de espectrogramas desde cero excede los datos disponibles; la biblioteca aporta los pesos y la interpolación del <i>embedding</i> posicional
Raven Pro / Lite	Origen de las anotaciones y destino de las predicciones exportadas	Sin alternativa: es la herramienta del analista, y su formato de tabla de selección es un requisito de RE2.4, no una elección de diseño

Tabla 1.12: Herramientas de desarrollo, inspección y reproducibilidad

Herramienta	Función	Por qué esta y no la alternativa
uv	Entorno virtual, resolución de dependencias y archivo de bloqueo	Instalar con <i>pip</i> sin bloqueo deja libres las versiones transitivas, y sin ellas el entorno de una corrida antigua no se reconstruye igual
Matplotlib	Figuras del análisis exploratorio y de los resultados	Sin alternativa que aporte algo distinto dentro del mismo ecosistema
PyQt6 y pyqtgraph	Visor interactivo que superpone espectrograma, anotación y predicción sobre la misma grabación	Raven no muestra la salida del modelo junto a la anotación, y una figura de Matplotlib no sostiene el desplazamiento continuo sobre una hora de audio
Ruff, ty y pytest	Formato, análisis estático y pruebas del código	Las pruebas cubren la conversión entre sistemas de coordenadas de caja, donde un error silencioso desplazaría todas las métricas sin fallar
Git	Versionado del código y de la configuración de cada experimento	Sin alternativa: es la condición para asociar un resultado reportado a un estado exacto del código

cargan un *checkpoint* existente y recalculan las métricas, de modo que reproducir una cifra publicada no exige reentrenar.

Respaldo y portabilidad. El código y la configuración se sincronizan en un repositorio remoto, y el entorno de ejecución se declara en un archivo de dependencias versionado, para que la falla del equipo de desarrollo o la ejecución en una máquina distinta no supongan rehacer trabajo. La gestión de la bibliografía se centraliza en Zotero a lo largo de todo el proceso.

La planificación que ordena todo lo anterior en el tiempo, mediante la estructura de desglose del trabajo, el cronograma, el presupuesto y la gestión de riesgos, se recoge en el Anexo A, fuera del cuerpo, porque no aporta al argumento científico y en el hilo del documento lo interrumpiría.

Capítulo 2

Marco Referencial

2.1. Marco Teórico

2.1.1. Formulación del problema de detección

El problema se plantea en dos niveles. El nivel de la *grabación* es el que le interesa al analista y define el producto; el nivel de la *ventana* es el que consume el modelo y define su entrada y su salida. Separarlos es necesario porque ninguna arquitectura actual procesa una hora de audio de una sola vez, y confundirlos oscurece qué predice realmente un detector.

Nivel de grabación

El sistema recibe un conjunto de grabaciones $G = \{g_1, g_2, \dots, g_M\}$. Cada grabación g_k es una señal de audio $x(t)$ en formato WAV, muestreada a $F_s = 44,1$ kHz, de duración D_k que puede llegar a la hora. Para cada una el sistema debe devolver una lista de eventos $E_k = \{e_1, e_2, \dots, e_{N_k}\}$, cuyo cardinal N_k no se conoce de antemano y donde cada evento es la tupla

$$e_i = (t_{\text{ini}}^{(i)}, t_{\text{fin}}^{(i)}, f_{\text{mín}}^{(i)}, f_{\text{máx}}^{(i)}, y^{(i)}, p^{(i)}). \quad (2.1)$$

$(t_{\text{ini}}, t_{\text{fin}})$ Instantes de inicio y fin del evento, en segundos desde el comienzo de la grabación, con $0 \leq t_{\text{ini}} < t_{\text{fin}} \leq D_k$.

$(f_{\text{mín}}, f_{\text{máx}})$ Banda de frecuencia que ocupa el evento, en hercios, con $0 \leq f_{\text{mín}} < f_{\text{máx}} \leq F_s/2$. Es la componente que distingue esta formulación de la detección de eventos sonoros puramente temporal.

y Etiqueta tomada de un vocabulario cerrado $Y = \{y_1, \dots, y_L\}$ cuyos elementos son pares de especie y tipo de llamada. La sección 2.2.5 justifica por qué la etiqueta es un par plano y no dos niveles predichos por separado; las proyecciones $\pi_{\text{esp}}(y)$ y $\pi_{\text{tipo}}(y)$ recuperan cada nivel cuando se lo necesita.

p Confianza en $[0, 1]$ asignada por el modelo, que ordena las predicciones y define el punto de operación de la revisión asistida.

Las cuatro primeras componentes definen una caja rectangular sobre el plano tiempo–frecuencia; las dos restantes la etiquetan y la puntúan. La Figura 2.1 muestra el resultado sobre un espectrograma.




Figura 2.1: Segmentación de audio en rangos de tiempo y frecuencia sobre un espectrograma. Cada rectángulo corresponde a una tupla de la ecuación (2.1).

Nivel de ventana

La grabación se recorta en ventanas de duración fija T_w , tomadas cada H segundos con $H < T_w$, de modo que ningún evento quede siempre partido por un borde. Cada ventana se convierte en un espectrograma mel $X \in \mathbb{R}^{F \times T}$, con F bandas de frecuencia y T tramas temporales, y ese tensor es la entrada del modelo.

El detector es una función de parámetros θ que a cada ventana le asigna un conjunto de tamaño fijo

$$f_\theta(X) = \left\{ (\hat{b}_q, \hat{\pi}_q) \right\}_{q=1}^Q, \quad \hat{b}_q \in [0, 1]^4, \quad \hat{\pi}_q \in [0, 1]^{L+1}, \quad (2.2)$$

donde Q es un número de consultas fijado por la arquitectura, independiente del contenido de la ventana y mayor que la cantidad de eventos que cabe esperar en ella. Cada consulta produce una caja $\hat{b}_q = (c_x, c_y, w, h)$ en coordenadas normalizadas al recuadro de la ventana — centro, ancho y alto, los cuatro en $[0, 1]$ — y una distribución $\hat{\pi}_q$ sobre $Y \cup \{\emptyset\}$, en la que $\emptyset$ es la clase «sin objeto» que absorbe las consultas sobrantes. El número de eventos no se predice: resulta de cuántas consultas eligen una clase de Y por encima del umbral de confianza.

Esta es la formulación de *predicción de conjuntos*: la salida no es una rejilla puntuada ni una secuencia, sino un conjunto sin orden, y durante el entrenamiento cada anotación de la ventana se asigna a exactamente una consulta mediante un emparejamiento biyectivo, mientras que el resto se supervisa hacia $\emptyset$. De ahí que dentro de la ventana no haya anclas ni supresión de no máximos.

Del marco normalizado al marco físico

Lo que emite el modelo no son segundos ni hercios sino fracciones de la ventana, y la conversión no es simétrica entre los dos ejes. En tiempo es afín: si la ventana empieza en t_0 ,

$$t_{\text{ini}} = t_0 + \left(c_x - \frac{w}{2}\right)T_w, \quad t_{\text{fin}} = t_0 + \left(c_x + \frac{w}{2}\right)T_w. \quad (2.3)$$

En frecuencia no lo es, porque el eje vertical del espectrograma está en escala mel. Con $m(\cdot)$ la función que convierte hercios a mel y $[f_{\text{lo}}, f_{\text{hi}}]$ los extremos del banco de filtros, la coordenada normalizada $u \in [0, 1]$ vuelve a hercios mediante

$$\varphi(u) = m^{-1}\left(m(f_{\text{lo}}) + u[m(f_{\text{hi}}) - m(f_{\text{lo}})]\right), \quad (2.4)$$

y entonces $f_{\text{mín}} = \varphi(c_y - h/2)$ y $f_{\text{máx}} = \varphi(c_y + h/2)$. La consecuencia práctica es que una caja de altura constante en el marco normalizado cubre una banda mucho más ancha en la parte alta del espectro que en la baja.

De las ventanas a la grabación

Como las ventanas se solapan, una misma vocalización puede predecirse en dos o tres de ellas, y una vocalización más larga que T_w solo puede predecirse por partes. Las predicciones de toda la grabación se llevan al marco común, se agrupan por clase y se depuran por supresión de no máximos, de modo que la lista E_k contenga un evento por vocalización. Ese es el punto en el que el nivel de ventana devuelve el control al nivel de grabación, y también el punto en el que el ventaneo deja su huella: la sección 4.3 documenta qué eventos quedan fuera de alcance por ser más largos que la ventana.

2.1.2. El espectrograma y la asimetría de sus ejes

La señal de audio es unidimensional, pero los eventos de interés se distinguen por cómo se distribuye su energía entre frecuencias a lo largo del tiempo. La transformada de Fourier de tiempo corto (STFT) recupera esa estructura: divide la señal en tramas solapadas, aplica una ventana a cada una y calcula su espectro. La magnitud del resultado es el espectrograma, una matriz $X \in \mathbb{R}^{F \times T}$ cuyos parámetros, como el tamaño de ventana, el salto entre ventanas y el tipo de ventana, fijan el compromiso entre resolución temporal y resolución frecuencial.

Las transformaciones que se aplican sobre esa matriz, como la escala mel, la compresión logarítmica y la normalización de energía por canal, y el criterio con el que se elige entre ellas se tratan en la sección 2.2.3, donde corresponden al eslabón de la cadena en que aparece esa decisión.

Interesa aquí una asimetría del espectrograma que conviene explicitar porque condiciona el diseño del detector. Tratarlo como una imagen es útil, pero sus dos ejes no son equivalentes: una traslación en tiempo preserva el significado del patrón, mientras que una traslación en frecuencia lo cambia: un mismo contorno desplazado media octava es otra vocalización, o ninguna. Los patrones espectro-temporales de los eventos sonoros dependen de la banda de frecuencia en que ocurren, de modo que la convolución bidimensional estándar, equivariante a traslación en ambos ejes, no es adecuada para el eje frecuencial (Nam et al., 2022). La consecuencia práctica es que el modelo debe conservar de forma explícita la posición en frecuencia en lugar de descartarla.

2.1.3. Detección de objetos sobre audio

Una vez que el sonido se representa como una matriz tiempo–frecuencia, la tarea de la ecuación (2.1) coincide con la de la detección de objetos en visión por computadora: afirmar que una clase está presente y localizarla, localización que se representa típicamente mediante una caja delimitadora (Lin et al., 2014). La analogía no es superficial. Los eventos acústicos se manifiestan como patrones bidimensionales de tiempo y frecuencia, con texturas y estructuras geométricas propias, análogos a los objetos que aparecen en imágenes naturales (Pham et al., 2018), y el encuadre trasciende la bioacústica hacia el análisis de señales en general (Wood et al., 2022).

Familia R-CNN. Los detectores de dos etapas proponen primero regiones candidatas y luego las clasifican y refinan. Su aplicación a espectrogramas está documentada en bioacústica marina, donde las cajas predichas llevan información estadística embebida sobre la vocalización, como su duración, ancho de banda y frecuencia central, directamente utilizable por el analista (Escobar-Amado et al., 2024). NBM adapta un detector de dos etapas a datos de audio y lo acompaña de anotaciones precisas en tiempo y frecuencia recolectadas por aficionados (Airale et al., 2025).

Familia YOLO. Los detectores de una etapa predicen clase y caja en una sola pasada sobre una rejilla, lo que los hace más rápidos y más simples de entrenar. Su uso sobre espectrogramas está reportado como línea base competitiva (González et al., 2025). En audio, la idea de regresar directamente los límites del evento en lugar de clasificar tramas aparece también en YOHO, que convierte la detección en una regresión de los puntos de inicio y fin de cada clase (Venkatesh et al., 2022).

Familia DETR y transformadores. Los detectores basados en atención eliminan las anclas y la supresión de no máximos, y formulan la detección como la predicción directa de un conjunto de objetos emparejado con las anotaciones. Su adaptación al audio es reciente: SoundDet trata el audio crudo como una señal espacio-temporal y detecta eventos móviles sobre ella (He et al., 2021), y Ebbers et al. (2024) formalizan la salida como cuádruplas de clase, inicio, fin y confianza, aunque manteniéndola sobre el eje temporal.

Cajas frente a máscaras. Una alternativa a la caja es la segmentación semántica, que asigna una etiqueta a cada celda tiempo–frecuencia y describe con más fidelidad

los contornos de una vocalización (Jin et al., 2022). Esta tesis opta por la caja por dos razones: es la forma en que el analista anota en Raven, y por tanto la única para la que existe una referencia disponible; y es la que se exporta sin pérdida a una tabla de selección. Una máscara exigiría reanotar el corpus completo.

2.2. Marco Conceptual

Los conceptos que siguen no se presentan por área temática sino siguiendo el recorrido de la señal, desde que el animal vocaliza hasta que el analista recibe una etiqueta revisable. Cada eslabón de ese recorrido pierde algo o introduce una ambigüedad, y es esa pérdida la que crea la necesidad del eslabón siguiente. El orden de las subsecciones es, por tanto, el orden en que aparecen los problemas.



Figura 2.2: Cadena de la señal.

2.2.1. Paisaje sonoro

La bioacústica estudia el sonido en los seres vivos. En este proyecto se aplica a través del monitoreo acústico pasivo, que despliega grabadoras autónomas para capturar el paisaje sonoro de un ecosistema sin intervenir en él (Blumstein et al., 2011). Lo que la grabadora registra no es la vocalización sino la suma de todo lo que llega al micrófono, y en un entorno como la Amazonía esa suma tiene tres componentes:

Biofonía. Los sonidos de origen biológico. Incluye la señal de interés las vocalizaciones de primates y también el coro de insectos, anfibios y aves, que ocupa las mismas bandas durante horas seguidas.

Geofonía. Los sonidos de origen físico: viento, lluvia, movimiento de la vegetación. Su energía se reparte sobre bandas amplias y su carácter es o bien cuasi-estacionario o bien de ráfaga.

Antropofonía. Los sonidos de origen humano: motosierras, disparos, motores. No solo interfieren con la señal, sino que son en sí mismos un indicador de presión sobre el ecosistema (Blumstein et al., 2011).

A ello se suma la atenuación: el animal está a una distancia desconocida del sensor, de modo que la misma vocalización llega unas veces nítida y otras apenas por encima del fondo. El archivo resultante contiene, entonces, una señal mezclada, atenuada y de relación señal-ruido variable dentro de una misma grabación. La pregunta que abre el eslabón siguiente es qué hay que buscar dentro de esa mezcla, es decir, qué constituye exactamente un evento.

2.2.2. Eventos acústicos

La vocalización se produce por el flujo de aire desde los pulmones, que hace vibrar las cuerdas vocales en la laringe y actúa como fuente sonora primaria; el tracto vocal supralaríngeo, formado por la faringe y las cavidades oral y nasal, filtra esa fuente y fija sus características finales: frecuencia fundamental, distribución de armónicos, amplitud, duración y timbre.

La consecuencia de esa estructura fuente-filtro es la que interesa aquí. La frecuencia fundamental queda determinada por la geometría y la tensión de las cuerdas vocales, y las resonancias del tracto vocal concentran la energía en un conjunto acotado de bandas. Un evento no es, por tanto, un instante con una etiqueta: es una región del plano tiempo-frecuencia con un límite inferior y un límite superior de frecuencia que dependen de la anatomía de quien vocaliza. La banda que ocupa una especie es una propiedad física de su aparato fonador, no una convención de dibujo del anotador. Esa es la razón por la que la caja tiempo-frecuencia de la ecuación (2.1) es la representación adecuada del evento, y no un rectángulo elegido por comodidad: los cuatro números que la definen tienen referente físico.

La misma estructura explica dos hechos que reaparecen más adelante. El primero es que distintas especies tienden a separarse por banda, lo que hace de la frecuencia una característica discriminante y no un dato accesorio. El segundo es que la producción

vocal en primates no humanos es en gran medida innata y ligada a estados internos, con control cortical limitado, pero admite variabilidad intraespecífica, incluidos dialectos, firmas individuales y variación según el contexto, que amplía el rango de formas que el detector debe reconocer como la misma clase.

El evento existe, entonces, como región bidimensional. El problema es que la señal grabada es unidimensional: hay que recuperar esa estructura antes de poder buscarla.

2.2.3. Representaciones tiempo–frecuencia

La transformada de Fourier de tiempo corto recupera la dimensión que falta: divide la señal en tramas solapadas y calcula el espectro de cada una, con lo que produce una matriz $X \in \mathbb{R}^{F \times T}$ en la que el eje vertical es frecuencia y el horizontal, tiempo. Sobre ella se aplican dos transformaciones habituales: la escala mel, que reagrupa las bandas según una progresión aproximadamente logarítmica, y la compresión logarítmica de la magnitud a decibelios. El resultado, el espectrograma log-mel, es la entrada estándar en detección de eventos sonoros.

Esta transformación es la bisagra del planteamiento: convierte un problema de audio en un problema de análisis de imágenes, y con ello habilita el uso de las técnicas de visión por computadora descritas en la sección 2.1.1 y siguientes.

La elección de la representación no es un trámite. La compresión logarítmica no es la única opción. La normalización de energía por canal (PCEN) combina control adaptativo de ganancia y compresión de rango dinámico, y en detección bioacústica de campo fue el contribuyente principal a la mejora de precisión sobre la línea base log-mel (Lostanlen et al., 2019). El criterio que decide entre ambas no es esa cifra sino una condición del ruido: la ventaja de PCEN proviene de estimar y descontar un fondo que varía lentamente respecto de la escala temporal del evento. El coro de insectos amazónico cumple esa condición, pues es cuasi-estacionario durante minutos, pero la lluvia y las ráfagas de viento no la cumplen, y sobre ellas el control de ganancia puede atenuar la propia vocalización junto con el fondo.

Dado que el corpus contiene ambos regímenes, esta tesis no da por establecida la superioridad de ninguna de las dos representaciones: las compara bajo un criterio declarado de antemano: el *recall* de eventos de baja relación señal-ruido al punto de operación fijado en la sección 1.6, y adopta la que lo maximice. Declarar el criterio antes

de medir es lo que impide elegir después la representación que favorezca al resultado obtenido.

Queda así una imagen en la que el evento es visible. Falta el mecanismo que lo localice dentro de ella.




Figura 2.3: Compromiso STFT.




Figura 2.4: Escala mel.

2.2.4. Detección de eventos sonoros

La detección de eventos sonoros (SED) consiste en identificar la presencia de un evento y localizar sus límites sobre la representación tiempo–frecuencia. La distinción decisiva dentro de esta tarea, que además constituye el concepto central de esta tesis, es la *forma de la salida*, porque no todas las formulaciones que se llaman SED devuelven un evento.




Figura 2.5: PCEN frente a log-mel.

Salida por segmento fijo. El sistema divide la grabación en fragmentos de duración constante y emite una probabilidad por fragmento y clase. Lo que devuelve es una rejilla puntuada, no un evento: el inicio y el fin de la vocalización quedan cuantizados al tamaño del fragmento, y su banda de frecuencia sencillamente no se estima.

Salida temporal delimitada. El sistema devuelve el instante de inicio y el de fin de cada evento, con su clase y su confianza. Es ya un evento con extensión propia, pero esa extensión existe solo sobre el eje temporal: descarta $f_{\min}$ y $f_{\max}$, que la subsección anterior estableció como magnitudes físicas del aparato fonador.

Salida tiempo–frecuencia. El sistema devuelve la tupla completa de la ecuación (2.1). Es la única de las tres formas que coincide con lo que el analista produce a mano en Raven y, por tanto, la única que puede sustituir su insumo en lugar de complementarlo.

Esta gradación es exactamente la causa C3 del árbol de problemas del Capítulo 1: la salida de los sistemas automáticos no sustituye el trabajo del analista porque su representación es más pobre que la del evento anotado. El marco conceptual la enuncia aquí como propiedad de la tarea; la sección 1.1.4 la usó como argumento de posicionamiento.

El problema impone seis exigencias, y cada familia de la literatura responde a una de ellas. Presentarlas en orden cronológico no dice nada; presentarlas por la exigencia que satisfacen permite decidir, y así las ordena la Tabla 2.1. Las vocalizaciones de primates se organizan en secuencias cuya identidad depende del orden y del espaciado de sus unidades, lo que explica por qué el contexto largo aparece como exigencia propia y no como un refinamiento del reconocimiento local.

Tabla 2.1: Cada exigencia del problema y la familia de arquitecturas que la resuelve

Exigencia	Familia	Qué aporta y dónde se queda corta
Reconocer un patrón espectro-temporal local	Redes convolucionales	Aplican filtros sobre vecindades del espectrograma y superan con claridad a los detectores por energía o por flujo espectral, pero una red simple carece de robustez frente a la variabilidad del ruido (Lostanlen et al., 2019)
Sostener el contexto a lo largo de una frase	Convolucionales recurrentes	Añaden capas recurrentes sobre las características convolucionales; fueron la arquitectura predominante en las primeras ediciones de los desafíos de localización y detección de eventos sonoros (Politis et al., 2020)
Ganar profundidad sin degradación	Conexiones residuales	Permiten entrenar redes muy profundas sin pérdida de desempeño (He et al., 2016); BirdNET, referencia en identificación de aves, emplea una arquitectura de esa familia (Kahl et al., 2021)
Modelar dependencias a larga distancia sin recurrencia	Transformadores	Autoatención y procesamiento paralelo; el <i>Audio Spectrogram Transformer</i> aparece como innovación en detección bioacústica de pocos ejemplos (Nolasco et al., 2023), pero produce representaciones de una sola escala
Preservar la posición en frecuencia	Ninguna de las anteriores por sí sola	La convolución bidimensional estándar es equivariante a traslación en ambos ejes, propiedad deseable en tiempo y errónea en frecuencia; corregirlo exige adaptar el filtro a la banda (Nam et al., 2022)
Emitir $f_{\min}$ y $f_{\max}$	Cabezas de detección de objetos	Única salida que coincide con la tupla de la ecuación (2.1); es la familia descrita en la sección 2.1.3

El criterio de descarte es la forma de la salida, no el desempeño reportado. Una arquitectura solo es candidata a arquitectura final si su cabeza puede emitir $f_{\min}$ y $f_{\max}$. Bajo esa regla, las cuatro primeras familias de la Tabla 2.1 quedan descartadas *como sistema completo*, porque su formulación habitual termina en una probabilidad por trama o por segmento; ninguna queda descartada *como extractor de características*, que es el papel en el que siguen siendo pertinentes. La cabeza que sí satisface la exigencia es la de los detectores de objetos descritos en la sección 2.1.3, y por eso la arquitectura de esta tesis combina un extractor de audio con una cabeza de detección, en lugar de adoptar una de las cuatro familias tal como se emplean en la literatura de SED.

Localizado el evento, queda el problema de nombrarlo.

2.2.5. Clasificación jerárquica

La etiqueta que el analista necesita contiene dos niveles anidados, la especie y, dentro de su repertorio, el tipo de llamada. Las unidades acústicas se agrupan en notas, trinos, sílabas, frases, motivos y cantos, y pueden estar jerárquicamente anidadas: una secuencia de unidades puede considerarse ella misma una unidad y ser reemplazada por una etiqueta única (Kershenbaum et al., 2016).

El conjunto de especies sobre el que se define el primer nivel es el de la Tabla 2.2. Los códigos de dos letras de la última columna son los que se emplean en el resto del documento.

El segundo nivel de la etiqueta se define dentro de cada especie, sobre el vocabulario de la Tabla 2.3. Los repertorios están desbalanceados, de modo que los 41 pares posibles no se reparten de forma pareja entre las ocho especies, y esa asimetría es la que condiciona la elección del esquema de clasificación.

Un mismo código puede designar llamadas distintas en especies distintas: **sc** es *squeak* en AA y AC, *shriek* en SB y *squeal* en SM. Por eso la unidad de etiquetado en el resto del documento es siempre el par, escrito **especie/tipo**, y nunca el código de llamada por sí solo.

Ante esa estructura caben tres esquemas. La *clasificación plana* crea una clase por cada par y trata la jerarquía como inexistente. El enfoque *local por nodo padre* entrena un clasificador de especie y, debajo, un clasificador de tipo por cada especie. El *modelo global jerárquico* aprende la estructura completa de una vez. Esta tesis adopta

Tabla 2.2: Especies de primates consideradas en el proyecto

Nombre común (inglés)	Nombre común (español)	Nombre científico	Código
Weddell's saddle-back tamarin	Tamarino de Weddell / pichico de vientre anaranjado	<i>Leontocebus weddelli</i>	LW
Toppin's titi monkey	Tití de Toppin / huicoco	<i>Plecturocebus toppini</i>	PT
Shock-headed capuchin	Capuchino de cabeza chata / machín blanco	<i>Cebus cuscinus</i>	CC
Peruvian spider monkey	Mono araña peruano / maquisapa	<i>Ateles chamek</i>	AC
Night monkey	Mono nocturno / musmuqui	<i>Aotus azarae</i>	AA
Large-headed capuchin	Capuchino de cabeza grande / machín negro	<i>Sapajus apella macrocephalus</i>	SM
Bolivian red howler	Mono aullador rojo boliviano / coto mono	<i>Alouatta sara</i>	AS
Bolivian squirrel monkey	Mono ardilla boliviano / fraile	<i>Saimiri boliviensis</i>	SB

la clasificación plana sobre un vocabulario cerrado de pares: los esquemas jerárquicos exigen un número mínimo de ejemplos en cada nodo hijo, y el desbalance del corpus deja varios pares con demasiados pocos como para sostener un clasificador propio. El Capítulo 4 documenta esa composición y cierra el vocabulario en consecuencia.

Queda un supuesto implícito en todo lo anterior: que la etiqueta de referencia contra la cual se entrena y se mide es un dato fijo. No lo es.

2.2.6. Anotaciones inconsistentes

Un sistema supervisado se entrena y se evalúa contra anotaciones humanas, de modo que las propiedades de esas anotaciones forman parte del planteamiento y no del apartado de limitaciones. Tres conceptos las describen.

Etiqueta fuerte y etiqueta débil. Una etiqueta *débil* declara que una clase está presente en algún lugar de la grabación, sin decir dónde; es lo que ofrecen los repositorios grandes de audio de fauna. Una etiqueta *fuerte* delimita el evento: aporta sus fronteras además de su clase. El material de esta tesis es de etiqueta fuerte y bidimensional, pues delimita también en frecuencia, lo que lo hace más informativo y, a la vez, más costoso

Tabla 2.3: Tipos de llamada admitidos en cada especie, con el código que aparece en la anotación

Especie	Tipos de llamada (código: nombre)	N.º
AA <i>Aotus azarae</i>	gc: <i>gulp</i> ; hm: <i>hoot</i> ; sc: <i>squeak</i>	3
AC <i>Ateles chamek</i>	chc: <i>chitter</i> ; gc: <i>growl</i> ; cc: <i>contact</i> ; whc: <i>whinnie</i> ; sc: <i>squeak</i> ; bc: <i>bark</i>	6
AS <i>Alouatta sara</i>	hc: <i>howl</i> ; bc: <i>bark</i>	2
CC <i>Cebus cuscinus</i>	cc: <i>contact</i>	1
LW <i>Leontocebus weddelli</i>	cc: <i>contact</i> ; cs: <i>contact syllable</i> ; aa: <i>aerial alarm</i> ; ta: <i>terrestrial alarm</i> ; sqc: <i>squeal</i> ; phc: <i>phee</i> ; tr: <i>trino</i> ; tf: <i>trino fast</i> ; tt: <i>trino transition</i> ; tj [†] sin denominación; vc: <i>visual contact</i>	11
PT <i>Plecturocebus toppini</i>	dc: <i>duet</i> ; ac: <i>alarm</i> ; bp [†] <i>bellow phrase</i> ; pp [†] <i>pant phrase</i> ; sqc [†] <i>squeal</i>	5
SB <i>Saimiri boliviensis</i>	pcc: <i>peep contact</i> ; ppc: <i>play peep</i> ; lpc: <i>long peep</i> ; spc: <i>spit</i> ; sc: <i>shriek</i>	5
SM <i>Sapajus macrocephalus</i>	cc: <i>contact</i> ; acc: <i>aggressive contact</i> ; sc: <i>squeal</i> ; pc: <i>purrr</i> ; whc: <i>whistle</i> ; hic: <i>hip</i> ; fc: <i>food</i> ; fs: <i>food syllable</i>	8
Total		41

[†] Categorías sin nombre establecido en la literatura del repertorio, acuñadas por el equipo de anotación. El Capítulo 4 documenta cuáles de ellas sobreviven al vocabulario cerrado y cuáles se descartan por ser unidades de nivel de frase.

de producir y más expuesto a desacuerdo, porque hay más decisiones que tomar por evento.

Acuerdo entre anotadores y consigo mismo. El acuerdo *inter-anotador* mide cuánto coinciden dos analistas que anotan el mismo audio; el *intra-anotador*, cuánto coincide un mismo analista consigo mismo al anotar dos veces el mismo segmento. Ambos son bajos en bioacústica: se ha medido menos del 50 % de acuerdo entre dos analistas y también un acuerdo pobre de un analista consigo mismo (Leroy et al., 2018), y la tarea genera errores específicos de cada anotador (Nguyen Hong Duc et al., 2021). Con veinte anotadores por clip, las etiquetas fuertes muestran variaciones grandes tanto en el tipo de evento como en los tiempos de inicio y fin (Koga et al., 2024).

Frontera borrosa del evento. El desacuerdo anterior no se reparte de forma uniforme: se concentra en los bordes. Una vocalización no empieza ni termina en un instante definido, sino que emerge del fondo y se desvanece en él, y lo mismo ocurre en frecuencia con los armónicos superiores. En detección de cajas tiempo–frecuencia se observan desplazamientos relativamente grandes entre la caja predicha y la anotada, de lo que se concluye que las fronteras de los eventos son borrosas y difíciles de determinar (Zhu and Sato, 2025).

Estos tres conceptos son la formulación conceptual de la causa C2 del árbol de problemas, y de ellos se siguen dos decisiones metodológicas que sin ellos parecerían arbitrarias. La primera es el **umbral de IoU bajo**: exigir un solapamiento alto entre la caja predicha y la anotada mediría el acuerdo con un borde que el propio anotador no reproduce, de modo que un umbral exigente penalizaría al modelo por no replicar ruido de etiquetado (Zhu and Sato, 2025). La segunda es el **sesgo hacia el *recall***: si el *ground truth* está sistemáticamente incompleto, porque las llamadas tenues o enmascaradas escapan tanto al método automático como al analista fatigado (Gibb et al., 2018), una parte de los falsos positivos de alta confianza son en realidad eventos válidos ausentes de la referencia, y el sistema, concebido para que un humano revise su salida, debe favorecer no perderlos. El Capítulo 5 retoma ambas decisiones al fijar el protocolo de evaluación.

Capítulo 3

Estado del Arte

3.1. Metodología de la revisión

3.1.1. Objetivos y preguntas de revisión

La revisión busca identificar y evaluar el estado del arte en técnicas de aprendizaje profundo aplicables a una solución automatizada que produzca anotaciones detalladas, que incluyen localización tiempo–frecuencia, identificación de especie y clasificación del tipo de vocalización, sobre grabaciones de monitoreo acústico pasivo de primates amazónicos. Se organiza en torno a cinco preguntas:

- P1.** ¿Qué estrategias de aprendizaje profundo han obtenido mejores resultados en la detección tiempo–frecuencia de vocalizaciones en grabaciones de monitoreo acústico pasivo capturadas en entornos ruidosos?
- P2.** ¿Qué estrategias han obtenido mejores resultados en la clasificación jerárquica fina de los eventos detectados, identificando de forma simultánea la especie y el tipo específico de vocalización?
- P3.** ¿Qué técnicas de procesamiento resultan más efectivas para mitigar el ruido ambiental y la variabilidad propia de sensores de bajo costo como AudioMoth?
- P4.** ¿Qué conjuntos de datos públicos existen con vocalizaciones etiquetadas, qué formatos de anotación emplean, y qué estrategias de aumento de datos compensan mejor la escasez y el desbalance de clases?

P5. ¿Cómo se adaptan mediante transferencia de aprendizaje los modelos preentrenados en audio general o en bioacústica de aves a las tareas de detección (P1) y clasificación jerárquica (P2)?

3.1.2. Estrategia de búsqueda

La búsqueda se ejecutó sobre dos bases indexadas. Scopus cubre publicaciones seriadas de más de cinco mil editores en 140 países e incorpora una herramienta de búsqueda asistida que agrupa los artículos relacionados con una consulta. Web of Science aporta herramientas de visualización sobre la relevancia y las tendencias de las revistas dentro de sus categorías temáticas. La Tabla 3.1 recoge las cadenas empleadas y el número de documentos recuperado en cada motor.

Tabla 3.1: Cadenas de búsqueda y documentos recuperados por motor

Motor	Cadena de búsqueda	Docs.
Scopus	TITLE-ABS-KEY (<i>deep learning</i> OR <i>neural network*</i> OR <i>artificial intelligence</i> OR <i>transformer*</i> OR <i>machine learning</i>) AND TITLE-ABS-KEY (<i>sound event detection</i> OR <i>acoustic event detection</i> OR <i>audio event localization</i> OR <i>bioacoustic detection</i>) AND TITLE-ABS-KEY (<i>biodiversity</i> OR <i>wildlife</i> OR <i>animal vocalizations</i> OR <i>primates</i> OR <i>anthropogenic noise</i> OR <i>forest monitoring</i> OR <i>ecological monitoring</i>)	33
Web of Science	TS = (mismos tres bloques de términos, unidos por AND)	6
Total		39

Los tres bloques combinan técnica, tarea y dominio de aplicación. El asterisco es el comodín de truncamiento de ambos motores.

3.1.3. Criterios de inclusión y exclusión

Los resultados se cribaron con los criterios de la Tabla 3.2. Dos de ellos hacen el trabajo principal de filtrado y merecen explicitarse: el criterio de detección de eventos descarta los trabajos que solo clasifican la grabación completa sin localizar nada dentro de ella, y el criterio de clasificación jerárquica descarta los clasificadores binarios o de un solo nivel taxonómico. Son precisamente los dos ejes en los que se sitúa el vacío descrito en la sección 1.1.4.

Tabla 3.2: Criterios de inclusión y exclusión aplicados a los resultados

Criterio	Inclusión	Exclusión
Temporalidad	Publicaciones de 2020 en adelante	Anteriores a 2020
Calidad	Revistas Q1 o conferencias de alto impacto	Revistas no indexadas o de cuartiles inferiores
Enfoque	Técnicas de aprendizaje profundo	Aprendizaje automático clásico sin componente profundo
Análisis de señal	Análisis tiempo–frecuencia	Análisis exclusivamente temporal o frecuencial
Dominio	Bioacústica, con preferencia por mamíferos y primates	Reconocimiento de voz humana sin transferencia al dominio
Entorno	Entornos naturales ruidosos, preferentemente tropicales	Entornos exclusivamente de laboratorio
Detección	Métodos que localizan el evento en tiempo y frecuencia	Métodos que clasifican la grabación completa
Clasificación	Clasificación multinivel de especie y tipo de vocalización	Clasificadores binarios o de un solo nivel
Desbalance	Técnicas para desbalance de clases y escasez de datos	Métodos que exigen grandes volúmenes etiquetados
Evaluación	Métricas completas de precisión, <i>recall</i> y F1	Trabajos sin evaluación cuantitativa
Idioma	Inglés o español	Otros idiomas

3.2. Resultados de la revisión

Ninguno de los trabajos recuperados evalúa arquitecturas de aprendizaje profundo para la detección y clasificación de vocalizaciones de primates en el contexto amazónico. Los resultados que siguen se apoyan, por tanto, en la extrapolación desde dominios bioacústicos adyacentes pero más desarrollados, sobre todo la detección de aves y la localización de eventos sonoros, que enfrentan desafíos análogos de ruido ambiental, variabilidad entre sensores y escasez de datos etiquetados (Lostanlen et al., 2019; Meedeniya et al., 2023).

3.2.1. P1: Estrategias de detección tiempo–frecuencia

Las redes convolucionales son la base de los sistemas que operan sobre espectrogramas. Un modelo convolucional de arquitectura relativamente simple ya supera de forma clara a métodos tradicionales como el flujo espectral o los detectores basados en energía, aunque adolece de falta de robustez y de generalización ante la variabilidad del ruido (Lostanlen et al., 2019). Las redes convolucionales recurrentes añaden capas recurrentes para modelar dependencias temporales más largas y fueron la arquitectura predominante en las ediciones iniciales de los desafíos de localización y detección de eventos sonoros (Politis et al., 2020). Las variantes residuales facilitan el entrenamiento de redes más profundas sin degradación (He et al., 2016), y son la base de BirdNET (Kahl et al., 2021).

Los transformadores aparecen como innovación arquitectónica en detección bioacústica de pocos ejemplos, si bien la mayoría de sistemas exitosos de ese desafío siguieron usando redes convolucionales (Nolasco et al., 2023). En detección con salida bidimensional, el trabajo relevante sustituye los *backbones* preentrenados en imágenes por representaciones nativas de audio y añade una pirámide multiescala, precisamente porque las arquitecturas de tipo transformador de espectrograma producen representaciones de una sola escala (Zhu and Sato, 2025).

Del lado de la representación de entrada, la normalización de energía por canal fue el contribuyente principal a la mejora de precisión sobre la línea base de espectrograma log-mel (Lostanlen et al., 2019), y también la representación mayoritaria entre los sistemas exitosos del desafío de detección con pocos ejemplos (Nolasco et al., 2023).

La elección de la representación resultó, en esos trabajos, tan determinante como la elección de la arquitectura (Bonet-Solá and Alsina-Pagès, 2021).

3.2.2. P2: Clasificación jerárquica fina

La revisión no identificó estrategias diseñadas y evaluadas explícitamente para la clasificación jerárquica fina que asigna de forma simultánea la especie y el tipo de vocalización. La literatura recuperada se concentra en tres tareas vecinas pero distintas: la detección de eventos, que localiza sin etiquetar en detalle (Lostanlen et al., 2019; Politis et al., 2020); la clasificación de especie, multiclase o multietiqueta, que identifica qué especies están presentes BirdNET reconoce 984 especies de aves (Kahl et al., 2021), y Kath et al. (2024) entrenan clasificadores lineales sobre *embeddings* para anuros; y la clasificación de eventos ya detectados en un conjunto plano de clases predefinidas (Politis et al., 2020).

La necesidad de distinguir tipos de llamada o sílabas se reconoce como un desafío de clasificación de grano fino en bioacústica, pero se enuncia como problema abierto y no como capacidad demostrada (Nolasco et al., 2023). Este es, en la revisión, el hueco más nítido y el que sostiene el eje de tarea de la sección 1.1.4.

3.2.3. P3: Mitigación de ruido y variabilidad entre sensores

Ningún trabajo recuperado prueba técnicas específicamente sobre ruido amazónico, pero varios abordan el ruido ambiental heterogéneo y la variabilidad entre sensores en despliegues de monitoreo acústico pasivo. Dos resultados son directamente aplicables.

El primero es la normalización de energía por canal como preprocesamiento del espectrograma: al combinar compresión de rango dinámico y control adaptativo de ganancia, suprime el ruido estacionario y realza los eventos transitorios, y con sus parámetros ajustados a entornos exteriores ruidosos produce distribuciones de magnitud consistentes y cuasi-gaussianas entre sensores distintos (Lostanlen et al., 2019). El segundo son las redes adaptativas al contexto, que procesan en una rama auxiliar estadísticas espectrales resumidas a largo plazo, mediante percentiles del espectrograma, y adaptan el modelo a las condiciones de cada punto de monitoreo, mejorando la robustez frente a la variabilidad espacial del ruido (Lostanlen et al., 2019). Ambas

técnicas resultaron complementarias: su combinación fue lo que produjo detección robusta a escala de red de sensores.

3.2.4. P4: Conjuntos de datos y aumento de datos

Los conjuntos públicos disponibles se concentran de forma abrumadora en aves: BirdVox, Xeno-canto y la Macaulay Library. Fuera de ese taxón, la revisión identificó AnuraSet para anuros, la base de Watkins para mamíferos marinos y los conjuntos de DCASE para sonidos generales. No se encontró ningún conjunto público a gran escala etiquetado específicamente para vocalizaciones de primates, lo que confirma por una segunda vía el eje de dominio de la sección 1.1.4.

En cuanto a formatos, los eventos localizados en tiempo se distribuyen típicamente como archivos delimitados con tiempo de inicio, tiempo de fin y etiqueta de clase (Nolasco et al., 2023); en tareas de localización se añade la dirección de llegada (Politis et al., 2020); y en repositorios grandes como Xeno-canto lo habitual son etiquetas débiles de presencia o ausencia a nivel de grabación completa (Kahl et al., 2021). Ninguno de esos formatos registra la banda de frecuencia del evento.

Frente a la escasez y al desbalance, las técnicas reportadas son la adición de ruido de fondo realista, el desplazamiento de tono, el estiramiento temporal, el enmascaramiento de bloques de tiempo o frecuencia sobre el espectrograma y el entrenamiento con mezcla de ejemplos (Kahl et al., 2021; Lostanlen et al., 2019; Politis et al., 2020). El sobremuestreo de clases minoritarias es la respuesta habitual al desbalance, mientras que el aprendizaje sensible al costo fue probado sin mejora apreciable (Kahl et al., 2021). Cuando los ejemplos etiquetados son muy escasos, las redes prototípicas permiten adaptarse a clases nuevas con apenas cinco ejemplos (Nolasco et al., 2023).

3.2.5. P5: Transferencia de aprendizaje

La transferencia de aprendizaje es la estrategia central cuando los datos etiquetados son limitados (Kath et al., 2024). El hallazgo más útil de la revisión es que la proximidad del dominio de origen importa más que el tamaño del modelo: BirdNET, entrenado en aves, transfiere mejor a la clasificación de anuros que modelos entrenados en audio general o en imágenes (Kath et al., 2024). Eso lo posiciona como candidato razonable para transferir a primates.

Sobre el método de adaptación, la revisión distingue dos rutas. La extracción de características usa el modelo preentrenado como extractor fijo y entrena un clasificador simple sobre sus *embeddings*; la penúltima capa de BirdNET resultó particularmente efectiva en esa función (Kath et al., 2024). El ajuste fino reentrena parcial o totalmente los pesos con los pocos datos de la tarea objetivo, y exige cuidado para no sobreajustar (Nolasco et al., 2023). Ninguno de los trabajos documenta la adaptación de estos modelos a la detección con salida bidimensional ni a la clasificación jerárquica de primates.

Detección y robustez (P1, P3). No se identificó ningún estudio que aplique y evalúe modelos de aprendizaje profundo a la detección tiempo–frecuencia de primates amazónicos. La literatura de dominios vecinos sí ofrece estrategias trasladables: las arquitecturas convolucionales y convolucionales recurrentes como base (Lostanlen et al., 2019; Politis et al., 2020), las variantes residuales y los transformadores para secuencias largas (He et al., 2016; Nolasco et al., 2023), y, frente a la variabilidad del ruido, la normalización de energía por canal junto con las redes adaptativas al contexto, cuya combinación resultó la más efectiva a escala de red de sensores (Lostanlen et al., 2019).

Clasificación jerárquica (P2). No se hallaron estrategias explícitamente diseñadas y evaluadas para asignar de forma conjunta especie y tipo de vocalización. Existen enfoques de clasificación multietiqueta sobre *embeddings* preentrenados (Kath et al., 2024), pero la tarea jerárquica específica sigue requiriendo desarrollo propio.

Datos y anotaciones (P4). Se confirma la ausencia de conjuntos públicos a gran escala etiquetados para primates y adecuados para aprendizaje profundo: el esfuerzo de la comunidad se concentra en aves. Los formatos de anotación de uso común registran tiempo de inicio, tiempo de fin y clase (Nolasco et al., 2023), y descartan la banda de frecuencia, lo que significa que incluso los conjuntos disponibles no servirían como referencia para la tarea de esta tesis sin reanotación.

Transferencia (P5). La transferencia desde dominios cercanos es la respuesta más viable a la escasez de datos etiquetados, con evidencia de transferencia exitosa de aves a otros taxones (Kath et al., 2024; Nolasco et al., 2023). Queda abierto cómo aplicarla cuando la salida deseada no es una etiqueta por segmento sino una caja tiempo–frecuencia, que es exactamente el problema que aborda el Capítulo 5.

Los dos ejes del vacío descrito en la sección 1.1.4 quedan confirmados de forma independiente por esta revisión: no hay trabajo publicado sobre primates neotropicales

en este contexto (eje de dominio) y no hay estrategias establecidas para la salida bidimensional con etiquetado jerárquico (eje de tarea). El cruce de ambos ejes es la posición que ocupa esta tesis.

Capítulo 4

Curación del Conjunto de Datos (OE1)

4.1. Análisis del conjunto original

4.1.1. Material recibido y formato

El material de partida son ocho carpetas, una por especie. Cada carpeta contiene grabaciones en formato WAV muestreadas a 44,1 kHz, capturadas con dispositivos AudioMoth desplegados en el bosque, junto con sus anotaciones en archivos de texto generados con Raven. La Figura 4.1 muestra un archivo de anotaciones tal como se recibe.

Selection	View	Channel	Begin Time (s)	End Time (s)	Low Freq (Hz)	High Freq (Hz)	Inband Power (dB FS)	Species	Call type	Rating	Reference
1	Spectrogram	1	1.336330093	1.865888854	7560.000	10080.000	-46.04	LW	CS C		
2	Spectrogram	1	4.441470101	4.971028862	7560.000	10080.000	-67.83		noise		1
3	Spectrogram	1	1.950136839	2.449607034	7766.599	10801.822	-41.65	LW	CS B		
4	Spectrogram	1	4.558815508	5.058285703	7766.599	10801.822	-70.12		noise		3
5	Spectrogram	1	2.527837305	3.057396066	8212.955	10444.737	-41.20	LW	CS B		
6	Spectrogram	1	4.868727738	5.398286499	8212.955	10444.737	-78.54		noise		5
7	Spectrogram	1	3.135626338	3.611025680	8034.413	10266.194	-40.34	LW	CS B		
8	Spectrogram	1	4.637045780	5.112445122	8034.413	10266.194	-75.00		noise		7
9	Spectrogram	1	3.767486223	4.182708433	7588.057	9552.024	-41.43	LW	CS B		
10	Spectrogram	1	5.016161711	5.431383921	7588.057	9552.024	-68.79		noise		9
11	Spectrogram	1	1.320278575	4.166656916	7422.772	10588.366	-42.46	LW	CC B		
12	Spectrogram	1	4.407365444	5.719457935	7422.772	10588.366	-67.57		noise		11

Figura 4.1: Archivo de anotaciones de una grabación, con las columnas diferenciadas por color. El formato es un archivo de texto delimitado por tabulaciones que Raven lee y escribe directamente.

Las anotaciones se crean y editan sobre la grabación en Raven (Figura 4.2). El analista dibuja una región rectangular sobre el espectrograma y el software deriva de ella el rango de frecuencias, los tiempos de inicio y fin, y la amplitud. Las columnas de

especie y tipo de llamada se escriben a mano, y son justamente las que concentran los problemas descritos a continuación.




Figura 4.2: Raven durante el procesamiento de una grabación junto con sus anotaciones. Cada caja del espectrograma corresponde a una fila del archivo de la Figura 4.1.

4.1.2. Defectos detectados

Un análisis exploratorio sobre el conjunto reveló cinco problemas que impiden usar el material directamente para entrenamiento.

Inconsistencias de etiquetado. Una misma clase aparece escrita de múltiples formas. El prototipo inicial de este trabajo, restringido a la sílaba de contacto del tamarino de Weddell, ya encontró en la columna de tipo de llamada el conjunto de valores distintos {CS, CS_u, CS_{uuuuuu}A, contact syllable, CC, contact call, noise, noise_{uuu}, noise|, noises, AA, A, B, C, TA}: cuatro grafías para una única clase, tres para el descarte por ruido y un encabezado de columna que unas veces es Call type y otras Call Type. Las Figuras 4.3 y 4.4 muestran los valores únicos encontrados en cada una de las dos columnas manuales sobre el corpus completo.

Integridad de los archivos. La carga automatizada de las grabaciones produce advertencias sobre archivos de audio dañados (Figura 4.5), que interrumpen el proceso si no se manejan de forma explícita. La corrupción se manifiesta como bloques de ceros en la señal y admite grados: la Figura 4.6 muestra un caso leve y la Figura 4.7 uno en


```

print("\nEspecies únicas en el dataset:")
print("-----")
for i, specie in enumerate(raw_annotations["specie"].unique(), 1):
    print(f"{i}. {specie}")
✓ 0.0s

Especies únicas en el dataset:
-----
1. CC
2. PT
3. nan
4. LW
5. 8
6. -
7. PTD
8. LW
9. L
10. }
11. AS
12. AC
13. AC
14. SW
15. AA
16. AN
17. SN
18. #
19. AS-----AS
20. SB

```

Figura 4.3: Etiquetas únicas encontradas en la columna de especie.

```

print("Tipos de llamadas únicas en el dataset:")
print("-----")
for i, call in enumerate(raw_annotations["call_type"].unique(), 1):
    print(f"{i}. {call}")
✓ 0.0s

Tipos de llamadas únicas en el dataset:
-----
1. CC
2. nan
3. BP
4. PP
5. AC
6. DC
7. SQC
8. D
9. CHC
10. CS
11. noise
12. AA
13. A
14. B
15. TA
16. C
17. CS
18. CS      A
19. noise
20. contact call
21. contact syllable
22. TT
23. TR
24. VC
25. TJ
26. TC
27. noise|
28. noises

```

Figura 4.4: Etiquetas únicas encontradas en la columna de tipo de llamada.

el que la mayor parte del archivo es inutilizable. El origen probable son cortes durante la transferencia o fallos del medio de almacenamiento.

```

Procesando 2674 archivos de audio...
=====
⚠ ADVERTENCIA en 20240117_060129.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240117_163024.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240207_102952.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240214_102327.wav: Anotaciones exceden duración del audio (7.65s > 6.87s)
⚠ ADVERTENCIA en 20240214_102452.wav: Anotaciones exceden duración del audio (5.92s > 5.13s)
⚠ ADVERTENCIA en 20240214_102634.wav: Anotaciones exceden duración del audio (13.15s > 13.11s)
⚠ ADVERTENCIA en 20240415_114228.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240429_104951.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240504_080326.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240510_065700.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240510_071046.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240516_081806.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240516_081815.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240530_110626.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240621_074433.wav: Anotaciones exceden duración del audio (30.69s > 27.25s)
⚠ ADVERTENCIA en 20240805_091140.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240805_091302.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154436.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154640.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154724.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154800.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240813_092636.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240815_170844.wav: El espectrograma contiene ceros.

```

Figura 4.5: Advertencias emitidas durante la carga automatizada de las grabaciones.

Discrepancias entre especie y carpeta. La etiqueta de especie escrita en la anotación no siempre coincide con el código de la carpeta contenedora, lo que obliga a decidir cuál de las dos fuentes prevalece antes de consolidar nada.




Figura 4.6: Grabación con corrupción leve




Figura 4.7: Grabación con corrupción severa

Frecuencias por encima de Nyquist. Algunas cajas declaran una frecuencia superior mayor que el límite de Nyquist de la señal (22 050 Hz a 44,1 kHz de muestreo), un valor que no puede corresponder a energía observable en la grabación.

Variabilidad en la unidad de análisis. La granularidad de las anotaciones no es uniforme. En unos casos el analista etiquetó sílabas individuales y en otros delimitó una secuencia completa con una sola caja. No se trata de un error de anotación sino de la manifestación directa del anidamiento jerárquico de las unidades acústicas (Kershenbaum et al., 2016) descrito en el Capítulo 2; la subsección 4.1.5 lo cuantifica.

4.1.3. Composición del conjunto curado

Tras aplicar el protocolo de la sección 4.2, el conjunto queda en **19 042 anotaciones sobre ocho especies, repartidas en 57 pares distintos de especie y tipo de llamada**. De esos 57 pares, 41 pertenecen al vocabulario declarado para el dominio y concentran 18 714 anotaciones; los 16 restantes, que suman 328 registros (el 1,7 %), quedan fuera del vocabulario y se marcan para revisión en lugar de descartarse en silencio. La Tabla 4.1 resume el reparto por especie.

Dos propiedades de esa tabla gobiernan el resto del capítulo. La primera es que **el vocabulario es desigual entre especies**: LW aporta once tipos de llamada distintos sobre 4 103 anotaciones, mientras que CC aporta un único tipo con 29. La segunda es que **la distribución dentro de una especie es tan sesgada como la distribución entre especies**: en SM, el par **sm/acc** cuenta con 8 anotaciones frente a las 2 040 de **sm/cc**, un factor de 255× dentro de un mismo repertorio. La cola es larga: los diez pares mayores concentran el 74 % de las 19 042 anotaciones y el resto se reparte hasta pares con una sola.

Tabla 4.1: Composición del vocabulario curado por especie

Especie	Cód.	En vocabulario		Experimento	
		Tipos	Anotaciones	Clases	Anotaciones
<i>Leontocebus weddelli</i>	LW	11	4 123	5	3 492
<i>Sapajus macrocephalus</i>	SM	8	3 605	5	3 395
<i>Alouatta sara</i>	AS	2	3 310	2	3 310
<i>Ateles chamek</i>	AC	6	3 081	4	3 017
<i>Saimiri boliviensis</i>	SB	5	2 326	4	2 277
<i>Plecturocebus toppini</i>	PT	5	1 156	2	1 030
<i>Aotus azarae</i>	AA	3	1 084	3	1 084
<i>Cebus cuscinus</i>	CC	1	29	0	N/D
Total		41	18 714	25	17 605

Las 328 anotaciones restantes hasta 19042 corresponden a los 16 pares fuera de vocabulario, marcados para revisión.

Los cuatro tipos de trino de LW cuentan como cuatro entradas del vocabulario y como una sola clase del experimento, por la fusión que justifica la sección 4.2.4.




Figura 4.8: Galería de llamadas.

4.1.4. Geometría de los eventos

Las llamadas anotadas son extraordinariamente desiguales en tamaño, y ese hecho condiciona todas las decisiones de diseño que siguen. La Tabla 4.2 lo mide sobre las 19 042 anotaciones.

Tabla 4.2: Variación de tamaño de las llamadas anotadas

	Mínimo	Máximo	Razón
Duración	0,034 s	73,3 s	2 134×
Ancho de banda	224 Hz	21 784 Hz	97×

La llamada más larga dura más de dos mil veces lo que la más corta. La magnitud se aprecia mejor por comparación: en COCO, la colección de imágenes con la que se evalúan habitualmente los detectores de objetos (Lin et al., 2014), los objetos mayores superan a los menores en un factor de entre 10 y 100. El problema que enfrenta este detector es, en ese eje, un orden de magnitud más severo que aquel para el que se diseñaron las arquitecturas que hereda.

La consecuencia inmediata es que **ninguna longitud de ventana única sirve para todas las clases**: una ventana capaz de contener un aullido de 73 s es demasiado gruesa para resolver un chirrido de 34 ms. La sección 4.3 documenta el compromiso adoptado y lo que cuesta.

La Figura 4.9 sitúa cada clase en duración y en banda de frecuencia, y hace visibles dos efectos a la vez. Las **especies se separan en buena medida por banda**: AS ocupa aproximadamente entre 25 y 1 410 Hz (percentiles 1 y 99), mientras que **lw/cs** nunca aparece anotada por debajo de 3 687 Hz. Los **tipos de llamada dentro de una misma especie no se separan**: en LW, la familia de trinos junto con vc y cs comparten banda y duración casi por completo.

Esa disociación tiene una consecuencia metodológica directa, y es la que sostiene el protocolo de evaluación del Capítulo 5: si la geometría distingue especies pero no tipos de llamada, entonces *localizar* y *etiquetar* son problemas de dificultad distinta y no deben puntuarse con una sola cifra. De ahí que la detección se entrene de forma agnóstica a la clase y la clasificación se evalúe por separado.

La Figura 4.10 desglosa la geometría par por par y revela un problema distinto del desbalance: **ac/bc** (coeficiente de variación del ancho de banda 0,60) y **sm/fs** (0,63) se

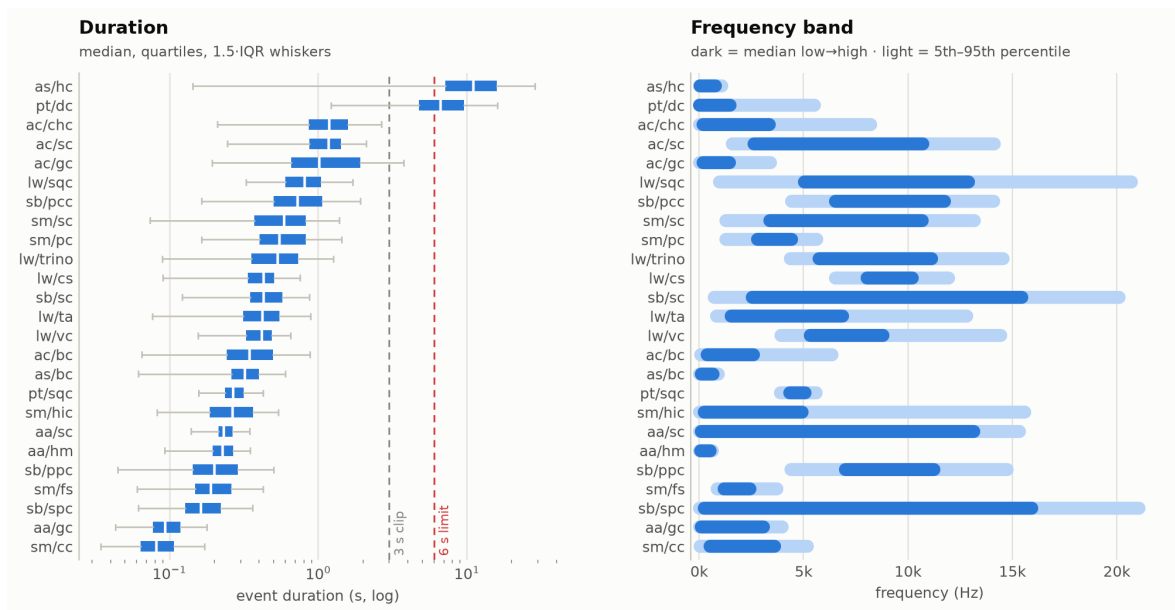


Figura 4.9: Dónde vive cada clase en tiempo y en frecuencia. Las especies ocupan bandas distintas; los tipos de llamada de una misma especie se solapan casi por completo. La figura abarca los pares del vocabulario curado con suficientes anotaciones para caracterizarlos, un conjunto algo más amplio que las veinticinco clases del experimento (Tabla 4.3).

parten cada uno en dos nubes claramente separadas en el plano duración × ancho de banda, mientras que **sb/ppc** (0,47) es una única mancha difusa. Que una etiqueta cubra dos nubes disjuntas sugiere que agrupa dos variantes de llamada que el vocabulario actual no distingue. Es un hallazgo sobre el esquema de anotación, no sobre el modelo. Son, además, las clases con peor *recall* en la evaluación del Capítulo 5.

4.1.5. Sílabas y frases

Una *frase* es una secuencia de *sílabas*, y los expertos anotan ambas: el 94,2 % de las frases **lw/cc** contienen al menos una sílaba **lw/cs**, y el 96,8 % de las frases **sm/fc** contienen una sílaba **sm/fs**. El mismo tramo de audio lleva, por tanto, una caja grande y varias cajas pequeñas dentro de ella.

El detector no puede representar esa relación. Devuelve una lista plana de cajas, y el emparejamiento durante el entrenamiento asocia cada anotación verdadera con exactamente una predicción, sin manera de expresar que “esta caja contiene a aquella”. Conservar ambos niveles equivaldría a pedir al modelo que informe dos veces el mismo sonido, como si fueran dos eventos no relacionados superpuestos. Es la consecuencia operativa del anidamiento jerárquico que Kershenbaum et al. (2016) describen como propiedad general de las unidades acústicas animales: una secuencia de unidades puede




Figura 4.10: Duración frente a ancho de banda, un panel por par del vocabulario curado. En gris, todas las clases; en color, la del panel. Las nubes partidas de *ac/bc* y *sm/fs* indican una etiqueta única que cubre dos variantes de llamada.

ella misma considerarse una unidad. Las dos clases de frase se excluyen, en consecuencia, antes del entrenamiento.




Figura 4.11: Anidamiento frase-sílaba.

4.2. Protocolo de curación y estandarización (RE1.1)

El protocolo se implementa como un *pipeline* programático, no como una corrección manual del material recibido. La distinción importa: un protocolo ejecutable puede volver a aplicarse sobre los datos primarios cada vez que sus reglas cambian, y deja registro de qué se descartó y por qué.

4.2.1. Carga y consolidación

El primer paso recorre la estructura de directorios, lee cada archivo de anotación y los unifica en una única tabla. Para cada archivo:

Emparejamiento con el audio. Solo se carga el archivo de anotación que tiene una grabación homónima junto a él. Un archivo de texto huérfano no aporta nada entrenable y su presencia suele indicar un error de transferencia.

Normalización de nombres de columna. Los encabezados originales se convierten a un formato programático uniforme; `Begin Time (s)` pasa a `begin_time_s`, y de forma análoga el resto. Esto resuelve de una vez la alternancia entre `Call type` y `Call Type` observada en el material crudo.




Figura 4.12: Pipeline de curación.

Descarte de columnas no utilizadas. Se eliminan las columnas de selección, vista, canal, referencia y desplazamiento de archivo, que corresponden al estado interno de Raven y no al evento.

Enriquecimiento con metadatos. Se añaden la ruta de la grabación de origen y el directorio contenedor, que preserva la especie declarada por la organización del corpus.

Los errores de lectura se capturan y se registran, de modo que un archivo dañado o un directorio vacío se omitan sin detener el proceso.

4.2.2. Normalización de etiquetas

Sobre la tabla consolidada se aplican, en este orden, las siguientes reglas.

Normalización tipográfica. Toda etiqueta se reduce a minúsculas y a caracteres alfanuméricos separados por guion bajo. Este único paso absorbe la mayoría de las variantes observadas, como espacios en blanco al final, mayúsculas inconsistentes y caracteres residuales, sin necesidad de enumerarlas.

Mapa de sinónimos. Un diccionario explícito unifica las variantes que la normalización tipográfica no captura, por ser errores de escritura o abreviaturas alternativas y no diferencias de formato: `noises` a `noise`, `cs_a` a `cs`, `whinnie` a `whc`, `tca` y `tac` a `ta`, `contact` a `cc`, `chcj` a `chc`, `php` a `phc`, `sqr` a `sqc`, y `tc` a `tr`. Al mapa se suma, por especie, la traducción del nombre legible del tipo de llamada a su código `contact syllable` a `cs`, de modo que las anotaciones escritas en prosa converjan con las escritas en código.

Descarte de ruido. Las anotaciones cuyo tipo de llamada, ya normalizado, es `noise` se eliminan: marcan la ausencia de evento, no un evento.

Corrección de pares imposibles. Un pequeño conjunto de correcciones explícitas resuelve pares que no existen en el repertorio de la especie y cuya intención es inequívoca; por ejemplo, `aa/hc` se corrige a `aa/hm`, dado que `AA` no tiene llamada de aullido pero sí de ululato.

Ante una discrepancia entre la especie escrita en la anotación y el código de la carpeta contenedora, prevalece la carpeta. El criterio no es arbitrario: el directorio es un dato estructural, fijado una vez por sesión de campo, mientras que la columna de especie se teclea en cada fila y es donde se observaron los errores de la Figura 4.3.

4.2.3. Saneamiento geométrico

Las coordenadas de la caja se validan de forma independiente de la etiqueta:

Recorte a Nyquist. La frecuencia superior se recorta a 22 050 Hz. Por encima de ese límite no hay energía observable en una señal muestreada a 44,1 kHz, de modo que un valor mayor es un error de anotación y no una propiedad del evento.

Descarte de cajas degeneradas. Se eliminan las anotaciones de duración inferior a 10 ms y las de ancho de banda nulo o negativo. Una caja sin área no define una región y no puede emparejarse con ninguna predicción.

Características derivadas. Se calculan la duración y el ancho de banda de cada caja, que son las magnitudes sobre las que se construye el análisis de la sección 4.1.4.

4.2.4. Vocabulario cerrado y selección del subconjunto

El vocabulario admisible se declara de forma explícita como el conjunto de pares (especie, tipo de llamada) válidos del dominio, no como aquello que aparezca en los datos. Cerrar el vocabulario es la respuesta a la condición subyacente S2 del árbol de problemas: las definiciones de unidad y las etiquetas semánticas varían ampliamente entre investigadores, incluso dentro de un mismo grupo taxonómico (Kershenbaum et al., 2016), de modo que sin una lista fija la misma señal recibe etiquetas distintas según quién la anote.

Los pares que caen fuera del vocabulario, 16 pares que suman 328 registros, no se eliminan: se marcan con una bandera de revisión. La diferencia es deliberada. Un par fuera de vocabulario puede ser un error de escritura no previsto o un tipo de llamada legítimo aún no incorporado, y solo el equipo de investigación puede distinguir uno de otro. Descartarlos en silencio destruiría esa evidencia.

Sobre el vocabulario se recorta el subconjunto de experimento en tres pasos:

1. **Exclusión por anidamiento.** Se retiran las dos clases de frase, **lw/cc** (517 anotaciones) y **sm/fc** (126), por la razón de la sección 4.1.5, y **sb/pcs** (8), que es la misma relación frase-sílaba dentro del repertorio de SB.
2. **Fusión de los trinos de LW.** Los cuatro tipos de trino (**tr**, 333; **tj**, 164; **tt**, 106; **tf**, 31) se reúnen en una única clase **lw/trino** de 634 anotaciones. El motivo es geométrico y proviene de la sección 4.1.4: los cuatro comparten banda y duración casi por completo, de modo que mantenerlos separados obliga al detector a distinguir lo que la representación no distingue, y reparte entre cuatro etiquetas escasas un material que como clase única sí alcanza masa suficiente.
3. **Umbral de frecuencia.** Se conservan los pares con al menos 100 anotaciones. Por debajo de ese piso una clase no sostiene ni entrenamiento ni evaluación por clase: la más escasa que sobrevive, **sb/sc** con 105 anotaciones, aporta apenas 126 cajas de entrenamiento.

El resultado son las **25 clases y 17 605 anotaciones** de la Tabla 4.3, el 92,5 % del conjunto curado, distribuidas sobre siete de las ocho especies. El umbral deja fuera 26 pares con 786 anotaciones; de ellos, once pertenecen al vocabulario y suman 466 anotaciones, entre los que está **cc/cc**: con 29 registros, la única llamada de CC no

alcanza el piso y esa especie queda fuera del experimento, aunque permanece en el conjunto curado.

La elección del umbral en 100 y no más arriba es deliberada, y responde a una tensión que conviene enunciar. Un umbral alto produce un experimento cómodo —pocas clases, todas abundantes— a costa de dejar sin cubrir la mayor parte del repertorio documentado: con el piso en 500 anotaciones sobrevivían diez clases, el 74 % del material, y veintinueve tipos de llamada del vocabulario quedaban sin usar. Bajar el piso a 100 cubre el 92,5 % del material y las cinco especies que antes aportaban una sola clase pasan a aportar entre dos y cinco, al precio de admitir clases cuyo desempeño estará limitado por su propia escasez y no por la arquitectura. El Capítulo 5 lee los resultados por clase con esa distinción presente, y la Figura 4.13 sitúa el umbral sobre la distribución completa de pares.

4.3. Particionado y ventaneo (RE1.2)

4.3.1. Partición por archivo de grabación

El conjunto se divide en entrenamiento, validación y prueba en proporción 60/22,5/17,5 de cajas por clase, con semilla fijada para que la partición sea reproducible. La asignación es golosa y recorre las clases de la más rara a la más común, de modo que el reparto de las clases escasas se decide primero y no queda como residuo del de las abundantes. El resultado son 21 966 ventanas de entrenamiento, 9 446 de validación y 8 007 de prueba, con 27 022, 10 090 y 7 985 cajas anotadas respectivamente. La división se hace **por archivo de grabación**: todas las anotaciones de una misma grabación caen en la misma partición, y ninguna ventana cruza particiones.

La alternativa de repartir anotaciones o ventanas sueltas no es un descuido hipotético. El prototipo inicial de este trabajo la cometió: barajaba los clips de 0,5 s y los repartía por índice, con lo que dos ventanas solapadas procedentes de la misma anotación podían quedar una en entrenamiento y otra en prueba. Sobre esa partición el clasificador alcanzaba un 99 % de exactitud, una cifra que no medía generalización sino memoria: el 91,2 % de los clips eran negativos, de modo que un predictor constante “sin llamada” ya obtenía 91,2 %. Dado que la variación en las etiquetas fuertes afecta por sí sola a la evaluación (Koga et al., 2024), no añadir además fuga de datos es la condición mínima para que las cifras resulten interpretables.




Figura 4.13: Anotaciones por par de especie y tipo de llamada. Las 25 clases por encima del umbral de 100 concentran el 92,5 % de las 19 042 anotaciones; la cola larga llega hasta pares con una sola.

Tabla 4.3: Clases del subconjunto de experimento y clases de frase excluidas

Clase	Tipo de llamada	Anot.	Cajas (train)	Rol
ac/bc	Ladrido	2 487	2 886	Experimento
lw/cs	Sílaba de contacto	2 316	2 706	Experimento
sm/cc	Llamada de contacto	2 040	2 359	Experimento
as/bc	Ladrido	1 909	2 233	Experimento
as/hc	Aullido	1 401	6 933	Experimento
sb/ppc	Llamada de juego	1 151	1 300	Experimento
aa/gc	Llamada de trago	796	924	Experimento
sb/spc	Llamada de escupido	730	860	Experimento
sm/fs	Sílaba de comida	691	801	Experimento
pt/dc	Dueto	638	1 950	Experimento
lw/trino	Trino (fusión de 4 tipos)	634	739	Experimento
pt/sqc	Chillido	392	465	Experimento
sb/pcc	Llamada de contacto (pío)	291	342	Experimento
lw/ta	Alarma terrestre	266	312	Experimento
sm/hic	Llamada <i>hip</i>	254	295	Experimento
sm/pc	Ronroneo	242	283	Experimento
ac/chc	Parloteo	232	276	Experimento
sm/sc	Chillido	168	200	Experimento
aa/sc	Chirrido	159	183	Experimento
ac/sc	Chirrido	158	188	Experimento
lw/sqc	Chillido	155	182	Experimento
ac/gc	Gruñido	140	191	Experimento
aa/hm	Ululato	129	148	Experimento
lw/vc	Contacto visual	121	140	Experimento
sb/sc	Alarido	105	126	Experimento
lw/cc	Llamada de contacto	517	—	Excluida: contiene sílabas
sm/fc	Llamada de comida	126	—	Excluida: contiene sílabas
sb/pcs	Secuencia de píos	8	—	Excluida: contiene sílabas
Total expe- rimento		17 605	27 022	

Las tres clases de frase se retiran por anidamiento (sección 4.1.5), no por escasez: **lw/cc** supera holgadamente el umbral y habría entrado al experimento.

La columna de cajas cuenta ventanas de 3 s de la partición de entrenamiento, no anotaciones. Las dos cifras no son proporcionales: **as/hc** y **pt/dc** multiplican su material porque cada llamada larga atraviesa varias ventanas (sección 4.3), y son las dos únicas clases donde eso ocurre.

La Tabla 4.4 recoge la composición resultante.

Tabla 4.4: Composición de las particiones tras el ventaneo

Partición	Grabaciones	Ventanas	Cajas
Entrenamiento	1 166	8 022	16 674
Validación	166	1 043	2 183
Prueba	335	2 490	5 343
Total	1 667	11 555	24 200

Hay más cajas que anotaciones porque una misma anotación puede caer en dos ventanas consecutivas: la ventana de 3 s avanza 1,5 s.

El balance entre clases se conserva a lo largo de las tres particiones, con un rango de cajas de entrenamiento que va de 3 273 para **lw/cs** a 320 para **as/hc**. Ese último número llama la atención: **as/hc** tiene 1 400 anotaciones en la Tabla 4.3 y, sin embargo, aporta menos cajas que clases con la mitad de anotaciones. La razón es estructural y se documenta a continuación.




Figura 4.14: Partición por grabación.

4.3.2. El ventaneo y lo que le cuesta a las llamadas largas

Las grabaciones tienen duración variable y el detector consume entradas de tamaño fijo, de modo que cada grabación se segmenta en ventanas de 3 s que avanzan 1,5 s. La regla de asignación no compara el solapamiento contra la duración del evento sino contra su *parte visible*, definida como el mínimo entre la duración del evento y la longitud de la ventana: una anotación entra en una ventana si el solapamiento cubre al menos la mitad de esa parte visible.

El detalle no es menor. Comparar contra la duración completa dejaría **inalcanzable a todo evento de más de 6 s**, porque no existe posición de la ventana en la que quepa la mitad de un aullido de 30 s; con el criterio de parte visible, en cambio, ese aullido entra en toda ventana que caiga dentro de él. Ninguna anotación del subconjunto de experimento queda sin ventana.

Lo que el ventaneo cobra es otra cosa, y la Tabla 4.5 la mide: las llamadas largas se **fragmentan**. Cada evento se reparte, en promedio, entre 2,6 ventanas —consecuencia directa del salto de 1,5 s, que hace que casi todo evento breve aparezca en dos—, pero **as/hc** se reparte entre 8,2 y **pt/dc** entre 5,1. El aullido de **as/hc**, con 1 401 anotaciones, aporta 11 557 cajas: el 26 % de todas las cajas del conjunto derivado provienen del 8 % de las anotaciones. Y esas cajas no son recortes cualesquiera: el 99,6 % de las de **as/hc** toca al menos un borde temporal de su ventana, y en el 78 % de los casos la caja ocupa la ventana entera de lado a lado.

Tabla 4.5: Efecto del ventaneo de 3 s sobre las clases de eventos largos

Clase	Anot.	Cajas	Cajas por anotación	Anot. > 3 s	Cajas en el borde
as/hc	1 401	11 557	8,2	94,6 %	99,6 %
pt/dc	638	3 249	5,1	90,8 %	99,2 %
Resto (23 clases)	15 566	30 291	1,9	0,3 %	11,8 %
Total	17 605	45 097	2,6	11,1 %	40,6 %

Una caja está “en el borde” cuando su lado temporal izquierdo o derecho coincide con el límite de la ventana, es decir, cuando el evento continúa fuera de ella.

Esto se documenta aquí, y no en el apartado de limitaciones, porque determina la lectura de los resultados por clase del Capítulo 5 en dos direcciones opuestas. Por un lado, **as/hc** y **pt/dc** se vuelven las clases *más fáciles* del conjunto: una caja que ocupa la ventana completa se acierta con casi cualquier predicción grande, y los cuatro modelos evaluados recuperan entre el 88 y el 95 % de las cajas de **as/hc** y entre el 70 y el 82 % de las de **pt/dc**, muy por encima de lo que obtienen en cualquier otra clase de tamaño comparable. Por otro, al aportar el 33 % de las cajas, esas dos clases dominan cualquier cifra agregada: un *recall* global que las incluya mide, en un tercio de su peso,

la capacidad de dibujar un rectángulo del tamaño de la ventana. Por eso el Capítulo 5 reporta el promedio por clase junto al agregado, y no en su lugar.

Es, además, la manifestación concreta del rango de $2\ 134\times$ en duración de la Tabla 4.2: una ventana única no puede a la vez resolver un chirrido de 34 ms y contener un aullido de 73 s. Una segunda longitud de ventana para las clases largas, o una etapa de agregación que reconstruya el evento completo a partir de sus fragmentos antes de puntuarlo, sigue siendo el principal pendiente de esta etapa.




Figura 4.15: Efecto del ventaneo.

4.3.3. Densidad de eventos por ventana

Conviene registrar cuántas anotaciones coinciden en una misma ventana de 3 s: la mediana es 1 y el máximo observado, 11; el 97 % de las ventanas con contenido lleva cuatro cajas o menos. Es una propiedad del conjunto derivado, pero se consigna aquí porque el Capítulo 5 la usa para dimensionar el número de predicciones simultáneas que el decodificador debe sostener: el presupuesto se fija sobre el máximo y no sobre la mediana.

A las ventanas con al menos una anotación se suma un 25 % de ventanas *vacías* tomadas al azar de tramos sin ninguna llamada. Sin ellas el modelo nunca ve fondo puro —selva, lluvia, insectos— y aprende que en toda entrada hay algo que reportar, que es exactamente el sesgo que la carga de revisión paga.

4.3.4. Representación y normalización de las cajas

Cada ventana se transforma en un espectrograma log-mel con los parámetros de la Tabla 4.6. Log-mel es la representación con la que se materializa el caché, y la que consumen las tres arquitecturas; la normalización de energía por canal anunciada en la sección 2.2.3 no la reemplaza sino que se aplica encima, como capa entrenable de entrada de la arquitectura propuesta (sección 5.1). La ablación que la compara contra la compresión logarítmica fija está implementada en el repositorio, pero todavía no medida. La columna de justificación registra qué falla con el ajuste alternativo, que es la información que permite revisar un parámetro sin repetir el experimento que lo fijó.

Tabla 4.6: Parámetros de preprocesamiento y motivo de cada elección

Parámetro	Valor	Justificación
Ventana / salto	3,0 s / 1,5 s	Contiene entera a 23 de las 25 clases; el costo es la fragmentación de las dos largas (Tabla 4.5)
Solapamiento mínimo	0,5	Un evento entra en una ventana si la mitad de su parte visible cae dentro; medirlo contra la parte visible y no contra la duración total es lo que mantiene alcanzables a los eventos de más de 6 s
Longitud de ventana STFT	1 024 (23 ms)	Más corta que los eventos más breves: 34 ms el mínimo, 81 ms la mediana de sm/cc
Puntos de la FFT	4 096	Relleno con ceros: densifica la rejilla de frecuencia sin tocar la resolución temporal
Salto STFT	400 (9 ms)	Produce 331 tramas por ventana
Bandas mel	128	Lo que espera el extractor preentrenado; 256 no dio ganancia medible
Rango de frecuencia	25 Hz – 22 050 Hz	Un techo de 16 kHz truncaba la mitad de las cajas de sb/spc , cuya frecuencia superior media es 16 110 Hz

Las cajas se normalizan al formato de centro, ancho y alto en el intervalo $[0, 1]$, con el eje de frecuencia mapeado a través de la misma escala mel que produce la imagen. La consecuencia es que una caja significa lo mismo en el espacio de píxeles que sobre la pantalla del analista: el rectángulo que el modelo predice es directamente el rectángulo que Raven dibuja, sin reinterpretación. La Figura 4.16 muestra una ventana de entrenamiento tal como el modelo la recibe.




Figura 4.16: Una ventana de entrenamiento: espectrograma log-mel de 3 s con los parámetros de la Tabla 4.6 y las cajas objetivo superpuestas en el marco normalizado. Las once cajas **sb/spc** de este clip son el caso más denso observado en todo el conjunto.




Figura 4.17: Coordenadas de la caja.

4.4. Balance del conjunto de experimento

Las 25 clases seleccionadas cubren el 92,5 % del material curado, pero la selección no corrige las dos causas estructurales que este capítulo documentó, y conviene dejar dicho qué queda en pie antes de leer los resultados del Capítulo 5.

El desbalance no desaparece: se traslada. Entre *ac/bc*, la clase mayoritaria una vez descontada la fragmentación de *as/hc*, con 2 886 cajas de entrenamiento, y *sb/sc*, con 126, median más de veinte veces, y el orden de magnitud se mantiene aunque el umbral baje o suba (Figura 4.18). La partición sí preserva el balance: cada clase conserva aproximadamente la misma proporción en las tres particiones, que es lo que permite comparar el desempeño por clase entre validación y prueba sin atribuir a la arquitectura una diferencia de composición.




Figura 4.18: Cajas por clase y partición. El balance se preserva entre particiones; el desbalance entre clases se mantiene, con más de un orden de magnitud entre la clase mayoritaria y las que apenas superan el umbral.

La escasez y la arquitectura se confunden en el análisis por clase. Once de las veinticinco clases aportan menos de 300 cajas de entrenamiento. Cuando una

de ellas obtiene mal *recall*, la causa puede ser el modelo o puede ser que nunca vio material suficiente, y el Capítulo 5 solo puede separar ambas cosas comparando el comportamiento de las cuatro arquitecturas sobre la misma clase: una clase que todas fallan por igual es escasez; una que unas recuperan y otras no es arquitectura.

La densidad por ventana es baja. La mediana de cajas por ventana de 3 s es 1 y el máximo 11 (Figura 4.19). El presupuesto de predicciones simultáneas del decodificador se dimensiona sobre el máximo, no sobre la mediana, y las 64 consultas de la arquitectura propuesta lo cubren con holgura.




Figura 4.19: Cajas anotadas por ventana de 3 s: mediana 1, máximo 11.

4.5. Ficha del conjunto derivado (RE1.3)

La documentación del conjunto sigue la estructura de las *datasheets* para conjuntos de datos, que proponen registrar motivación, composición, proceso de recolección, transformaciones aplicadas y usos recomendados, con el propósito de aumentar la transparencia y la rendición de cuentas (Geburu et al., 2021). La ficha distingue de forma explícita dos capas de responsabilidad.

Conjunto primario. Las grabaciones y las anotaciones originales, producidas por el equipo de investigación. La ficha documenta su origen, el equipo de captura, la frecuencia de muestreo y el procedimiento de anotación en Raven, pero no reclama su autoría.

Conjunto derivado. El resultado de aplicar el protocolo de la sección 4.2: normalización de etiquetas, vocabulario cerrado, saneamiento geométrico, selección del subconjunto, partición por archivo de grabación y ventaneo. Esta capa sí es contribución de esta tesis, y la ficha registra cada transformación junto con lo que descarta.

La ficha declara además, como limitaciones conocidas del conjunto derivado:

- La fragmentación de las llamadas largas bajo el ventaneo de 3 s (Tabla 4.5): **as/hc** y **pt/dc** sobreviven como series de cajas recortadas al borde de la ventana, y el conjunto no incluye ningún mecanismo que las reagrupe en el evento original.
- Las tres clases de frase excluidas por anidamiento (sección 4.1.5), que dejan sin cubrir el nivel superior de la jerarquía vocal.
- Los once tipos de llamada en vocabulario que no alcanzan el umbral de 100 anotaciones (466 registros) y quedan fuera del experimento, entre ellos la única clase de CC, que hace que el conjunto de experimento cubra siete especies y no ocho.
- Los 16 pares fuera de vocabulario (328 registros) pendientes de revisión por el equipo de investigación.
- Las once clases con menos de 300 cajas de entrenamiento, cuyo desempeño individual no puede atribuirse limpiamente a la arquitectura.
- La heterogeneidad geométrica de **ac/bc**, **sm/fs** y **sb/ppc** (Figura 4.10), que sugiere etiquetas que agrupan variantes distintas de llamada.
- La ausencia de una medición de acuerdo entre anotadores, que impide separar el error del modelo del techo impuesto por la propia tarea.

Capítulo 5

Detección, Evaluación y Utilidad Operativa (OE2 y OE3)

5.1. Arquitectura propuesta y línea base (RE2.1)




Figura 5.1: Arquitectura propuesta.




Figura 5.2: Pirámide multiescala.

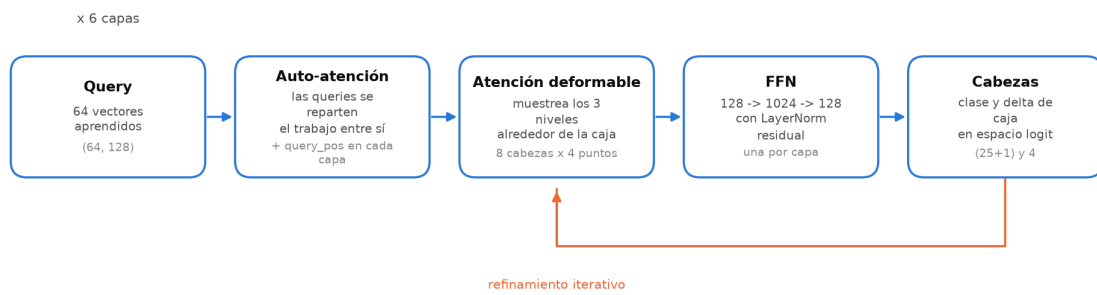


Figura 5.3: Capa del decodificador.




Figura 5.4: Muestreo deformable.

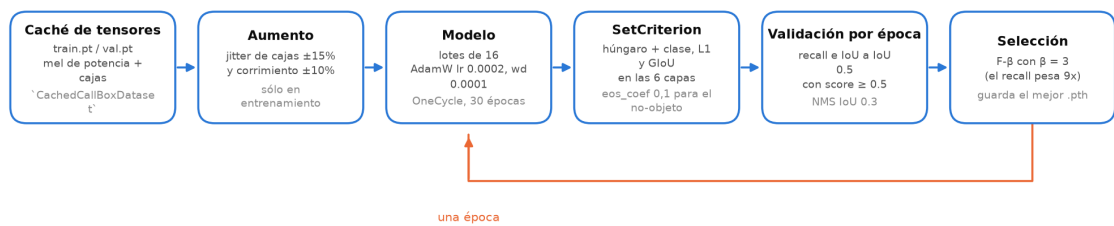


Figura 5.5: Pipeline de entrenamiento.




Figura 5.6: Emparejamiento húngaro.



Figura 5.7: Pipeline de inferencia.

5.2. Pipeline de entrenamiento e inferencia (RE2.2)

5.3. Protocolo de evaluación




Figura 5.8: Umbral de confianza.

5.4. Resultados (RE2.3)

Esta sección compara cuatro configuraciones entrenadas sobre el mismo conjunto derivado de 25 clases, con la misma partición y el mismo protocolo de evaluación. Las

cifras de validación sirvieron para elegir el *checkpoint*; las de prueba se reportan una sola vez, sobre el modelo ya elegido.

5.4.1. Configuraciones comparadas

La Tabla 5.1 resume qué se compara. Las cuatro configuraciones comparten datos y protocolo, pero no presupuesto de entrenamiento, y esa asimetría condiciona toda lectura posterior: la arquitectura propuesta ajusta 3,1 millones de parámetros sobre un extractor congelado, mientras que las dos líneas base ajustan todos los suyos partiendo de pesos de COCO.

Tabla 5.1: Configuraciones comparadas sobre el conjunto de 25 clases

Configuración	Extractor	Parám. totales	Parám. entren.	Selección del <i>checkpoint</i>
AST-Def-DETR <i>ts</i> 5 (propuesta)	AST/AudioSet congelado	88,7 M	3,1 M	F ₃ en validación (época 13 de 30)
AST-Def-DETR <i>ts</i> 10	AST/AudioSet congelado	88,7 M	3,1 M	F ₃ en validación (época 18 de 30)
Faster R-CNN R50-FPN v2	ResNet-50/COCO	43,4 M	43,2 M	F ₃ en validación (época 4 de 30)
YOLO26s	YOLO26s/COCO	10,0 M	10,0 M	Aptitud de Ultralytics, basada en mAP (época 18 de 48)

ts es el paso temporal del parcheado del AST: con *ts* = 5 la ventana de 3 s produce 12×64 tokens (47 ms por token) y con *ts* = 10, 12×32 (94 ms).

Del AST solo se entrena la proyección de parches; el resto queda congelado en los pesos de AudioSet. La normalización de energía por canal (PCEN) que lo precede sí es entrenable.

La última fila registra una **inconsistencia metodológica** de esta comparación: YOLO se entrena con la herramienta de Ultralytics, que elige su *checkpoint* con una aptitud basada en mAP y no con la F₃ declarada en la sección 1.6.1. La consecuencia se analiza más abajo.

5.4.2. Desempeño al punto de operación declarado

La Tabla 5.2 reporta las magnitudes del protocolo al punto de comparación común: confianza $\geq 0,5$ y emparejamiento a IoU $\geq 0,5$. Lo primero que conviene registrar es que **validación y prueba coinciden**: ninguna configuración se mueve más de 0,008 en *recall* ni más de 0,005 en F₃ entre una partición y otra, y la precisión, que es la magnitud más inestable, se mueve como máximo 0,022. La selección de *checkpoint* sobre

validación no se transfirió como optimismo a la prueba, y las diferencias entre modelos que siguen son mayores que esa dispersión.

Tabla 5.2: Resultados al punto de operación común (confianza $\geq 0,5$, IoU $\geq 0,5$)

Configuración	Part.	Recall	Prec.	F ₃	mAP50	mAP 50-95	FP/TP	Prop. por h
Faster R-CNN	val	0,770	0,500	0,731	0,474	0,205	1,00	3 952
	test	0,777	0,499	0,736	0,487	0,211	1,01	3 731
AST-Def-DETR <i>ts5</i>	val	0,694	0,532	0,674	0,362	0,136	0,88	3 345
	test	0,694	0,517	0,671	0,373	0,143	0,94	3 217
AST-Def-DETR <i>ts10</i>	val	0,677	0,521	0,657	0,357	0,138	0,92	3 329
	test	0,682	0,499	0,658	0,347	0,138	1,00	3 271
YOLO26s	val	0,533	0,819	0,552	0,531	0,263	0,22	1 669
	test	0,532	0,805	0,550	0,520	0,264	0,24	1 582

Recall y precisión son agnósticos a la clase, como fija la sección 1.6.1; mAP50 y mAP50-95 sí exigen la etiqueta correcta.

Las propuestas por hora se cuentan sobre ventanas de 3 s con salto de 1,5 s y *antes* de agregar entre ventanas, de modo que un evento en la zona de solapamiento se cuenta dos veces. Es una cota superior de la carga real, útil para comparar entre modelos.

Leída sin más, la tabla dice dos cosas incompatibles. Por *recall* y por F₃ —la métrica principal y el criterio de selección de esta tesis— el orden es Faster R-CNN, la propuesta con *ts5*, la propuesta con *ts10* y, último y por mucho, YOLO: 0,777 contra 0,532 son 6 207 eventos recuperados contra 4 246, es decir 1 961 de diferencia sobre los 7 985 anotados de la partición de prueba. Por mAP y por precisión el orden se invierte casi por completo: YOLO obtiene el mejor mAP50 (0,520) y casi duplica a la propuesta en mAP50-95 (0,264 contra 0,143), con una precisión de 0,805 que implica un cuarto de falso positivo por acierto donde Faster R-CNN paga uno entero.

La contradicción es aparente y su origen es metodológico: **el umbral fijo de 0,5 no compara arquitecturas, compara puntos distintos de curvas distintas**. El apartado siguiente lo separa.

5.4.3. Confianza calibrada y comparación a carga igual

La confianza que emite un detector no es una probabilidad comparable entre arquitecturas: depende de la función de pérdida, del número de propuestas que la cabeza produce y de cómo se normaliza la puntuación. Sobre la partición de prueba, YOLO

emite 29 174 detecciones por encima de 0,001 y solo 5 277 —el 18 %— sobreviven al umbral de 0,5; Faster R-CNN emite 176 423 y conserva 12 447, el 7 %. Fijar 0,5 para los dos no los sitúa en el mismo régimen de operación: sitúa a YOLO en la parte conservadora de su curva y a Faster R-CNN en la permisiva.

El techo de *recall* de cada modelo lo muestra sin ambigüedad. Bajando el umbral hasta 0,001, YOLO recupera 6 774 de los 7 985 eventos anotados (0,848), por encima de los 6 322 (0,792) de la propuesta con *ts5*. *YOLO no tiene un problema de cobertura: tiene un umbral mal elegido para esta tarea*. Su déficit de *recall* en la Tabla 5.2 no mide una limitación de la arquitectura sino la consecuencia de haber elegido su *checkpoint* y su punto de operación con un criterio —la aptitud basada en mAP de Ultralytics— que pondera precisión y cobertura de forma distinta a la F_3 declarada por esta tesis.

La comparación honesta, entonces, no fija el umbral sino la **carga**: se pregunta cuántos eventos recupera cada modelo cuando a todos se les permite proponer la misma cantidad de cajas por hora de audio. La Tabla 5.3 responde esa pregunta barriendo el umbral de cada configuración desde 0,001 hasta 1 sobre la partición de prueba.

Tabla 5.3: Cobertura (*recall* agnóstico a IoU 0,5) a igual número de propuestas por hora de audio

Propuestas por hora	Faster R-CNN	Def-DETR <i>ts5</i>	Def-DETR <i>ts10</i>	YOLO26s
1 582	0,508	0,481	0,472	0,532
2 000	0,595	0,561	0,552	0,628
3 000	0,728	0,680	0,666	0,758
3 731	0,777	0,719	0,703	0,795
5 000	0,817	0,749	0,736	0,821
7 500	0,845	0,773	0,762	0,843
10 000	0,855	0,782	0,772	0,848
Techo (sin umbral)	0,921	0,792	0,780	0,848
Carga en el techo	52 877	19 243	14 439	8 745

Cada columna es la curva de un modelo leída a la misma abscisa. Las cuatro se calculan sobre las mismas 8 007 ventanas (3,34 horas de audio) y con el mismo tope de 64 detecciones por ventana, de modo que ninguna consigue cola por poder emitir más cajas que las otras.

El techo es el *recall* con el umbral en 0,001, esto es, con todo lo que el modelo es capaz de proponer.

El resultado invierte por completo la lectura de la Tabla 5.2. **YOLO recupera más eventos que cualquier otra configuración en todo el rango de carga que**

un revisor humano podría absorber, hasta unas 5 000 propuestas por hora; por encima de esa cifra Faster R-CNN lo alcanza y termina superándolo, a costa de una carga que ya no es operativa. Para igualar el 0,777 de cobertura que Faster R-CNN entrega en su punto de operación, YOLO necesita 3 252 propuestas por hora contra las 3 727 de Faster R-CNN: la misma cobertura con un 13 % menos de material que revisar.

La arquitectura propuesta queda última en todo el rango. No es que rinda menos a un umbral desfavorable: rinde menos *a cualquier carga*, y su techo —0,792 con *ts5*— queda por debajo del que YOLO alcanza con menos de la mitad de propuestas. Los 1 663 eventos que la propuesta no recupera ni con el umbral en 0,001 son eventos para los que nunca emitió una caja con $\text{IoU} \geq 0,5$; el problema no está en la puntuación sino en la localización.

Conviene extraer de aquí la lección metodológica, porque condiciona todo el Capítulo y el protocolo de OE3: **un umbral compartido no es un punto de operación compartido**. La confianza de cada arquitectura vive en una escala propia, y comparar cuatro modelos en 0,5 mide dónde cae cada escala tanto como mide la calidad de cada modelo. La magnitud comparable es la curva de cobertura frente a carga, y las dos cifras que la resumen son la cobertura al presupuesto de revisión elegido y el techo. El umbral de 0,5 conserva un solo uso legítimo: ser el punto fijo con el que se comparan *checkpoints* de una *misma* configuración durante el entrenamiento.

5.4.4. Lectura por clase

El agregado de la Tabla 5.2 está dominado por dos clases. **as/hc** y **pt/dc** aportan el 33 % de las cajas de prueba y son, por la fragmentación que documenta la sección 4.3, las más fáciles del conjunto: sus cajas ocupan la ventana entera. Por eso la Tabla 5.4 reporta también el promedio por clase, que trata igual a **sb/sc** —37 cajas de prueba— que a **as/hc**.

El promedio por clase separa las configuraciones mucho más que el agregado: Faster R-CNN 0,645, la propuesta 0,509 y 0,505, YOLO 0,360. Y el orden se sostiene si en lugar de promediar se excluye **as/hc** del agregado: 0,705, 0,606, 0,591 y 0,409 respectivamente. La ventaja de Faster R-CNN no proviene de las clases fáciles.

Tres patrones se leen en la tabla.

Tabla 5.4: *Recall* por clase al punto de operación (prueba, confianza $\geq 0,5$)

Clase	Cajas train	Cajas test	Faster R-CNN	Def-DETR <i>ts5</i>	Def-DETR <i>ts10</i>	YOLO26s
as/hc	6933	2023	0,947	0,928	0,911	0,879
ac/bc	2886	842	0,652	0,654	0,646	0,589
lw/cs	2706	792	0,880	0,799	0,802	0,674
sm/cc	2359	688	0,719	0,625	0,580	0,249
as/bc	2233	651	0,702	0,548	0,485	0,313
pt/dc	1950	568	0,819	0,794	0,798	0,704
sb/ppc	1300	472	0,585	0,449	0,417	0,104
aa/gc	924	269	0,781	0,732	0,736	0,290
sb/spc	860	251	0,641	0,542	0,494	0,096
sm/fs	801	232	0,655	0,504	0,500	0,530
lw/trino	739	222	0,761	0,604	0,644	0,532
pt/sqc	465	138	0,841	0,536	0,616	0,036
sb/pcc	342	99	0,475	0,263	0,253	0,202
lw/ta	312	91	0,703	0,626	0,549	0,352
sm/hic	295	87	0,402	0,391	0,402	0,207
sm/pc	283	83	0,627	0,253	0,289	0,024
ac/chc	276	80	0,713	0,438	0,400	0,362
sm/sc	200	58	0,224	0,103	0,121	0,017
ac/gc	191	56	0,250	0,143	0,179	0,089
ac/sc	188	54	0,296	0,148	0,204	0,222
aa/sc	183	53	0,849	0,679	0,679	0,585
lw/sqc	182	54	0,667	0,463	0,444	0,500
aa/hm	148	44	0,773	0,750	0,727	0,750
lw/vc	140	41	0,780	0,366	0,488	0,488
sb/sc	126	37	0,378	0,378	0,270	0,216
Promedio por clase	27 022	7 985	0,645	0,509	0,505	0,360
Agregado (micro)			0,767	0,687	0,672	0,528

Este *recall* sí exige la etiqueta correcta, a diferencia del agregado agnóstico de la Tabla 5.2. La distancia entre ambos mide el costo de clasificar: 0,777 frente a 0,767 en Faster R-CNN, 0,694 frente a 0,687 en la propuesta. **Una vez que el evento se localiza, la etiqueta casi nunca se pierde**, y el cuello de botella de este sistema está en la detección y no en la clasificación.

En negrita, el mejor de las cuatro configuraciones en cada clase.

Las clases escasas fallan en todas las configuraciones. *sm/sc* (200 cajas de entrenamiento), *ac/gc* (191) y *ac/sc* (188) quedan por debajo de 0,30 incluso en el mejor modelo. Cuando las cuatro arquitecturas fallan por igual sobre una clase, la causa razonable es el material y no el diseño: son las clases que el umbral de 100 anotaciones dejó entrar y cuyo desempeño la sección 4.4 anticipó como no atribuible a la arquitectura.

La escasez no lo explica todo. *aa/sc* (183 cajas) alcanza 0,849 y *lw/vc* (140) llega a 0,780 con Faster R-CNN. Ambas ocupan bandas de frecuencia estrechas y bien separadas, lo que sugiere que la separabilidad geométrica de la sección 4.1.4 pesa más que el volumen de ejemplos. La comparación de *pt/sqc* lo hace evidente en la otra dirección: 0,841 en Faster R-CNN y 0,036 en YOLO sobre la misma clase de 465 cajas. Es la caja más pequeña del conjunto —mediana de 267 ms por 666 Hz, esto es $0,088 \times 0,038$ del marco normalizado— y la diferencia mide qué tan lejos llega cada arquitectura en objetos diminutos, no cuánto material vieron.

Los dos pasos temporales del AST se comportan casi igual. La diferencia entre *ts5* y *ts10* es de 0,012 en *recall* agregado y de 0,004 en promedio por clase, muy por debajo de lo que separa a cualquiera de las dos de las líneas base. Duplicar la resolución temporal del parcheado —de 94 a 47 ms por token, y con ella el costo de atención— no compra cobertura. El resultado es informativo: si el cuello de botella estuviera en la resolución temporal del extractor, *ts5* debería separarse de *ts10*, y no lo hace.

5.4.5. Qué establece esta comparación

Sobre el conjunto de 25 clases y con el presupuesto de entrenamiento descrito, la arquitectura propuesta **no supera a ninguna de las dos líneas base**. Al punto de operación declarado queda segunda, detrás de Faster R-CNN por 8 puntos de *recall* agregado y por 14 de promedio por clase; a carga igual (Tabla 5.3) queda última en todo el rango, y también es última en calidad de encuadre, con un mAP50-95 de 0,143 frente a 0,264 de YOLO. Registrarlo así es parte del resultado: la comparación se declaró antes de correrla, con su regla de decisión fijada, y el desenlace no la cambia.

El costo de inferencia refuerza la misma conclusión. Medido sobre las mismas 8007 ventanas de prueba y en la misma GPU (RTX 4060 Laptop, 8 GB), incluyendo preprocesamiento y supresión de no máximos, YOLO consume **0,17 minutos de GPU**

por hora de audio; la propuesta, 0,56 con *ts10* y 1,22 con *ts5*; Faster R-CNN, 2,38. YOLO procesa el conjunto de prueba unas 360 veces más rápido que en tiempo real y Faster R-CNN unas 25 veces: los cuatro son viables para PAM, pero separados por un factor de catorce entre extremos.

La configuración que este trabajo llevaría a producción es, con la evidencia disponible, **YOLO26s operado a un umbral mucho más bajo que su 0,5 de fábrica**: es la que más cobertura entrega por propuesta revisada en todo el régimen de carga plausible, la que mejor encuadra y la más barata en inferencia. También es la más barata de entrenar entre las que este trabajo cronometró: 3,7 horas de GPU para 48 épocas, frente a las 20 horas que Faster R-CNN consumió hasta la época 17 —de las cuales solo las cuatro primeras aportaron algo, porque su mejor *checkpoint* es el de la época 4 y a partir de la quinta el *recall* de validación cae mientras la precisión sube. Y lo consigue en su variante pequeña: **yolo26s** es el segundo modelo más chico de su familia, de modo que la comparación ni siquiera enfrenta a la propuesta con la mejor línea base disponible.

Tres factores acotan qué se puede concluir de esa derrota, y ninguno de los tres se resuelve con la evidencia disponible:

1. **El presupuesto de ajuste es un orden de magnitud menor.** La propuesta entrena 3,1 M de parámetros sobre un extractor congelado; Faster R-CNN ajusta 43,2 M y YOLO 10,0 M, ambos partiendo de COCO. La comparación mide, en rigor, “características de AudioSet congeladas más una cabeza pequeña” contra “detectores de imagen ajustados por completo”, no una arquitectura contra otra.
2. **El programa de entrenamiento es corto para un decodificador de tipo DETR.** El mejor *checkpoint* aparece en las épocas 13 y 18 de un programa de 30, mientras que la literatura de Deformable DETR trabaja con programas de 50 épocas sobre COCO y el DETR original con 500 (Zhu et al., 2021). El emparejamiento húngaro necesita muchas épocas para estabilizar la asignación consulta–objeto, y detenerse antes penaliza justamente el encuadre, que es donde la propuesta pierde por más.
3. **El extractor congelado puede no transferir.** El AST se preentrenó sobre AudioSet a 16 kHz con un parcheado de 10 ms, y aquí recibe un mel de 44,1 kHz con otra rejilla temporal y otra escala de frecuencia, con la incrustación posicional

interpolada. La ablación que separa “congelado” de “ajustado” está implementada y no medida, y es el experimento que decide si el problema es el extractor o la cabeza.

El punto es relevante porque el precedente directo de esta arquitectura reporta lo contrario. Zhu and Sato (2025) combinan un AST *autosupervisado* con un decodificador deformable y superan a un Faster R-CNN con *backbone* residual sobre un conjunto de silbidos de aspas de aerogenerador. Las dos diferencias entre aquella configuración y esta —extractor autosupervisado y ajustado frente a extractor supervisado y congelado, y un dominio de una sola clase de sonido frente a 25 clases con desbalance de dos órdenes de magnitud— son exactamente las que la ablación pendiente debe separar. Este trabajo no contradice ese precedente: muestra que no se traslada sin más a un repertorio de primates con el extractor congelado.

Lo que la comparación sí establece con la evidencia disponible es más útil que un ganador:

- **La tarea es viable con detectores de objetos sobre espectrogramas.** Dentro de un presupuesto de 3 700 propuestas por hora de audio, las cuatro configuraciones recuperan más de dos tercios de los eventos anotados de 25 clases a IoU 0,5, sobre un conjunto con más de un orden de magnitud de desbalance y un rango de duraciones de $2\,134\times$.
- **El cuello de botella es la detección, no la clasificación.** Distinguir 25 pares de especie y tipo de llamada cuesta alrededor de un punto de *recall* una vez que el evento fue localizado. La decisión de puntuar localización y etiquetado por separado (sección 1.6.1) queda respaldada por los datos.
- **La elección del punto de operación pesa más que la elección de arquitectura.** La sección 5.4.3 muestra que mover el umbral de un mismo modelo cambia su cobertura más que cambiar de arquitectura al umbral fijo, y que el orden entre modelos se invierte según dónde se los mida. Es la razón por la que OE3 elige el punto de operación barriendo el umbral y no heredando un 0,5.




Figura 5.9: Detecciones cualitativas.

- 5.5. Exportación a Raven (RE2.4)
- 5.6. Publicación del código y del modelo (RE2.5)
- 5.7. Protocolo de evaluación operativa (RE3.1)
- 5.8. Cobertura frente a carga de revisión (RE3.2)
- 5.9. Taxonomía de discrepancias (RE3.3)
- 5.10. Validación experta (RE3.4, condicional)




Figura 5.10: Matriz de confusión.




Figura 5.11: Distribución de IoU.




Figura 5.12: Ablación acumulada.




Figura 5.13: Línea de tiempo de detecciones.

La tabla de selección que abre el analista

primeras 10 de 36 detecciones de 20240219_103940.wav · columnas exactas de Raven más la de score, que ordena la revisión

Selection	View	Channel	Begin Time (s)	End Time (s)	Low Freq (Hz)	High Freq (Hz)	Species	Call type	Score
1	Spectrogram 1	1	0.252	0.604	849.9	2461.9	AC	BC	0.983
2	Spectrogram 1	1	1.591	2.274	294.3	4719.6	AC	BC	0.518
3	Spectrogram 1	1	6.479	6.760	177.1	18123.3	SB	SPC	0.948
4	Spectrogram 1	1	6.914	7.071	6213.7	9734.5	SB	PPC	0.556
5	Spectrogram 1	1	7.797	7.883	6329.8	11010.3	SB	PPC	0.966
6	Spectrogram 1	1	7.798	8.017	101.4	17137.2	SB	SPC	0.583
7	Spectrogram 1	1	8.455	8.600	38.2	17021.2	SB	SPC	0.673
8	Spectrogram 1	1	8.763	9.007	602.6	20983.5	SB	SPC	0.612
9	Spectrogram 1	1	9.010	9.362	5829.1	11412.6	SB	PCC	0.851
10	Spectrogram 1	1	9.011	9.136	6736.6	10595.5	SB	PPC	0.723

Figura 5.14: Previsualización de la tabla de Raven.

Apéndice A

Plan del Proyecto

A.1. Justificación y viabilidad

A.1.1. Justificación

La investigación es conveniente porque ataca directamente el cuello de botella descrito en el Capítulo 1: el análisis manual del audio recolectado. El monitoreo acústico pasivo con sensores de bajo costo permite recolectar a gran escala, pero ese potencial queda desaprovechado mientras el análisis siga siendo lento, costoso y laborioso. Un sistema de pre-anotación asistida hace que el monitoreo a gran escala resulte operativamente viable y permite que el tiempo experto se dedique a la interpretación ecológica en lugar de al procesamiento.

En el plano práctico, el proyecto reduce la infrautilización del material acústico acumulado y, con ella, la latencia entre la recolección y la generación de conocimiento. En el plano teórico, aborda dos vacíos confirmados de forma independiente por la revisión del Capítulo 3: la ausencia de modelos y de conjuntos de datos con anotación tiempo–frecuencia para primates neotropicales, y la falta de estrategias establecidas para el etiquetado jerárquico de especie y tipo de llamada sobre eventos detectados.

A.1.2. Beneficios esperados

- Reducir la carga de revisión por hora de audio analizada: menos material que inspeccionar para la misma cobertura de eventos.
- Poner en uso el audio ya grabado que hoy permanece sin anotar.
- Acortar la latencia entre la recolección y la obtención de resultados ecológicos.

- Disminuir el costo y el error humano asociados al análisis manual.
- Entregar una herramienta reutilizable, con código y pesos públicos, integrable al flujo de trabajo existente en Raven.

A.1.3. Viabilidad técnica

El proyecto no depende de ningún desarrollo previo inexistente. Las arquitecturas necesarias están disponibles y documentadas (He et al., 2016; Kahl et al., 2021; Nolasco et al., 2023); las herramientas son software libre de uso extendido (Tabla 1.11); los recursos de cómputo se cubren con acceso a GPU en la nube; los datos iniciales, aproximadamente 10 GB de grabaciones WAV capturadas con AudioMoth, con sus anotaciones de Raven, ya están entregados; y la metodología de trabajo (CRISP-DM) está establecida y es la que estructura el documento.

A.1.4. Viabilidad temporal

El cronograma es factible dentro del calendario académico, con dos puntos de tensión identificados. El primero es OE1: la curación y estandarización del conjunto es meticulosa y cualquier retraso ahí se propaga a todo lo que sigue. El segundo es OE2, que consume tiempo tanto de cómputo como de análisis humano en la experimentación. Juega a favor que no haya recolección de datos en campo: el material de partida ya existe.

A.1.5. Viabilidad económica

El grueso del software es de código abierto y sin costo. Los sensores ya están desplegados y su costo no recae sobre este proyecto. El desembolso real se concentra en cómputo en la nube y en servicios de almacenamiento; el resto del presupuesto es una valorización del tiempo dedicado, no un pago efectivo.

A.2. Definición y alcance del proyecto

A.2.1. Alcance

El proyecto desarrolla y evalúa un sistema de pre-anotación asistida que produce cajas tiempo–frecuencia etiquetadas sobre grabaciones de monitoreo acústico pasivo, para las ocho especies de la Tabla 2.2. El sistema debe cumplir tres tareas: localizar el evento en

tiempo y frecuencia, identificar la especie y clasificar el tipo de vocalización. Una parte central del alcance es la caracterización cuantitativa de su comportamiento operativo: la cobertura que alcanza sobre un conjunto de prueba independiente, la carga de revisión asociada y la naturaleza de sus discrepancias. Queda fuera del alcance la medición cronometrada del tiempo de un revisor experto, que depende de la disponibilidad del equipo de investigación y se declara como resultado condicional. El proyecto recorre el ciclo completo de CRISP-DM, desde la preparación de los datos hasta el procesamiento de grabaciones nuevas.

A.2.2. Entregables y criterios de aceptación

Los entregables son los resultados esperados enumerados en la sección 1.4. La Tabla A.1 recoge el criterio de aceptación de cada uno: la condición verificable que permite declararlo terminado.

A.2.3. Exclusiones

- No se desarrolla un sistema de monitoreo en tiempo real desplegable en campo; el alcance es el procesamiento de grabaciones existentes.
- El análisis detallado de sonidos antropogénicos queda fuera del foco primario, más allá de su detección y categorización general.
- El estudio se limita a las ocho especies declaradas.
- No se desarrolla hardware de adquisición.
- No se realiza nueva recolección de datos en campo.

A.2.4. Limitaciones y restricciones

Limitaciones. La ausencia de conjuntos etiquetados a gran escala para primates neotropicales obliga a invertir un esfuerzo considerable en OE1, y la calidad de las anotaciones manuales recibidas es subjetiva y variable. El entorno acústico amazónico es denso y presenta con frecuencia baja relación señal-ruido. La variabilidad intraespecífica de las vocalizaciones y su naturaleza graduada dificultan definir categorías discretas, y las llamadas superpuestas o de baja intensidad son especialmente difíciles de modelar. Los sensores de bajo costo añaden variabilidad entre dispositivos. Por último, sin revisión experta las predicciones de alta confianza situadas en regiones sin anotación (tipo D

Tabla A.1: Criterios de aceptación

Entreg.	Criterio de aceptación
RE1.1	El protocolo define reglas de sintaxis para las etiquetas de especie y tipo de llamada, y especifica el tratamiento de errores, duplicados e inconsistencias de las anotaciones originales.
RE1.2	Todas las anotaciones del conjunto final cumplen las reglas de RE1.1, y se entrega un manifiesto con la asignación de cada archivo de grabación a una partición.
RE1.3	La ficha describe la estructura de directorios, incluye un diccionario de datos por columna y declara transformaciones, sesgos y limitaciones conocidas.
RE2.1	El documento justifica la arquitectura propuesta y la línea base a partir del estado del arte, y fija la configuración e hiperparámetros iniciales de ambas.
RE2.2	El <i>pipeline</i> ejecuta el ciclo completo de entrenamiento, evaluación e inferencia, e incluye instrucciones de instalación y ejecución.
RE2.3	El informe presenta las métricas de los tres ejes para la propuesta y la línea base, discute los resultados y concluye con una recomendación justificada.
RE2.4	Los pesos del modelo se cargan sin error y un script de demostración produce predicciones en el formato de tabla de selección de Raven sobre un clip de prueba.
RE2.5	El repositorio público contiene el código del <i>pipeline</i> , los pesos del modelo final y las instrucciones para reproducir la inferencia.
RE3.1	El protocolo, fechado antes de la evaluación, especifica el material de prueba, el criterio de elección del punto de operación, el umbral de IoU que define un verdadero positivo, la agregación por archivo y las cuatro categorías de discrepancia.
RE3.2	Se reporta la curva de cobertura frente a propuestas por hora de audio, el punto de operación elegido con su criterio, el cociente FP/TP, la fracción de audio sin propuestas y el costo de inferencia por hora de audio.
RE3.3	El informe distribuye la muestra de predicciones de alta confianza entre las cuatro categorías, caracteriza la categoría D por banda, duración y puntuación frente a los eventos anotados, e incluye ejemplos sobre el espectrograma.
RE3.4	<i>Condicional.</i> Si el equipo de investigación está disponible, se resuelve una muestra de categoría D entre evento omitido y falso positivo genuino y se estima el acuerdo con el criterio experto; si no, la limitación queda declarada.

de la Tabla 1.7) no pueden clasificarse de forma concluyente entre eventos omitidos por la referencia y falsos positivos genuinos: esta tesis las caracteriza geométricamente y las reporta como una cantidad acotada, y deja su resolución como trabajo futuro condicionado a la disponibilidad del equipo de investigación.

Restricciones. El desarrollo está sujeto al calendario académico. El proyecto depende del conjunto de datos entregado y de la verificación de su calidad. El acceso a GPU limita la escala de la experimentación, en particular la búsqueda exhaustiva de hiperparámetros. El desarrollo, la implementación y la evaluación recaen sobre el autor, con la supervisión del asesor.

A.3. Planificación del proyecto

A.3.1. Estructura de desglose del trabajo

La estructura de desglose se organiza según las fases de CRISP-DM y los objetivos específicos. La Tabla A.2 resume los paquetes de trabajo y el entregable asociado a cada uno.



Figura A.1: EDT en árbol.

Tabla A.2: EDT del proyecto

ID	Paquete	Contenido	Entregable
1	Gestión del proyecto	Planificación, seguimiento, comunicación con el asesor, gestión de riesgos y de la calidad, cierre	N/A
2	Comprensión de la investigación	Objetivos, formulación del problema de detección y criterios de éxito	N/A
3	Comprensión de los datos	Acceso al corpus, descripción del formato, análisis exploratorio y verificación de calidad	N/A
4.1	Limpieza y estandarización	Corrección de etiquetas, tratamiento de audios dañados	RE1.1
4.2	Curación del conjunto	Aplicación del protocolo, vocabulario cerrado, partición por grabación	RE1.2
4.3	Ingeniería de características	Preprocesamiento, representación tiempo–frecuencia, ventaneo, aumento de datos	N/A
4.4	Documentación del conjunto	Ficha del conjunto derivado	RE1.3
5.1	Diseño del detector	Arquitectura propuesta y línea base, con justificación	RE2.1
5.2	Implementación	<i>Pipeline</i> de entrenamiento, evaluación e inferencia	RE2.2
5.3	Publicación del código	Repositorio con código y pesos	RE2.5
6.1	Evaluación cuantitativa	Métricas por eje, comparación con la línea base, análisis de errores	RE2.3
6.2	Selección del modelo final	Modelo elegido y exportador a tabla de selección de Raven	RE2.4
6.3	Protocolo de evaluación operativa	Material, criterio de elección del punto de operación, emparejamiento y taxonomía	RE3.1
6.4	Curva de cobertura y carga	Barrido de umbral, elección del punto de operación y métricas de carga e inferencia	RE3.2
6.5	Análisis de discrepancias	Clasificación geométrica de las predicciones de alta confianza y caracterización de la categoría D	RE3.3
6.6	Validación experta (condicional)	Revisión de una muestra de categoría D con el equipo de investigación	RE3.4
7	Despliegue	Inferencia por lotes sobre grabaciones no vistas y generación de tablas de anotación	N/A
8	Documentación y difusión	Redacción de la tesis y preparación de la defensa	N/A

A.3.2. Cronograma

El cronograma se ajusta al calendario académico y se organiza en bloques que respetan las dependencias entre paquetes: la preparación de datos precede al modelado, el modelado precede a la evaluación, y el barrido de umbral que produce la curva de cobertura frente a carga precede al análisis de discrepancias, porque este se realiza sobre las predicciones del modelo ya seleccionado en el punto de operación ya elegido. El paquete condicional de validación experta se planifica al final y fuera de la ruta crítica.

A.3.3. Estimación de costos

Los costos se presentan en dólares estadounidenses y distinguen desembolso real de valorización. Las Tablas A.3 a A.6 detallan cada categoría, y la Tabla A.7 las consolida.

Tabla A.3: Costos de equipos y hardware

Categoría	Descripción	USD
Almacenamiento externo	SSD de 512 GB para el conjunto de datos y sus derivados	150,00
Equipo de desarrollo	Laptop con GPU dedicada ^a	1 500,00
Cómputo en la nube	Instancia con GPU de 48 GiB de memoria, estimada por horas de uso	600,00
Subtotal		2 250,00

^a Equipo preexistente propiedad del tesista. No representa un desembolso del proyecto, pero sí un recurso valorizado.

Tabla A.4: Valorización del capital intelectual

Recurso	Horas	USD/h	Total USD
Tesista ^a	600	5,00	2 500,00
Asesor de tesis ^b	40	25,00	1 000,00
Subtotal			3 500,00

^a Valorización del tiempo dedicado; no implica un pago real.

^b Cubierto por la institución.

A.3.4. Lista de recursos

Personas. El tesista, responsable del desarrollo, la implementación y el análisis; y el asesor, que aporta guía, supervisión y validación experta.

Tabla A.5: Costos de software, licencias y servicios en la nube

Software o servicio	Licencia	Meses	USD/mes	Total USD
Python, uv, Pandas, NumPy	Código abierto	12	0,00	0,00
PyTorch, torchaudio, Transformers	Código abierto	12	0,00	0,00
Visual Studio Code	Código abierto	12	0,00	0,00
Zotero	Gratuito	12	0,00	0,00
Raven Lite	Licencia de estudiante	12	0,00	0,00
Entorno de cómputo con GPU	Suscripción	12	9,99	119,88
Almacenamiento en la nube	Suscripción	12	1,67	20,00
Subtotal				139,88

Tabla A.6: Costos indirectos

Categoría	Descripción	Meses	Total USD
Internet	Conexión para investigación y acceso a la nube	12	480,00
Electricidad	Consumo del equipo y periféricos	12	360,00
Impresiones y otros	Materiales de estudio e impresiones	12	120,00
Subtotal			960,00

Tabla A.7: Resumen de costos

Categoría	Total USD
Equipamiento (hardware)	2 250,00
Recursos humanos (valorización)	3 500,00
Software y servicios	139,88
Costos indirectos	960,00
Total	6 849,88

Equipamiento. Equipo de desarrollo con GPU dedicada, almacenamiento externo para el conjunto de datos y sus derivados, y acceso a servidores con GPU para el entrenamiento.

Herramientas. Las de la Tabla 1.11, más el acceso a Raven para la validación cualitativa de las predicciones.

A.3.5. Gestión de riesgos

La Tabla A.8 recoge los riesgos identificados con su probabilidad, impacto, severidad y las acciones previstas.

Tabla A.8: Riesgos del proyecto, mitigación y contingencia

Riesgo	Prob.	Sever.	Mitigación	Contingencia
R1. Calidad de los datos: anotaciones inconsistentes y audios dañados	Baja	Media	Validación cruzada de una muestra con el asesor; detección automática de archivos corruptos o vacíos	Excluir el material bajo umbral mínimo de calidad y documentar la inconsistencia como limitación
R2. Recursos de cómputo insuficientes	Baja	Media	Espectrogramas precalculados; <i>pipeline</i> de datos optimizado; planificación de las corridas largas	Reducir la complejidad de las configuraciones menos prometedoras; acotar la búsqueda de hiperparámetros; parada temprana
R3. Baja disponibilidad de revisores expertos para la validación	Media	Baja	Ningún resultado comprometido de OE3 depende de un revisor externo; la validación experta se declara como RE3.4 condicional y fuera de la ruta crítica	Cerrar OE3 con la caracterización geométrica de la categoría D y declarar la limitación de forma explícita
R4. Falla del equipo de desarrollo	Alta	Media	Código, datos y documentos sincronizados en repositorio remoto; entorno replicable por archivo de configuración	Reinstalar el sistema, clonar el repositorio y recrear el entorno desde su especificación
R5. Incompatibilidad del entorno de ejecución	Media	Media	Requerimientos explícitos y versionados; contenedor de ejecución; versiones estables de las bibliotecas clave	Proveer un entorno preconfigurado listo para ejecutar; migrar a versiones compatibles
R6. Aumento del costo de cómputo en la nube	Baja	Baja	Desarrollo y depuración en recursos locales o gratuitos; uso eficiente de la GPU; priorización de experimentos	Reducir el alcance de la experimentación; solicitar créditos académicos; usar recursos de la universidad
R7. Retrasos por disponibilidad limitada del tesista	Alta	Alta	Cronograma con holgura basado en la EDT; bloques de tiempo protegidos; seguimiento semanal del avance	Replanificar al detectar la desviación; negociar reducción de alcance con el asesor; priorizar la ruta crítica

Bibliografía

- Airale, L., Pajot, A., and Linossier, J. (2025). NBM: an open dataset for the acoustic monitoring of nocturnal migratory birds in europe.
- Blumstein, D. T., Mennill, D. J., Clemins, P., Girod, L., Yao, K., Patricelli, G., Deppe, J. L., Krakauer, A. H., Clark, C., Cortopassi, K. A., Hanser, S. F., McCowan, B., Ali, A. M., and Kirschel, A. N. G. (2011). Acoustic monitoring in terrestrial environments using microphone arrays: applications, technological considerations and prospectus. *Journal of Applied Ecology*, 48(3):758–767.
- Bonet-Solá, D. and Alsina-Pagès, R. M. (2021). A comparative survey of feature extraction and machine learning methods in diverse acoustic environments. *Sensors*, 21(4):1274.
- Campos, R., Krofel, M., Rio-Maior, H., and Renna, F. (2025). Howlish: a cnn for automated wolf howl detection. *Remote Sensing in Ecology and Conservation*.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., and Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- Ebbers, J., Germain, F. G., Wichern, G., and Roux, J. L. (2024). Sound event bounding boxes.
- Escobar-Amado, C., Badiey, M., and Wan, L. (2024). Computer vision for bioacoustics: Detection of bearded seal vocalizations in the chukchi shelf using YOLOV5. *IEEE Journal of Oceanic Engineering*, 49(1):133–144.
- Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daume III, H., and Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12):86–92.
- Gibb, R., Browning, E., Glover-Kapfer, P., and Jones, K. E. (2018). Emerging opportunities and challenges in passive acoustic monitoring. *Methods in Ecology and Evolution*, 9(5):1191–1201.
- González, S. S., Quiros, S. B., and Toledano, D. T. (2025). YOLO-based transfer learning for sound event detection using visual object detection techniques. *Applied Sciences*, 16(1).
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778.

- He, Y., Trigoni, N., and Markham, A. (2021). SoundDet: Polyphonic moving sound event detection and localization from raw waveform.
- Heinicke, S., Kalan, A. K., Wagner, O. J., Mundry, R., Lukashevich, H., and Kuhl, H. S. (2015). Assessing the performance of a semi-automated acoustic monitoring system for primates. *Methods in Ecology and Evolution*, 6(7):753–763.
- Jin, C., Kim, M., Jang, S., and Paeng, D.-G. (2022). Semantic segmentation-based whistle extraction of indo-pacific bottlenose dolphin residing at the coast of jeju island. *Ecological Indicators*, 137:108792.
- Kahl, S., Wood, C. M., Eibl, M., and Klinck, H. (2021). BirdNET: A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 61:101236.
- Kath, H., Serafini, P. P., Campos, I. B., Gouvêa, T. S., and Sonntag, D. (2024). Leveraging transfer learning and active learning for data annotation in passive acoustic monitoring of wildlife. *Ecological Informatics*, 82:102710.
- Kershenbaum, A., Blumstein, D. T., Roch, M. A., Akçay, Ç., Backus, G., Bee, M. A., Bohn, K., Cao, Y., Carter, G., Cašar, C., Coen, M., DeRuiter, S. L., Doyle, L., Edelman, S., Ferrer-i Cancho, R., Freeberg, T. M., Garland, E. C., Gustison, M., Harley, H. E., Huetz, C., Hughes, M., Hyland Bruno, J., Ilany, A., Jin, D. Z., Johnson, M., Ju, C., Karnowski, J., Lohr, B., Manser, M. B., McCowan, B., Mercado III, E., Narins, P. M., Piel, A., Rice, M., Salmi, R., Sasahara, K., Sayigh, L., Shiu, Y., Taylor, C., Vallejo, E. E., Waller, S., and Zamora-Gutiérrez, V. (2016). Acoustic sequences in non-human animals: a tutorial review and prospectus. *Biological Reviews*, 91(1):13–52.
- Koga, N., Bando, Y., and Imoto, K. (2024). LEAD dataset: How can labels for sound event detection vary depending on annotators? In *2024 Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*, pages 1–6. ISSN: 2640-0103.
- Leroy, E. C., Thomisch, K., Royer, J.-Y., Boebel, O., and Van Opzeeland, I. (2018). On the reliability of acoustic annotations and automatic detections of Antarctic blue whale calls under different acoustic conditions. *The Journal of the Acoustical Society of America*, 144(2):740–754.
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., and Zitnick, C. L. (2014). Microsoft coco: Common objects in context. In *Computer Vision – ECCV 2014*, pages 740–755.
- Lostanlen, V., Salamon, J., Farnsworth, A., Kelling, S., and Bello, J. P. (2019). Robust sound event detection in bioacoustic sensor networks. *PLOS ONE*, 14(10):e0214168.
- Meedeniya, D., Ariyaratne, I., Bandara, M., Jayasundara, R., and Perera, C. (2023). A survey on deep learning based forest environment sound classification at the edge. *ACM Computing Surveys*, 56(3):1–36.
- Nam, H., Kim, S.-H., Ko, B.-Y., and Park, Y.-H. (2022). Frequency dynamic convolution: Frequency-adaptive pattern recognition for sound event detection. pages 2763–2767.

- Nguyen Hong Duc, P., Torterotot, M., Samaran, F., White, P. R., Gérard, O., Adam, O., and Cazau, D. (2021). Assessing inter-annotator agreement from collaborative annotation campaign in marine bioacoustics. *Ecological Informatics*, 61:101185.
- Nolasco, I., Singh, S., Morfi, V., Lostanlen, V., Strandburg-Peshkin, A., Vidaña-Vila, E., Gill, L., Pamuła, H., Whitehead, H., Kiskin, I., Jensen, F. H., Morford, J., Emmerson, M. G., Versace, E., Grout, E., Liu, H., Ghani, B., and Stowell, D. (2023). Learning to detect an animal sound from five examples. *Ecological Informatics*, 77:102258.
- Pham, P., Li, J., Szurley, J., and Das, S. (2018). Eventness: Object detection on spectrograms for temporal localization of audio events.
- Politis, A., Adavanne, S., and Virtanen, T. (2020). A dataset of reverberant spatial sound scenes with moving sources for sound event localization and detection. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events 2020 Workshop (DCASE2020)*, pages 165–169.
- Stowell, D. (2022). Computational bioacoustics with deep learning: a review and roadmap. *PeerJ*, 10:e13152.
- Vellinga, W.-P. (2026). Xeno-canto - bird sounds from around the world.
- Venkatesh, S., Moffat, D., and Miranda, E. R. (2022). You only hear once: A YOLO-like algorithm for audio segmentation and sound event detection. *Applied Sciences*, 12(7):3293.
- Veselý, A. (2008). Problem tree: A problem structuring heuristic. *Central European Journal of Public Policy*, 2(2):68–80.
- Wood, L., Anderson, K., Gerstoft, P., Bell, R., Subbaraman, R., and Bharadia, D. (2022). Deep learning object detection approaches to signal identification.
- Zhu, X., Su, W., Lu, L., Li, B., Wang, X., and Dai, J. (2021). Deformable DETR: Deformable transformers for end-to-end object detection. In *International Conference on Learning Representations (ICLR)*.
- Zhu, Z. and Sato, Y. (2025). Sound event detection using time-frequency bounding boxes with a self-supervised audio spectrogram transformer. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events 2025 Workshop (DCASE2025)*, Barcelona, Spain.