

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS E INGENIERÍA



**Detección de vocalizaciones de primates
neotropicales mediante cajas tiempo–frecuencia
para la pre-anotación asistida de grabaciones
de monitoreo acústico pasivo**

Tesis para obtener el título profesional de
Ingeniero Informático que presenta:

Fernando Nelson Candia Aroni

Asesor:

Dr. Edwin Rafael Villanueva Talavera

Lima, 2026

Índice general

1. Generalidades	2
1.1. Problemática	2
1.1.1. Recolección de datos acelerada	2
1.1.2. Análisis lento e inconsistente	3
1.1.3. Investigaciones anteriores	4
1.1.4. Vacío y contribución	5
1.2. Árbol de problemas	7
1.2.1. Condiciones subyacentes	8
1.2.2. Problema central	8
1.2.3. Causas	9
1.2.4. Efectos	10
1.3. Objetivos	12
1.3.1. Objetivo general	12
1.3.2. Objetivos específicos	13
1.4. Resultados esperados	13
1.4.1. OE1: Protocolo y conjunto de datos curado	13
1.4.2. OE2: Detector y evaluación	16
1.4.3. OE3: Tiempo de revisión y análisis de errores	17
1.5. Trazabilidad	19
1.6. Métodos y procedimientos	19
1.6.1. Metodología CRISP-DM	19
1.6.2. Herramientas	25
1.6.3. Procedimientos y reproducibilidad	26
2. Marco Referencial	28
2.1. Marco Teórico	28
2.1.1. Formulación del problema de detección	28
2.1.2. El espectrograma y la asimetría de sus ejes	31
2.1.3. Detección de objetos sobre audio	31
2.2. Marco Conceptual	33
2.2.1. Paisaje sonoro	33
2.2.2. Eventos acústicos	34
2.2.3. Representaciones tiempo–frecuencia	35

2.2.4.	Detección de eventos sonoros	37
2.2.5.	Clasificación jerárquica	39
2.2.6.	Anotaciones inconsistentes	41
3.	Estado del Arte	43
3.1.	Metodología de la revisión	43
3.1.1.	Objetivos y preguntas de revisión	43
3.1.2.	Estrategia de búsqueda	44
3.1.3.	Criterios de inclusión y exclusión	44
3.2.	Resultados de la revisión	45
3.2.1.	P1: Estrategias de detección tiempo–frecuencia	45
3.2.2.	P2: Clasificación jerárquica fina	46
3.2.3.	P3: Mitigación de ruido y variabilidad entre sensores	47
3.2.4.	P4: Conjuntos de datos y aumento de datos	47
3.2.5.	P5: Transferencia de aprendizaje	48
4.	Curación del Conjunto de Datos (OE1)	50
4.1.	Introducción	50
4.2.	El material recibido	51
4.2.1.	Estructura y formato	51
4.2.2.	Inventario	53
4.2.3.	Defectos detectados	53
4.3.	Protocolo de curación y estandarización documentado (RE1.1)	55
4.3.1.	Esquema del protocolo	55
4.3.2.	Reglas	55
4.3.3.	Verificación de RE1.1	60
4.3.4.	Fuera de alcance	62
4.4.	Conjunto acústico curado y particionado (RE1.2)	62
4.4.1.	Selección de clases	62
4.4.2.	Partición por grabación	66
4.4.3.	Ventaneo	67
4.4.4.	Representación de entrada	71
4.4.5.	Entregables y verificación	74
4.5.	Ficha del conjunto derivado (RE1.3)	77
4.5.1.	Propósito y autoría	77
4.5.2.	Composición	78
4.5.3.	Geometría de los eventos	79
4.5.4.	Recolección (capa primaria)	79
4.5.5.	Transformaciones (capa derivada)	81
4.5.6.	Diccionario de datos	82
4.5.7.	Usos	84
4.5.8.	Versión del conjunto	85
4.5.9.	Limitaciones	86

4.5.10. Verificación de RE1.3	87
4.6. Discusión	88
5. Detección y Evaluación del Modelo (OE2)	90
5.1. Introducción	90
5.2. Diseño experimental, arquitectura propuesta y líneas base (RE2.1) . . .	91
5.2.1. La tarea	91
5.2.2. Arquitectura propuesta: AST-Deformable-DETR	91
5.2.3. Líneas base	97
5.2.4. Diseño experimental	99
5.2.5. Verificación de RE2.1	103
5.3. Pipeline reproducible de entrenamiento, evaluación e inferencia (RE2.2)	104
5.3.1. Dependencias declaradas	104
5.3.2. Las cuatro etapas y su interfaz	105
5.3.3. Artefactos de una corrida y autonomía del <i>checkpoint</i>	107
5.3.4. Costo de las corridas	107
5.3.5. Reproducibilidad	108
5.3.6. Verificación de RE2.2	109
5.4. Informe comparativo de resultados (RE2.3)	109
5.4.1. Lo que se compara	110
5.4.2. Desempeño al punto de operación	111
5.4.3. Detección, encuadre y clasificación	112
5.4.4. Cobertura frente a carga de revisión	113
5.4.5. Lectura por clase	116
5.4.6. Ejemplos cualitativos	117
5.4.7. Selección del modelo y qué establece la comparación	118
5.4.8. Costo de inferencia	120
5.4.9. Verificación de RE2.3	120
5.5. Modelo final cargable y demostración funcional (RE2.4)	120
5.5.1. El modelo final	121
5.5.2. Formato de salida	122
5.5.3. Demostración	122
5.5.4. Verificación de RE2.4	125
5.6. Código y modelo disponibles en un repositorio (RE2.5)	125
5.6.1. Estructura	125
5.6.2. Qué contiene y qué no	127
5.6.3. Verificación de RE2.5	127
5.7. Discusión	127
6. Tiempo de Revisión y Análisis de Errores (OE3)	132
6.1. Introducción	132
6.2. Metodología de validación comparativa (RE3.1)	133
6.3. Medición comparativa del tiempo de revisión (RE3.2)	133

6.4. Análisis cualitativo de errores y hallazgos (RE3.3)	133
6.5. Discusión	133
7. Conclusiones	134
7.1. Implicaciones de los resultados	134
7.2. Cumplimiento de los resultados esperados	135
7.3. Cumplimiento de los objetivos específicos	135
7.4. Cumplimiento del objetivo general	136
7.5. La propuesta frente al problema central	136
7.6. Trabajo futuro	136
A. Plan del Proyecto	138
A.1. Justificación y viabilidad	138
A.1.1. Justificación	138
A.1.2. Beneficios esperados	138
A.1.3. Viabilidad técnica	139
A.1.4. Viabilidad temporal	139
A.1.5. Viabilidad económica	139
A.2. Definición y alcance del proyecto	139
A.2.1. Alcance	139
A.2.2. Entregables y criterios de aceptación	140
A.2.3. Exclusiones	140
A.2.4. Limitaciones y restricciones	140
A.3. Planificación del proyecto	142
A.3.1. Estructura de desglose del trabajo	142
A.3.2. Cronograma	142
A.3.3. Estimación de costos	144
A.3.4. Lista de recursos	144
A.3.5. Gestión de riesgos	146

Índice de figuras

1.1. Anotación tiempo–frecuencia en Raven	3
1.2. Tres formas de salida	5
1.3. Árbol de problemas y condiciones subyacentes	7
1.4. CRISP-DM aplicado a este proyecto	20
1.5. Criterio de IoU	23
2.1. Segmentación tiempo–frecuencia	29
2.2. Cadena de la señal	33
2.3. Compromiso de la STFT	35
2.4. Escala mel	36
2.5. Los tres <i>front-ends</i> sobre la misma ventana	36
4.1. Tabla de selección de Raven	51
4.2. Anotación en Raven Pro	52
4.3. Valores en la columna de especie	53
4.4. Valores en la columna de tipo de llamada	53
4.5. Avisos de audio dañado	54
4.6. Corrupción leve	54
4.7. Corrupción severa	54
4.8. Reglas del protocolo	56
4.9. De las anotaciones curadas al caché	63
4.10. Anotaciones por par	64
4.11. Anidamiento frase–sílabas	66
4.12. Reparto goloso por grabación	67
4.13. Cajas por clase y partición	69
4.14. Asignación de eventos a ventanas	70
4.15. Cajas anotadas por ventana	71
4.16. Normalización de una caja	73
4.17. La ventana más densa	73
4.18. Llamada larga, cortada en ambos bordes	73
4.19. Ventana vacía	74
4.20. Capas del conjunto	77
4.21. Galería de llamadas	83
4.22. Duración frente a ancho de banda	84

4.23. Etiquetas con dos formas	85
4.24. Distribución temporal	85
5.1. Arquitectura propuesta	92
5.2. Pirámide multiescala	93
5.3. Duración de las clases frente a la pirámide	94
5.4. Una capa del decodificador	95
5.5. Muestreo deformable de una cabeza sobre un nivel	95
5.6. Emparejamiento húngaro	96
5.7. Líneas base	99
5.8. Protocolo de comparación	102
5.9. Pipeline del proyecto	105
5.10. Una época del entrenador	107
5.11. Curvas de entrenamiento	109
5.12. Distribución del IoU	113
5.13. Matriz de confusión	114
5.14. Cobertura frente a carga	114
5.15. Ejemplos cualitativos	118
5.16. Flujo de inferencia	123
5.17. Demostración sobre una grabación	124
5.18. La tabla generada abierta en Raven	124
5.19. Árbol del repositorio	126
A.1. EDT en árbol	144

Índice de tablas

1.1. Material recibido por especie	3
1.2. Vacío del problema	6
1.3. Disponibilidad en Xeno-canto	6
1.4. IOV de OE1	14
1.5. IOV de OE2	15
1.6. IOV de OE3	17
1.7. Taxonomía de discrepancias	19
1.8. Trazabilidad del planteamiento	20
1.9. Métricas de evaluación	24
1.10. Stack técnico: pipeline	25
1.11. Stack técnico: desarrollo	26
2.1. Arquitecturas frente a requisitos	38
2.2. Especies consideradas	39
2.3. Repertorio por especie	40
3.1. Cadenas de búsqueda	44
3.2. Criterios de inclusión y exclusión	45
4.1. Especies del corpus	51
4.2. Columnas de las tablas crudas	52
4.3. Mapa de sinónimos	57
4.4. Vocabulario cerrado	58
4.5. Pares marcados para revisión	59
4.6. Filas que toca cada regla	61
4.7. Valores distintos tras cada etapa	61
4.8. Pares excluidos del experimento	65
4.9. Composición de las particiones	68
4.10. Las 25 clases del experimento	68
4.11. Efecto del ventaneo en las clases largas	70
4.12. Parámetros del espectrograma	72
4.13. Contenido del caché	74
4.14. Composición por especie	78
4.15. Duración y banda por clase	80
4.16. Transformaciones aplicadas	81

4.17. Columnas de las tablas curadas	82
4.18. Estructuras del caché	83
5.1. Niveles de la pirámide	94
5.2. Hiperparámetros de la propuesta	98
5.3. Parámetros por bloque	98
5.4. Configuraciones comparadas	100
5.5. Recetas de entrenamiento	100
5.6. Métricas por eje	102
5.7. Verificación de RE2.1	103
5.8. Claves de un checkpoint	108
5.9. Costo de las corridas	108
5.10. Verificación de RE2.2	110
5.11. Resultados al punto de operación	111
5.12. Detección, encuadre y clasificación	112
5.13. Cobertura a carga igual	115
5.14. Recall por clase	116
5.15. Verificación de RE2.3	121
5.16. Columnas de la tabla de salida	122
5.17. Primeras filas de la tabla de salida	123
5.18. Ubicación de cada elemento del indicador	126
7.1. Cumplimiento de los resultados esperados	135
A.1. Criterios de aceptación	141
A.2. EDT del proyecto	143
A.3. Costos de equipos	145
A.4. Capital intelectual	145
A.5. Costos de software y servicios	145
A.6. Costos indirectos	146
A.7. Resumen de costos	146
A.8. Riesgos del proyecto	147

Capítulo 1

Generalidades

1.1. Problemática

1.1.1. Recolección de datos acelerada

El monitoreo acústico pasivo (PAM) consiste en dejar grabadoras autónomas en el campo y registrar el sonido del ecosistema de forma continua. Frente a otros métodos de muestreo, los sensores acústicos no son invasivos, suelen ser omnidireccionales y ofrecen un área de detección mayor y menos restricciones taxonómicas que las cámaras trampa (Gibb et al., 2018). Permiten muestrear durante periodos largos con poco esfuerzo manual, lo que aumenta la probabilidad de detectar especies raras o poco vocales (Gibb et al., 2018), justamente el caso de los primates neotropicales de la Amazonía peruana, difíciles de observar de forma directa. El producto de ese registro es audio continuo sin estructura; lo que un analista obtiene de él es una anotación como la de la Figura 1.1, un rectángulo de tiempo y frecuencia con la especie y el tipo de llamada que contiene.

La aparición de sensores de bajo costo y código abierto está ampliando rápidamente el acceso a estas tecnologías y permite desplegar redes multisensor a escala (Gibb et al., 2018). El costo de grabar y almacenar cayó lo suficiente como para hacer viable la captura continua de audio (Stowell, 2022). El conjunto sobre el que trabaja esta tesis lo ilustra: 3 356 grabaciones de ocho especies de primates, con una duración acumulada de 32,69 horas, de las cuales 2 819 (26,34 horas) cuentan con anotaciones expertas. La composición por especie se detalla en la Tabla 1.1. Sobre ese material, el protocolo de




Figura 1.1: Anotación tiempo–frecuencia en Raven

curación del Capítulo 4 deja 19 213 anotaciones utilizables: es la magnitud que conviene retener para contrastarla, más adelante, con lo disponible públicamente.

Tabla 1.1: Material recibido por especie

Especie (código)	Grabado		Anotado		
	N.º	Horas	N.º	Evento (min)	Fracción (%)
Mono aullador (AS)	808	7,57	778	324,6	71,5
Capuchino de cabeza grande (SM)	659	6,13	582	16,6	4,5
Mono araña peruano (AC)	561	6,07	384	30,7	8,4
Tamarino de Weddell (LW)	530	5,28	410	47,5	15,0
Tití de Toppin (PT)	375	3,35	320	94,3	47,0
Mono ardilla boliviano (SB)	290	3,08	256	12,2	6,6
Mono nocturno (AA)	117	1,10	82	2,5	3,8
Capuchino de cabeza chata (CC)	16	0,11	7	0,1	1,2
Total	3 356	32,69	2 819	528,5	26,9

1.1.2. Análisis lento e inconsistente

El cuello de botella habitual es la falta de tiempo-persona de analistas entrenados (Stowell, 2022), y recolectar anotaciones es el principal cuello de botella para construir estos métodos (Nguyen Hong Duc et al., 2021). El trabajo se hace a mano. El analista abre cada grabación, inspecciona el espectrograma, dibuja un recuadro alrededor de cada vocalización y le asigna una etiqueta. En detección de eventos sonoros, recolectar etiquetas fuertes a gran escala consume mucho tiempo, y en la mayoría de los casos

varios trabajadores se reparten las anotaciones para construir un solo conjunto de datos (Koga et al., 2024).

Ese reparto introduce un segundo problema ya que la anotación manual es subjetiva, y resulta difícil cuantificar los sesgos ligados al nivel de conocimiento del analista (Gibb et al., 2018); estudios recientes muestran que la tarea genera errores específicos de cada anotador (Nguyen Hong Duc et al., 2021). Al comparar varios anotadores sobre el mismo audio, las etiquetas fuertes presentan variaciones grandes tanto en el tipo de evento como en los tiempos de inicio y fin, hasta el punto de que determinar una etiqueta única resulta difícil (Koga et al., 2024). En bioacústica marina, Leroy et al. (2018) encontraron menos del 50 % de acuerdo entre dos analistas, y también un acuerdo pobre de un mismo analista al anotar dos veces el mismo segmento.

La variación temporal en las etiquetas fuertes es inevitable, y afecta tanto al entrenamiento del modelo como a la evaluación de su desempeño (Koga et al., 2024). Esto significa que en proyectos donde se aplica PAM, una gran parte del audio queda sin anotar y las etiquetas anotadas son inconsistentes.

1.1.3. Investigaciones anteriores

Los trabajos previos se separan por la forma que toma su salida, y esa forma admite tres variantes (Figura 1.2). Los sistemas más difundidos clasifican segmentos de duración fija. BirdNET identifica cientos de especies de aves puntuando ventanas cortas de audio (Kahl et al., 2021) y, en un caso más cercano al de esta tesis, HOWLish detecta aullidos de lobo con una precisión de 0,006 bajo un desbalance extremo, y aun así reduce unas 15 veces el tiempo del operador frente a anotar todo a mano (Campos et al., 2025). Ese resultado es relevante porque muestra que, cuando un humano revisa la salida, aceptar precisión baja a cambio de recall alto es una estrategia válida. Su limitación es la forma del resultado: una probabilidad por segmento, no un evento delimitado.

Una segunda línea sí devuelve eventos. Los *sound event bounding boxes* formalizan cada predicción como una cuádrupla de clase, tiempo de inicio, tiempo de fin y una puntuación global de confianza (Ebberts et al., 2024). Es un evento con extensión propia, pero esa extensión existe solo sobre el eje temporal.

La tercera línea trata el espectrograma como una imagen. La idea de partida es que los eventos acústicos se manifiestan como patrones bidimensionales de tiempo y frecuencia, con texturas y estructuras geométricas propias, análogos a los objetos que aparecen en imágenes naturales (Pham et al., 2018). El trabajo más cercano al de esta tesis es NBM, que publica anotaciones precisas de tiempo y frecuencia recolectadas por decenas de aficionados a las aves en Francia, junto con un modelo de detección de objetos de dos etapas adaptado a datos de audio (Airale et al., 2025).




Figura 1.2: Tres formas de salida

1.1.4. Vacío y contribución

El vacío tiene dos ejes, y esta tesis se sitúa en el cruce (Tabla 1.2).

Eje de dominio. Los sistemas maduros existen para aves, lobos y mamíferos marinos. Para primates neotropicales de la Amazonía no hay un conjunto público con anotaciones tiempo–frecuencia. La Tabla 1.3 lo documenta sobre el repositorio abierto

Tabla 1.2: Vacío del problema

	Tarea madura: detección temporal	Tarea poco explorada: cajas tiempo–frecuencia
Dominio con recursos (aves, mamíferos marinos, cánidos)	BirdNET, SEBB, YOHO	NBM (Airale et al., 2025), YOLOv5 en focas barbudas (Escobar-Amado et al., 2024)
Dominio sin recursos (primates neotropicales)	Heinicke et al. (2015), primates africanos	Vacío: esta tesis

de grabaciones de fauna más utilizado: para las ocho especies objetivo, Xeno-canto contiene 32 grabaciones en primer plano y poco más de una hora de audio en total, tres especies no tienen ninguna grabación, y ninguna de las disponibles incluye anotaciones tiempo–frecuencia.

Tabla 1.3: Disponibilidad en Xeno-canto

Especie	Grabaciones (primer plano)	Duración total
<i>Alouatta sara</i>	8	41:14
<i>Plecturocebus toppini</i>	13	19:20
<i>Ateles chamek</i>	4	03:42
<i>Saimiri boliviensis</i>	4	02:28
<i>Aotus azarae</i>	3	02:18
<i>Cebus cuscinus</i>	0	N/D
<i>Leontocebus weddelli</i>	0	N/D
<i>Sapajus apella macrocephalus</i>	0	N/D
Total	32	69:02

Consulta realizada el 19 de agosto de 2026 sobre el nombre científico de cada especie (Vellinga, 2026).

Eje de tarea. El vacío tampoco es solo de dominio. La investigación existente ha pasado por alto en gran medida el rango de frecuencia de los eventos; el SED temporal descarta información codificada en el dominio frecuencial, y por eso la detección precisa de cajas tiempo–frecuencia puede asistir al investigador humano. Pese a esa relevancia, sigue siendo un área en gran medida inexplorada (Zhu and Sato, 2025).

En el cruce de ambos ejes se sitúa esta tesis, que desarrolla un protocolo de curación y estandarización sobre las anotaciones producidas por el equipo de investigación, y un

detector que devuelve cajas tiempo–frecuencia con especie, tipo de llamada y confianza, concebido como herramienta de pre-annotación asistida.

1.2. Árbol de problemas

El árbol se estructura siguiendo el heurístico de análisis causa–efecto propuesto por Veselý (2008), y sirve de puente entre la brecha operativa descrita en la sección anterior y los objetivos de la investigación. Organiza el área temática en causas, problema central y efectos para ordenar el trabajo posterior, sin cuantificar las relaciones entre sus elementos. La Figura 1.3 lo resume; las dos condiciones de la franja inferior enmarcan el problema sin ser causas sobre las que esta tesis pueda actuar. Los apartados que siguen desarrollan cada elemento.




Figura 1.3: Árbol de problemas y condiciones subyacentes

1.2.1. Condiciones subyacentes

Dos condiciones enmarcan el problema sin ser causas sobre las que esta tesis pueda actuar. Se consignan aparte, siguiendo la recomendación de Veselý (2008) de ubicar fuera del eje causal aquello sin lo cual el problema no existiría o existiría de otra forma.

S1: Grabar se volvió barato, pero analizar no

Los sensores de bajo costo permiten desplegar redes de muchos micrófonos a escala (Gibb et al., 2018). La condición no es negativa en sí misma; es la que vuelve visible y creciente la distancia entre lo que se graba y lo que se llega a revisar.

S2: La unidad acústica no tiene una definición estable ni fronteras discretas

Las unidades acústicas pueden estar jerárquicamente anidadas, de modo que una secuencia de unidades puede considerarse ella misma una unidad y ser reemplazada por una etiqueta; se organizan en notas, trinos, sílabas, frases, motivos y cantos, y las definiciones de unidad varían ampliamente entre investigadores, incluso dentro de un mismo grupo taxonómico (Kershenbaum et al., 2016). A ello se suma que las unidades producidas por animales exhiben variación graduada en sus rasgos, mientras que la mayoría de métodos analíticos asume categorías discretas (Kershenbaum et al., 2016). La indefinición de granularidad es, entonces, anterior al anotador y no se resuelve entrenándolo mejor. Esta condición es la que justifica, más adelante, una curación metodológica explícita en lugar de una corrección de las anotaciones recibidas.

1.2.2. Problema central

El análisis del audio de monitoreo acústico pasivo no acompaña al ritmo de su recolección, y las anotaciones que sí se producen no son consistentes entre sí.

El enunciado tiene deliberadamente dos predicados, porque el problema tiene dos dimensiones que ninguna de las dos agota por separado: un déficit de *caudal* (se anota mucho menos de lo que se graba) y un déficit de *consistencia* (lo que se anota no obedece a un criterio único). Un planteamiento que solo recogiera el primero dejaría sin cubrir la causa C2 y el efecto E2; uno que solo recogiera el segundo no explicaría todo el audio que queda sin anotar.

Del lado de la recolección, el despliegue a escala es hoy accesible (S1). Del lado del análisis, la gran cantidad de audio que se acumula hace que un cuello de botella común sea la falta de tiempo-persona de analistas entrenados (Stowell, 2022). Conforme escala el número de grabadoras desplegadas, detectar señales acústicas en los paisajes sonoros registrados se vuelve un obstáculo logístico que limita la escalabilidad de los estudios de PAM (Campos et al., 2025).

El material recibido mide esa distancia. De las 32,69 horas grabadas, sólo 528,5 minutos corresponden a tramos marcados como evento: el 26,9 % del tiempo registrado, y con un reparto muy desigual entre especies (Tabla 1.1). El mono aullador llega al 71,5 % porque sus coros son largos y continuos; el capuchino de cabeza grande se queda en 4,5 % sobre una cantidad de horas parecida. La fracción no mide cuánto vocaliza cada especie, sino cuánto de lo grabado llegó a revisarse y anotarse.

1.2.3. Causas

C1: Hay pocas horas de analista experto disponibles

Los eventos sonoros requieren que un experto los anote con las etiquetas correctas, y ese tiempo experto suele escasear; la restricción se siente tanto en distinciones categóricas finas como en el monitoreo a gran escala, donde el volumen de datos excede con mucho las horas-persona disponibles (Stowell, 2022). En detección de eventos sonoros, recolectar etiquetas fuertes a gran escala consume mucho tiempo, y por eso varios trabajadores se reparten las anotaciones para construir un solo conjunto de datos (Koga et al., 2024). El reparto entre anotadores es la respuesta habitual a esta restricción, y es también el punto donde C1 y C2 se encuentran: alivia el caudal a costa de multiplicar los criterios en juego.

C2: Inconsistencia entre anotadores y dentro de un mismo anotador

La tarea es subjetiva y genera errores específicos de cada anotador (Nguyen Hong Duc et al., 2021), y los sesgos ligados al nivel de conocimiento del analista son difíciles de cuantificar (Gibb et al., 2018). La magnitud está medida: menos del 50 % de acuerdo entre analistas, y acuerdo pobre de un mismo analista consigo mismo (Leroy et al., 2018); con 20 anotadores por clip, las etiquetas fuertes presentan variaciones grandes en tipo de evento y en tiempos de inicio y fin (Koga et al., 2024).

Estudios previos no han encontrado soluciones suficientes, y la variación afecta tanto el entrenamiento como la evaluación (Koga et al., 2024).

Interesa subrayar que este desacuerdo es una propiedad medible de la tarea y no un defecto individual corregible: descansa sobre S2, que fija su piso. Reducirlo a cero no es un objetivo alcanzable, y cualquier propuesta metodológica debe trabajar con él en lugar de suponerlo ausente.

C3: La salida de los sistemas automáticos no sustituye el trabajo del analista

La automatización sería la vía natural para aliviar C1, pero su producto actual no es un reemplazo directo del insumo que el analista necesita. Esto ocurre por dos motivos distintos, uno de representación y otro de cobertura.

En cuanto a la representación, los sistemas basados en segmentos fijos entregan una probabilidad asociada a una rejilla, no un evento con extensión propia: BirdNET divide las grabaciones en fragmentos de 3 s y almacena las probabilidades por especie de cada segmento (Kahl et al., 2021), y HOWLish segmenta en ejemplos de 0,96 s y promedia las predicciones con una ventana móvil (Campos et al., 2025). Los sistemas que sí entregan eventos delimitados los definen solo sobre el eje temporal, sea como cuádruplas de clase, onset, offset y confianza (Ebberts et al., 2024), sea regresando los puntos de inicio y fin de cada clase (Venkatesh et al., 2022). La frecuencia, sin embargo, aporta información que el biólogo usa: las cajas predichas llevan información estadística embebida sobre la vocalización, como su duración, ancho de banda y frecuencia central (Escobar-Amado et al., 2024).

En cuanto a la cobertura, aun cuando la precisión es alta, los métodos del estado del arte fallan con regularidad al distinguir llamadas tenues, transitorias o parcialmente enmascaradas, produciendo tasas altas de falsos negativos (Gibb et al., 2018). Una salida automática incompleta no descarga al analista: lo obliga a revisar igual.

1.2.4. Efectos

Los efectos se organizan por actor afectado, siguiendo el criterio que Veselý (2008) ilustra en su tercer ejemplo, en lugar de asignar un efecto a cada causa. E1 y E2 son efectos directos; E3 se deriva de ambos.

E1: Para el equipo de investigación, el material grabado crece más rápido de lo que puede analizarse

El volumen de datos excede con mucho las horas-persona disponibles (Stowell, 2022), y la detección de señales en los paisajes sonoros registrados se convierte en un obstáculo logístico conforme escalan los despliegues (Campos et al., 2025). El efecto práctico es que el esfuerzo y el gasto de despliegue quedan inmovilizados en material sin procesar, y que la porción del material efectivamente anotada responde a la disponibilidad del analista antes que a un criterio de muestreo.

E2: Para el desarrollo metodológico, no hay una referencia confiable contra la cual medir el avance

La variación en las etiquetas fuertes no solo afecta el entrenamiento del modelo, sino que tiene un impacto significativo sobre la evaluación de su desempeño (Koga et al., 2024). En el terreno de las cajas tiempo–frecuencia, Zhu and Sato (2025) observan desplazamientos relativamente grandes de las cajas predichas frente a las anotadas, y concluyen que las fronteras de los eventos son borrosas y difíciles de determinar, por lo que fijar un umbral de IoU bajo es razonable. A la heterogeneidad se suma un faltante no aleatorio: las llamadas tenues o enmascaradas escapan a los métodos automáticos (Gibb et al., 2018), de modo que los eventos ausentes de la referencia son sistemáticamente los más difíciles. La consecuencia es que las cifras de desempeño reportadas son difíciles de comparar entre trabajos y tienden a describir mejor las condiciones fáciles que el problema completo.

E3: Para la ecología y la gestión, las preguntas se responden tarde o sobre muestras sesgadas

Efecto indirecto, derivado de E1 y E2. El PAM es cada vez más adecuado para programas de monitoreo orientados a objetivos, cuyos protocolos deben ser estandarizables, escalables y financieramente sostenibles (Gibb et al., 2018); sus beneficios incluyen el muestreo continuo con poco esfuerzo manual y una mayor probabilidad de detectar especies raras o poco vocales (Gibb et al., 2018). Cuando el análisis no acompaña a la recolección, esas ventajas no se materializan: la ventaja de detección de lo raro se pierde por E1, y la confianza en lo que se reporta se erosiona por E2. En primates, Heinicke et al. (2015) ya habían señalado el costo de esta brecha al evaluar un sistema de monitoreo acústico en un ambiente de selva altamente ruidoso.

1.3. Objetivos

1.3.1. Objetivo general

OG. Desarrollar y evaluar un sistema de pre-annotación asistida que proponga cajas tiempo–frecuencia con especie y tipo de llamada sobre grabaciones de PAM de primates amazónicos, con el fin de reducir el tiempo de revisión experta.

El encuadre asistido cuenta con respaldo en la literatura. La inteligencia artificial no reemplaza la experiencia, y conforme estos sistemas se estandarizan asumen el papel de pares expertos con quienes se consulta y debate, sin desplazar el rol del experto ni el del trabajo colaborativo (Stowell, 2022). También tiene precedente cuantificado en primates. Heinicke et al. (2015) evaluaron un sistema de monitoreo acústico para cuatro especies de primates en el ambiente altamente ruidoso del Parque Nacional Tai, y reportan que, pese a una precisión aparentemente baja, la inversión de tiempo para remover manualmente los falsos positivos de la salida del sistema fue de apenas 3–5 % comparada con la de un humano recolectando y procesando los datos de vocalización.

El mismo patrón se repite fuera de primates, y con dos cifras que conviene distinguir. HOWLish recupera el 81,3 % de los eventos de aullido observados y ofrece una reducción de 15 veces en el tiempo del operador frente a la detección totalmente manual, y su tubería redujo 22 veces el volumen de datos que un operador debía procesar manualmente (Campos et al., 2025). La primera es una medida de tiempo humano y exige cronometrar a una persona; la segunda es una cantidad contable que se deriva de la propia salida del sistema. El objetivo general se compromete con la primera, reducir el tiempo de revisión experta, que es la magnitud que le importa al equipo de investigación y la que fija el indicador de RE3.2. La segunda acompaña a esa medición y la explica: cuántas propuestas hay que inspeccionar y cuánto audio queda sin ninguna es lo que hace que el tiempo baje, y se deriva del propio conjunto de prueba sin depender de un revisor externo.

El enunciado fija además el compromiso que el sistema asume de antemano: priorizar la cobertura aceptando falsos positivos. Ese sesgo no es una concesión sino una decisión con precedente cuantificado, ya que HOWLish resulta útil operando con una precisión

de 0,006 bajo desbalance extremo (Campos et al., 2025). Su contrapartida es que la carga generada por ese sesgo debe quedar acotada y reportada, y de eso se ocupa OE3.

1.3.2. Objetivos específicos

Cada objetivo específico responde a una de las tres causas del árbol: OE1 a la inconsistencia del etiquetado (C2), OE2 a la forma de la salida (C3) y OE3 a la escasez de horas de analista (C1).

OE1. Definir un protocolo de curación y estandarización, y aplicarlo sobre las anotaciones entregadas por el equipo de investigación para construir un conjunto de datos consistente de cajas tiempo–frecuencia etiquetadas por especie y tipo de llamada.

OE2. Implementar y evaluar un detector que reciba un espectrograma y devuelva cajas tiempo–frecuencia con especie, tipo de llamada y confianza, comparándolo con una línea base establecida.

OE3. Cuantificar la reducción del tiempo de revisión que aporta el sistema y caracterizar sus errores mediante revisión experta de una muestra de predicciones.

1.4. Resultados esperados

1.4.1. OE1: Protocolo y conjunto de datos curado

Las grabaciones y las anotaciones primarias provienen del equipo de investigación. La contribución de esta tesis es la normalización, el particionado y la caracterización del conjunto derivado, no la anotación original.

RE1.1. Protocolo documentado: vocabulario cerrado de clases, mapa de sinónimos, reglas de descarte y criterio de partición. Las definiciones de unidad y las etiquetas semánticas varían ampliamente entre investigadores (Kershenbaum et al., 2016), lo que justifica cerrar el vocabulario, y los protocolos de monitoreo deben ser estandarizables (Gibb et al., 2018).

RE1.2. Conjunto curado y particionado por archivo de grabación, sin solapamiento entre particiones. La variación en las etiquetas fuertes impacta la evaluación (Koga et al., 2024), por lo que una partición que no infle artificialmente el resultado es condición para que las cifras sean interpretables.

Tabla 1.4: IOV de OE1

RE	Resultado	Medio de verificación	Indicador objetivamente verificable (IOV)
RE1.1	Protocolo de curación y estandarización documentado.	Documento del protocolo.	Define la normalización de columnas y etiquetas, el mapa de sinónimos, el descarte de ruido y cajas degeneradas, la corrección de pares imposibles, el recorte al límite de Nyquist y el tratamiento de registros fuera de vocabulario.
RE1.2	Conjunto acústico curado y particionado para el experimento.	Directorio <code>data/processed/</code> : etiquetas, metadatos y tres archivos <code>.pt</code> .	Los archivos procesados cargan sin error; <code>meta.json</code> registra la semilla, el criterio de selección, las exclusiones, la etiqueta usada y la normalización; el código divide por archivo de grabación con proporciones 60/22,5/17,5 y no por ventanas aisladas.
RE1.3	Ficha del conjunto derivado.	Capítulo de curación, README y metadatos del conjunto.	Describe las ocho especies, el vocabulario, la composición, el desbalance, el diccionario de campos, el ventaneo de 3 s con salto de 1,5 s, la normalización log-mel, las exclusiones y las limitaciones conocidas.

RE1.3. Ficha del conjunto derivado: composición, desbalance, sesgos conocidos y limitaciones. Pese a la importancia de los datos para el aprendizaje automático, no existe un proceso estandarizado para documentar conjuntos de datos; las *datasheets* proponen documentar motivación, composición, proceso de recolección y usos recomendados, con el potencial de aumentar la transparencia y la rendición de cuentas (Gebu et al., 2021). La ficha distingue dos capas: el conjunto primario, producido por el equipo de investigación, y el conjunto derivado, producido por esta tesis.

La decisión de excluir las clases de frase se apoya directamente en Kershenbaum et al. (2016): las unidades pueden estar jerárquicamente anidadas, de modo que una secuencia de unidades puede considerarse ella misma una unidad, y un detector de conjunto plano no puede representar esa relación.

Tabla 1.5: IOV de OE2

RE	Resultado	Medio de verificación	Indicador objetivamente verificable (IOV)
RE2.1	Diseño experimental, arquitectura propuesta y línea base.	Documento de diseño y módulo de arquitecturas.	Especifica la arquitectura AST-Deformable-DETR implementada, con dimensión 128, 64 consultas y 3 niveles, sus hiperparámetros, y define la comparación con las líneas base declaradas.
RE2.2	Pipeline reproducible de entrenamiento, evaluación e inferencia.	Scripts de datos, entrenamiento, evaluación e inferencia; módulos de <code>src/pipelines/</code> ; <code>pyproject.toml</code> y manual técnico.	El pipeline genera los splits procesados, entrena desde un conjunto de configuración, evalúa un checkpoint y ejecuta inferencia sobre un WAV; las dependencias y comandos de ejecución están declarados.
RE2.3	Informe comparativo de resultados.	Informe de experimentación y archivos de métricas.	Reporta, como mínimo, recall, precisión, F1, IoU medio, AP a IoU 0,25 y 0,5, recall por clase y matriz de confusión; separa detección, encuadre y clasificación y justifica la selección del modelo.
RE2.4	Modelo final cargable y demostración funcional.	Checkpoint <code>.pth</code> , <code>labels.json</code> y ejecución de <code>src/infer.py</code> .	El checkpoint se carga sin claves incompatibles y la inferencia sobre un WAV produce un archivo tabulado con las columnas de Raven, incluidas coordenadas tiempo–frecuencia, especie, tipo de llamada y puntuación.
RE2.5	Código y modelo disponibles en un repositorio.	Repositorio de control de versiones.	La URL del repositorio permite localizar el código de curación, entrenamiento, evaluación e inferencia, junto con las instrucciones de ejecución y los artefactos del modelo final que se hayan decidido publicar.

1.4.2. OE2: Detector y evaluación

RE2.1. Documento de diseño: arquitectura propuesta y línea base, con justificación de ambas. Los eventos se manifiestan como patrones bidimensionales con texturas y estructuras geométricas propias, análogos a los objetos de imágenes naturales (Pham et al., 2018), y detectar un objeto implica tanto afirmar que una clase está presente como localizarla, localización que se representa típicamente mediante una caja delimitadora (Lin et al., 2014). La brecha de modalidad entre imagen y audio justifica sustituir los *backbones* preentrenados en imágenes (Zhu and Sato, 2025). Como precedentes de detección bidimensional en bioacústica se consideran Escobar-Amado et al. (2024) y Airale et al. (2025), y como línea base sobre espectrogramas, González et al. (2025).

RE2.2. Pipeline reproducible de entrenamiento, evaluación e inferencia. La pirámide multiescala corrige que las arquitecturas de tipo ViT y AST produzcan representaciones de escala única (Zhu and Sato, 2025).

RE2.3. Informe de evaluación desagregado en detección, encuadre y clasificación, con comparación contra la línea base. Un umbral de IoU bajo es razonable cuando las fronteras de los eventos son borrosas (Zhu and Sato, 2025), y el sesgo hacia el recall se justifica por el fallo sistemático de los métodos automáticos ante llamadas tenues o enmascaradas (Gibb et al., 2018).

RE2.4. Modelo final y exportador a tabla de selección de Raven. Las cajas llevan información estadística embebida útil para el analista, como la duración, el ancho de banda y la frecuencia central (Escobar-Amado et al., 2024).

RE2.5. Repositorio público con código y pesos del modelo.

El contraste que sostiene RE2.4 es directo: BirdNET y HOWLish entregan probabilidad por segmento (Kahl et al., 2021; Campos et al., 2025), los *sound event bounding boxes* y YOHO entregan límites temporales (Ebberts et al., 2024; Venkatesh et al., 2022), y esta tesis entrega la tupla completa de tiempo, frecuencia, especie, tipo de llamada y confianza.

Tabla 1.6: IOV de OE3

RE	Resultado	Medio de verificación	Indicador objetivamente verificable (IOV)
RE3.1	Metodología de validación comparativa.	Documento de metodología y protocolo de revisión experta.	Especifica el subconjunto de prueba, el punto de operación (confianza 0,5 y NMS IoU 0,3), el umbral IoU 0,5 para verdadero positivo, las métricas, el emparejamiento y el procedimiento para revisar discrepancias y eventos potencialmente omitidos.
RE3.2	Medición comparativa del tiempo de revisión.	Informe de validación, registros de tiempo y medición de inferencia.	Reporta minutos por hora de audio en condición manual y asistida, describe el material comparable y el orden de revisión, y presenta el tiempo de procesamiento del modelo por hora de audio. No fija un porcentaje de ahorro antes de medirlo.
RE3.3	Análisis cualitativo de errores y hallazgos.	Informe de análisis y espectrogramas anotados.	Clasifica una muestra de predicciones de alta confianza en evento no anotado, ruido y error de encuadre, e incluye ejemplos visuales de aciertos, errores comunes y detecciones correctas ausentes de la anotación de referencia.

1.4.3. OE3: Tiempo de revisión y análisis de errores

OE3 cierra el argumento del objetivo general: mide en minutos por hora de audio lo que cuesta revisar el mismo material con y sin la asistencia del detector, y somete una muestra de sus predicciones al criterio experto para saber de qué están hechos sus errores. Las dos mediciones se apoyan en una metodología fijada y fechada de antemano, que es el primero de los tres resultados.

RE3.1. Metodología de validación comparativa, redactada y fechada antes de ejecutar la evaluación: material de prueba, punto de operación, umbral de emparejamiento, métricas y protocolo con que el revisor experto resuelve las discrepancias, siguiendo el marco de tubería para identificación automatizada de sonidos (Gibb et al., 2018). Fijarla de antemano impide elegir a posteriori el umbral o la métrica que mejor favorezcan al resultado ya obtenido. El punto de operación queda comprometido

en confianza 0,5 con supresión de no máximos a IoU 0,3, y un verdadero positivo exige IoU 0,5 contra la anotación de referencia.

RE3.2. Medición comparativa del tiempo de revisión: minutos por hora de audio en condición manual y en condición asistida, sobre material comparable y con el orden de revisión declarado, más el tiempo de procesamiento del modelo por hora de audio, que forma parte del costo de la condición asistida. El indicador no fija de antemano un porcentaje de ahorro: se mide y se reporta con sus condiciones. El precedente en primates es la inversión de 3–5 % de tiempo que reportan Heinicke et al. (2015); el precedente metodológico para las magnitudes que se derivan de la salida del sistema (propuestas por hora de audio y fracción de audio sin ninguna propuesta) es la reducción de 22 veces del volumen que un operador debía procesar (Campos et al., 2025), que acompaña a la medición cronometrada y explica de dónde sale el ahorro.

RE3.3. Análisis cualitativo de los errores: una muestra de predicciones de alta confianza clasificada en evento no anotado, ruido y error de encuadre, con ejemplos visuales de aciertos, de errores comunes y de detecciones correctas ausentes de la anotación de referencia. La separación se apoya en la relación geométrica entre la caja predicha y las cajas anotadas, resumida en la Tabla 1.7: las tres primeras categorías quedan determinadas por esa relación, mientras que la categoría D, las predicciones que no solapan con ninguna anotación, es la que el revisor experto resuelve entre evento omitido por la referencia y falso positivo genuino. Los dos modos de error que documenta Zhu and Sato (2025), una caja anotada detectada como varias y varias detectadas como una, corresponden a la categoría B, y la borrosidad de las fronteras del evento que ese mismo trabajo describe es lo que hace necesaria la categoría A. Que la referencia omita eventos es plausible de antemano: los métodos automáticos fallan con llamadas tenues o enmascaradas (Gibb et al., 2018), y la variabilidad intra-analista (Leroy et al., 2018) apunta en la misma dirección desde el lado humano.

Limitación declarada. La resolución de las predicciones de alta confianza situadas en regiones sin anotación (tipo D) entre eventos omitidos por la referencia y falsos positivos genuinos depende del criterio experto, y este trabajo lo obtiene sobre una muestra,

Tabla 1.7: Taxonomía de discrepancias

Tipo	Discrepancia	Definición	¿Resoluble sin experto?
A	Encuadre	Solapa con una anotación de la misma clase, pero con IoU inferior al umbral de emparejamiento.	Sí
B	Unidad	Varias predicciones sobre una misma anotación, o una predicción sobre varias anotaciones: división y fusión.	Sí
C	Clase	Encuadre correcto sobre una anotación, con etiqueta de especie o de tipo de llamada incorrecta.	Sí
D	Región sin anotación	No solapa con ninguna caja anotada. Puede ser un evento omitido por la referencia o un falso positivo genuino.	No

no sobre el total. Lo que quede fuera de esa muestra se caracteriza geométricamente y se reporta como una cantidad acotada; el tamaño de la muestra y la disponibilidad del equipo de investigación son, por tanto, una limitación del alcance de RE3.3 y se declaran como tal en el Capítulo 6.

1.5. Trazabilidad

La relación entre las causas del problema, sus efectos y los productos comprometidos se resume en la Tabla 1.8. En la práctica, OE1 aborda la heterogeneidad del etiquetado, OE2 la representación funcional de los eventos, y OE3 la utilidad operativa del sistema dentro del flujo de trabajo del analista. OE3 ataca C1, la escasez de horas de analista, midiendo directamente el tiempo que cuesta revisar una hora de audio con y sin la asistencia del sistema.

1.6. Métodos y procedimientos

1.6.1. Metodología CRISP-DM

El desarrollo se organiza siguiendo CRISP-DM (*Cross-Industry Standard Process for Data Mining*), un marco iterativo, independiente de la industria y de la herramienta, que proporciona una hoja de ruta general para proyectos de minería de datos (Chapman et al., 2000). Su estructura cíclica, desde la comprensión del problema hasta el

Tabla 1.8: Trazabilidad del planteamiento

Causa	Efecto	Objetivo	Resultados esperados
C1: Velocidad	E1	OE3	RE3.1, RE3.2, RE3.3
C2: Consistencia	E2	OE1	RE1.1, RE1.2, RE1.3
C3: Forma de la salida	E1, E2	OE2	RE2.1, RE2.2, RE2.3, RE2.4, RE2.5
E1, E2	E3	OG	Sistema de pre-anotación asistida integrado




Figura 1.4: CRISP-DM aplicado a este proyecto

despliegue de la solución, se ajusta a un proyecto de investigación aplicada en el que la comprensión de los datos, la experimentación con modelos y la evaluación continua se realimentan entre sí. La Figura 1.4 resume la correspondencia entre las seis fases, los objetivos específicos y los capítulos de este documento.

Fase 1: Comprensión del negocio o de la investigación.

Convierte el conocimiento del dominio y los objetivos del proyecto en una definición formal del problema de minería de datos (Chapman et al., 2000). Esa traducción es el

contenido de las secciones anteriores de este capítulo: la brecha operativa se estructura como árbol de problemas y de ahí derivan el objetivo general, los objetivos específicos y los resultados esperados. Los criterios de éxito son a la vez técnicos, relacionados con el desempeño en detección, encuadre y clasificación, y operativos, vinculados con la cobertura alcanzada y con la carga de revisión que genera alcanzarla, como recomienda el marco para asegurar que el resultado sea útil y no solo correcto.

Fase 2: Comprensión de los datos.

Los datos primarios son grabaciones en formato WAV muestreadas a 44,1 kHz, capturadas con dispositivos AudioMoth y entregadas por el equipo de investigación junto con sus anotaciones. Cada especie llega en una carpeta con grabaciones de duración heterogénea y un archivo de texto delimitado por tabulaciones producido con Raven Pro, en el que cada fila registra tiempo de inicio y fin, frecuencia mínima y máxima, amplitud, calidad, etiqueta de especie y etiqueta de tipo de llamada. La fase comprende el análisis exploratorio visualización de espectrogramas, distribución de clases, distribución de duraciones y rangos de frecuencia, junto con la verificación de calidad de los archivos de audio corruptos, errores tipográficos y etiquetas inconsistentes. El Capítulo 4 desarrolla ambos.

Fase 3: Preparación de datos.

Comprende la limpieza y normalización de etiquetas sobre un vocabulario cerrado, el preprocesamiento del audio, el cálculo de la representación tiempo–frecuencia, la segmentación de las grabaciones largas en ventanas de duración fija con solapamiento, y el aumento de datos mediante adición de ruido de fondo del propio entorno, desplazamiento de tono, estiramiento temporal y enmascaramiento de bloques de tiempo o frecuencia sobre el espectrograma. Aquí se resuelve la comparación entre log-mel y PCEN anunciada en la sección 2.2.3, bajo el criterio allí declarado.

Fase 4: Modelado.

La forma de la salida no está en discusión: el sistema debe emitir la tupla completa de la ecuación (2.1), y esa exigencia excluye de antemano toda arquitectura cuya cabeza produzca una probabilidad por trama o por segmento. Lo que se compara, por tanto, no son familias de arquitectura sino configuraciones que sí satisfacen la exigencia: la arquitectura propuesta sobre un extractor de audio con cabeza de detección, y tres

líneas base de detector sobre espectrogramas: uno de dos etapas con propuestas de región, uno denso de una etapa (González et al., 2025) y uno de conjuntos con extractor preentrenado en imágenes.

La regla de decisión se fija antes de entrenar: gana la configuración con mayor valor de la métrica principal definida en la Fase 5, medida sobre la partición de *validación*; la partición de prueba se reserva para reportar el desempeño de la configuración ya elegida y no participa de la elección. La implementación se realiza en PyTorch con código modular, separando la definición de la arquitectura, el bucle de entrenamiento y las utilidades.

Fase 5: Evaluación.

Los modelos entrenados se evalúan sobre la partición de prueba y los resultados se leen contra los criterios de éxito de la Fase 1. El análisis no se agota en una cifra agregada: identifica qué clases se detectan mejor y peor, qué tipos de error predominan, entre ellos la confusión entre especies acústicamente próximas, los falsos positivos por ruido y los errores de localización en tiempo o en frecuencia, y acompaña las cifras con ejemplos visualizados sobre el espectrograma.

Reportar varias métricas sin jerarquía permitiría elegir a posteriori la que favorezca al modelo preferido. Para evitarlo, la Tabla 1.9 asigna a cada una un rol fijado de antemano.

La **métrica principal** es el *recall* a nivel de evento, medido al punto de operación que la partición de validación elige para cada configuración: el umbral de confianza de mayor *recall* entre los que alcanzan una precisión de al menos 0,70. El *recall* manda porque el sistema es de pre-anotación asistida y un humano revisa su salida: perder una vocalización cuesta más que descartar un falso positivo. Se acompaña siempre de su intervalo de confianza por remuestreo de grabaciones, y dos configuraciones cuyos intervalos se solapan se declaran no separadas por el experimento.

Un **umbral de confianza fijo y compartido** entre configuraciones no sirve para esta comparación: la confianza que emite cada cabeza depende de su función de pérdida y de cómo normaliza la puntuación, de modo que un mismo número cae en puntos distintos de cada curva y mediría calibración tanto como detección. Por eso cada modelo trae el suyo, elegido en validación, y viaja junto a su *checkpoint*.

El **criterio de selección de *checkpoint*** dentro de una misma corrida es la precisión media (mAP) a IoU 0,3 sobre validación, que es libre de umbral y por tanto no premia a la época mejor calibrada sino a la que mejor detecta. Es también la **métrica secundaria** de la comparación entre configuraciones, y la que decide cuando la primaria no separa. Junto a ellas se reporta el cociente **FP/TP al punto de operación**, que es literalmente la carga de revisión que el experto asume por cada acierto y la magnitud que conecta esta fase con OE3.

El acierto se decide a IoU 0,3 y el encuadre se puntúa aparte, a 0,5. El IoU es el cociente entre el área común y el área total de dos cajas, y la Figura 1.5 muestra a qué corresponde cada umbral. Emparejar a 0,3 responde a si la llamada se *encontró*, que es lo que decide si el revisor la ve; exigir 0,5 en el mismo paso mezclaría esa pregunta con la de si la caja quedó ajustada, y las fronteras del evento son borrosas incluso entre anotadores (Zhu and Sato, 2025). El punto de operación que compromete OE3 (confianza 0,5, IoU 0,5 para verdadero positivo y supresión de no máximos a IoU 0,3) es una decisión distinta y posterior: fija cómo se cronometra la revisión asistida, no cómo se comparan las arquitecturas.

El encuadre se puntúa aparte, con el IoU medio sobre los pares ya emparejados y la precisión media a varios umbrales de IoU. El barrido incluye umbrales bajos porque las fronteras del evento son borrosas incluso entre anotadores (Zhu and Sato, 2025), de modo que exigir un solapamiento alto mediría el acuerdo con un borde que el propio anotador no reproduce.




Figura 1.5: Criterio de IoU

Tabla 1.9: Métricas de evaluación

Métrica	Definición	Rol
<i>Recall</i> por evento, al punto de operación	Proporción de eventos anotados recuperados por alguna predicción cuyo solapamiento con la caja anotada supera IoU 0,3, al umbral que la validación elige para ese modelo con precisión $\geq 0,70$. Se reporta con intervalo de confianza.	Principal
mAP a IoU 0,3	Precisión media sobre las clases de detección, integrando toda la curva precisión–recall: no depende del umbral y por tanto no premia la calibración.	Secundaria y selección de <i>checkpoint</i>
FP/TP al punto de operación	Falsos positivos por cada verdadero positivo: la carga de revisión que el experto asume por cada acierto.	Costo de revisión (OE3)
IoU mediano del encuadre	Solapamiento entre la caja predicha y la anotada, sobre los eventos ya emparejados. Mide encuadre, no detección.	Encuadre
AP a IoU 0,25 y a IoU 0,5	La misma precisión media leída a un umbral de solapamiento laxo y a uno estricto: la distancia entre ambas mide cuánto se pierde al exigir encuadre.	Encuadre
Acierto sobre pares emparejados	Exactitud de la etiqueta de especie y tipo de llamada, condicionada a que la detección sea correcta.	Clasificación
Desempeño por clase	<i>Recall</i> individual para cada par de especie y tipo de llamada, con la causa atribuida a cada caída.	Diagnóstico

Fase 6: Despliegue.

En un proyecto de investigación el despliegue consiste en aplicar el modelo final a un volumen de grabaciones que no participaron del entrenamiento ni de la evaluación, y en producir con ellas tablas de anotación automáticas que el analista pueda abrir directamente en Raven. El artefacto es un *pipeline* de inferencia que recibe un directorio de audio, aplica exactamente el mismo preprocesamiento del entrenamiento, obtiene las predicciones crudas, ejecuta el posprocesamiento y escribe la tabla de selección en el formato esperado.

1.6.2. Herramientas

Cada herramienta se justifica por el requisito que satisface y por la alternativa que se descarta, no por sus virtudes generales. La Tabla 1.10 recoge las que intervienen en el recorrido del dato y la Tabla 1.11 las que sostienen el desarrollo. Donde no hay alternativa real, se dice.

Tabla 1.10: Stack técnico: pipeline

Herramienta	Función en el <i>pipeline</i>	Por qué esta y no la alternativa
Python 3.12	Lenguaje de todo el sistema	R y MATLAB carecen de implementaciones de referencia de detectores de objetos, que es el componente que no se va a reimplementar
Pandas	Consolidación, limpieza y particionado de las anotaciones tabulares	Procesar los archivos de Raven con scripts <i>ad hoc</i> no deja registro reproducible de qué filas se descartaron y por qué
NumPy	Representación en memoria del audio y de las cajas antes de pasar a tensores	Sin alternativa práctica: es la interfaz común entre SoundFile, PyTorch y Matplotlib
SoundFile y soxr	Lectura por bloques de las grabaciones y remuestreo a 44,1 kHz	Permiten leer solo la ventana pedida de un archivo de una hora, en lugar de cargarlo entero en memoria
torchaudio	Cálculo del espectrograma mel que consume el modelo	Librosa devuelve arreglos de NumPy y obligaría a convertir en cada lote; aquí la transformada entrega tensores que el PCEN entrenable recibe directamente
PyTorch	Definición, entrenamiento y evaluación del detector	Las implementaciones de referencia de detectores están mayoritariamente en PyTorch, y portarlas a otro marco no se justifica
Transformers	Carga del <i>backbone</i> AST preentrenado en AudioSet	Entrenar un transformador de espectrogramas desde cero excede los datos disponibles; la biblioteca aporta los pesos y la interpolación del <i>embedding</i> posicional
Raven Pro / Lite	Origen de las anotaciones y destino de las predicciones exportadas	Sin alternativa: es la herramienta del analista, y su formato de tabla de selección es un requisito de RE2.4, no una elección de diseño

Tabla 1.11: Stack técnico: desarrollo

Herramienta	Función	Por qué esta y no la alternativa
uv	Entorno virtual, resolución de dependencias y archivo de bloqueo	Instalar con <i>pip</i> sin bloqueo deja libres las versiones transitivas, y sin ellas el entorno de una corrida antigua no se reconstruye igual
Matplotlib	Figuras del análisis exploratorio y de los resultados	Sin alternativa que aporte algo distinto dentro del mismo ecosistema
Ruff, ty y pytest	Formato, análisis estático y pruebas del código	Las pruebas cubren la conversión entre sistemas de coordenadas de caja, donde un error silencioso desplazaría todas las métricas sin fallar
Git	Versionado del código y de la configuración de cada experimento	Sin alternativa: es la condición para asociar un resultado reportado a un estado exacto del código

1.6.3. Procedimientos y reproducibilidad

Las fases anteriores describen qué se hace con los datos y por qué. Esta subsección recoge únicamente lo operativo que no pertenece a ninguna fase en particular porque atraviesa todas: cómo se custodia el material, cómo se registran los experimentos y qué garantiza que un número reportado pueda volver a obtenerse.

Custodia del material primario. Los audios y sus anotaciones se mantienen bajo una estructura de directorios fija que no se edita nunca a mano. Toda transformación se produce por script a partir de ella y escribe en un directorio derivado distinto. Esa separación es la que permite reconstruir el conjunto de trabajo desde cero cada vez que el protocolo de curación cambia, y la que impide que una corrección puntual quede sin registro.

Registro de experimentos. Cada corrida queda asociada a un identificador de configuración y a un *commit* del repositorio. El bucle de entrenamiento registra los hiperparámetros, guarda *checkpoints* de forma periódica y evalúa sobre validación a intervalos fijos. Los scripts de evaluación son independientes de los de entrenamiento: cargan un *checkpoint* existente y recalculan las métricas, de modo que reproducir una cifra publicada no exige reentrenar.

Respaldo y portabilidad. El código y la configuración se sincronizan en un repositorio remoto, y el entorno de ejecución se declara en un archivo de dependencias versionado, para que la falla del equipo de desarrollo o la ejecución en una máquina distinta no supongan rehacer trabajo. La gestión de la bibliografía se centraliza en Zotero a lo largo de todo el proceso.

La planificación que ordena todo lo anterior en el tiempo, mediante la estructura de desglose del trabajo, el cronograma, el presupuesto y la gestión de riesgos, se recoge en el Anexo A, fuera del cuerpo, porque no aporta al argumento científico y en el hilo del documento lo interrumpiría.

Capítulo 2

Marco Referencial

2.1. Marco Teórico

2.1.1. Formulación del problema de detección

El problema se plantea en dos niveles. El nivel de la *grabación* es el que le interesa al analista y define el producto; el nivel de la *ventana* es el que consume el modelo y define su entrada y su salida. Separarlos es necesario porque ninguna arquitectura actual procesa una hora de audio de una sola vez, y confundirlos oscurece qué predice realmente un detector.

Nivel de grabación

El sistema recibe un conjunto de grabaciones $G = \{g_1, g_2, \dots, g_M\}$. Cada grabación g_k es una señal de audio $x(t)$ en formato WAV, muestreada a $F_s = 44,1$ kHz, de duración D_k que puede llegar a la hora. Para cada una el sistema debe devolver una lista de eventos $E_k = \{e_1, e_2, \dots, e_{N_k}\}$, cuyo cardinal N_k no se conoce de antemano y donde cada evento es la tupla

$$e_i = (t_{\text{ini}}^{(i)}, t_{\text{fin}}^{(i)}, f_{\text{mín}}^{(i)}, f_{\text{máx}}^{(i)}, y^{(i)}, p^{(i)}). \quad (2.1)$$

$(t_{\text{ini}}, t_{\text{fin}})$ Instantes de inicio y fin del evento, en segundos desde el comienzo de la grabación, con $0 \leq t_{\text{ini}} < t_{\text{fin}} \leq D_k$.

$(f_{\text{mín}}, f_{\text{máx}})$ Banda de frecuencia que ocupa el evento, en hercios, con $0 \leq f_{\text{mín}} < f_{\text{máx}} \leq F_s/2$. Es la componente que distingue esta formulación de la detección de eventos sonoros puramente temporal.

y Etiqueta tomada de un vocabulario cerrado $Y = \{y_1, \dots, y_L\}$ cuyos elementos son pares de especie y tipo de llamada. La sección 2.2.5 justifica por qué la etiqueta es un par plano y no dos niveles predichos por separado; las proyecciones $\pi_{\text{esp}}(y)$ y $\pi_{\text{tipo}}(y)$ recuperan cada nivel cuando se lo necesita.

p Confianza en $[0, 1]$ asignada por el modelo, que ordena las predicciones y define el punto de operación de la revisión asistida.

Las cuatro primeras componentes definen una caja rectangular sobre el plano tiempo–frecuencia; las dos restantes la etiquetan y la puntúan. La Figura 2.1 muestra el resultado sobre un espectrograma.




Figura 2.1: Segmentación tiempo–frecuencia

Nivel de ventana

La grabación se recorta en ventanas de duración fija T_w , tomadas cada H segundos con $H < T_w$, de modo que ningún evento quede siempre partido por un borde. Cada ventana se convierte en un espectrograma mel $X \in \mathbb{R}^{F \times T}$, con F bandas de frecuencia y T tramas temporales, y ese tensor es la entrada del modelo.

El detector es una función de parámetros θ que a cada ventana le asigna un conjunto de tamaño fijo

$$f_{\theta}(X) = \left\{ (\hat{b}_q, \hat{\pi}_q) \right\}_{q=1}^Q, \quad \hat{b}_q \in [0, 1]^4, \quad \hat{\pi}_q \in [0, 1]^{L+1}, \quad (2.2)$$

donde Q es un número de consultas fijado por la arquitectura, independiente del contenido de la ventana y mayor que la cantidad de eventos que cabe esperar en ella. Cada consulta produce una caja $\hat{b}_q = (c_x, c_y, w, h)$ en coordenadas normalizadas al recuadro de la ventana (centro, ancho y alto, los cuatro en $[0, 1]$) y una distribución $\hat{\pi}_q$ sobre $Y \cup \{\emptyset\}$, en la que $\emptyset$ es la clase “sin objeto” que absorbe las consultas sobrantes. El número de eventos no se predice: resulta de cuántas consultas eligen una clase de Y por encima del umbral de confianza.

Esta es la formulación de *predicción de conjuntos*: la salida no es una rejilla puntuada ni una secuencia, sino un conjunto sin orden, y durante el entrenamiento cada anotación de la ventana se asigna a exactamente una consulta mediante un emparejamiento biyectivo, mientras que el resto se supervisa hacia $\emptyset$. De ahí que dentro de la ventana no haya anclas ni supresión de no máximos.

Del marco normalizado al marco físico

Lo que emite el modelo no son segundos ni hercios sino fracciones de la ventana, y la conversión no es simétrica entre los dos ejes. En tiempo es afín: si la ventana empieza en t_0 ,

$$t_{\text{ini}} = t_0 + \left(c_x - \frac{w}{2}\right)T_w, \quad t_{\text{fin}} = t_0 + \left(c_x + \frac{w}{2}\right)T_w. \quad (2.3)$$

En frecuencia no lo es, porque el eje vertical del espectrograma está en escala mel. Con $m(\cdot)$ la función que convierte hercios a mel y $[f_{\text{lo}}, f_{\text{hi}}]$ los extremos del banco de filtros, la coordenada normalizada $u \in [0, 1]$ vuelve a hercios mediante

$$\varphi(u) = m^{-1}\left(m(f_{\text{lo}}) + u[m(f_{\text{hi}}) - m(f_{\text{lo}})]\right), \quad (2.4)$$

y entonces $f_{\text{mín}} = \varphi(c_y - h/2)$ y $f_{\text{máx}} = \varphi(c_y + h/2)$. La consecuencia práctica es que una caja de altura constante en el marco normalizado cubre una banda mucho más ancha en la parte alta del espectro que en la baja.

De las ventanas a la grabación

Como las ventanas se solapan, una misma vocalización puede predecirse en dos o tres de ellas, y una vocalización más larga que T_w solo puede predecirse por partes. Las

predicciones de toda la grabación se llevan al marco común, se agrupan por clase y se depuran por supresión de no máximos, de modo que la lista E_k contenga un evento por vocalización. Ese es el punto en el que el nivel de ventana devuelve el control al nivel de grabación, y también el punto en el que el ventaneo deja su huella: la sección 4.4.3 documenta qué eventos quedan fuera de alcance por ser más largos que la ventana.

2.1.2. El espectrograma y la asimetría de sus ejes

La señal de audio es unidimensional, pero los eventos de interés se distinguen por cómo se distribuye su energía entre frecuencias a lo largo del tiempo. La transformada de Fourier de tiempo corto (STFT) recupera esa estructura: divide la señal en tramas solapadas, aplica una ventana a cada una y calcula su espectro. La magnitud del resultado es el espectrograma, una matriz $X \in \mathbb{R}^{F \times T}$ cuyos parámetros, como el tamaño de ventana, el salto entre ventanas y el tipo de ventana, fijan el compromiso entre resolución temporal y resolución frecuencial.

Las transformaciones que se aplican sobre esa matriz, como la escala mel, la compresión logarítmica y la normalización de energía por canal, y el criterio con el que se elige entre ellas se tratan en la sección 2.2.3, donde corresponden al eslabón de la cadena en que aparece esa decisión.

Interesa aquí una asimetría del espectrograma que conviene explicitar porque condiciona el diseño del detector. Tratarlo como una imagen es útil, pero sus dos ejes no son equivalentes: una traslación en tiempo preserva el significado del patrón, mientras que una traslación en frecuencia lo cambia: un mismo contorno desplazado media octava es otra vocalización, o ninguna. Los patrones espectro-temporales de los eventos sonoros dependen de la banda de frecuencia en que ocurren, de modo que la convolución bidimensional estándar, equivariante a traslación en ambos ejes, no es adecuada para el eje frecuencial (Nam et al., 2022). La consecuencia práctica es que el modelo debe conservar de forma explícita la posición en frecuencia en lugar de descartarla.

2.1.3. Detección de objetos sobre audio

Una vez que el sonido se representa como una matriz tiempo–frecuencia, la tarea de la ecuación (2.1) coincide con la de la detección de objetos en visión por computadora: afirmar que una clase está presente y localizarla, localización que se representa

típicamente mediante una caja delimitadora (Lin et al., 2014). La analogía no es superficial. Los eventos acústicos se manifiestan como patrones bidimensionales de tiempo y frecuencia, con texturas y estructuras geométricas propias, análogos a los objetos que aparecen en imágenes naturales (Pham et al., 2018), y el encuadre trasciende la bioacústica hacia el análisis de señales en general (Wood et al., 2022).

Familia R-CNN. Los detectores de dos etapas proponen primero regiones candidatas y luego las clasifican y refinan. Su aplicación a espectrogramas está documentada en bioacústica marina, donde las cajas predichas llevan información estadística embebida sobre la vocalización, como su duración, ancho de banda y frecuencia central, directamente utilizable por el analista (Escobar-Amado et al., 2024). NBM adapta un detector de dos etapas a datos de audio y lo acompaña de anotaciones precisas en tiempo y frecuencia recolectadas por aficionados (Airale et al., 2025).

Familia YOLO. Los detectores de una etapa predicen clase y caja en una sola pasada sobre una rejilla, lo que los hace más rápidos y más simples de entrenar. Su uso sobre espectrogramas está reportado como línea base competitiva (González et al., 2025). En audio, la idea de regresar directamente los límites del evento en lugar de clasificar tramas aparece también en YOHO, que convierte la detección en una regresión de los puntos de inicio y fin de cada clase (Venkatesh et al., 2022).

Familia DETR y transformadores. Los detectores basados en atención eliminan las anclas y la supresión de no máximos, y formulan la detección como la predicción directa de un conjunto de objetos emparejado con las anotaciones. Su adaptación al audio es reciente: SoundDet trata el audio crudo como una señal espacio-temporal y detecta eventos móviles sobre ella (He et al., 2021), y Ebbers et al. (2024) formalizan la salida como cuádruplas de clase, inicio, fin y confianza, aunque manteniéndola sobre el eje temporal.

Cajas frente a máscaras. Una alternativa a la caja es la segmentación semántica, que asigna una etiqueta a cada celda tiempo-frecuencia y describe con más fidelidad los contornos de una vocalización (Jin et al., 2022). Esta tesis opta por la caja por dos razones: es la forma en que el analista anota en Raven, y por tanto la única para la que existe una referencia disponible; y es la que se exporta sin pérdida a una tabla de selección. Una máscara exigiría reanotar el corpus completo.

2.2. Marco Conceptual

Los conceptos que siguen no se presentan por área temática sino siguiendo el recorrido de la señal, desde que el animal vocaliza hasta que el analista recibe una etiqueta revisable. Cada eslabón de ese recorrido pierde algo o introduce una ambigüedad, y es esa pérdida la que crea la necesidad del eslabón siguiente (Figura 2.2). El orden de las subsecciones es, por tanto, el orden en que aparecen los problemas.




Figura 2.2: Cadena de la señal

2.2.1. Paisaje sonoro

La bioacústica estudia el sonido en los seres vivos. En este proyecto se aplica a través del monitoreo acústico pasivo, que despliega grabadoras autónomas para capturar el paisaje sonoro de un ecosistema sin intervenir en él (Blumstein et al., 2011). Lo que la grabadora registra no es la vocalización sino la suma de todo lo que llega al micrófono, y en un entorno como la Amazonía esa suma tiene tres componentes:

Biofonía. Los sonidos de origen biológico. Incluye la señal de interés las vocalizaciones de primates y también el coro de insectos, anfibios y aves, que ocupa las mismas bandas durante horas seguidas.

Geofonía. Los sonidos de origen físico: viento, lluvia, movimiento de la vegetación. Su energía se reparte sobre bandas amplias y su carácter es o bien cuasi-estacionario o bien de ráfaga.

Antropofonía. Los sonidos de origen humano: motosierras, disparos, motores. No solo interfieren con la señal, sino que son en sí mismos un indicador de presión sobre el ecosistema (Blumstein et al., 2011).

A ello se suma la atenuación: el animal está a una distancia desconocida del sensor, de modo que la misma vocalización llega unas veces nítida y otras apenas por encima del fondo. El archivo resultante contiene, entonces, una señal mezclada, atenuada y de

relación señal-ruido variable dentro de una misma grabación. La pregunta que abre el eslabón siguiente es qué hay que buscar dentro de esa mezcla, es decir, qué constituye exactamente un evento.

2.2.2. Eventos acústicos

La vocalización se produce por el flujo de aire desde los pulmones, que hace vibrar las cuerdas vocales en la laringe y actúa como fuente sonora primaria; el tracto vocal supralaríngeo, formado por la faringe y las cavidades oral y nasal, filtra esa fuente y fija sus características finales: frecuencia fundamental, distribución de armónicos, amplitud, duración y timbre.

La consecuencia de esa estructura fuente-filtro es la que interesa aquí. La frecuencia fundamental queda determinada por la geometría y la tensión de las cuerdas vocales, y las resonancias del tracto vocal concentran la energía en un conjunto acotado de bandas. Un evento no es, por tanto, un instante con una etiqueta: es una región del plano tiempo-frecuencia con un límite inferior y un límite superior de frecuencia que dependen de la anatomía de quien vocaliza. La banda que ocupa una especie es una propiedad física de su aparato fonador, no una convención de dibujo del anotador. Esa es la razón por la que la caja tiempo-frecuencia de la ecuación (2.1) es la representación adecuada del evento, y no un rectángulo elegido por comodidad: los cuatro números que la definen tienen referente físico.

La misma estructura explica dos hechos que reaparecen más adelante. El primero es que distintas especies tienden a separarse por banda, lo que hace de la frecuencia una característica discriminante y no un dato accesorio. El segundo es que la producción vocal en primates no humanos es en gran medida innata y ligada a estados internos, con control cortical limitado, pero admite variabilidad intraespecífica, incluidos dialectos, firmas individuales y variación según el contexto, que amplía el rango de formas que el detector debe reconocer como la misma clase.

El evento existe, entonces, como región bidimensional. El problema es que la señal grabada es unidimensional: hay que recuperar esa estructura antes de poder buscarla.

2.2.3. Representaciones tiempo–frecuencia

La transformada de Fourier de tiempo corto recupera la dimensión que falta: divide la señal en tramas solapadas y calcula el espectro de cada una, con lo que produce una matriz $X \in \mathbb{R}^{F \times T}$ en la que el eje vertical es frecuencia y el horizontal, tiempo. Sobre ella se aplican dos transformaciones habituales: la escala mel, que reagrupa las bandas según una progresión aproximadamente logarítmica, y la compresión logarítmica de la magnitud a decibelios. El resultado, el espectrograma log-mel, es la entrada estándar en detección de eventos sonoros.

Ninguna de las dos transformaciones es gratuita. La longitud de la trama fija un compromiso: tramas largas resuelven la frecuencia y emborronan el tiempo, tramas cortas hacen lo contrario (Figura 2.3). Y la escala mel reparte las bandas de forma no uniforme, de modo que un mismo salto en hercios ocupa más altura en los graves que en los agudos (Figura 2.4).




Figura 2.3: Compromiso de la STFT

Esta transformación es la bisagra del planteamiento: convierte un problema de audio en un problema de análisis de imágenes, y con ello habilita el uso de las técnicas de visión por computadora descritas en la sección 2.1.1 y siguientes.

La elección de la representación no es un trámite. La compresión logarítmica no es la única opción. La normalización de energía por canal (PCEN) combina control adaptativo de ganancia y compresión de rango dinámico, y en detección bioacústica de campo fue el contribuyente principal a la mejora de precisión sobre la línea base log-mel (Lostanlen et al., 2019). El criterio que decide entre ambas no es esa cifra sino una condición del ruido: la ventaja de PCEN proviene de estimar y descontar un fondo




Figura 2.4: Escala mel

que varía lentamente respecto de la escala temporal del evento. El coro de insectos amazónico cumple esa condición, pues es cuasi-estacionario durante minutos, pero la lluvia y las ráfagas de viento no la cumplen, y sobre ellas el control de ganancia puede atenuar la propia vocalización junto con el fondo.

Dado que el corpus contiene ambos regímenes, esta tesis no da por establecida la superioridad de ninguna de las dos representaciones: las compara bajo un criterio declarado de antemano: el *recall* de eventos de baja relación señal-ruido al punto de operación fijado en la sección 1.6, y adopta la que lo maximice. Declarar el criterio antes de medir es lo que impide elegir después la representación que favorezca al resultado obtenido.

La Figura 2.5 pinta la misma ventana con las tres entradas que el detector admite: el mel de potencia sin transformar, el log-mel y PCEN.




Figura 2.5: Los tres *front-ends* sobre la misma ventana

Queda así una imagen en la que el evento es visible. Falta el mecanismo que lo localice dentro de ella.

2.2.4. Detección de eventos sonoros

La detección de eventos sonoros (SED) consiste en identificar la presencia de un evento y localizar sus límites sobre la representación tiempo–frecuencia. La distinción decisiva dentro de esta tarea, que además constituye el concepto central de esta tesis, es la *forma de la salida*, porque no todas las formulaciones que se llaman SED devuelven un evento.

Salida por segmento fijo. El sistema divide la grabación en fragmentos de duración constante y emite una probabilidad por fragmento y clase. Lo que devuelve es una rejilla puntuada, no un evento: el inicio y el fin de la vocalización quedan cuantizados al tamaño del fragmento, y su banda de frecuencia sencillamente no se estima.

Salida temporal delimitada. El sistema devuelve el instante de inicio y el de fin de cada evento, con su clase y su confianza. Es ya un evento con extensión propia, pero esa extensión existe solo sobre el eje temporal: descarta $f_{\min}$ y $f_{\max}$, que la subsección anterior estableció como magnitudes físicas del aparato fonador.

Salida tiempo–frecuencia. El sistema devuelve la tupla completa de la ecuación (2.1). Es la única de las tres formas que coincide con lo que el analista produce a mano en Raven y, por tanto, la única que puede sustituir su insumo en lugar de complementarlo.

Esta gradación es exactamente la causa C3 del árbol de problemas del Capítulo 1: la salida de los sistemas automáticos no sustituye el trabajo del analista porque su representación es más pobre que la del evento anotado. El marco conceptual la enuncia aquí como propiedad de la tarea; la sección 1.1.4 la usó como argumento de posicionamiento.

El problema impone seis exigencias, y cada familia de la literatura responde a una de ellas. Presentarlas en orden cronológico no dice nada; presentarlas por la exigencia que satisfacen permite decidir, y así las ordena la Tabla 2.1. Las vocalizaciones de primates se organizan en secuencias cuya identidad depende del orden y del espaciado de sus unidades, lo que explica por qué el contexto largo aparece como exigencia propia y no como un refinamiento del reconocimiento local.

Tabla 2.1: Arquitecturas frente a requisitos

Exigencia	Familia	Qué aporta y dónde se queda corta
Reconocer un patrón espectro-temporal local	Redes convolucionales	Aplican filtros sobre vecindades del espectrograma y superan con claridad a los detectores por energía o por flujo espectral, pero una red simple carece de robustez frente a la variabilidad del ruido (Lostanlen et al., 2019)
Sostener el contexto a lo largo de una frase	Convolucionales recurrentes	Añaden capas recurrentes sobre las características convolucionales; fueron la arquitectura predominante en las primeras ediciones de los desafíos de localización y detección de eventos sonoros (Politis et al., 2020)
Ganar profundidad sin degradación	Conexiones residuales	Permiten entrenar redes muy profundas sin pérdida de desempeño (He et al., 2016); BirdNET, referencia en identificación de aves, emplea una arquitectura de esa familia (Kahl et al., 2021)
Modelar dependencias a larga distancia sin recurrencia	Transformadores	Autoatención y procesamiento paralelo; el <i>Audio Spectrogram Transformer</i> aparece como innovación en detección bioacústica de pocos ejemplos (Nolasco et al., 2023), pero produce representaciones de una sola escala
Preservar la posición en frecuencia	Ninguna de las anteriores por sí sola	La convolución bidimensional estándar es equivariante a traslación en ambos ejes, propiedad deseable en tiempo y errónea en frecuencia; corregirlo exige adaptar el filtro a la banda (Nam et al., 2022)
Emitir $f_{\min}$ y $f_{\max}$	Cabezas de detección de objetos	Única salida que coincide con la tupla de la ecuación (2.1); es la familia descrita en la sección 2.1.3

El criterio de descarte es la forma de la salida, no el desempeño reportado. Una arquitectura solo es candidata a arquitectura final si su cabeza puede emitir $f_{\min}$ y $f_{\max}$. Bajo esa regla, las cuatro primeras familias de la Tabla 2.1 quedan descartadas *como sistema completo*, porque su formulación habitual termina en una probabilidad por trama o por segmento; ninguna queda descartada *como extractor de características*, que es el papel en el que siguen siendo pertinentes. La cabeza que sí satisface la exigencia es la de los detectores de objetos descritos en la sección 2.1.3, y por eso la arquitectura

de esta tesis combina un extractor de audio con una cabeza de detección, en lugar de adoptar una de las cuatro familias tal como se emplean en la literatura de SED.

Localizado el evento, queda el problema de nombrarlo.

2.2.5. Clasificación jerárquica

La etiqueta que el analista necesita contiene dos niveles anidados, la especie y, dentro de su repertorio, el tipo de llamada. Las unidades acústicas se agrupan en notas, trinos, sílabas, frases, motivos y cantos, y pueden estar jerárquicamente anidadas: una secuencia de unidades puede considerarse ella misma una unidad y ser reemplazada por una etiqueta única (Kershenbaum et al., 2016).

El conjunto de especies sobre el que se define el primer nivel es el de la Tabla 2.2. Los códigos de dos letras de la última columna son los que se emplean en el resto del documento.

Tabla 2.2: Especies consideradas

Nombre común (inglés)	Nombre común (español)	Nombre científico	Código
Weddell's saddle-back tamarin	Tamarino de Weddell / pichico de vientre anaranjado	<i>Leontocebus weddelli</i>	LW
Toppin's titi monkey	Tití de Toppin / huicoco	<i>Plecturocebus toppini</i>	PT
Shock-headed capuchin	Capuchino de cabeza chata / machín blanco	<i>Cebus cuscinus</i>	CC
Peruvian spider monkey	Mono araña peruano / maquisapa	<i>Ateles chamek</i>	AC
Night monkey	Mono nocturno / musmuqui	<i>Aotus azarae</i>	AA
Large-headed capuchin	Capuchino de cabeza grande / machín negro	<i>Sapajus apella macrocephalus</i>	SM
Bolivian red howler	Mono aullador rojo boliviano / coto mono	<i>Alouatta sara</i>	AS
Bolivian squirrel monkey	Mono ardilla boliviano / fraile	<i>Saimiri boliviensis</i>	SB

El segundo nivel de la etiqueta se define dentro de cada especie, sobre el vocabulario de la Tabla 2.3. Los repertorios están desbalanceados, de modo que los 41 pares

posibles no se reparten de forma pareja entre las ocho especies, y esa asimetría es la que condiciona la elección del esquema de clasificación.

Tabla 2.3: Repertorio por especie

Especie	Tipos de llamada (código: nombre)	N.º
AA <i>Aotus azarae</i>	gc: <i>gulp</i> ; hm: <i>hoot</i> ; sc: <i>squeak</i>	3
AC <i>Ateles chamek</i>	chc: <i>chitter</i> ; gc: <i>growl</i> ; cc: <i>contact</i> ; whc: <i>whinnie</i> ; sc: <i>squeak</i> ; bc: <i>bark</i>	6
AS <i>Alouatta sara</i>	hc: <i>howl</i> ; bc: <i>bark</i>	2
CC <i>Cebus cuscinus</i>	cc: <i>contact</i>	1
LW <i>Leontocebus weddelli</i>	cc: <i>contact</i> ; cs: <i>contact syllable</i> ; aa: <i>aerial alarm</i> ; ta: <i>terrestrial alarm</i> ; sqc: <i>squeal</i> ; phc: <i>phee</i> ; tr: <i>trino</i> ; tf: <i>trino fast</i> ; tt: <i>trino transition</i> ; tj [†] sin denominación; vc: <i>visual contact</i>	11
PT <i>Plecturocebus toppini</i>	dc: <i>duet</i> ; ac: <i>alarm</i> ; bp [†] <i>bellow phrase</i> ; pp [†] <i>pant phrase</i> ; sqc [†] <i>squeal</i>	5
SB <i>Saimiri boliviensis</i>	pcc: <i>peep contact</i> ; ppc: <i>play peep</i> ; lpc: <i>long peep</i> ; spc: <i>spit</i> ; sc: <i>shriek</i>	5
SM <i>Sapajus macrocephalus</i>	cc: <i>contact</i> ; acc: <i>aggressive contact</i> ; sc: <i>squeal</i> ; pc: <i>purr</i> ; whc: <i>whistle</i> ; hic: <i>hip</i> ; fc: <i>food</i> ; fs: <i>food syllable</i>	8
Total		41

[†] Categorías sin nombre establecido en la literatura del repertorio, acuñadas por el equipo de anotación. El Capítulo 4 documenta cuáles de ellas sobreviven al vocabulario cerrado y cuáles se descartan por ser unidades de nivel de frase.

Un mismo código puede designar llamadas distintas en especies distintas: **sc** es *squeak* en AA y AC, *shriek* en SB y *squeal* en SM. Por eso la unidad de etiquetado en el resto del documento es siempre el par, escrito **especie/tipo**, y nunca el código de llamada por sí solo.

Ante esa estructura caben tres esquemas. La *clasificación plana* crea una clase por cada par y trata la jerarquía como inexistente. El enfoque *local por nodo padre* entrena un clasificador de especie y, debajo, un clasificador de tipo por cada especie. El *modelo global jerárquico* aprende la estructura completa de una vez. Esta tesis adopta la clasificación plana sobre un vocabulario cerrado de pares: los esquemas jerárquicos exigen un número mínimo de ejemplos en cada nodo hijo, y el desbalance del corpus

deja varios pares con demasiados pocos como para sostener un clasificador propio. El Capítulo 4 documenta esa composición y cierra el vocabulario en consecuencia.

Queda un supuesto implícito en todo lo anterior: que la etiqueta de referencia contra la cual se entrena y se mide es un dato fijo. No lo es.

2.2.6. Anotaciones inconsistentes

Un sistema supervisado se entrena y se evalúa contra anotaciones humanas, de modo que las propiedades de esas anotaciones forman parte del planteamiento y no del apartado de limitaciones. Tres conceptos las describen.

Etiqueta fuerte y etiqueta débil. Una etiqueta *débil* declara que una clase está presente en algún lugar de la grabación, sin decir dónde; es lo que ofrecen los repositorios grandes de audio de fauna. Una etiqueta *fuerte* delimita el evento: aporta sus fronteras además de su clase. El material de esta tesis es de etiqueta fuerte y bidimensional, pues delimita también en frecuencia, lo que lo hace más informativo y, a la vez, más costoso de producir y más expuesto a desacuerdo, porque hay más decisiones que tomar por evento.

Acuerdo entre anotadores y consigo mismo. El acuerdo *inter-anotador* mide cuánto coinciden dos analistas que anotan el mismo audio; el *intra-anotador*, cuánto coincide un mismo analista consigo mismo al anotar dos veces el mismo segmento. Ambos son bajos en bioacústica: se ha medido menos del 50 % de acuerdo entre dos analistas y también un acuerdo pobre de un analista consigo mismo (Leroy et al., 2018), y la tarea genera errores específicos de cada anotador (Nguyen Hong Duc et al., 2021). Con veinte anotadores por clip, las etiquetas fuertes muestran variaciones grandes tanto en el tipo de evento como en los tiempos de inicio y fin (Koga et al., 2024).

Frontera borrosa del evento. El desacuerdo anterior no se reparte de forma uniforme: se concentra en los bordes. Una vocalización no empieza ni termina en un instante definido, sino que emerge del fondo y se desvanece en él, y lo mismo ocurre en frecuencia con los armónicos superiores. En detección de cajas tiempo–frecuencia se observan desplazamientos relativamente grandes entre la caja predicha y la anotada, de lo que se concluye que las fronteras de los eventos son borrosas y difíciles de determinar (Zhu and Sato, 2025).

Estos tres conceptos son la formulación conceptual de la causa C2 del árbol de problemas, y de ellos se siguen dos decisiones metodológicas que sin ellos parecerían arbitrarias. La primera es el **umbral de IoU bajo**: exigir un solapamiento alto entre la caja predicha y la anotada mediría el acuerdo con un borde que el propio anotador no reproduce, de modo que un umbral exigente penalizaría al modelo por no replicar ruido de etiquetado (Zhu and Sato, 2025). La segunda es el **sesgo hacia el *recall***: si el *ground truth* está sistemáticamente incompleto, porque las llamadas tenues o enmascaradas escapan tanto al método automático como al analista fatigado (Gibb et al., 2018), una parte de los falsos positivos de alta confianza son en realidad eventos válidos ausentes de la referencia, y el sistema, concebido para que un humano revise su salida, debe favorecer no perderlos. El Capítulo 5 retoma ambas decisiones al fijar el protocolo de evaluación.

Capítulo 3

Estado del Arte

3.1. Metodología de la revisión

3.1.1. Objetivos y preguntas de revisión

La revisión busca identificar y evaluar el estado del arte en técnicas de aprendizaje profundo aplicables a una solución automatizada que produzca anotaciones detalladas, que incluyen localización tiempo–frecuencia, identificación de especie y clasificación del tipo de vocalización, sobre grabaciones de monitoreo acústico pasivo de primates amazónicos. Se organiza en torno a cinco preguntas:

- P1.** ¿Qué estrategias de aprendizaje profundo han obtenido mejores resultados en la detección tiempo–frecuencia de vocalizaciones en grabaciones de monitoreo acústico pasivo capturadas en entornos ruidosos?
- P2.** ¿Qué estrategias han obtenido mejores resultados en la clasificación jerárquica fina de los eventos detectados, identificando de forma simultánea la especie y el tipo específico de vocalización?
- P3.** ¿Qué técnicas de procesamiento resultan más efectivas para mitigar el ruido ambiental y la variabilidad propia de sensores de bajo costo como AudioMoth?
- P4.** ¿Qué conjuntos de datos públicos existen con vocalizaciones etiquetadas, qué formatos de anotación emplean, y qué estrategias de aumento de datos compensan mejor la escasez y el desbalance de clases?

P5. ¿Cómo se adaptan mediante transferencia de aprendizaje los modelos preentrenados en audio general o en bioacústica de aves a las tareas de detección (P1) y clasificación jerárquica (P2)?

3.1.2. Estrategia de búsqueda

La búsqueda se ejecutó sobre dos bases indexadas. Scopus cubre publicaciones seriadas de más de cinco mil editores en 140 países e incorpora una herramienta de búsqueda asistida que agrupa los artículos relacionados con una consulta. Web of Science aporta herramientas de visualización sobre la relevancia y las tendencias de las revistas dentro de sus categorías temáticas. La Tabla 3.1 recoge las cadenas empleadas y el número de documentos recuperado en cada motor.

Tabla 3.1: Cadenas de búsqueda

Motor	Cadena de búsqueda	Docs.
Scopus	TITLE-ABS-KEY (<i>deep learning</i> OR <i>neural network*</i> OR <i>artificial intelligence</i> OR <i>transformer*</i> OR <i>machine learning</i>) AND TITLE-ABS-KEY (<i>sound event detection</i> OR <i>acoustic event detection</i> OR <i>audio event localization</i> OR <i>bioacoustic detection</i>) AND TITLE-ABS-KEY (<i>biodiversity</i> OR <i>wildlife</i> OR <i>animal vocalizations</i> OR <i>primates</i> OR <i>anthropogenic noise</i> OR <i>forest monitoring</i> OR <i>ecological monitoring</i>)	33
Web of Science	TS = (mismos tres bloques de términos, unidos por AND)	6
Total		39

Los tres bloques combinan técnica, tarea y dominio de aplicación. El asterisco es el comodín de truncamiento de ambos motores.

3.1.3. Criterios de inclusión y exclusión

Los resultados se cribaron con los criterios de la Tabla 3.2. Dos de ellos hacen el trabajo principal de filtrado y merecen explicitarse: el criterio de detección de eventos descarta los trabajos que solo clasifican la grabación completa sin localizar nada dentro de ella, y el criterio de clasificación jerárquica descarta los clasificadores binarios o de un solo nivel taxonómico. Son precisamente los dos ejes en los que se sitúa el vacío descrito en la sección 1.1.4.

Tabla 3.2: Criterios de inclusión y exclusión

Criterio	Inclusión	Exclusión
Temporalidad	Publicaciones de 2020 en adelante	Anteriores a 2020
Calidad	Revistas Q1 o conferencias de alto impacto	Revistas no indexadas o de cuartiles inferiores
Enfoque	Técnicas de aprendizaje profundo	Aprendizaje automático clásico sin componente profundo
Análisis de señal	Análisis tiempo–frecuencia	Análisis exclusivamente temporal o frecuencial
Dominio	Bioacústica, con preferencia por mamíferos y primates	Reconocimiento de voz humana sin transferencia al dominio
Entorno	Entornos naturales ruidosos, preferentemente tropicales	Entornos exclusivamente de laboratorio
Detección	Métodos que localizan el evento en tiempo y frecuencia	Métodos que clasifican la grabación completa
Clasificación	Clasificación multinivel de especie y tipo de vocalización	Clasificadores binarios o de un solo nivel
Desbalance	Técnicas para desbalance de clases y escasez de datos	Métodos que exigen grandes volúmenes etiquetados
Evaluación	Métricas completas de precisión, <i>recall</i> y F1	Trabajos sin evaluación cuantitativa
Idioma	Inglés o español	Otros idiomas

3.2. Resultados de la revisión

Ninguno de los trabajos recuperados evalúa arquitecturas de aprendizaje profundo para la detección y clasificación de vocalizaciones de primates en el contexto amazónico. Los resultados que siguen se apoyan, por tanto, en la extrapolación desde dominios bioacústicos adyacentes pero más desarrollados, sobre todo la detección de aves y la localización de eventos sonoros, que enfrentan desafíos análogos de ruido ambiental, variabilidad entre sensores y escasez de datos etiquetados (Lostanlen et al., 2019; Mee-deniyi et al., 2023).

3.2.1. P1: Estrategias de detección tiempo–frecuencia

Las redes convolucionales son la base de los sistemas que operan sobre espectrogramas. Un modelo convolucional de arquitectura relativamente simple ya supera de

forma clara a métodos tradicionales como el flujo espectral o los detectores basados en energía, aunque adolece de falta de robustez y de generalización ante la variabilidad del ruido (Lostanlen et al., 2019). Las redes convolucionales recurrentes añaden capas recurrentes para modelar dependencias temporales más largas y fueron la arquitectura predominante en las ediciones iniciales de los desafíos de localización y detección de eventos sonoros (Politis et al., 2020). Las variantes residuales facilitan el entrenamiento de redes más profundas sin degradación (He et al., 2016), y son la base de BirdNET (Kahl et al., 2021).

Los transformadores aparecen como innovación arquitectónica en detección bioacústica de pocos ejemplos, si bien la mayoría de sistemas exitosos de ese desafío siguieron usando redes convolucionales (Nolasco et al., 2023). En detección con salida bidimensional, el trabajo relevante sustituye los *backbones* preentrenados en imágenes por representaciones nativas de audio y añade una pirámide multiescala, precisamente porque las arquitecturas de tipo transformador de espectrograma producen representaciones de una sola escala (Zhu and Sato, 2025).

Del lado de la representación de entrada, la normalización de energía por canal fue el contribuyente principal a la mejora de precisión sobre la línea base de espectrograma log-mel (Lostanlen et al., 2019), y también la representación mayoritaria entre los sistemas exitosos del desafío de detección con pocos ejemplos (Nolasco et al., 2023). La elección de la representación resultó, en esos trabajos, tan determinante como la elección de la arquitectura (Bonet-Solá and Alsina-Pagès, 2021).

3.2.2. P2: Clasificación jerárquica fina

La revisión no identificó estrategias diseñadas y evaluadas explícitamente para la clasificación jerárquica fina que asigna de forma simultánea la especie y el tipo de vocalización. La literatura recuperada se concentra en tres tareas vecinas pero distintas: la detección de eventos, que localiza sin etiquetar en detalle (Lostanlen et al., 2019; Politis et al., 2020); la clasificación de especie, multiclase o multietiqueta, que identifica qué especies están presentes BirdNET reconoce 984 especies de aves (Kahl et al., 2021), y Kath et al. (2024) entrenan clasificadores lineales sobre *embeddings* para anuros; y la clasificación de eventos ya detectados en un conjunto plano de clases predefinidas (Politis et al., 2020).

La necesidad de distinguir tipos de llamada o sílabas se reconoce como un desafío de clasificación de grano fino en bioacústica, pero se enuncia como problema abierto y no como capacidad demostrada (Nolasco et al., 2023). Este es, en la revisión, el hueco más nítido y el que sostiene el eje de tarea de la sección 1.1.4.

3.2.3. P3: Mitigación de ruido y variabilidad entre sensores

Ningún trabajo recuperado prueba técnicas específicamente sobre ruido amazónico, pero varios abordan el ruido ambiental heterogéneo y la variabilidad entre sensores en despliegues de monitoreo acústico pasivo. Dos resultados son directamente aplicables.

El primero es la normalización de energía por canal como preprocesamiento del espectrograma: al combinar compresión de rango dinámico y control adaptativo de ganancia, suprime el ruido estacionario y realza los eventos transitorios, y con sus parámetros ajustados a entornos exteriores ruidosos produce distribuciones de magnitud consistentes y cuasi-gaussianas entre sensores distintos (Lostanlen et al., 2019). El segundo son las redes adaptativas al contexto, que procesan en una rama auxiliar estadísticas espectrales resumidas a largo plazo, mediante percentiles del espectrograma, y adaptan el modelo a las condiciones de cada punto de monitoreo, mejorando la robustez frente a la variabilidad espacial del ruido (Lostanlen et al., 2019). Ambas técnicas resultaron complementarias: su combinación fue lo que produjo detección robusta a escala de red de sensores.

3.2.4. P4: Conjuntos de datos y aumento de datos

Los conjuntos públicos disponibles se concentran de forma abrumadora en aves: BirdVox, Xeno-canto y la Macaulay Library. Fuera de ese taxón, la revisión identificó AnuraSet para anuros, la base de Watkins para mamíferos marinos y los conjuntos de DCASE para sonidos generales. No se encontró ningún conjunto público a gran escala etiquetado específicamente para vocalizaciones de primates, lo que confirma por una segunda vía el eje de dominio de la sección 1.1.4.

En cuanto a formatos, los eventos localizados en tiempo se distribuyen típicamente como archivos delimitados con tiempo de inicio, tiempo de fin y etiqueta de clase (Nolasco et al., 2023); en tareas de localización se añade la dirección de llegada (Politis et al., 2020); y en repositorios grandes como Xeno-canto lo habitual son etiquetas débi-

les de presencia o ausencia a nivel de grabación completa (Kahl et al., 2021). Ninguno de esos formatos registra la banda de frecuencia del evento.

Frente a la escasez y al desbalance, las técnicas reportadas son la adición de ruido de fondo realista, el desplazamiento de tono, el estiramiento temporal, el enmascaramiento de bloques de tiempo o frecuencia sobre el espectrograma y el entrenamiento con mezcla de ejemplos (Kahl et al., 2021; Lostanlen et al., 2019; Politis et al., 2020). El sobremuestreo de clases minoritarias es la respuesta habitual al desbalance, mientras que el aprendizaje sensible al costo fue probado sin mejora apreciable (Kahl et al., 2021). Cuando los ejemplos etiquetados son muy escasos, las redes prototípicas permiten adaptarse a clases nuevas con apenas cinco ejemplos (Nolasco et al., 2023).

3.2.5. P5: Transferencia de aprendizaje

La transferencia de aprendizaje es la estrategia central cuando los datos etiquetados son limitados (Kath et al., 2024). El hallazgo más útil de la revisión es que la proximidad del dominio de origen importa más que el tamaño del modelo: BirdNET, entrenado en aves, transfiere mejor a la clasificación de anuros que modelos entrenados en audio general o en imágenes (Kath et al., 2024). Eso lo posiciona como candidato razonable para transferir a primates.

Sobre el método de adaptación, la revisión distingue dos rutas. La extracción de características usa el modelo preentrenado como extractor fijo y entrena un clasificador simple sobre sus *embeddings*; la penúltima capa de BirdNET resultó particularmente efectiva en esa función (Kath et al., 2024). El ajuste fino reentrena parcial o totalmente los pesos con los pocos datos de la tarea objetivo, y exige cuidado para no sobreajustar (Nolasco et al., 2023). Ninguno de los trabajos documenta la adaptación de estos modelos a la detección con salida bidimensional ni a la clasificación jerárquica de primates.

Detección y robustez (P1, P3). No se identificó ningún estudio que aplique y evalúe modelos de aprendizaje profundo a la detección tiempo–frecuencia de primates amazónicos. La literatura de dominios vecinos sí ofrece estrategias trasladables: las arquitecturas convolucionales y convolucionales recurrentes como base (Lostanlen et al., 2019; Politis et al., 2020), las variantes residuales y los transformadores para secuencias largas (He et al., 2016; Nolasco et al., 2023), y, frente a la variabilidad del ruido, la

normalización de energía por canal junto con las redes adaptativas al contexto, cuya combinación resultó la más efectiva a escala de red de sensores (Lostanlen et al., 2019).

Clasificación jerárquica (P2). No se hallaron estrategias explícitamente diseñadas y evaluadas para asignar de forma conjunta especie y tipo de vocalización. Existen enfoques de clasificación multietiqueta sobre *embeddings* preentrenados (Kath et al., 2024), pero la tarea jerárquica específica sigue requiriendo desarrollo propio.

Datos y anotaciones (P4). Se confirma la ausencia de conjuntos públicos a gran escala etiquetados para primates y adecuados para aprendizaje profundo: el esfuerzo de la comunidad se concentra en aves. Los formatos de anotación de uso común registran tiempo de inicio, tiempo de fin y clase (Nolasco et al., 2023), y descartan la banda de frecuencia, lo que significa que incluso los conjuntos disponibles no servirían como referencia para la tarea de esta tesis sin reanotación.

Transferencia (P5). La transferencia desde dominios cercanos es la respuesta más viable a la escasez de datos etiquetados, con evidencia de transferencia exitosa de aves a otros taxones (Kath et al., 2024; Nolasco et al., 2023). Queda abierto cómo aplicarla cuando la salida deseada no es una etiqueta por segmento sino una caja tiempo–frecuencia, que es exactamente el problema que aborda el Capítulo 5.

Los dos ejes del vacío descrito en la sección 1.1.4 quedan confirmados de forma independiente por esta revisión: no hay trabajo publicado sobre primates neotropicales en este contexto (eje de dominio) y no hay estrategias establecidas para la salida bidimensional con etiquetado jerárquico (eje de tarea). El cruce de ambos ejes es la posición que ocupa esta tesis.

Capítulo 4

Curación del Conjunto de Datos (OE1)

4.1. Introducción

Este capítulo presenta los resultados alcanzados para el primer objetivo específico:

OE1. Definir un protocolo de curación y estandarización, y aplicarlo sobre las anotaciones entregadas por el equipo de investigación para construir un conjunto de datos consistente de cajas tiempo–frecuencia etiquetadas por especie y tipo de llamada.

Los tres resultados comprometidos en la Tabla 1.4 ocupan una sección cada uno: el protocolo documentado (RE1.1, sección 4.3), el conjunto curado y particionado (RE1.2, sección 4.4) y la ficha del conjunto derivado (RE1.3, sección 4.5). Cada sección describe el resultado, cómo se alcanzó con los métodos y procedimientos del Capítulo 1, cómo reproducirlo, y la verificación y las mediciones con que se comprueba su indicador. La sección 4.6 discute los tres en conjunto.

Antes de los resultados, la sección 4.2 caracteriza el material tal como se recibe: es el diagnóstico que justifica cada regla del protocolo.

4.2. El material recibido

4.2.1. Estructura y formato

El material llega en una carpeta por especie, nombrada <nombre_común>__<CÓDIGO>, con las grabaciones WAV a 44,1 kHz capturadas con dispositivos AudioMoth desplegados en el bosque y, junto a cada una, la tabla de selección que el analista exportó desde Raven Pro. La Tabla 4.1 lista las ocho especies y sus códigos. El código de la carpeta es un dato estructural, fijado una vez por sesión de campo, y el protocolo lo trata como la fuente de verdad de la especie (sección 4.3.2).

Tabla 4.1: Especies del corpus

Cód.	Especie	Carpeta
AA	<i>Aotus azarae</i>	night_monkey__AA
AC	<i>Ateles chamek</i>	peruvian_spider_monkey__AC
AS	<i>Alouatta sara</i>	howler_monkey__AS
CC	<i>Cebus cuscinus</i>	shock_headed_capuchin_monkey__CC
LW	<i>Leontocebus weddelli</i>	weddells_saddleBack_tamarin__LW
PT	<i>Plecturocebus toppini</i>	toppings_titi_monkey__PT
SB	<i>Saimiri boliviensis</i>	bolivian_squirrel_monkey__SB
SM	<i>Sapajus macrocephalus</i>	large_headed_capuchin__SM

Cada tabla de selección es un archivo de texto delimitado por tabulaciones, con una fila por caja, que Raven lee y escribe directamente (Figura 4.1).

Selection	View	Channel	Begin Time (s)	End Time (s)	Low Freq (Hz)	High Freq (Hz)	Inband Power (dB FS)	Species	Call type	Rating	Reference
1	Spectrogram	1	1.336330093	1.865888854	7560.000	10080.000	-46.04	LW	CS C		
2	Spectrogram	1	4.441470101	4.971028862	7560.000	10080.000	-67.83		noise		1
3	Spectrogram	1	1.950136839	2.449607034	7766.599	10801.822	-41.65	LW	CS B		
4	Spectrogram	1	4.558815508	5.058285703	7766.599	10801.822	-70.12		noise		3
5	Spectrogram	1	2.527837305	3.057396066	8212.955	10444.737	-41.20	LW	CS B		
6	Spectrogram	1	4.868727738	5.398286499	8212.955	10444.737	-78.54		noise		5
7	Spectrogram	1	3.135626338	3.611025680	8034.413	10266.194	-40.34	LW	CS B		
8	Spectrogram	1	4.637045780	5.112445122	8034.413	10266.194	-75.00		noise		7
9	Spectrogram	1	3.767486223	4.182708433	7588.057	9552.024	-41.43	LW	CS B		
10	Spectrogram	1	5.016161711	5.431383921	7588.057	9552.024	-68.79		noise		9
11	Spectrogram	1	1.320278575	4.166656916	7422.772	10588.366	-42.46	LW	CC B		
12	Spectrogram	1	4.407365444	5.719457935	7422.772	10588.366	-67.57		noise		11

Figura 4.1: Tabla de selección de Raven

Esa fila no se teclea: Raven deriva las cuatro coordenadas de la región rectangular que el analista dibuja sobre el espectrograma. La Figura 4.2 muestra la operación desde el otro lado, con cada caja pintada sobre la grabación.




Figura 4.2: Anotación en Raven Pro

Las columnas de especie y tipo de llamada, en cambio, sí se escriben a mano, y son las que concentran los defectos que el protocolo corrige. En el corpus aparecen 14 encabezados distintos, y no todos sobreviven: la Tabla 4.2 recoge el destino de cada uno.

Tabla 4.2: Columnas de las tablas crudas

Columna de Raven	En cleaned/	Tratamiento
Begin Time (s)	begin_time_s	Se conserva; define el lado izquierdo de la caja
End Time (s)	end_time_s	Se conserva; lado derecho
Low Freq (Hz)	low_freq_hz	Se conserva; lado inferior
High Freq (Hz)	high_freq_hz	Se conserva, recortada a Nyquist
Species	species	Se reemplaza por el código de la carpeta
Call type	call_type	Se normaliza y se mapea al vocabulario
Selection, View, Channel		Estado interno de Raven; se descartan
Begin File, File Offset (s), Reference		Referencias al archivo; se descartan
Inband Power (dB FS), Rating		No se usan; no llegan a cleaned/

4.2.2. Inventario

El corpus de primates tiene 3 356 grabaciones y 2 835 tablas de anotación. De ellas, 2 823 tienen una grabación homónima junto a ellas, 12 no la tienen y 4 no pueden leerse por estar vacías o truncadas. Las tablas emparejadas suman 20 082 filas crudas, que son el punto de partida de todo lo que sigue.

4.2.3. Defectos detectados

El análisis exploratorio del material reveló cinco problemas que impiden usarlo directamente para entrenar.

Inconsistencias de etiquetado. Una misma clase aparece escrita de varias formas. La columna de tipo de llamada trae 63 valores distintos escritos a mano y la de especie, 19 (Figuras 4.3 y 4.4). Entre ellos conviven mayúsculas y minúsculas, espacios finales, separadores y errores de escritura: CS, CS_□, CS_{□□}A, contact syllable, noise|, noises, _□BC y bC designan tres clases, no ocho.

```
print("\nEspecies únicas en el dataset:")
print("-----")
for i, especie in enumerate(raw_annotations["specie"].unique(), 1):
    print(f"{i}. {especie}")

✓ 0.0s

Especies únicas en el dataset:
-----
1. CC
2. PT
3. nan
4. LW
5. 8
6. -
7. PTD
8. LW
9. L
10. }
11. AS
12. AC
13. AC
14. SM
15. AA
16. AN
17. SN
18. #
19. AS-----AS
20. SB
```

Figura 4.3: Valores en la columna de especie

```
print("Tipos de llamadas únicas en el dataset:")
print("-----")
for i, call in enumerate(raw_annotations["call_type"].unique(), 1):
    print(f"{i}. {call}")

✓ 0.0s

Tipos de llamadas únicas en el dataset:
-----
1. CC
2. nan
3. BP
4. PP
5. AC
6. DC
7. SQC
8. D
9. CHC
10. CS
11. noise
12. AA
13. A
14. B
15. TA
16. C
17. CS
18. CS A
19. noise
20. contact call
21. contact syllable
22. TT
23. TR
24. VC
25. TJ
26. TC
27. noise|
28. noises
```

Figura 4.4: Valores en la columna de tipo de llamada

Integridad de los archivos. La carga automatizada de las grabaciones emite advertencias sobre archivos de audio dañados (Figura 4.5), que detienen el proceso si no se manejan de forma explícita. La corrupción se manifiesta como bloques de ceros en la señal y admite grados: la Figura 4.6 muestra un caso leve y la Figura 4.7 uno en el

que la mayor parte del archivo es inutilizable. El origen probable son cortes durante la transferencia o fallos del medio de almacenamiento.

```
Procesando 2674 archivos de audio...
=====
⚠ ADVERTENCIA en 20240117_060129.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240117_163024.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240207_102952.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240214_102327.wav: Anotaciones exceden duración del audio (7.65s > 6.87s)
⚠ ADVERTENCIA en 20240214_102452.wav: Anotaciones exceden duración del audio (5.92s > 5.13s)
⚠ ADVERTENCIA en 20240214_102634.wav: Anotaciones exceden duración del audio (13.15s > 13.11s)
⚠ ADVERTENCIA en 20240415_114228.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240429_104951.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240504_080326.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240510_065700.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240510_071046.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240516_081806.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240516_081815.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240530_110626.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240621_074433.wav: Anotaciones exceden duración del audio (30.69s > 27.25s)
⚠ ADVERTENCIA en 20240805_091140.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240805_091302.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154436.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154640.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154724.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154800.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240813_092636.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240815_170844.wav: El espectrograma contiene ceros.
```

Figura 4.5: Avisos de audio dañado




Figura 4.6: Corrupción leve




Figura 4.7: Corrupción severa

Discrepancias entre especie escrita y carpeta. La etiqueta de especie de la anotación no siempre coincide con el código de la carpeta contenedora: en 879 filas la columna viene vacía y en 129 trae un valor distinto. Hay que decidir cuál de las dos fuentes prevalece antes de consolidar nada.

Frecuencias por encima de Nyquist. 8 cajas declaran una frecuencia superior mayor que el límite de Nyquist de la señal (22 050 Hz a 44,1 kHz de muestreo), un valor que no puede corresponder a energía observable en la grabación.

Variabilidad en la unidad de análisis. La granularidad de las anotaciones no es uniforme: en unos casos el analista etiquetó sílabas individuales y en otros delimitó la secuencia completa con una sola caja. No es un error de anotación sino la manifestación

directa del anidamiento jerárquico de las unidades acústicas (Kershenbaum et al., 2016) descrito en el Capítulo 2; la sección 4.4.1 lo cuantifica y decide qué hacer con él.

4.3. Protocolo de curación y estandarización documentado (RE1.1)

Resultado. Un protocolo documentado que convierte las anotaciones entregadas por el equipo de investigación en un conjunto consistente de cajas tiempo–frecuencia etiquetadas por especie y tipo de llamada. Define la normalización de columnas y etiquetas, el mapa de sinónimos, el descarte de ruido y de cajas degeneradas, la corrección de pares imposibles, el recorte al límite de Nyquist y el tratamiento de los registros fuera de vocabulario, que son los siete elementos que exige su indicador (Tabla 1.4).

Cómo se alcanzó. El protocolo es un programa, no una edición manual del material recibido. La distinción importa: un protocolo ejecutable vuelve a aplicarse sobre los datos primarios cada vez que una regla cambia, y deja registro de qué descarta y por qué; una corrección a mano no es reproducible ni auditable. El guion `src/prepare_annotations.py` recorre `data/raw/`, aplica las reglas de `src/data/annotations.py` en el orden de la Figura 4.8 y escribe `data/cleaned/`.

Medio de verificación. Esta sección, que es el documento del protocolo; su implementación en los dos archivos citados; y las cifras de la Tabla 4.6, que cuentan qué toca cada regla sobre las 20 082 filas crudas.

4.3.1. Esquema del protocolo

La Figura 4.8 recorre el protocolo de la entrada a la salida. Las reglas se aplican en el orden mostrado y cada una tiene su apartado más abajo; la unión de copias es la única que se aplica al cargar `cleaned/` y no al escribirlo, porque necesita ver todas las carpetas a la vez.

4.3.2. Reglas

Emparejamiento con la grabación. Sólo se procesa la tabla que tiene una grabación homónima junto a ella. El nombre del `.wav` se obtiene del de la tabla quitando el sufijo `.Table.1.selections` que Raven añade, y tolerando un espacio final. Una tabla




Figura 4.8: Reglas del protocolo

huérfana no aporta nada entrenable y su presencia suele indicar un error de transferencia: se omite y se lista en el registro. Una tabla ilegible se captura sin detener el proceso y también se registra.

Normalización de columnas. Los encabezados se convierten a `snake_case` programático (`Begin Time (s)` → `begin_time_s`). Un solo paso absorbe las variantes de mayúsculas y espacios, y hace que el resto del código dependa de un nombre estable. Las columnas de estado interno de Raven se descartan: describen la sesión de trabajo, no el evento.

Normalización del tipo de llamada. Sobre la columna manual se aplican, en este orden, dos reglas. La *normalización tipográfica* reduce toda etiqueta a minúsculas y a caracteres alfanuméricos separados por guion bajo; el paso absorbe mayúsculas, espacios y signos sin necesidad de enumerarlos, y en 52 filas el valor cambia más allá de la mayúscula. El *mapa de sinónimos* (Tabla 4.3, 10 entradas) unifica lo que la tipografía

no captura por ser un error de escritura o una abreviatura alternativa; a él se suma, por especie, la traducción del nombre legible al código (`contact syllable` $\rightarrow$ `cs`), de modo que las tablas escritas en prosa converjan con las escritas en código. Toca 105 filas.

Tabla 4.3: Mapa de sinónimos

Escrito	Código
<code>noises</code>	<code>noise</code>
<code>cs_a</code>	<code>cs</code>
<code>whinnie</code>	<code>whc</code>
<code>tca</code>	<code>ta</code>
<code>tac</code>	<code>ta</code>
<code>contact</code>	<code>cc</code>
<code>chcj</code>	<code>chc</code>
<code>php</code>	<code>phc</code>
<code>sqr</code>	<code>sqc</code>
<code>tc</code>	<code>tr</code>

Asignación de especie por directorio. La columna `Species` se reemplaza por el código de la carpeta contenedora. El criterio no es arbitrario: el directorio se fija una vez por sesión de campo, mientras que la columna se teclea en cada fila, y es donde se acumulan los errores de la sección 4.2.3. Pero una llamada de otra especie anotada dentro de una carpeta, si es real, no debe recibir la especie de la carpeta: la fila conserva lo escrito en `written_species` y se marca `requires_review`, de modo que ni entra al experimento con la especie equivocada ni se descarta en silencio. La unión de copias resuelve el caso en que esa llamada sí está anotada en su propia carpeta.

Descarte de ruido. Las filas cuyo tipo de llamada normalizado es `noise` (866) marcan la ausencia de evento, no un evento, y se eliminan. El fondo que el detector debe aprender a no proponer entra al conjunto por otra vía (las ventanas vacías de la sección 4.4.3) y no por estas filas. Las 180 filas sin tipo de llamada, en cambio, son cajas que el analista dibujó sobre un evento: no se eliminan, se marcan para revisión.

Corrección de pares imposibles. Un conjunto pequeño de correcciones explícitas resuelve pares que no existen en el repertorio de la especie y cuya intención es inequívoca: `aa/hc` pasa a `aa/hm`, porque *Aotus azarae* no tiene llamada de aullido pero sí de

ululato (23 filas). Toda corrección de este tipo se declara en código (**MANUAL_FIXES**); ninguna se aplica a mano sobre los datos.

Vocabulario cerrado y marca de revisión. El vocabulario admisible se declara como el conjunto de pares (especie, tipo de llamada) válidos del dominio (41 pares, Tabla 4.4), no como aquello que aparezca en los datos. Cerrar el vocabulario responde a que las definiciones de unidad y las etiquetas semánticas varían ampliamente entre investigadores, incluso dentro de un mismo grupo taxonómico (Kershenbaum et al., 2016): sin una lista fija, la misma señal recibe etiquetas distintas según quién la anote.

Tabla 4.4: Vocabulario cerrado

Esp.	Tipos	Códigos de tipo de llamada
AA	3	gc (gulp call), hm (hoot call), sc (squeak call)
AC	6	chc (chitter call), gc (growl call), cc (contact call), whc (whinnie call), sc (squeak call), bc (bark call)
AS	2	hc (howl call), bc (bark call)
CC	1	cc (contact call)
LW	11	cc (contact call), cs (contact syllable), aa (aerial alarm call), ta (terrestrial alarm call), sqc (squeal call), phc (phee call), tr (trino call), tf (trino fast call), tj (unofficial tj call), tt (trino transition call), vc (visual contact call)
PT	5	dc (duet call), ac (alarm call), bp (unofficial bellow phrase), pp (unofficial pant phrase), sqc (unofficial squeal call)
SB	5	pcc (peep contact call), ppc (play peep call), lpc (long peep call), spc (spit call), sc (shriek call)
SM	8	cc (contact call), acc (aggressive contact call), sc (squeal call), pc (purr call), whc (whistle call), hic (hip call), fc (food call), fs (food syllable)

Toda fila que no pueda asignarse con certeza a un par del vocabulario se marca con la bandera **requires_review** en lugar de eliminarse. Son tres los motivos: el par (especie de la carpeta, tipo) no está en el vocabulario (336 filas), el tipo de llamada viene vacío (180) o la especie escrita difiere de la carpeta (129). En **data/cleaned/** quedan así 643 anotaciones marcadas, el 3,3 % del total, repartidas en 45 pares distintos; los 32 pares que el vocabulario no reconoce, con 516 anotaciones, son los de la Tabla 4.5.

La diferencia con descartarlas es deliberada, y la razón es que **no hay forma de distinguir un error de escritura de una subdivisión legítima del repertorio**. Entre los pares fuera de vocabulario conviven las dos cosas: variantes tipográficas que el mapa de sinónimos no previó, y códigos que parecen subdivisiones no documentadas

Tabla 4.5: Pares marcados para revisión

Par	Filas	Par	Filas
as/cp	91	sb/phc	3
as/pp	85	as/pc	3
as/ip	73	sm/chc	3
as/	53	lw/c	3
sm/	47	cc/	2
pt/	30	sb/cc	1
ac/	21	sb/hic	1
lw/a	20	as/chc	1
lw/b	15	sm/spc	1
lw/	15	aa/hf	1
sb/	11	aa/	1
sb/pcs	8	pt/d	1
sm/hc	8	pt/chc	1
aa/sqc	6	lw/t	1
as/cc	4	lw/chc	1
sm/sic	4	lw/lw	1

de un tipo de llamada ya conocido: **as/cp**, **as/pp** e **as/ip** sobre *Alouatta sara* son el caso más visible. Decidir cuál es cuál exigiría una referencia del repertorio vocal que no acompaña a las anotaciones, de modo que el protocolo no decide: marca y conserva. **cleaned/** los guarda con la bandera y RE1.2 los deja fuera del experimento (no entran como clase, y toda ventana que los pisa se descarta para no enseñarlos tampoco como fondo), pero la evidencia queda intacta para cuando el vocabulario se amplíe. El capítulo asume, y así lo declara la sección 4.5.9, que el material llega sucio en la columna de tipo de llamada: es una limitación del conjunto y, a la vez, el margen más claro de mejora para una versión futura del detector.

Saneamiento geométrico. Las coordenadas de la caja se validan con independencia de la etiqueta. La frecuencia superior se *recorta a Nyquist* (22 050 Hz): por encima de la mitad de la frecuencia de muestreo no hay energía observable en una señal a 44,1 kHz, de modo que un valor mayor (8 filas) es un error de anotación y no una propiedad del evento. Se *descartan las cajas degeneradas*, de duración inferior a 10 ms o de ancho de banda nulo o negativo (3 filas): una caja sin área no define una región y no puede emparejarse con ninguna predicción. Y se calculan la *duración* y el *ancho de banda* de cada caja, sobre los que se construye el análisis de geometría de la sección 4.5.3.

Unión de copias de una misma grabación. Al cargar `cleaned/` se detecta que una misma grabación está copiada, byte a byte, en dos o tres carpetas de especie, y que cada copia lleva sólo las anotaciones de la especie de su carpeta. Tratarlas como grabaciones distintas deja la llamada de la otra especie sin anotar en cada copia, da supervisión contradictoria sobre el mismo audio y permite que caiga en dos particiones distintas, con la consiguiente fuga entre entrenamiento y prueba. La regla identifica las copias por tamaño y huella MD5 del primer megabyte, las funde en una sola grabación con la unión de sus anotaciones y descarta las anotaciones repetidas. En el corpus hay 128 copias, que reducen las grabaciones anotadas a 2 691.

4.3.3. Verificación de RE1.1

La Tabla 4.6 es la medición que verifica este resultado: cuenta, para cada regla del indicador, cuántas filas toca sobre las 20 082 crudas. El protocolo conserva 19 213 anotaciones, el 95,7 %, y casi todo lo que descarta es ruido marcado como tal por el propio analista. La Tabla 4.7 mide el efecto de la normalización desde el otro lado: cuántos valores distintos quedan en las dos columnas manuales tras cada etapa, de 63 grafías de tipo de llamada a 31 códigos del vocabulario.

La auditoría de la Tabla 4.6 vuelve a aplicar el protocolo sobre `data/raw/` y llega a 19 213 anotaciones, 2 más que las 19 211 que quedan en `data/cleaned/`. La diferencia está localizada y es instructiva: la auditoría trabaja sobre la tabla completa en memoria, que conserva las columnas de medición de Raven, mientras que `cleaned/` guarda sólo las ocho columnas del protocolo (Tabla 4.17); dos pares de anotaciones de una misma grabación son idénticas en esas ocho columnas y sólo se distinguen por **Inband Power**, de modo que la unión de copias las funde en una. Que ambas cifras se puedan comparar y que su diferencia se pueda explicar fila por fila es, en sí mismo, la propiedad que persigue un protocolo ejecutable.

Cada pasada deja un registro de lo que hizo: cuántas grabaciones y anotaciones salieron, cuántas quedaron marcadas para revisión, cuántas tablas resultaron ilegibles y cuáles no tenían grabación al lado. La unión de copias ocurre en `data.annotations.load_annotations()`, que es la única puerta por la que el resto del trabajo lee las anotaciones, de modo que ninguna etapa posterior puede ver las copias sin unir.

Tabla 4.6: Filas que toca cada regla

Regla	Filas	Tratamiento
Tablas sin grabación homónima	12	se omiten
Tablas ilegibles	4	se omiten y se registran
Filas crudas en tablas con audio	20 082	punto de partida
Tipo de llamada con espacios o signos de más	52	se normaliza
Tipo de llamada por sinónimo o nombre legible	105	mapa explícito
Especie vacía	879	la de la carpeta
Especie escrita distinta de la carpeta	129	la de la carpeta + requires_review
Tipo de llamada vacío	180	requires_review
Tipo de llamada noise	866	se descarta
Par imposible corregido	23	aa/hc → aa/hm
Frecuencia superior por encima de Nyquist	8	se recorta a 22 050 Hz
Caja degenerada (< 10 ms o sin banda)	3	se descarta
Par fuera de vocabulario	336	requires_review
Copias del mismo audio en otra carpeta	128	se unen a su original
Anotaciones repetidas entre copias	0	se descartan
Anotaciones conservadas	19 213	→ data/cleaned/
De ellas, marcadas requires_review	643	fuera del experimento (RE1.2)

Tabla 4.7: Valores distintos tras cada etapa

Etapas	Especie	Tipo de llamada
crudo	19	63
tipografía	15	55
sinónimos	8	42
vocabulario	8	31

La especie converge a ocho valores porque la fija la carpeta; el tipo de llamada converge al vocabulario de la Tabla 4.4.

4.3.4. Fuera de alcance

- No corrige coordenadas más allá del recorte a Nyquist ni desplaza cajas: la geometría dibujada por el analista se respeta tal cual.
- No resuelve el anidamiento frase-sílaba; esa decisión se toma al seleccionar las clases del experimento (sección 4.4.1), porque depende de la forma de salida del detector y no de la calidad de la anotación.
- No mide el acuerdo entre anotadores. Sin una doble anotación de una muestra, el error de etiquetado residual no puede separarse del error del modelo; la ficha lo declara como limitación.
- No decide qué hacer con las anotaciones marcadas `requires_review`: las conserva y las deja al equipo de investigación.

4.4. Conjunto acústico curado y particionado (RE1.2)

Resultado. El directorio `data/processed/`: las 25 clases del experimento, la partición por grabación en proporción 60,0 / 22,5 / 17,5 y el caché de 38 713 ventanas de 3 s con 44 983 cajas normalizadas, más los metadatos que permiten reconstruirlo.

Cómo se alcanzó. `src/prepare_data.py` parte de las 19 211 anotaciones de `data/cleaned/`, aplica las cuatro reglas de selección de clases de la sección 4.4.1, reparte las grabaciones enteras con el algoritmo de la sección 4.4.2, segmenta cada grabación en ventanas (sección 4.4.3) y materializa el espectrograma mel de cada una (sección 4.4.4). La Figura 4.9 resume el recorrido.

Medio de verificación. El propio directorio `data/processed/`: tres archivos `.pt`, `labels.json`, `meta.json` y los `*_sources.json`. La sección 4.4.5 comprueba los tres extremos que pide el indicador.

4.4.1. Selección de clases

Las anotaciones curadas cubren 37 pares (especie, tipo de llamada) del vocabulario. No todos pueden ser clase de un detector, y el paso de uno a otro sigue cuatro reglas declaradas en `src/prepare_data.py` y registradas en `meta.json`.




Figura 4.9: De las anotaciones curadas al caché

1. **Anotaciones en revisión.** Las 643 filas marcadas `requires_review` por RE1.1 no entran como clase, y toda ventana que las pisa se descarta del caché: hasta que el equipo las resuelva no se enseñan ni como caja ni como fondo.
2. **Exclusión por anidamiento.** Se retiran las clases de *frase*, por la razón que desarrolla la sección 4.4.1.
3. **Fusión de variantes.** Los tipos de trino de LW se reúnen en `lw/trino`, y el pío largo `sb/lpc` se une al pío de juego `sb/ppc`. Las variantes comparten banda y duración casi por completo (sección 4.5.3) y por separado no alcanzan el umbral de la regla siguiente.
4. **Umbral de frecuencia.** Se conservan los pares con al menos 100 anotaciones. Por debajo de ese piso una clase no sostiene ni entrenamiento ni evaluación por clase.

El resultado son 25 clases con 17 495 anotaciones, el 93,6 % del material en vocabulario. La Figura 4.10 sitúa el umbral sobre la distribución completa de pares y la Tabla 4.8 lista los 44 pares del vocabulario que quedan fuera, con 1 595 anotaciones. Entre los 41 que no alcanzan el umbral está `cc/cc`, la única llamada de *Cebus cuscinus*, de modo que el experimento cubre 7 de las 8 especies.

La elección del umbral en 100 y no más arriba responde a una tensión que conviene enunciar. Un umbral alto produce un experimento cómodo (pocas clases, todas abundantes) a costa de dejar sin cubrir la mayor parte del repertorio documentado. Bajarlo hasta 100 cubre el 93,6 % del material y hace que cinco especies aporten entre dos y cinco clases en lugar de una, al precio de admitir clases cuyo desempeño estará




Figura 4.10: Anotaciones por par

limitado por su propia escasez y no por la arquitectura. El Capítulo 5 lee los resultados por clase con esa distinción presente.

Sílabas y frases

Una *frase* es una secuencia de *sílabas*, y los expertos anotan ambas: el 94,2 % de las frases *lw/cc* contienen al menos una sílaba *lw/cs*, y el 96,8 % de las frases *sm/fc* contienen una sílaba *sm/fs*. El mismo tramo de audio lleva, por tanto, una caja grande y varias pequeñas dentro de ella (Figura 4.11).

El detector no puede representar esa relación. Devuelve una lista plana de cajas, y el emparejamiento durante el entrenamiento asocia cada anotación con exactamente una predicción, sin manera de expresar que una caja contiene a otra. Conservar ambos niveles equivaldría a pedirle que informe dos veces el mismo sonido, como si fueran dos eventos superpuestos sin relación. Es la consecuencia operativa del anidamiento

Tabla 4.8: Pares excluidos del experimento

Par	Tipo de llamada	Anot.	Motivo
lw/cc	contact call	536	excluida (frase)
sm/fc	food call	126	excluida (frase)
as/cp		91	marcada para revisión
as/pp		85	marcada para revisión
lw/aa	aerial alarm call	80	< 100 anotaciones
sm/whc	whistle call	76	< 100 anotaciones
as/ip		73	marcada para revisión
as/		53	marcada para revisión
sm/		47	marcada para revisión
pt/ac	alarm call	44	< 100 anotaciones
pt/pp	unofficial pant phrase	43	< 100 anotaciones
pt/bp	unofficial bellow phrase	39	< 100 anotaciones
ac/whc	whinnie call	35	< 100 anotaciones
lw/phc	phee call	34	< 100 anotaciones
pt/		30	marcada para revisión
ac/cc	contact call	29	< 100 anotaciones
cc/cc	contact call	29	< 100 anotaciones
ac/		21	marcada para revisión
lw/a		20	marcada para revisión
lw/b		15	marcada para revisión
lw/		15	marcada para revisión
sb/		11	marcada para revisión
sb/pcs		8	excluida (frase)
sm/acc	aggressive contact call	8	< 100 anotaciones
sm/hc		8	marcada para revisión
aa/sqc		6	marcada para revisión
as/cc		4	marcada para revisión
sm/sic		4	marcada para revisión
sb/phc		3	marcada para revisión
as/pc		3	marcada para revisión
sm/chc		3	marcada para revisión
lw/c		3	marcada para revisión
cc/		2	marcada para revisión
sb/cc		1	marcada para revisión
sb/hic		1	marcada para revisión
as/chc		1	marcada para revisión
sm/spc		1	marcada para revisión
aa/hf		1	marcada para revisión
aa/		1	marcada para revisión
pt/d		1	marcada para revisión
pt/chc		1	marcada para revisión
lw/t		1	marcada para revisión
lw/chc		1	marcada para revisión
lw/lw		1	marcada para revisión

jerárquico que Kershenbaum et al. (2016) describen como propiedad general de las unidades acústicas animales: una secuencia de unidades puede ella misma considerarse una unidad. Las clases de frase se excluyen, en consecuencia, antes del entrenamiento.




Figura 4.11: Anidamiento frase-sílaba

4.4.2. Partición por grabación

Regla. La unidad de partición es la *grabación*: todas las ventanas de un mismo archivo caen en la misma partición. Repartir ventanas sueltas dejaría dos ventanas solapadas de una misma anotación en particiones distintas, y la prueba mediría memoria en lugar de generalización (Koga et al., 2024).

La alternativa no es un descuido hipotético. El prototipo inicial de este trabajo la cometió: barajaba los clips y los repartía por índice, con lo que dos ventanas solapadas de la misma anotación podían quedar una en entrenamiento y otra en prueba. Sobre esa partición el clasificador alcanzaba un 99 % de exactitud, una cifra que no medía generalización sino memoria.

Algoritmo. La asignación es golosa y estratificada por clase (`split_manifest` en `src/data/manifest.py`); la Figura 4.12 la esquematiza.

1. Se cuenta, por grabación, cuántas cajas de cada clase contiene, y se fija como objetivo de cada partición la fracción 60,0 / 22,5 / 17,5 del total de cada clase.
2. Las clases se recorren **de la más rara a la más común**. Para cada clase, las grabaciones que la contienen y aún no están asignadas se ordenan de más a menos

cajas de esa clase, y cada una va a la partición con mayor déficit en esa clase; en caso de empate, a la que tenga menos ventanas respecto de su objetivo.

3. Las grabaciones sin cajas de ninguna clase (las ventanas vacías de la sección 4.4.3) van donde falten ventanas.

Recorrer las clases de la más rara a la más común hace que el reparto de las escasas se decida primero y no quede como residuo del de las abundantes: una clase con un centenar de anotaciones concentradas en pocas grabaciones podría, de otro modo, caer entera en una sola partición. La semilla (42) fija el orden inicial de las grabaciones y hace la partición reproducible.




Figura 4.12: Reparto goloso por grabación

Composición. La Tabla 4.9 recoge la composición de las tres particiones tras el ventaneo, y la Tabla 4.10 la desglosa por clase. La proporción de entrenamiento se conserva clase a clase (última columna) mientras que el desbalance entre clases se mantiene, con 23 veces entre **ac/bc** (2838 cajas de entrenamiento) y **sb/sc** (126). La Figura 4.13 muestra ambos hechos a la vez.

4.4.3. Ventaneo

Regla de asignación. Las grabaciones tienen duración variable y el detector consume entradas de tamaño fijo, de modo que cada grabación se segmenta en ventanas de 3 s que avanzan 1,5 s. Una anotación entra en una ventana si el solapamiento entre ambas cubre al menos la mitad de la *parte visible* del evento, definida como el mínimo entre su duración y la longitud de la ventana (Figura 4.14). Comparar contra la duración completa dejaría inalcanzable a todo evento de más de 6 s, porque no hay posición de la

Tabla 4.9: Composición de las particiones

Partición	Grabaciones	Ventanas	Vacías	% vacías	Cajas	GB
Entrenamiento	1 248	21 751	4 608	21,2 %	26 938	3,44
Validación	690	9 364	2 713	29,0 %	10 114	1,48
Prueba	601	7 598	2 357	31,0 %	7 931	1,20
Total	2 539	38 713	9 678	25,0 %	44 983	6,13

Hay más cajas que anotaciones porque una anotación puede caer en dos ventanas consecutivas: la ventana de 3 s avanza 1,5 s (sección 4.4.3).

1 grabación del conjunto de experimento está dañada y no puede leerse: no entra al caché aunque tenga anotaciones, y por eso el total de grabaciones es menor que las 2527 que aportan alguna anotación de alguna clase.

Tabla 4.10: Las 25 clases del experimento

Clase	Tipo de llamada	Anot.	Grab.	Train	Val	Test	Train %
ac/bc	bark call	2 453	137	2 838	1 065	828	60 %
lw/cs	contact syllable	2 279	248	2 667	1 000	779	60 %
sm/cc	contact call	2 031	466	2 353	883	686	60 %
as/bc	bark call	1 894	236	2 216	831	647	60 %
as/hc	howl call	1 375	697	6 933	2 599	2 021	60 %
sb/ppc	play peep call (ppc, lpc)	1 189	191	1 340	529	464	57 %
aa/gc	gulp call	797	58	922	345	269	60 %
sb/spc	spit call	729	166	859	323	250	60 %
sm/fs	food syllable	691	89	799	301	232	60 %
lw/trino	trino (tr, tj, tt, tf)	633	122	739	278	216	60 %
pt/dc	duet call	632	292	1 944	729	567	60 %
pt/sqc	unofficial squeal call	387	13	465	161	138	61 %
sb/pcc	peep contact call	290	95	341	128	100	60 %
lw/ta	terrestrial alarm call	265	80	311	116	91	60 %
sm/hic	hip call	254	61	296	111	86	60 %
sm/pc	purr call	242	83	283	106	83	60 %
ac/chc	chitter call	229	142	281	105	82	60 %
sm/sc	squeal call	163	33	195	73	56	60 %
aa/sc	squeak call	159	33	183	68	53	60 %
ac/sc	squeak call	158	31	188	71	54	60 %
lw/sqc	squeal call	154	43	182	69	52	60 %
ac/gc	growl call	140	65	191	71	56	60 %
aa/hm	hoot call	127	24	148	54	44	60 %
lw/vc	visual contact call	119	44	138	52	40	60 %
sb/sc	shriek call	105	51	126	46	37	60 %
Total		17 495	2 527	26 938	10 114	7 931	60 %

Las tres columnas de partición cuentan cajas en ventanas del caché, no anotaciones. as/hc y pt/dc multiplican su material porque cada llamada larga atraviesa varias ventanas (Tabla 4.11).




Figura 4.13: Cajas por clase y partición

ventana en la que quepa la mitad de un aullido de 30s; con la parte visible, ese aullido entra en toda ventana que caiga dentro de él y ninguna anotación del experimento queda sin ventana. Al entrar, la caja se recorta a los límites de la ventana.

Efecto sobre los eventos largos. Lo que el ventaneo cobra es la fragmentación, y la Tabla 4.11 la mide. Cada anotación se reparte, en promedio, entre 2,6 ventanas (el salto de 1,5s hace que casi todo evento breve aparezca en dos), pero las dos clases largas, *as/hc* y *pt/dc*, se reparten entre ocho y cinco. Casi todas sus cajas tocan al menos un borde temporal de la ventana y en la mayoría ocupan la ventana entera: *as/hc* aporta 8,4 cajas por anotación, el 99,6 % de ellas tocando un borde y el 77,5 % ocupando la ventana de lado a lado. Entre las dos aportan el 33 % de las cajas del conjunto.




Figura 4.14: Asignación de eventos a ventanas

Tabla 4.11: Efecto del ventaneo en las clases largas

Clase	Anot.	Cajas	Cajas por anotación	Anot. > 3 s	Cajas en el borde	Ventana entera
as/hc	1 375	11 553	8,4	94,7 %	99,6 %	77,5 %
pt/dc	632	3 240	5,1	91,0 %	99,2 %	63,5 %
Resto (23 clases)	15 488	30 190	1,9	0,3 %	12,1 %	0,2 %
Total	17 495	44 983	2,6	11,0 %	40,8 %	24,6 %

Una caja está en el borde cuando su lado temporal izquierdo o derecho coincide con el límite de la ventana, es decir, cuando el evento continúa fuera de ella; ocupa la ventana entera cuando toca los dos.

Esto se consigna aquí, y no entre las limitaciones, porque determina la lectura de los resultados por clase del Capítulo 5 en dos direcciones opuestas. Por un lado, las dos clases largas se vuelven las *más fáciles* del conjunto: una caja que ocupa la ventana completa se acierta con casi cualquier predicción grande. Por otro, al aportar el 33 % de las cajas, dominan cualquier cifra agregada: un *recall* global que las incluya mide, en un tercio de su peso, la capacidad de dibujar un rectángulo del tamaño de la ventana. Por eso el Capítulo 5 reporta el promedio por clase junto al agregado, y no en su lugar.

Ventanas vacías. A las ventanas con al menos una anotación se suma un 25 % de ventanas *vacías*, tomadas al azar (semilla 42) de tramos sin ninguna llamada y sin ningún evento a medias: una ventana que ve menos de la mitad de una llamada no cuenta como vacía. Sin ellas el modelo nunca ve fondo puro (selva, lluvia, insectos) y aprende que en toda entrada hay algo que reportar, que es justamente el sesgo que

paga la carga de revisión. Son 9 678 ventanas, el 25,0 % del total; su proporción difiere entre particiones porque se reparten por grabación, no por ventana.

Densidad de eventos por ventana. La mediana de cajas por ventana con contenido es 1, el máximo 11 y el 97 % de las ventanas lleva cuatro o menos (Figura 4.15). El Capítulo 5 fija sobre el máximo, y no sobre la mediana, el número de predicciones simultáneas del decodificador.




Figura 4.15: Cajas anotadas por ventana

4.4.4. Representación de entrada

Espectrograma log-mel. Cada ventana se transforma en un espectrograma mel de potencia con los parámetros de la Tabla 4.12, y el caché guarda ese mel sin comprimir, en `float32`. La compresión logarítmica y la normalización de energía por canal se aplican como primera capa de cada modelo (Capítulo 5), de modo que un mismo caché sirve a todos. Los once parámetros fijan el espectrograma de principio a fin: `torchaudio.transforms.MelSpectrogram` instanciada con estos valores lo reproduce.

Normalización de las cajas. Las cajas se guardan en formato centro, ancho y alto normalizados al intervalo $[0, 1]$ de la ventana (Figura 4.16): el tiempo se divide por los 3 s de la ventana, y la frecuencia pasa por la misma escala mel que produce la imagen,

$$y(f) = \frac{m(f) - m(f_{\min})}{m(f_{\max}) - m(f_{\min})}, \quad m(f) = 2595 \log_{10} \left(1 + \frac{f}{700} \right).$$

La consecuencia es que el rectángulo que el modelo predice es el rectángulo que Raven dibuja, sin reinterpretación, y la inversa $y \mapsto f$ recupera los hercios al exportar (Capítulo 5).

Tabla 4.12: Parámetros del espectrograma

Parámetro	Valor	Justificación
Frecuencia de muestreo	44 100 Hz	Igual a la de las grabaciones, de modo que esta etapa no remuestrea; su mitad, 22 050 Hz, es el techo de Nyquist que fija el límite superior del rango de frecuencia
Ventana / salto	3,0 s / 1,5 s	Contiene entera a casi todas las clases; el costo es la fragmentación de las dos largas (Tabla 4.11)
Solapamiento mínimo	0,5	Un evento entra si la mitad de su parte visible cae en la ventana; medirlo contra la parte visible es lo que mantiene alcanzables a los eventos de más de 6 s
Longitud de ventana STFT	1 024 (23 ms)	Más corta que los eventos más breves: 34 ms el mínimo, 81 ms la mediana de <code>sm/cc</code>
Función de ventana	Hann	Valor por defecto de <code>torchaudio</code> ; ninguna clase mostró fuga espectral atribuible a la ventana
Puntos de la FFT	4 096	Relleno con ceros: densifica la rejilla de frecuencia sin tocar la resolución temporal
Salto STFT	400 (9 ms)	Produce 331 tramas por ventana
Bandas mel	128	Lo que espera el extractor preentrenado del modelo propuesto; 256 no dio ganancia medible
Escala mel	HTK ($q = 2\,595$, $f_{\text{quiebre}} = 700$ Hz)	Convención por defecto de <code>torchaudio</code> ; es la misma fórmula con la que se mapean las cajas
Rango de frecuencia	25 Hz – 22 050 Hz	Un techo de 16 kHz truncaba la mitad de las cajas de <code>sb/spc</code> , cuya frecuencia superior media supera los 16 kHz
Rango en dB	−54,3 a 27,9 dB	Percentiles 1 y 99,9 de $10 \log_{10}(\text{mel} + 10^{-6})$ sobre 2 000 ventanas de entrenamiento; los modelos que pintan el mel como imagen normalizan con él




Figura 4.16: Normalización de una caja

Las tres figuras que siguen muestran ventanas del caché tal como las recibe el modelo, con el mel en decibelios y las cajas ya normalizadas. La Figura 4.17 es la más poblada del conjunto: las cajas se superponen y comparten banda, que es el caso que obliga al detector a separar eventos simultáneos.




Figura 4.17: La ventana más densa

La Figura 4.18 es el caso contrario: una llamada más larga que la ventana, que entra cortada por los dos bordes. El modelo nunca ve su principio ni su final, y es el efecto que la Tabla 4.11 cuantifica.




Figura 4.18: Llamada larga, cortada en ambos bordes

La Figura 4.19 no tiene ninguna caja. Las ventanas vacías no se descartan: son las que enseñan al modelo qué no es un evento, y en este conjunto el fondo que contienen es el coro de insectos y las bandas de ruido estable que atraviesan el espectrograma de lado a lado.




Figura 4.19: Ventana vacía

4.4.5. Entregables y verificación

`data/processed/` contiene los archivos de la Tabla 4.13, en total 6,1 GB. Los tres `.pt` son diccionarios con las mismas tres claves: `images`, un tensor $(N, 1, 128, 331)$ en `float32` con el mel de cada ventana; `boxes`, una lista de N tensores $(n_i, 4)$ con las cajas normalizadas; y `labels`, una lista de N tensores $(n_i,)$ con el índice de clase de cada caja según `labels.json`.

Tabla 4.13: Contenido del caché

Archivo	Contenido
<code>train.pt</code> , <code>val.pt</code> , <code>test.pt</code> <code>labels.json</code>	Ventanas de cada partición: mel, cajas y etiquetas Índice de clase $\rightarrow$ nombre <code>especie/llamada</code> , las 25 clases en orden alfabético
<code>meta.json</code>	Semilla, criterio de selección, exclusiones y fusiones, proporciones de partición, rango en dB y parámetros del espectrograma
<code>train_sources.json</code> , ...	Grabación y segundo de inicio de cada ventana, para volver al audio
<code>prepare_data.log</code>	Registro de la ejecución que construyó el caché

El indicador de RE1.2 pide tres comprobaciones, y las tres se verifican sobre el caché que está en disco:

1. **Los archivos procesados cargan sin error.** Los tres `.pt` se abren con `torch.load(path, mmap=True, weights_only=True)`, que lee cajas y etiquetas sin traer los espectrogramas a memoria, y se comprueban las claves y las formas: 21 751, 9 364 y 7 598 ventanas de (1, 128, 331).
2. **meta.json registra la semilla, el criterio de selección, las exclusiones, la etiqueta usada y la normalización.** El Listado 4.1 lo reproduce íntegro. Cada corrida de entrenamiento lo copia en su `config.json` y en el propio *checkpoint*, de modo que un modelo lleva consigo la descripción del conjunto con el que se entrenó.
3. **El código divide por archivo de grabación y no por ventanas aisladas.** Los `*_sources.json` de las tres particiones no comparten ni una sola grabación: las tres intersecciones son vacías. La partición se decide sobre la grabación entera, de modo que ninguna ventana de una grabación puede caer en un lado y su vecina solapada en otro.

Listado 4.1: meta.json del caché actual

```
{
  "seed": 42,
  "min_pair_count": 100,
  "empty_ratio": 0.25,
  "split_ratios": [
    0.6,
    0.225,
    0.175
  ],
  "excluded_labels": [
    "lw/cc",
    "sm/fc",
    "sb/pcs"
  ],
  "joined_labels": {
    "lw/tr": "lw/trino",
    "lw/tj": "lw/trino",
```

```

    "lw/tt": "lw/trino",
    "lw/tf": "lw/trino",
    "sb/lpc": "sb/ppc"
  },
  "db_range": [
    -54.27337650299072,
    27.8653164958956
  ],
  "params": {
    "clip_len_s": 3.0,
    "clip_hop_s": 1.5,
    "min_overlap": 0.5,
    "pad_seed": 0,
    "target_sr": 44100,
    "n_fft": 4096,
    "win_length": 1024,
    "hop_length": 400,
    "n_mels": 128,
    "f_min": 25.0,
    "f_max": 22050.0,
    "mel_scale": "htk",
    "mel_break_hz": 700.0,
    "mel_scale_q": 2595.0,
    "eps": 1e-06
  }
}

```

La construcción es determinista. Con la misma `cleaned/`, la misma semilla y los mismos parámetros se obtienen las mismas ventanas en el mismo orden, de modo que el conjunto no depende de cuándo se construyó. Volver a aplicar hoy las cuatro reglas de selección sobre `data/cleaned/` devuelve 25 clases, las mismas 25 de `labels.json` y en el mismo orden: el conjunto de experimento no depende de cuándo se ejecutó el *pipeline* sino de las reglas y de la semilla, que es lo que exige el indicador.

4.5. Ficha del conjunto derivado (RE1.3)

Resultado. La ficha del conjunto derivado, que es esta sección junto con el **README** del repositorio y los metadatos de `data/processed/`. Describe las 8 especies, el vocabulario, la composición, el desbalance, el diccionario de campos, el ventaneo, la normalización, las exclusiones y las limitaciones conocidas, que son los nueve elementos de su indicador.

Cómo se alcanzó. Siguiendo la estructura de las *datasheets* para conjuntos de datos (Gebru et al., 2021) (propósito, composición, recolección, transformaciones, usos previstos y limitaciones), sobre el conjunto ya construido. Se omite deliberadamente el apartado de distribución y mantenimiento que esa estructura contempla: publicar el conjunto o sostenerlo como recurso de terceros está fuera del alcance de la tesis y es una decisión del equipo de investigación, no del autor. La ficha distingue dos capas de responsabilidad (Figura 4.20), y esa distinción gobierna todo lo que sigue.




Figura 4.20: Capas del conjunto

4.5.1. Propósito y autoría

Finalidad. Entrenar y evaluar un detector que reciba un espectrograma y devuelva cajas tiempo–frecuencia con especie, tipo de llamada y confianza (OE2), sobre vocalizaciones de primates neotropicales grabadas con sensores pasivos de bajo costo. Las anotaciones primarias existían antes de esta tesis, producidas para el estudio del repertorio vocal de cada especie; la capa derivada las convierte en un conjunto consistente, particionado y documentado.

Autoría. Capa primaria: el equipo de investigación que opera los sensores y anota en Raven. Capa derivada: el autor, con la supervisión del asesor.

4.5.2. Composición

El conjunto derivado tiene dos niveles de instancia. En **cleaned/** la instancia es la *anotación*: una caja tiempo-frecuencia sobre una grabación, con especie y tipo de llamada. En **processed/** la instancia es la *ventana* de 3 s: un espectrograma mel con cero o más cajas normalizadas.

En total, 2 691 grabaciones anotadas que suman 25,0 horas de audio, 19 211 anotaciones sobre 8 especies y 37 pares del vocabulario; de ellas, 17 495 anotaciones en 25 clases forman el conjunto de experimento, sobre 7 de las 8 especies. Quedan fuera del experimento, pero dentro de **cleaned/**, las 643 anotaciones marcadas para revisión y los pares que no alcanzan el umbral. La Tabla 4.14 lo desglosa por especie.

Tabla 4.14: Composición por especie

Especie	Cód.	Grab.	Horas	Anot.	Pares	Clases	Anot. en experimento
<i>Leontocebus weddelli</i>	LW	410	3,7	4 159	8	5	3 450
<i>Sapajus macrocephalus</i>	SM	582	5,3	3 668	8	5	3 381
<i>Alouatta sara</i>	AS	778	7,2	3 619	2	2	3 269
<i>Ateles chamek</i>	AC	384	3,7	3 106	6	4	2 980
<i>Saimiri boliviensis</i>	SB	256	2,8	2 348	4	4	2 313
<i>Plecturocebus toppini</i>	PT	320	2,8	1 185	5	2	1 019
<i>Aotus azarae</i>	AA	82	0,8	1 095	3	3	1 083
<i>Cebus cuscinus</i>	CC	7	0,0	31	1	0	0
Total		2 691	25,0	19 211	37	25	17 495

Grabaciones y horas cuentan las que tienen al menos una anotación de la especie; una grabación con dos especies anotadas cuenta en ambas, por lo que las filas suman más que el total. Pares: tipos de llamada del vocabulario con al menos una anotación. Clases: pares que entran al experimento.

Desbalance. La distribución es de cola larga en dos niveles. Entre especies, *Leontocebus weddelli* aporta 8 tipos de llamada y *Cebus cuscinus* uno solo, con tan pocas anotaciones que no llega a ser clase. Dentro de una especie la distribución es tan sesgada como entre especies: los diez pares mayores concentran el 76 % de las anotaciones en vocabulario y la cola llega hasta pares con una sola (Figura 4.10). Entre **ac/bc**, con 2 487 anotaciones, y **sb/sc**, con 105, median más de veinte veces.

4.5.3. Geometría de los eventos

Las llamadas anotadas son extraordinariamente desiguales en tamaño, y ese hecho condiciona todas las decisiones de diseño posteriores. La más larga dura 73,3s y la más corta 34ms, una razón de $2\,134\times$; el ancho de banda va de 224 a 21\,784 Hz, $97\times$. La magnitud se aprecia mejor por comparación: en COCO, la colección con la que se evalúan habitualmente los detectores de objetos (Lin et al., 2014), los objetos mayores superan a los menores en un factor de entre 10 y 100. El problema que enfrenta este detector es, en ese eje, un orden de magnitud más severo que aquel para el que se diseñaron las arquitecturas que hereda, y la consecuencia inmediata es que ninguna longitud de ventana única sirve para todas las clases.

La Tabla 4.15 sitúa cada clase en duración y banda, y hace visibles dos efectos a la vez. Las **especies se separan en buena medida por banda**: *Alouatta sara* ocupa el grave, por debajo de 1,5 kHz, mientras que la banda mediana de **lw/cs** empieza por encima de los 8 kHz. Los **tipos de llamada de una misma especie no se separan**: en LW, los trinos, **lw/vc** y **lw/cs** comparten banda y duración casi por completo.

Esa disociación tiene una consecuencia metodológica directa, y es la que sostiene el protocolo de evaluación del Capítulo 5: si la geometría distingue especies pero no tipos de llamada, entonces *localizar* y *etiquetar* son problemas de dificultad distinta y no deben puntuarse con una sola cifra.

La Figura 4.21 muestra 9 clases sobre el espectrograma: la más anotada de cada especie y las siguientes en volumen, ordenadas por banda del grave al agudo.

La Figura 4.22 desglosa la misma geometría clase por clase, y revela un problema distinto del desbalance.

En **ac/bc** y **sm/fs** (coeficientes de variación del ancho de banda 0,60 y 0,63) la nube de duración frente a ancho de banda se parte en dos grupos separados (Figura 4.23). Que una etiqueta cubra dos nubes disjuntas sugiere que agrupa dos variantes de llamada que el vocabulario actual no distingue. Es un hallazgo sobre el esquema de anotación, no sobre el modelo.

4.5.4. Recolección (capa primaria)

Las grabaciones se capturaron con dispositivos AudioMoth desplegados en el bosque, a 44,1 kHz, en archivos WAV de duración corta: el 93 % dura un minuto o menos, con

Tabla 4.15: Duración y banda por clase

Clase	Anot.	Duración (s) mediana [RIC]	Banda (Hz)	Ancho de banda (Hz)	CV del ancho
as/hc	1 375	11,0 [7,1–15,8]	47–769	718	0,23
pt/dc	632	6,7 [4,8–9,5]	25–1 474	1 385	0,68
ac/chc	229	1,2 [0,89–1,6]	192–3 378	3 208	0,50
ac/sc	158	1,2 [0,87–1,4]	2 640–10 726	8 135	0,34
ac/gc	140	1,0 [0,66–1,9]	198–1 465	1 276	0,55
lw/sqc	154	0,81 [0,60–1,0]	5 034–12 950	7 753	0,48
sb/pcc	290	0,73 [0,50–1,1]	6 536–11 755	4 955	0,34
sm/sc	163	0,59 [0,35–0,82]	3 381–10 753	6 946	0,36
sm/pc	242	0,55 [0,40–0,82]	2 806–4 435	1 542	0,42
lw/trino	633	0,53 [0,35–0,73]	5 744–11 126	5 459	0,29
lw/cs	2 279	0,43 [0,34–0,50]	8 038–10 215	2 099	0,34
sb/sc	105	0,43 [0,35–0,58]	2 534–15 464	13 243	0,23
lw/vc	119	0,42 [0,33–0,49]	5 438–8 808	3 491	0,40
lw/ta	265	0,42 [0,31–0,55]	1 546–6 880	5 151	0,27
ac/bc	2 453	0,34 [0,24–0,50]	374–2 616	2 234	0,60
as/bc	1 894	0,32 [0,26–0,40]	105–667	566	0,30
pt/sqc	387	0,27 [0,24–0,31]	4 338–5 078	666	0,42
sm/hic	254	0,27 [0,19–0,36]	249–4 927	4 649	0,54
aa/sc	159	0,23 [0,21–0,27]	107–13 147	12 790	0,19
aa/hm	127	0,23 [0,20–0,27]	66–529	452	0,17
sb/ppc	1 189	0,20 [0,15–0,30]	7 010–11 185	3 898	0,47
sm/fs	691	0,19 [0,15–0,26]	1 210–2 438	1 292	0,63
sb/spc	729	0,16 [0,13–0,22]	249–15 931	15 601	0,18
aa/gc	797	0,09 [0,08–0,12]	97–3 074	2 857	0,35
sm/cc	2 031	0,08 [0,06–0,11]	523–3 604	3 064	0,33

RIC: rango intercuartílico (percentiles 25–75). La banda es [mediana de $f_{\min}$, mediana de $f_{\max}$] por clase; el ancho de banda es la mediana de $f_{\max} - f_{\min}$ anotación por anotación, no la resta de la columna anterior. CV: coeficiente de variación del ancho de banda.

mediana de 31 s. Los nombres de archivo codifican la fecha y la hora de inicio: el material va del 14/12/2023 al 27/02/2025, con la mayoría de las grabaciones entre las cinco y las doce de la mañana, un segundo bloque a media tarde y un pico en 05/2024 (Figura 4.24). Las anotaciones se crearon en Raven Pro: el analista dibuja una región rectangular sobre el espectrograma, el programa deriva de ella los tiempos y las frecuencias, y las columnas de especie y tipo de llamada se escriben a mano.

El protocolo de campo (sitio, número de sensores, ganancia, ciclo de trabajo y criterio con que se eligieron los archivos que se anotaron) no acompaña al material entregado. Lo que sí se puede reconstruir del propio corpus se describe arriba, a partir de los nombres de archivo y de las cabeceras de los WAV; lo demás queda declarado como lo que es, información de procedencia no disponible, en la sección 4.5.9.

4.5.5. Transformaciones (capa derivada)

Cada transformación es un programa del repositorio y se documentó en las secciones anteriores; la Tabla 4.16 las enumera para que la ficha se lea sin saltar atrás.

Tabla 4.16: Transformaciones aplicadas

Etapas	Qué hace	Dónde
Curación	Normaliza columnas y etiquetas, fija la especie por carpeta, descarta ruido y cajas degeneradas, recorta a Nyquist, marca los pares fuera de vocabulario y une las copias de una misma grabación	§4.3
Selección de clases	Excluye las frases anidadas, fusiona variantes de trino y de pío, exige 100 anotaciones por clase	§4.4.1
Partición	Reparte las grabaciones enteras en train/val/test (60,0 / 22,5 / 17,5), estratificando por clase de la más rara a la más común	§4.4.2
Ventaneo	Corta cada grabación en ventanas de 3 s con salto de 1,5 s; una anotación entra si la ventana cubre la mitad de su parte visible; añade 25 % de ventanas vacías	§4.4.3
Representación	Espectrograma mel de potencia (128 bandas, 25 Hz–22 050 Hz, HTK) y cajas normalizadas (c_x, c_y, w, h) con el eje de frecuencia en escala mel	§4.4.4

4.5.6. Diccionario de datos

```

data/
  raw/<nombre_comun>__<COD>/      capa primaria, sin modificar
    <AAAAMMDD_HHMMSS>.wav
    <AAAAMMDD_HHMMSS>.Table.1.selections.txt
  cleaned/<nombre_comun>__<COD>/  RE1.1: una tabla normalizada por
    grabacion
    <AAAAMMDD_HHMMSS>.txt
  processed/                      RE1.2: el cache de ventanas
    train.pt  val.pt  test.pt
    labels.json  meta.json
    train_sources.json  val_sources.json  test_sources.json
    prepare_data.log

```

Tabla 4.17: Columnas de las tablas curadas

Columna	Tipo	Significado
species	texto	Código de especie en minúscula (1w); el de la carpeta
written_species	texto	Lo que traía la columna Species , en minúscula
call_type	texto	Código del tipo de llamada normalizado (cs); puede estar fuera del vocabulario
begin_time_s	real	Inicio de la caja, en segundos desde el inicio de la grabación
end_time_s	real	Fin de la caja, en segundos; mayor que <code>begin_time_s + 0,01</code>
low_freq_hz	real	Frecuencia inferior de la caja, en Hz
high_freq_hz	real	Frecuencia superior, en Hz; no mayor que 22050
requires_review	lógico	La fila no pudo asignarse con certeza a un par del vocabulario

Al cargar con `data.annotations.load_annotations()` se añaden `audio_path`, `duration_s` y `bandwidth_hz`, y se unen las copias de una misma grabación (sección 4.3.2).




Figura 4.21: Galería de llamadas

Tabla 4.18: Estructuras del caché

Clave o archivo	Tipo	Significado
images	float32 ($N, 1, 128, 331$)	Mel de potencia de cada ventana, sin comprimir
boxes	lista de ($n_i, 4$)	Cajas (c_x, c_y, w, h) en $[0, 1]$: x es tiempo, y frecuencia en escala mel
labels	lista de ($n_i,$ int64	Índice de clase de cada caja, según labels.json
labels.json	JSON	Índice $\rightarrow$ nombre de clase
meta.json	JSON	Listado 4.1
*_sources.json	JSON	recordings, recording_of_window y clip_start_s: qué grabación y qué segundo origina cada ventana




Figura 4.22: Duración frente a ancho de banda

4.5.7. Usos

Uso previsto. Entrenar y evaluar detectores de cajas tiempo–frecuencia (Capítulo 5) y medir la reducción del tiempo de revisión que aportan (Capítulo 6). Las particiones son fijas: validación elige *checkpoints* y umbrales, prueba se mide una vez.

Usos secundarios. Clasificación de ventanas (una etiqueta por ventana, derivable de las cajas), detección agnóstica a la clase y estudio de la geometría del repertorio por especie.

Usos no recomendados. Estimar abundancia o presencia de las especies: las grabaciones se seleccionaron para anotar, no por muestreo del paisaje. Comparar tipos




Figura 4.23: Etiquetas con dos formas




Figura 4.24: Distribución temporal

de llamada entre especies como si fueran categorías homólogas: el vocabulario es por especie. Inferir el comportamiento del detector sobre las clases de frase excluidas o sobre las especies sin clase.

4.5.8. Versión del conjunto

La versión del conjunto derivado queda identificada por `meta.json` (que registra la semilla, el criterio de selección, las exclusiones, la etiqueta usada y la normalización) y por la huella SHA-256 de la lista de grabaciones de cada partición. Dos capas derivadas con el mismo `meta.json` y las mismas huellas son el mismo conjunto. Cuando el equipo entrega anotaciones nuevas o corrige las existentes, el conjunto se vuelve a construir desde `data/raw/` y la versión cambia.

Fuera de alcance. La distribución del conjunto derivado y su mantenimiento como recurso público no forman parte de esta tesis: las grabaciones y las anotaciones primarias pertenecen al equipo de investigación y el trabajo aquí descrito termina en la capa derivada que alimenta los Capítulos 5 y 6.

4.5.9. Limitaciones

- **Anotación de una sola fuente.** No hay medición de acuerdo entre anotadores, de modo que el error de etiquetado residual no puede separarse del error del modelo.
- **La columna de tipo de llamada llega sucia y no se puede sanear sin el repertorio de referencia.** 32 pares quedan fuera del vocabulario cerrado y, entre ellos, no hay forma de separar el error tipográfico de la subdivisión legítima aún no documentada (sección 4.3.2). El protocolo los marca y los conserva en lugar de decidir, pero el conjunto de experimento se construye asumiendo que lo que quedó fuera es ruido. Si parte de ello fuera repertorio real, el vocabulario está incompleto: es la vía de mejora más directa para una versión futura del detector, y no depende de la arquitectura sino de ampliar la referencia.
- **Procedencia de campo no documentada.** El material entregado no viene acompañado del protocolo de despliegue (sitio, número de sensores, ganancia, ciclo de trabajo y criterio con que se eligieron los archivos que se anotaron), de modo que la ficha reconstruye lo que se puede leer del propio corpus y nada más. Eso impide, por ejemplo, saber si el sesgo horario que se describe arriba es del comportamiento de los animales o del muestreo.
- **Cajas dibujadas con criterio variable en frecuencia.** El eje de frecuencia lo fija el analista a ojo, lo que obliga a emparejar con un umbral de IoU tolerante en el Capítulo 5.
- **Fragmentación de las llamadas largas.** as/hc y pt/dc sobreviven al ventaneo como series de cajas recortadas al borde de la ventana, sin ningún mecanismo que las reagrupe en el evento original (Tabla 4.11). Corregirlo exigiría una segunda longitud de ventana para esas clases, o una agregación que reconstruya el evento completo a partir de sus fragmentos antes de puntuarlo; ninguna de las dos

se implementó, y por eso el Capítulo 5 reporta el promedio por clase junto al agregado.

- **Frases excluidas.** Las clases de frase quedan fuera por anidamiento y dejan sin cubrir el nivel superior de la jerarquía vocal.
- **Cobertura parcial del repertorio.** Los tipos de llamada bajo el umbral de 100 anotaciones y los 32 pares fuera de vocabulario no entran al experimento; *Cebus cuscinus* no tiene ninguna clase.
- **Escasez en 11 clases,** que aportan menos de 300 cajas de entrenamiento cada una. Cuando una de ellas obtiene mal *recall*, la causa puede ser el modelo o puede ser que nunca vio material suficiente.
- **Etiquetas que esconden dos formas.** *ac/bc* y *sm/fs* agrupan cada una dos variantes geométricas distintas (Figura 4.23).
- **Copias de grabaciones en la capa primaria.** El mismo audio aparece en varias carpetas de especie, anotado sólo para la especie de cada carpeta; la capa derivada las une, pero la llamada de una tercera especie no anotada en ninguna copia sigue sin caja.
- **Sesgo horario y estacional.** La mayoría de las grabaciones son matinales y se concentran en pocos meses (Figura 4.24); no hay garantía de que el fondo acústico de otras horas o estaciones esté representado.
- **Un solo sistema de captura.** Todo el material proviene de AudioMoth; la transferencia a otros sensores no está medida.

4.5.10. Verificación de RE1.3

El indicador de RE1.3 exige que la ficha describa las ocho especies (Tabla 4.14), el vocabulario (Tabla 4.4), la composición (Tabla 4.14 y Tabla 4.10), el desbalance (Figura 4.10), el diccionario de campos (Tablas 4.17 y 4.18), el ventaneo (sección 4.4.3), la normalización log-mel (Tabla 4.12), las exclusiones (Tabla 4.8) y las limitaciones conocidas (esta sección). Los nueve elementos están.

4.6. Discusión

Qué se obtuvo. El objetivo específico se cumple con sus tres resultados. El protocolo (RE1.1) convierte 20 082 filas escritas a mano, con 63 grafías distintas de tipo de llamada, en 19 211 anotaciones sobre un vocabulario cerrado de 31 códigos, y deja marcadas (no borradas) las 643 que no puede resolver por sí solo. El conjunto particionado (RE1.2) lleva esas anotaciones a 38 713 ventanas y 44 983 cajas repartidas por grabación en 60,0 / 22,5 / 17,5, sin una sola grabación compartida entre particiones. La ficha (RE1.3) documenta ambas capas y declara diez limitaciones conocidas.

Qué significan. El resultado central no es el tamaño del conjunto sino su *trazabilidad*: cada anotación que entra al experimento puede seguirse hasta la fila cruda de la que salió y hasta la regla que la tocó, y cada cifra de este capítulo se regenera con un comando. Eso es lo que permite que el Capítulo 5 atribuya una diferencia de desempeño a la arquitectura y no al conjunto. Dos propiedades del conjunto condicionan de antemano la lectura de esos resultados. La primera es que la geometría separa especies pero no tipos de llamada dentro de una especie (sección 4.5.3), de donde se sigue que localizar y clasificar son problemas de dificultad distinta y que puntuarlos con una sola cifra ocultaría cuál de los dos falla. La segunda es que el ventaneo de 3s multiplica las dos clases largas hasta el 33 % de las cajas, de modo que cualquier promedio agregado está dominado por las clases más fáciles del conjunto; de ahí la insistencia en el promedio por clase.

Consistencia con la literatura. Las tres decisiones de mayor consecuencia tienen precedente. Cerrar el vocabulario responde a que las definiciones de unidad y las etiquetas semánticas varían ampliamente entre investigadores (Kershenbaum et al., 2016); excluir las clases de frase es la consecuencia operativa del anidamiento jerárquico que ese mismo trabajo describe, y que un detector de lista plana no puede representar; y particionar por archivo de grabación evita que la variación de las etiquetas fuertes se sume a una fuga de datos que inflaría la evaluación (Koga et al., 2024). La forma de la ficha sigue las *datasheets* de Gebru et al. (2021), cuya motivación (que no existe un proceso estandarizado para documentar conjuntos de datos) se verifica en este caso: nada del material recibido venía acompañado de una descripción de su composición o de sus sesgos.

Generalización. El protocolo es transferible en dos niveles distintos. Su *estructura* (normalizar, sanear, cerrar el vocabulario, marcar lo dudoso en lugar de descartarlo y unir copias) no depende de este corpus y se aplica a cualquier material de PAM anotado en Raven por varias personas a lo largo del tiempo. Su *contenido* sí es propio: el mapa de sinónimos, las correcciones de pares imposibles y el vocabulario de 41 pares describen a estas ocho especies y a quienes las anotaron. Otro corpus reutilizaría el programa y reescribiría esas tres tablas. Las decisiones de RE1.2 son más dependientes del material: la ventana de 3 s y el umbral de 100 anotaciones se eligieron para este reparto de duraciones y este volumen, y habría que revisarlos antes de reutilizarlos.

Limitaciones. La sección 4.5.9 las declara todas; tres pesan sobre lo que sigue. La ausencia de una medición de acuerdo entre anotadores impide separar el error del modelo del techo que impone la propia tarea, y es la única de las tres que no puede corregirse sin trabajo del equipo de investigación. La fragmentación de las llamadas largas no se resuelve, se documenta: el conjunto no incluye ningún mecanismo que reconstruya el evento completo a partir de sus fragmentos. Y la exclusión de las clases de frase deja sin cubrir el nivel superior de la jerarquía vocal, de modo que el sistema que esta tesis evalúa detecta sílabas, no secuencias.

Capítulo 5

Detección y Evaluación del Modelo (OE2)

5.1. Introducción

Este capítulo presenta los resultados alcanzados para el segundo objetivo específico:

OE2. Implementar y evaluar un detector que reciba un espectrograma y devuelva cajas tiempo–frecuencia con especie, tipo de llamada y confianza, comparándolo con una línea base establecida.

Los cinco resultados comprometidos en la Tabla 1.5 ocupan una sección cada uno: el diseño experimental, la arquitectura propuesta y las líneas base (RE2.1, sección 5.2), el *pipeline* reproducible de entrenamiento, evaluación e inferencia (RE2.2, sección 5.3), el informe comparativo de resultados (RE2.3, sección 5.4), el modelo final cargable y su demostración (RE2.4, sección 5.5) y la publicación del código y del modelo (RE2.5, sección 5.6). Cada sección describe el resultado, cómo se alcanzó con los métodos y procedimientos del Capítulo 1, cómo reproducirlo, y la verificación y las mediciones con que se comprueba su indicador. La sección 5.7 discute los cinco en conjunto.

El conjunto sobre el que se entrena y se mide es el que produce el Capítulo 4: 21 751 ventanas de entrenamiento, 9 364 de validación y 7 598 de prueba, repartidas por grabación y con 25 clases de especie y tipo de llamada. El costo de revisión que genera el modelo elegido aquí se mide en el Capítulo 6.

5.2. Diseño experimental, arquitectura propuesta y líneas base (RE2.1)

Resultado. La arquitectura propuesta (un AST-Deformable-DETR de dimensión 128, 100 consultas y 4 niveles, implementada en `src/models/`), sus hiperparámetros, las tres líneas base contra las que se compara, las recetas de entrenamiento y el protocolo de comparación con su regla de decisión fijada antes de correr el experimento.

Cómo se alcanzó. Partiendo de la formulación como detección de objetos sobre el espectrograma (sección 2.1.3) y de la representación que fija el Capítulo 4: el modelo recibe exactamente el tensor que el caché almacena y devuelve cajas en el mismo marco normalizado en el que se anotaron. Las tres decisiones que lo separan de un detector de imágenes estándar (extractor preentrenado en audio, pirámide sobre una rejilla de tokens sin jerarquía y cabeza de predicción de conjuntos) responden cada una a una propiedad del material documentada en el capítulo anterior.

Medio de verificación. Esta sección y el módulo de arquitecturas `src/models/`; la sección 5.2.5 contrasta cada elemento del indicador con el código.

5.2.1. La tarea

La entrada es una ventana de 3s convertida en espectrograma mel de potencia $X \in \mathbb{R}^{1 \times 128 \times 331}$ (sección 4.4.4). La salida es un *conjunto* de detecciones $\{(b_k, c_k, s_k)\}$, cada una con una caja $b_k = (c_x, c_y, w, h) \in [0, 1]^4$ en el marco normalizado de la ventana, una clase c_k entre las 25 posibles y una confianza $s_k \in [0, 1]$.

La formulación separa tres preguntas, y el protocolo de la sección 5.2.4 las puntúa por separado: si la llamada se *encontró* (detección), si la caja quedó bien *encuadrada* (localización) y si la etiqueta es *correcta* (clasificación). Mantenerlas separadas no es un refinamiento metodológico: es lo que permite decir, al final del capítulo, dónde está el error.

5.2.2. Arquitectura propuesta: AST-Deformable-DETR

La Figura 5.1 recorre el modelo de la entrada a la salida. Tres decisiones lo definen.

Un extractor preentrenado en audio, no en imágenes. El AST (*Audio Spectrogram Transformer*) preentrenado en AudioSet (MIT/`ast-finetuned-audioset-10-`

10-0.4593) sustituye al *backbone* convolucional de imágenes que traen los detectores estándar. La brecha de modalidad entre imagen y audio justifica esa sustitución (Zhu and Sato, 2025): las estadísticas de un espectrograma (ejes asimétricos, sin invariancia a la traslación en frecuencia) no son las de una fotografía.

Una pirámide multiescala sobre los tokens. El AST produce una única rejilla de 12×32 tokens, es decir, una sola escala, mientras que la duración mediana de las clases va de 81 ms (**sm/cc**) a 11,0s (**as/hc**), un rango de más de dos órdenes de magnitud (sección 4.5.3). La pirámide corrige que las arquitecturas de tipo ViT produzcan representaciones de escala única (Zhu and Sato, 2025), siguiendo la receta de ViTDet: deconvoluciones y una convolución con paso 2 sobre el mismo mapa.

Un decodificador deformable de predicción de conjuntos. La cabeza es el decodificador de Deformable DETR (Zhu et al., 2021): 100 consultas aprendidas atienden a unos pocos puntos muestreados alrededor de una caja de referencia, en los 4 niveles, y refinan la caja capa a capa. No hay anclas, y el emparejamiento húngaro durante el entrenamiento fuerza una predicción por evento.




Figura 5.1: Arquitectura propuesta

Front-end y normalización de entrada

El caché guarda el mel de potencia sin comprimir y la primera capa del modelo decide cómo comprimirlo. Hay tres opciones intercambiables (`-hp frontend=none|logmel|pcen`): la identidad, la compresión logarítmica $\log(\text{mel} + 10^{-6})$ y una normalización de energía por canal (PCEN) con sus cuatro parámetros (s, α, δ, r) aprendibles por banda. PCEN es una ganancia automática que aplanar el fondo y realza los transitorios, y tiene precedente en bioacústica como alternativa robusta al log-mel (Lostanlen

et al., 2019). A continuación, una `BatchNorm2d` sin parámetros afines lleva la entrada a media 0 y varianza 1 por lote, y se divide entre 2: es el rango con el que el AST se preentrenó. La corrida que se compara en la sección 5.4 usa `logmel`.

Extractor: AST con paso temporal adaptado

El AST corta el espectrograma en parches de 16×16 y los proyecta a 768 dimensiones. Con el paso original de 10 en ambos ejes, una ventana de 128 bandas por 331 tramas produce 12×32 tokens, es decir unos 94 ms de audio por token en el eje temporal. La incrustación posicional del *checkpoint*, entrenada para otra rejilla, se interpola bilinealmente a la nueva. El extractor se afina entero, a la misma tasa que la cabeza: con el extractor congelado la propuesta quedó última en una comparación anterior, y descongelarlo es lo que la pone a la altura de las líneas base.

Pirámide multiescala

Los tokens se proyectan de 768 a 128 dimensiones y se reordenan como un mapa 12×32 . Sobre ese mapa, cuatro ramas producen los 4 niveles de la Figura 5.2, cuyo tamaño de celda recoge la Tabla 5.1. El nivel más fino resuelve 23,4 ms por celda, por debajo de la mediana de la clase más corta (**sm/cc**, 81 ms); el más grueso, 187,5 ms, del orden de las sílabas largas. La Figura 5.3 sitúa las 25 clases frente a esas cuatro resoluciones y frente a la ventana: sólo 2 clases (las dos de ventana) tienen una duración mediana mayor que la propia ventana de 3 s.




Figura 5.2: Pirámide multiescala

Tabla 5.1: Niveles de la pirámide

Escala	Mapa (bandas $\times$ tramas)	ms por celda	Bandas mel por celda
$4\times$	48×128	23,4	2,7
$2\times$	24×64	46,9	5,3
$1\times$	12×32	93,8	10,7
$\frac{1}{2}\times$	6×16	187,5	21,3




Figura 5.3: Duración de las clases frente a la pirámide

Decodificador deformable

El decodificador tiene 6 capas idénticas (Figura 5.4), de dimensión 128, con 8 cabezas de atención, FFN de 1024 y *dropout* 0,1. Cada una de las 100 consultas lleva dos vectores aprendidos, contenido y posición, y de la posición se deriva un punto de referencia inicial (c_x, c_y) que, con un tamaño inicial de 0,1, forma la caja de referencia de la primera capa. En cada capa ocurre lo siguiente:

1. **Autoatención** entre consultas, con la posición sumada a las claves y consultas en cada capa, para que las consultas no se diluyan y puedan repartirse los eventos entre sí.
2. **Atención cruzada deformable** (Figura 5.5): en lugar de atender a todas las celdas de los cuatro mapas, cada consulta y cada cabeza muestrean 4 puntos por nivel, en posiciones que la propia consulta predice como desplazamientos relativos al tamaño de su caja de referencia, y los combinan con pesos que también predice (*softmax* sobre los 4×4 puntos). Los desplazamientos arrancan en una rejilla radial y no en ruido, como en el diseño original (Zhu et al., 2021). Es lo que hace tratable atender a un mapa de 48×128 celdas y lo que permite mezclar escalas sin elegir una.
3. **FFN** y normalización residual.
4. **Cabezas por capa.** Una cabeza lineal produce los 25 logits de clase y un MLP de tres capas produce un delta de caja que se suma, en el espacio logit, a la caja de referencia; la caja refinada es la referencia de la capa siguiente, sin gradiente entre capas. Cada capa se supervisa por separado (pérdidas auxiliares).





Figura 5.4: Una capa del decodificador



Para cada consulta y cabeza, la consulta predice 4 desplazamientos Δ y 4 pesos a (el tamaño del punto). El punto muestreado es $c + \Delta \cdot (w, h)/2$ y su valor, la interpolación bilineal del mapa. Se repite en los 4 niveles y los pesos se normalizan sobre los 4×4 puntos.

Figura 5.5: Muestreo deformable de una cabeza sobre un nivel

Emparejamiento y pérdida

Las 100 predicciones de una ventana y sus n cajas anotadas se emparejan uno a uno con el algoritmo húngaro sobre una matriz de costo (Figura 5.6):

$$C_{kj} = 2,0 \mathcal{C}_{\text{focal}}(p_k, c_j) + 5,0 \|b_k - b_j\|_1 - 2,0 \text{GIoU}(b_k, b_j),$$

donde el costo de clase es la pérdida focal positiva menos la negativa que se ahorra (Zhu et al., 2021). Sobre los pares emparejados se calcula la pérdida

$$\mathcal{L} = 1,0 \mathcal{L}_{\text{focal}} + 5,0 \mathcal{L}_1 + 2,0 \mathcal{L}_{\text{GIoU}},$$

con la focal ($\alpha = 0,25$, $\gamma = 2,0$) sobre sigmoides independientes por clase y sin canal de “no objeto”: la confianza de una consulta no emparejada se empuja a cero en todas las clases. El modelo puede así emitir una caja de alta confianza con la etiqueta equivocada, que el protocolo mide como acierto de detección y fallo de clasificación, que es exactamente la separación que la sección 5.2.4 necesita. Los sesgos de las cabezas de clase se inicializan en $\log \frac{1-\pi}{\pi}$ con $\pi = 0,01$, para que al inicio casi ninguna consulta dispare.




Figura 5.6: Emparejamiento húngaro

Inferencia

La confianza de cada consulta es el máximo de sus 25 sigmoides y la clase, su argumento; se conservan las cajas con confianza $\geq 0,001$ (el piso del protocolo) y, como para todos los modelos, a lo sumo 100 por ventana. El emparejamiento uno a uno desalienta los duplicados al entrenar, pero 100 consultas sobre una a tres llamadas dejan en inferencia cajas repetidas y anidadas, de modo que se aplica la misma supresión de no máximos por clase que usan las líneas base (IoU 0,3). El presupuesto de 100 consultas se dimensiona sobre el máximo de cajas por ventana del conjunto (11, sección 4.4.3) y no sobre la mediana (1).

Cabeza preentrenada con cantos de aves

La cabeza deformable se entrena desde cero, mientras que las líneas base parten de un detector completo. Para acortar esa asimetría, la configuración que entra a la comparación preentrena la misma arquitectura, con los mismos hiperparámetros, sobre un caché aparte de cantos de aves construido con el ventaneo y el mel del Capítulo 4 (`data/processed_extra/`), y después la afina con primates: el afinado carga en el modelo recién construido todo tensor del preentrenado con el mismo nombre y forma (todo salvo las cabezas de clase, que dependen del número de clases) y sigue la receta de la propuesta.

Hiperparámetros y tamaño

La Tabla 5.2 reúne los hiperparámetros tal como los declara el código y la Tabla 5.3 cuánto pesa cada bloque. El reparto importa para leer la comparación: el extractor concentra el 96,5 % de los 88,6 M de parámetros y la cabeza completa cabe en 3,1 M. Cambiar el número de clases o ensanchar la cabeza cuesta poco; lo que cuesta (en memoria y en tiempo) es afinar el AST.

5.2.3. Líneas base

Se declaran tres líneas base y cada una controla una cosa distinta (Figura 5.7). Las tres consumen el mismo mel del caché, pintado como imagen con el rango en dB que registra `meta.json`, y devuelven cajas en el mismo marco normalizado, de modo que comparten datos, particiones y protocolo con la propuesta.

Faster R-CNN R50-FPN v2. El detector de dos etapas de referencia, con *backbone* ResNet-50 y pirámide FPN preentrenados en COCO; el mel se reescala a 512×1024 píxeles y se replica en tres canales. Se adaptan las razones de aspecto de las anclas porque las cajas de llamadas van de muy anchas a muy altas, lejos de las razones de los objetos de COCO. Es la línea base sobre espectrogramas con precedente directo en bioacústica (Escobar-Amado et al., 2024).

YOLO26s. Un detector denso de una etapa, pequeño (10,0 M de parámetros), entrenado con la herramienta de Ultralytics desde sus pesos de COCO sobre una imagen gris de 512×512 ; es la línea base de la familia YOLO sobre espectrogramas (González et al., 2025). Las aumentaciones de imagen que no tienen sentido

Tabla 5.2: Hiperparámetros de la propuesta

Hiperparámetro	Valor	Motivo
Extractor	AST	MIT/ast-finetuned-audioset-10-10-0.4593, afinado entero
Paso temporal de parcheo	10	12×32 tokens, 94 ms por token
Dimensión de la cabeza	128	Cabeza pequeña sobre tokens de 768
Niveles de la pirámide	4	De 23,4 a 187,5 ms por celda
Consultas	100	Muy por encima de 11, el máximo de cajas por ventana
Capas del decodificador	6	Como Deformable DETR
Cabezas / puntos por nivel	8 / 4	Como Deformable DETR
FFN / <i>dropout</i>	1 024 / 0,1	Como Deformable DETR
Focal α , γ	0,25, 2,0	Valores de RetinaNet
Costos de emparejamiento (clase, L_1 , GIoU)	2,0, 5,0, 2,0	Zhu et al. (2021)
Pesos de la pérdida (clase, L_1 , GIoU)	1,0, 5,0, 2,0	La clase pesa el doble al asignar que al entrenar
Prior de las cabezas de clase	0,01	Casi nada dispara al inicio
Front-end	logmel	PCEN queda como ablación
NMS por clase	IoU 0,3	El mismo posprocesado que las líneas base

Tabla 5.3: Parámetros por bloque

Bloque	Parámetros (M)	Fracción
Extractor AST (12 capas, 768 d)	85,55	96,5 %
Front-end y normalización de entrada	0,00	0,0 %
Proyección a la dimensión de la cabeza	0,10	0,1 %
Pirámide multiescala	0,26	0,3 %
Decodificador deformable (6 capas)	2,72	3,1 %
Total	88,64	100 %

El front-end no aparece con parámetros porque la configuración comparada usa logmel, que no tiene ninguno; con PCEN añadiría cuatro por banda mel.

en un espectrograma se apagan (volteos, mosaico, tono y saturación) y quedan un corrimiento pequeño, una escala y brillo.

RT-DETR-L. Un detector de conjuntos con extractor de imagen preentrenado en COCO (32,9 M), también por Ultralytics. Es la línea base que separa las dos hipótesis que la propuesta mezcla: si una cabeza de tipo DETR rinde distinto por ser una cabeza DETR, o por el extractor de audio que la alimenta. Entró al experimento después que las otras dos, de forma exploratoria, y la sección 5.2.5 declara la consecuencia que eso tiene sobre su reproducibilidad.




Figura 5.7: Líneas base

5.2.4. Diseño experimental

Recetas de entrenamiento

Cada configuración se entrena con la receta de su *preset* (Tabla 5.5). Los modelos del proyecto usan AdamW con un programa OneCycle, recorte del gradiente y las mismas aumentaciones sobre el audio: ganancia aleatoria, mezcla de una ventana vacía a un SNR dado, corrimiento temporal y pegado de llamadas de otras ventanas, además de un *jitter* de las cajas objetivo. Los dos modelos de Ultralytics se entrenan con su propia herramienta y sus aumentaciones de imagen, restringidas como se dijo. **Las recetas no están igualadas, y se declara:** cada marco usa la suya, de modo que la comparación mide sistemas completos y no sólo arquitecturas.

Tabla 5.4: Configuraciones comparadas

Configuración	Extractor	Parám. (M)	Preen- trenado	Qué controla
AST-Def-DETR (propuesta)	AST / AudioSet (afinado); cabeza / aves	88,6	extractor y cabeza	—
Faster R-CNN R50-FPN v2	ResNet-50 / COCO	43,4	detector entero	detector de dos etapas preentrenado en COCO
YOLO26s	CSP / COCO	10,0	detector entero	detector denso de una etapa preentrenado en COCO
RT-DETR-L	HGNetv2 / COCO	32,9	detector entero	cabeza de conjuntos con extractor de imagen preentrenado en COCO

Parámetros según el registro de cada corrida. En la propuesta y en las dos de Ultralytics se entrena todo; en Faster R-CNN, el tallo y las dos primeras etapas del ResNet quedan congelados (43,2 M entrenables de 43,4 M).

Tabla 5.5: Recetas de entrenamiento

Configuración	Épocas	Lote	lr	Optimizador	Elección de best.pt
AST-Def-DETR (propuesta)	30	8	10^{-4}	AdamW + OneCycle	mAP@0,3 en validación
Faster R-CNN R50-FPN v2	12	4	10^{-4}	AdamW + OneCycle	mAP@0,3 en validación
YOLO26s	30	32	auto	auto (Ultralytics)	aptitud de Ultralytics
RT-DETR-L	30	16	10^{-4}	AdamW	aptitud de Ultralytics

La asimetría de la última columna es una diferencia de receta, no de protocolo: las dos corridas de Ultralytics eligen su *checkpoint* con la aptitud de su propio validador y no con la mAP@0,3 que usan las otras dos. El protocolo de comparación vuelve a medirlos a todos con la misma vara.

Protocolo de comparación

El protocolo vive en `src/evaluation/protocol.py`, se fijó antes de mirar los resultados de prueba y la sección 5.4 lo aplica sin cambios (Figura 5.8). Consta de seis reglas.

1. **Se vuelcan predicciones, no métricas.** De cada `best.pt` se guardan, por ventana de validación y de prueba, todas las cajas con confianza $\geq 0,001$; toda cifra sale después de esos volcados. Cambiar una métrica o un umbral no exige volver a pasar los modelos por la GPU.
2. **Mismo presupuesto para todos.** Se conservan las 100 mejores cajas por ventana: torchvision corta en 100 y Ultralytics en 300, y sin techo común la cola de la curva precisión–recall sería del marco de trabajo y no del modelo.
3. **Acierto a $\text{IoU} \geq 0,3$.** Se mide si la llamada se *encontró*, no si la caja quedó ajustada: el eje de frecuencia lo dibuja el anotador con criterio variable y las llamadas son cortas. A $\text{IoU} 0,5$ el corrimiento temporal tolerado es un tercio del ancho de la caja; a $0,3$ sube a la mitad. Más abajo no: a $0,25$ una predicción de banda completa acertaría una parte de las cajas sin encuadrar nada. Un umbral de IoU bajo es razonable cuando las fronteras de los eventos son borrosas (Zhu and Sato, 2025). El encuadre se reporta aparte, a $0,5$. La precisión media se calcula con la definición y la interpolación de la curva precisión–recall que fija COCO (Lin et al., 2014).
4. **Umbral por modelo, elegido en validación.** De la rejilla $0,01$ – $0,99$, el umbral de mayor recall entre los que alcanzan una precisión de al menos $0,70$. Un umbral fijo compartido mide calibración, no detección: cada cabeza reparte sus confianzas a su manera, y la sección 5.4.4 muestra cuánto cambia la lectura según dónde se mida.
5. **La prueba se mide una vez**, en ese umbral, con intervalos de confianza al 95 % por *bootstrap* de 1 000 remuestreos *de grabaciones*: las ventanas vecinas comparten la mitad del audio y la calidad de una grabación es de la grabación entera. Remuestrear ventanas daría intervalos más angostos de lo que corresponde.

6. **Las clases de ventana van aparte.** Si la mediana del ancho de caja de una clase ocupa al menos el 95 % de la ventana (*as/hc*, *pt/dc*), detectarla es clasificar la ventana: se reportan, pero no entran en la mAP ni en el promedio por clase. Quedan 23 clases de detección.




Figura 5.8: Protocolo de comparación

Métricas por eje y regla de decisión

La Tabla 5.6 asigna a cada eje la pregunta que responde y la magnitud con que se responde, en la línea que fija la sección 1.6.1.

Tabla 5.6: Métricas por eje

Eje	Pregunta	Magnitud
Detección	£Se encontró la llamada?	<i>Recall</i> y precisión emparejando sin mirar la clase, a IoU 0,3, al punto de operación
Encuadre	£La caja está donde el anotador la dibujó?	IoU mediano de esos pares; <i>recall</i> con clase a IoU 0,5; AP a IoU 0,25 y 0,5
Clasificación	£Se etiquetó bien lo que se encontró?	Fracción de pares con la clase y con la especie correctas; <i>recall</i> y AP por clase; matriz de confusión
Operación	£Cuánto cuesta revisar?	Umbral elegido, F_1 , FP/TP, propuestas por hora de audio, minutos de GPU por hora de audio

La regla de decisión se declara antes de correr el experimento y no se cambia después:

La métrica **primaria** es el *recall* en prueba al punto de operación de precisión $\geq 0,70$, con su intervalo de confianza; la **secundaria** es la mAP@0,3. Dos configuraciones cuyos intervalos se solapan *no se separan* con este experimento, y se dice así. El modelo que pasa a RE2.4 es el de mayor *recall*

primario; si la primaria no separa, decide la secundaria, y en caso de empate también en ella, el más barato en inferencia.

La hipótesis de diseño era que un extractor preentrenado en audio con una cabeza de conjuntos iguala o supera a los detectores de imagen preentrenados en COCO. La sección 5.4 la contrasta.

5.2.5. Verificación de RE2.1

El indicador pide que se especifique la arquitectura implementada, con sus hiperparámetros, y que se defina la comparación con las líneas base declaradas. La Tabla 5.7 contrasta cada elemento con el código.

Tabla 5.7: Verificación de RE2.1

Elemento del IOV	Valor	Dónde se comprueba
Arquitectura AST-Deformable-DETR implementada	sí	<code>src/models/deformable_detr.py</code> y <code>backbone.py</code> ; la Figura 5.1 es su recorrido
Dimensión 128	128	DIM en <code>deformable_detr.py</code> , y es el valor con el que se entrenó la corrida comparada
64 consultas	100	Desviación declarada: <code>N_QUERIES = 100</code>
3 niveles	4	Desviación declarada: <code>N_LEVELS = 4</code>
Hiperparámetros	88,6 M	Tablas 5.2 y 5.3, generadas desde el código y desde el <code>best.pt</code>
Comparación con las líneas base	3 líneas base	Sección 5.2.3, Tabla 5.4 y protocolo de la sección 5.2.4

Las dos desviaciones respecto del indicador. El indicador se redactó con un prototipo de 128 dimensiones, 64 consultas y 3 niveles, y la implementación final usa 100 consultas y 4 niveles. Ninguna de las dos es un cambio de arquitectura, y las dos se registran aquí porque el indicador es un compromiso y no una descripción aproximada:

- **De 64 a 100 consultas.** El presupuesto de consultas acota cuántos eventos puede emitir el modelo en una ventana. El máximo observado en el conjunto es 11 cajas por ventana, de modo que 64 ya bastaba; subirlo a 100 añade 100×128 parámetros de incrustación (una fracción despreciable de los 88,6 M) y deja margen para escenas más densas que las de este corpus. El costo es cuadrático en la autoatención entre consultas, que sobre 100 elementos es irrelevante frente al extractor.

- **De 3 a 4 niveles.** El nivel que se añadió es el $\frac{1}{2}\times$, el más grueso (187,5 ms por celda), y la razón está en la Figura 5.3: con tres niveles la resolución más gruesa habría sido 93,8 ms, por debajo de la duración mediana de buena parte de las clases, y el decodificador habría tenido que componer los eventos largos a partir de celdas finas.

Una cuarta configuración, incorporada después. RT-DETR-L se lanzó de forma exploratoria con la herramienta de Ultralytics, fuera del registro de *presets*, y su receta se recuperó del `config.json` de la corrida para dejarla en `src/train.py` como `-arch rtdetr`. Comparte el flujo de YOLO26s salvo en dos puntos, que son los que la corrida original fijó a mano: el optimizador, AdamW con tasa inicial 10^{-4} , porque con el que elige Ultralytics por su cuenta la configuración no converge; y el lote, 16 en lugar de 32, porque el decodificador de conjuntos no entra en memoria con el lote de YOLO. Su *checkpoint* se carga en modo estricto y reproduce su volcado caja por caja, de modo que las cifras que aquí se reportan proceden del mismo código que se publica.

5.3. Pipeline reproducible de entrenamiento, evaluación e inferencia (RE2.2)

Resultado. Un *pipeline* de ocho puntos de entrada que va de las tablas de Raven a las tablas de Raven: prepara los datos, entrena desde una configuración, evalúa un *checkpoint* y ejecuta inferencia sobre un WAV, con las dependencias y los comandos declarados.

Cómo se alcanzó. Cada etapa es un *script* de `src/` con su propio `-help`; ninguna modifica los artefactos de la anterior, de modo que se puede volver a ejecutar cualquiera desde su entrada (Figura 5.9). Las etapas de datos son las del Capítulo 4; las de modelo, las de la sección anterior.

Medio de verificación. Los *scripts* de `src/`, `pyproject.toml` y esta sección como manual técnico; la sección 5.3.6 recorre el indicador etapa por etapa.

5.3.1. Dependencias declaradas

El entorno está declarado y bloqueado, que es la condición para que el *pipeline* sea reproducible y no sólo ejecutable en una máquina. `pyproject.toml` fija Python




Figura 5.9: Pipeline del proyecto

≥ 3.12 y las dependencias base (PyTorch, torchvision, torchaudio, pandas y soundfile) y separa en dos extras lo que sólo necesita una familia de arquitecturas: **detr** (transformers, timm) para las dos basadas en DETR y **yolo** (ultralytics, opencv) para las dos de Ultralytics. Esa separación tiene una consecuencia práctica: una instalación de inferencia no arrastra las librerías de entrenamiento. `uv.lock` fija las versiones exactas de todo el árbol.

Los pesos preentrenados (el AST de AudioSet, el Deformable DETR de COCO) se resuelven en el primer uso y quedan en caché local, de modo que las corridas posteriores no dependen de la red. El entrenamiento se hizo sobre una GPU de 24 GB; la inferencia no necesita GPU.

5.3.2. Las cuatro etapas y su interfaz

El indicador de este resultado exige que los comandos de ejecución queden declarados. El Listado 5.1 los recoge: es la interfaz del *pipeline*, no un instructivo, y cada línea corresponde a una caja de la Figura 5.9.

Listado 5.1: Interfaz del pipeline, una línea por etapa

```
# 1. datos (capítulo 4)
prepare_annotations.py [--force]      raw/ -> cleaned/
prepare_data.py      [--force]      cleaned/ -> processed/
export_yolo.py              processed/ -> yolo/ (solo Ultralytics
    )

# 2. entrenamiento: --arch elige el preset; --hp y --cfg lo pisan
train.py --arch detr  --name detr_t10_logmel --hp frontend=logmel
train.py --arch frcnn --name frcnn_v3
train.py --arch yolo  --name yolo26s_v3 --hp model=yolo26s
train.py --arch detr  --limit 64 --cfg epochs=1      # prueba de humo
notebooks/pretrain_birds_train.py --name detr_birds_v2
notebooks/pretrain_birds_train.py --finetune <aves>/best.pt --name <
    corrida>

# 3. evaluacion: volcar primero, medir despues
dump_predictions.py --run <corrida> [--device cuda:1]
compare_models.py runs/*/*_predictions.pt --output <salida>
./evaluation.sh [corridas...]      las dos cosas, solo lo desactualizado

# 4. inferencia
detect.py <audio o carpeta> --model runs/<corrida>/best.pt
```

Una corrida se identifica por su *preset* (la arquitectura del registro `models.registry.ARCHITECTURES` con sus hiperparámetros y su `TrainConfig`) y por lo que se le pisa encima. Cualquier valor que se cambie respecto del *preset* queda escrito en el nombre de la corrida, en su `config.json` y dentro del propio *checkpoint*: es lo que permite, meses después, saber con qué se entrenó un archivo de pesos sin depender de ninguna anotación externa.

El ciclo de entrenamiento (Figura 5.10) es común a las arquitecturas del proyecto; las de Ultralytics delegan en su herramienta con las aumentaciones restringidas de la sección anterior y al terminar exportan su mejor época al formato de *checkpoint* del proyecto, de modo que aguas abajo las cuatro se tratan igual.




Figura 5.10: Una época del entrenador

5.3.3. Artefactos de una corrida y autonomía del *checkpoint*

Una corrida deja su `config.json` con la arquitectura, los hiperparámetros y el `meta.json` del caché con el que se entrenó; su `train.log` y su `metrics.jsonl` con una línea por época; el `best.pt` de la mejor época y el `last.pt` con optimizador y programa para reanudar; después de la evaluación, los dos volcados y su `operating_point.json`.

Un *checkpoint* es autocontenido (Tabla 5.8): `models.registry.load_checkpoint(path)` reconstruye el modelo a partir de `architecture`, `hparams` y el número de clases de `labels`, carga el `state_dict` en modo estricto (ninguna clave puede faltar ni sobrar) y devuelve el modelo junto con las etiquetas, la configuración y el umbral de operación si existe. Es lo que abren `detect.py` y `dump_predictions.py`, y es la propiedad que RE2.4 verifica.

5.3.4. Costo de las corridas

La Tabla 5.9 registra las cuatro corridas de la comparación: cuántas épocas corrieron de las planificadas, en cuál quedó el *checkpoint* elegido y cuánto costó cada una. El total es de 17,4 horas de GPU, con un reparto muy desigual: 1,0 h la más barata y 6,6 h la propuesta, que es la única que afina un extractor de 88,6 M de parámetros.

La Figura 5.11 muestra las curvas de validación. Las dos corridas del proyecto se miden con la `mAP@0,3` del protocolo y las dos de Ultralytics con la `mAP@0,5` de su propio validador: no son la misma magnitud y por eso van en paneles separados. Lo que se lee en las cuatro es la misma forma: la mayor parte de la mejora ocurre en

Tabla 5.8: Claves de un checkpoint

Clave	Contenido	Para qué
<code>architecture</code>	<code>ast_deformable_detr</code>	clave de <code>models.registry.ARCHITECTURES</code> con la que se rearma
<code>hparams</code>	5 claves	hiperparámetros del modelo, los mismos que recibió <code>build_model</code>
<code>labels</code>	25 nombres	las clases, en orden: fija el número de salidas y el nombre de cada una
<code>config</code>	15 claves	la receta de la corrida y el <code>meta.json</code> del caché con el que se entrenó
<code>state_dict</code>	398 tensores, 88,6 M de parámetros	los pesos
<code>epoch</code>	16	la época de la que salió
<code>metrics</code>	3 claves	sus métricas de validación

Tabla 5.9: Costo de las corridas

Configuración	Épocas	Época elegida	Minutos por época	Horas de GPU
AST-Def-DETR (propuesta)	30 de 30	16	13,2	6,6
Faster R-CNN R50-FPN v2	12 de 12	7	28,1	5,6
YOLO26s	27 de 30	17	2,3	1,0
RT-DETR-L	23 de 30	13	10,9	4,2

Horas de GPU: diferencia entre la primera y la última marca de tiempo del registro de la corrida, de modo que incluye la validación de cada época. La GPU se compartió con otros procesos: son cotas superiores y no son estrictamente comparables entre corridas. Las dos corridas de Ultralytics pararon antes de las 30 épocas por su criterio de paciencia. La corrida de la propuesta cuenta sólo el afinado con primates, no el preentrenamiento con aves.

el primer tercio del programa y después la curva se aplana. La propuesta alcanza su máximo en la época 16 de 30 y Faster R-CNN en la 7 de 12; prolongar el programa no habría cambiado la elección.

5.3.5. Reproducibilidad

- **Semillas.** Una semilla única (42) fija la partición, las ventanas vacías, el orden de los lotes, las aumentaciones y el *bootstrap* del protocolo; las corridas de Ultralytics reciben la misma y corren en modo determinista.




Figura 5.11: Curvas de entrenamiento

- **Trazabilidad.** Cada *checkpoint* lleva dentro el `meta.json` del caché con el que se entrenó y sus hiperparámetros; cada corrida, su `config.json` y su registro con marcas de tiempo. Una cifra de este capítulo se rastrea a un *commit* (b895fe2), un `meta.json` y un `best.pt`.
- **Fallo temprano.** `prepare_*` se niegan a pisar salidas, el entrenamiento de Ultralytics se niega a entrenar sobre un export de otra versión del caché, `compare_models.py` se niega a comparar volcados que no evaluaron las mismas ventanas, y `load_checkpoint` carga en modo estricto.
- **Pruebas de humo.** `-limit N -cfg epochs=1 workers=0` recorre el ciclo completo en minutos; es la prueba que precede a cada corrida larga.
- **Lo que no está fijado.** El orden de las operaciones en GPU no es determinista en todos los núcleos de cuDNN: dos corridas con la misma semilla dan curvas parecidas, no idénticas. El costo de una corrida depende de la carga de la GPU compartida.

5.3.6. Verificación de RE2.2

El indicador enumera cuatro capacidades y dos requisitos de declaración. La Tabla 5.10 las recorre con la evidencia de cada una.

5.4. Informe comparativo de resultados (RE2.3)

Resultado. La comparación de las cuatro configuraciones sobre la misma partición de prueba, con el mismo protocolo, separada en los tres ejes (detección, encuadre

Tabla 5.10: Verificación de RE2.2

Capacidad	Comando	Evidencia
Genera las particiones procesadas	<code>prepare_annotations.py</code> , <code>prepare_data.py</code>	<code>data/processed/</code> con los tres <code>.pt</code> , <code>labels.json</code> y <code>meta.json</code> (sección 4.4.5)
Entrena desde un conjunto de configuración	<code>train.py -arch</code>	Las cuatro corridas de la Tabla 5.9, cada una con su <code>config.json</code>
Evalúa un <i>checkpoint</i>	<code>dump_predictions.py</code> , <code>compare_models.py</code> , <code>evaluation.sh</code>	<code>runs/comparacion/</code> con el umbral, las métricas y el reparto por clase de cada corrida
Ejecuta inferencia sobre un WAV	<code>detect.py</code>	La demostración de la sección 5.5, con su transcripción
Dependencias declaradas	<code>pyproject.toml</code> , <code>uv.lock</code>	Python ≥ 3.12 , extras <code>detr</code> y <code>yolo</code>
Comandos declarados	Listado 5.1	Los ocho puntos de entrada de la Figura 5.9

y clasificación) y con la selección del modelo justificada por la regla declarada en la sección 5.2.4.

Cómo se alcanzó. Ejecutando `evaluation.sh`, que vuelca las predicciones crudas de cada `best.pt` sobre validación y prueba y aplica el protocolo sin volver a pasar los modelos por la GPU. Las cifras de validación eligen el umbral de cada modelo; las de prueba se miden una sola vez con ese umbral.

Medio de verificación. Esta sección y los archivos de métricas `runs/comparacion/comparacion_modelos_v3.txt` y su `.json`; la sección 5.4.9 contrasta el indicador magnitud por magnitud.

5.4.1. Lo que se compara

Las cuatro configuraciones de la Tabla 5.4 se entrenaron sobre el mismo conjunto derivado de 25 clases, con la misma partición por grabación, y se miden sobre las mismas 7598 ventanas de prueba (7931 cajas anotadas, 3,17 horas de audio). El protocolo comprueba esa igualdad antes de comparar nada y se niega a seguir si dos volcados no evaluaron las mismas ventanas.

5.4.2. Desempeño al punto de operación

La Tabla 5.11 reporta el umbral que la validación eligió para cada modelo y lo que ese umbral rinde en prueba.

Tabla 5.11: Resultados al punto de operación

Configuración	Umbral	Recall (val)	Recall (test)	IC 95 %	Prec.	F ₁	mAP @0,25	mAP @0,3	mAP @0,5
AST-Def-DETR (propuesta)	0,21	0,827	0,797	[0,771; 0,825]	0,669	0,728	0,589	0,577	0,451
Faster R-CNN R50-FPN v2	0,69	0,806	0,781	[0,753; 0,808]	0,680	0,727	0,592	0,574	0,457
YOLO26s	0,11	0,837	0,811	[0,787; 0,835]	0,665	0,731	0,629	0,620	0,521
RT-DETR-L	0,39	0,836	0,808	[0,786; 0,829]	0,673	0,734	0,619	0,601	0,499

El *recall* y la precisión de esta tabla exigen la etiqueta correcta; la Tabla 5.12 los separa del acierto de detección. Las mAP se promedian sobre las 23 clases de detección, sin las dos de ventana.

El intervalo es de 1 000 remuestreos de grabaciones, no de ventanas.

Lo primero que hay que registrar, porque condiciona todo lo que sigue, es que **la métrica primaria no separa a ninguna pareja de configuraciones**: los cuatro intervalos de confianza se solapan, el *recall* de prueba va de 0,781 a 0,811 (una diferencia de 0,030) y las cuatro F₁ caben en tres milésimas. Por la regla declarada en la sección 5.2.4, eso no se redondea a un ganador: se dice que el experimento no las distingue en esa magnitud, y se pasa a la secundaria.

La métrica secundaria sí ordena, y con un margen de 0,047:

$$\text{YOLO26s (0,620)} > \text{RT-DETR-L (0,601)} > \text{AST-Def-DETR (0,577)} \approx \text{Faster R-CNN (0,574)}$$

La mAP es libre de umbral: integra toda la curva precisión–*recall* en lugar de leer un punto, de modo que no depende de dónde cada cabeza puso su escala de confianza. Que ordene donde el punto de operación no ordena significa que las cuatro configuraciones alcanzan una cobertura equivalente al presupuesto de revisión que fija 0,70 de precisión, pero no con la misma calidad de curva: dos de ellas sostienen mejor la precisión cuando se les pide más cobertura. El mismo orden se mantiene a IoU 0,25 y a IoU 0,5, y la distancia crece al apretar el encuadre (0,521 contra 0,451), lo que apunta a que la diferencia está en cómo encuadran y no en cuánto encuentran.

Los umbrales elegidos son muy distintos entre sí. 0,11 para YOLO26s y 0,69 para Faster R-CNN, con la propuesta en 0,21 y RT-DETR-L en 0,39. Esto es exacta-

mente lo que la cuarta regla del protocolo anticipaba: un umbral fijo compartido (por ejemplo el 0,5 de fábrica) habría situado a cada modelo en un punto distinto de su curva y habría medido calibración tanto como detección. La sección 5.4.4 desarrolla la consecuencia.

5.4.3. Detección, encuadre y clasificación

La Tabla 5.12 separa los tres ejes. Es la tabla más importante del capítulo, porque es la que dice dónde está el error.

Tabla 5.12: Detección, encuadre y clasificación

Configuración	Detección		Encuadre		Clasificación	
	Recall	Prec.	IoU mediano	Recall @0,5	Clase correcta	Especie correcta
AST-Def-DETR (propuesta)	0,811	0,681	0,766	0,729	0,982	0,994
Faster R-CNN R50-FPN v2	0,793	0,691	0,768	0,716	0,983	0,991
YOLO26s	0,823	0,676	0,792	0,754	0,981	0,992
RT-DETR-L	0,817	0,681	0,797	0,747	0,985	0,996

Detección: emparejando sin mirar la clase. Encuadre: IoU mediano de esos mismos pares, y *recall* exigiendo la clase a IoU 0,5. Clasificación: de lo que se encontró, qué fracción lleva la clase y la especie anotadas.

La clasificación no es el problema. Entre 0,981 y 0,985 de los pares emparejados llevan la clase correcta, y al menos 0,991 la especie correcta, en las cuatro configuraciones. Distinguir 25 pares de especie y tipo de llamada, con un desbalance de dos órdenes de magnitud entre la clase más y la menos frecuente, cuesta menos de dos puntos una vez que el evento está localizado. La distancia entre el *recall* de detección de la Tabla 5.12, que empareja sin mirar la clase, y el de la Tabla 5.11, que sí exige la etiqueta, mide ese costo: para el modelo seleccionado es de poco más de un punto.

El encuadre sí separa. El IoU mediano va de 0,766 a 0,797, y la fracción de pares que superan IoU 0,5 (el umbral estricto) va de 90,7 % a 92,2 %. La Figura 5.12 muestra la distribución completa: las cuatro tienen la misma forma, una moda ancha entre 0,7 y 0,9, pero las dos configuraciones de Ultralytics la desplazan a la derecha. Esta es la diferencia que la mAP@0,5 amplifica.




Figura 5.12: Distribución del IoU

La matriz de confusión del modelo seleccionado (Figura 5.13) confirma la lectura por el otro lado. Sobre 6 531 pares emparejados, sólo el 0,019 de la masa cae fuera de la diagonal, y el 55,4 % de esos errores es entre tipos de llamada de la *misma* especie, el error que el Capítulo 4 anticipó al mostrar que la geometría separa especies pero no tipos de llamada dentro de una especie (sección 4.5.3). La confusión más frecuente, $ac/bc \rightarrow sm/cc$, suma 17 pares, el 14,0 % de todos los errores de etiqueta.

5.4.4. Cobertura frente a carga de revisión

La confianza que emite un detector no es una probabilidad comparable entre arquitecturas: depende de la función de pérdida, del número de propuestas que la cabeza produce y de cómo se normaliza la puntuación. Los cuatro umbrales elegidos (de 0,11 a 0,69) lo muestran sin ambigüedad.

La magnitud que sí es comparable, y además es la que interesa a OE3, es **cuántos eventos recupera cada modelo cuando a todos se les permite proponer la misma cantidad de cajas por hora de audio**. La Figura 5.14 barre el umbral de cada configuración y lee su curva a la misma abscisa; la Tabla 5.13 la tabula en seis presupuestos.

El resultado refuerza la lectura de la Tabla 5.11 y añade algo que el punto de operación no dejaba ver.

En el rango de carga que un revisor humano puede absorber, las cuatro configuraciones son indistinguibles. A 3 000 propuestas por hora (aproximadamente la carga de los cuatro puntos de operación, que promedian 2 980) la cobertura va de




Figura 5.13: Matriz de confusión




Figura 5.14: Cobertura frente a carga

Tabla 5.13: Cobertura a carga igual

Propuestas por hora	AST-Def- DETR	Faster R-CNN	YOLO26s	RT-DETR-L
1 500	0,522	0,526	0,526	0,521
2 000	0,652	0,650	0,657	0,649
3 000	0,799	0,793	0,807	0,807
4 000	0,854	0,849	0,863	0,869
6 000	0,893	0,891	0,901	0,903
9 000	0,910	0,916	—	0,915
Techo (sin umbral)	0,932	0,953	0,912	0,940
Carga en el techo	133 421	84 093	7 528	109 197

Cada columna es la curva de un modelo leída a la misma abscisa. El techo es el *recall* con el umbral en el piso del protocolo, esto es, con todo lo que el modelo es capaz de proponer; la última fila es la carga a la que lo alcanza. Un guion significa que el modelo no llega a emitir tantas propuestas por hora.

0,793 a 0,807. Cuatro arquitecturas con 10,0, 32,9, 43,4 y 88,6 millones de parámetros, con extractores preentrenados en tres corpus distintos y con recetas de entrenamiento que no están igualadas, convergen a la misma cobertura cuando se les da el mismo presupuesto de revisión. *La elección de arquitectura pesa menos, en esta tarea y con este material, que la elección del punto de operación.*

Lo que separa a las curvas es dónde termina cada una. El techo de cobertura (lo que el modelo recupera emitiendo absolutamente todo lo que puede proponer) va de 0,912 (YOLO26s) a 0,953 (Faster R-CNN). Pero el precio de ese techo es abismalmente distinto: Faster R-CNN necesita 84 093 propuestas por hora para alcanzarlo y YOLO26s llega al suyo con 7 528, un orden de magnitud menos. Ninguna de esas cifras es operativa (revisar ochenta mil cajas por hora de audio no es asistencia), pero la comparación sí dice algo: las curvas de los otros tres modelos sólo superan a YOLO26s en una región de carga que nadie va a usar.

El umbral de 0,5 de fábrica no habría comparado nada. El umbral que la validación elige para YOLO26s es 0,11, cinco veces menor. Operarlo a 0,5 lo habría situado en la parte conservadora de su curva y a Faster R-CNN (cuyo umbral elegido es 0,69) en la permisiva, y el orden entre los dos se habría invertido sin que ninguna propiedad de las arquitecturas cambiara. Es la razón por la que el Capítulo 6 elige su punto de operación barriendo el umbral y no heredando uno.

5.4.5. Lectura por clase

El agregado está dominado por dos clases: **as/hc**, **pt/dc** aportan el 32,6 % de las cajas de prueba y son, por la fragmentación que documenta la sección 4.4.3, las más fáciles del conjunto, porque sus cajas ocupan la ventana entera. Por eso la Tabla 5.14 reporta también el promedio por clase, que trata igual a una clase de 37 cajas que a una de dos mil.

Tabla 5.14: Recall por clase

Clase	Cajas test	AST-Def-DETR	Faster R-CNN	YOLO26s	RT-DETR-L
as/hc*	2021	0,972	0,980	0,947	0,963
ac/bc	828	0,819	0,806	0,820	0,848
lw/cs	779	0,877	0,807	0,813	0,866
sm/cc	686	0,758	0,845	0,847	0,850
as/bc	647	0,672	0,543	0,617	0,583
pt/dc*	567	0,966	0,961	0,942	0,938
sb/ppc	464	0,552	0,433	0,692	0,603
aa/gc	269	0,770	0,751	0,807	0,743
sb/spc	250	0,660	0,644	0,776	0,640
sm/fs	232	0,530	0,513	0,625	0,664
lw/trino	216	0,690	0,560	0,648	0,671
pt/sqc	138	0,935	0,935	0,993	0,942
sb/pcc	100	0,500	0,630	0,710	0,650
lw/ta	91	0,747	0,901	0,857	0,934
sm/hic	86	0,500	0,500	0,593	0,581
sm/pc	83	0,446	0,578	0,518	0,699
ac/chc	82	0,585	0,732	0,720	0,720
ac/gc	56	0,357	0,304	0,339	0,125
sm/sc	56	0,375	0,196	0,304	0,214
ac/sc	54	0,333	0,333	0,389	0,500
aa/sc	53	0,642	0,792	0,755	0,792
lw/sqc	52	0,865	0,808	0,865	0,827
aa/hm	44	0,818	0,591	0,795	0,568
lw/vc	40	0,575	0,900	0,800	0,700
sb/sc	37	0,622	0,486	0,676	0,568
Promedio por clase		0,636	0,634	0,694	0,665
Agregado (micro)	7931	0,797	0,781	0,811	0,808

En negrita, el mejor de las cuatro configuraciones en cada clase. Un asterisco marca las dos clases de ventana, que no entran en el promedio por clase.

El promedio por clase separa las configuraciones mucho más que el agregado: 0,694 para YOLO26s, 0,665 para RT-DETR-L, 0,636 para la propuesta y 0,634 para Faster R-CNN. Es el mismo orden que la mAP, y con una distancia mayor: el modelo seleccionado le saca seis puntos de promedio por clase a la propuesta mientras que en el agregado le saca uno y medio. La ventaja no viene de las clases fáciles, viene de las escasas.

Tres patrones se leen en la tabla.

Hay un suelo que ninguna configuración cruza. *ac/gc*, *sm/sc* quedan por debajo de 0,5 en las cuatro, y son dos de las 8 clases con 60 cajas de prueba o menos. Cuando las cuatro arquitecturas fallan por igual sobre una clase, la causa razonable es el material y no el diseño: son las clases que el umbral de 100 anotaciones dejó entrar por poco y cuyo desempeño la sección 4.5.9 anticipó como no atribuible a la arquitectura.

La escasez no lo explica todo. *lw/ta* (91 cajas) llega a 0,934 y *pt/sqc* (138) a 0,993 con el modelo seleccionado, por encima de clases cinco veces más numerosas. Ambas ocupan bandas de frecuencia estrechas y bien separadas, lo que sugiere que la separabilidad geométrica de la sección 4.5.3 pesa más que el volumen de ejemplos. En la otra dirección, *as/bc* (647 cajas) no pasa de 0,672 en ninguna configuración: es una llamada que convive con la clase de ventana *as/hc* de la misma especie y queda enterrada en el coro.

Ninguna configuración gana en todas partes. El modelo seleccionado es el mejor en 9 de las 23 clases de detección, RT-DETR-L en 7, la propuesta en 4 y Faster R-CNN en 3. La propuesta gana justamente donde el contexto largo importa (*as/bc* y *lw/trino*, dos clases que se emiten en secuencia), que es lo que cabría esperar de una cabeza de conjuntos con atención sobre toda la ventana.

5.4.6. Ejemplos cualitativos

La Figura 5.15 muestra seis ventanas de prueba con las anotaciones del equipo y las predicciones del modelo seleccionado a su umbral. Las seis se eligieron por criterio explícito y no por aspecto: dos escenas densas, dos ventanas con todos sus eventos recuperados, una con un evento que el modelo no encontró y una con un falso positivo de alta confianza, todas de grabaciones distintas.

Las dos escenas densas ilustran los dos extremos del comportamiento del modelo sobre el mismo tipo de material. En la primera recupera la mayoría de una serie de llamadas cortas y repetidas, con alguna caja de más; en la segunda, una serie equivalente de la misma clase en otra grabación, no emite ni una sola caja por encima del umbral. La diferencia entre ambas no está en la densidad sino en la relación señal-ruido: la segunda tiene el coro de fondo encima de la banda de la llamada. Es el modo de fallo




Figura 5.15: Ejemplos cualitativos

que el Capítulo 6 tiene que caracterizar, porque determina qué fracción del material queda sin asistir.

5.4.7. Selección del modelo y qué establece la comparación

El modelo que pasa a RE2.4 es YOLO26s (corrida yolo26s_v3). La regla declarada lo decide en tres pasos, y conviene dejar escrito cada uno:

1. La métrica primaria (*recall* en prueba con su intervalo) **no separa** a ninguna de las seis parejas posibles. No elige.
2. La secundaria (*mAP@0,3*) ordena las cuatro y pone a YOLO26s primero con 0,620 frente a 0,601 del segundo. Elige.
3. El desempate por costo de inferencia no hizo falta, pero apunta en la misma dirección: el modelo seleccionado es también el más barato (sección 5.4.8).

La hipótesis de diseño no se confirma, y tampoco se refuta. La propuesta (un extractor preentrenado en audio con una cabeza de conjuntos) iguala a Faster R-CNN en las dos métricas y queda por detrás de los dos detectores preentrenados en COCO en la secundaria. Que la primaria no separe a nadie impide afirmar que la pierde; que la secundaria la ordene tercera impide afirmar que la gana. Lo que el

experimento sí permite decir es más preciso: *el extractor preentrenado en audio no aporta una ventaja medible sobre un extractor preentrenado en imágenes, en esta tarea y con este presupuesto de entrenamiento.*

Tres factores acotan qué se puede concluir de ese empate, y ninguno se resuelve con la evidencia disponible:

1. **Las recetas no están igualadas.** Las dos corridas de Ultralytics usan el optimizador, el programa de tasa de aprendizaje y las aumentaciones de su marco de trabajo; las otras dos, los del proyecto. La comparación mide sistemas completos, no arquitecturas aisladas, y eso se declaró antes de correrla.
2. **El presupuesto de entrenamiento es muy desigual.** La propuesta consumió 6,6 horas de GPU afinando 88,6 M de parámetros y el modelo seleccionado 1,0 h ajustando 10,0 M. Que el modelo barato empate o gane es informativo; que el caro no despegue con más cómputo no está demostrado, porque no se probó un programa más largo.
3. **La ablación que importa no está medida.** Separar el aporte del extractor del aporte de la cabeza exige correr la propuesta con el extractor congelado y con PCEN, y la cabeza de COCO sobre el mismo mel. Las tres son variantes del *preset* y no código nuevo (`frozen_backbone`, `frontend` y el *preset detr_resnet*), pero ninguna entró a esta comparación.

El punto es relevante porque el precedente directo de esta arquitectura reporta una ventaja. Zhu and Sato (2025) combinan un AST *autosupervisado* con un decodificador deformable y superan a un Faster R-CNN con *backbone* residual sobre un conjunto de silbidos de aspas de aerogenerador. Las dos diferencias entre aquella configuración y esta (extractor autosupervisado frente a supervisado, y un dominio de una sola clase de sonido frente a 25 clases con desbalance de dos órdenes de magnitud) son exactamente las que la ablación pendiente debería separar. Este trabajo no contradice ese precedente: muestra que no se traslada sin más a un repertorio de primates.

Lo que la comparación sí establece es más útil que un ganador:

- **La tarea es viable con detectores de objetos sobre espectrogramas.**

Dentro de un presupuesto de 3000 propuestas por hora de audio, las cuatro

configuraciones recuperan cerca de ocho de cada diez eventos anotados de 25 clases, sobre un conjunto con más de un orden de magnitud de desbalance y un rango de duraciones de 34 ms a 73,3 s.

- **El cuello de botella es la detección y el encuadre, no la clasificación.** Distinguir 25 pares de especie y tipo de llamada cuesta menos de dos puntos una vez que el evento fue localizado (sección 5.4.3). La decisión de puntuar los tres ejes por separado (sección 1.6.1) queda respaldada por los datos, y es la que impide leer un agregado bajo como “el modelo confunde las clases”.
- **La elección del punto de operación pesa más que la elección de arquitectura.** La sección 5.4.4 muestra que mover el umbral de un mismo modelo cambia su cobertura mucho más que cambiar de arquitectura a carga fija, y que todas las configuraciones convergen dentro del rango de carga operativo.

5.4.8. Costo de inferencia

El costo se midió sobre las mismas 512 ventanas de prueba y en la misma GPU (NVIDIA RTX A5500), incluyendo el preprocesamiento de cada arquitectura, la supresión de no máximos y el tope de 100 cajas por ventana. El modelo seleccionado consume 0,12 minutos de GPU por hora de audio; la propuesta, 0,30; RT-DETR-L, 0,32; Faster R-CNN, 0,87. Son 7,3 veces entre los extremos. En términos operativos, el modelo seleccionado procesa el audio unas 501 veces más rápido que en tiempo real y el más lento unas 69 veces: las cuatro son viables para monitoreo acústico pasivo, de modo que el costo de inferencia es un criterio de desempate y no una restricción.

5.4.9. Verificación de RE2.3

El indicador enumera siete magnitudes mínimas, exige separar los tres ejes y justificar la selección del modelo. La Tabla 5.15 las localiza una por una.

5.5. Modelo final cargable y demostración funcional (RE2.4)

Resultado. El *checkpoint* del modelo seleccionado, con su vocabulario y su punto de operación, y la demostración de que una inferencia sobre un WAV produce una tabla

Tabla 5.15: Verificación de RE2.3

Elemento del IOV	Dónde	Valor del modelo seleccionado
<i>Recall</i>	Tabla 5.11	0,811 [0,787; 0,835]
Precisión	Tabla 5.11	0,665
F ₁	Tabla 5.11	0,731
IoU medio	Tabla 5.12, Figura 5.12	0,792 (mediano)
AP a IoU 0,25	Tabla 5.11	0,629
AP a IoU 0,5	Tabla 5.11	0,521
<i>Recall</i> por clase	Tabla 5.14	0,694 de promedio por clase
Matriz de confusión	Figura 5.13	0,019 fuera de la diagonal
Separa detección, encuadre y clasificación	Sección 5.4.3, Tabla 5.12	los tres ejes, por separado
Justifica la selección del modelo	Sección 5.4.7	regla declarada, aplicada en tres pasos

Los archivos de métricas son `runs/comparacion/comparacion_modelos_v3.txt` y su `.json` con las mismas cifras. Toda magnitud de este capítulo procede de volver a aplicar el protocolo sobre los volcados crudos, no de una cifra transcrita.

de selección de Raven con coordenadas tiempo–frecuencia, especie, tipo de llamada y puntuación.

Cómo se alcanzó. `detect.py` corta cada grabación en las mismas ventanas de 3 s con salto de 1,5 s del caché, ejecuta el modelo por lotes, aplica el posprocesamiento de la evaluación, funde entre ventanas solapadas las cajas anidadas de la misma clase y escribe la tabla junto a cada audio (Figura 5.16).

Medio de verificación. El *checkpoint* `runs/yolo26s_v3/best.pt` con su punto de operación, el vocabulario de `data/processed/labels.json` y la tabla de selección que la inferencia produce sobre una grabación de prueba (sección 5.5.3).

5.5.1. El modelo final

El modelo que pasa a producción es el ganador de la comparación: `yolo26s_v3`, la época 17 de su corrida, con 10,0 M de parámetros en un *checkpoint* de 40 MB. Su punto de operación, elegido en validación con precisión $\geq 0,70$, es un umbral de confianza de 0,11, al que en prueba recupera 0,811 de las cajas anotadas con precisión 0,665. El umbral viaja junto al *checkpoint* en `operating_point.json` y es el que `detect.py` usa por defecto, de modo que el usuario no tiene que conocerlo.

Carga sin claves incompatibles. `load_checkpoint` reconstruye la arquitectura a partir de las claves `architecture` y `hparams` del archivo, con el número de clases que dicta `labels` (25), y carga el `state_dict` en modo estricto: los 708 tensores del archivo coinciden uno a uno con los del modelo reconstruido, sin faltantes ni sobrantes.

5.5.2. Formato de salida

La salida es una *tabla de selección* de Raven Pro: texto delimitado por tabulaciones con las 10 columnas de la Tabla 5.16, que Raven abre sobre la grabación y dibuja como cajas sobre el espectrograma. Es el mismo formato en el que el equipo entrega sus anotaciones (sección 4.2), con dos diferencias: la columna **Score**, que Raven ignora y permite ordenar o filtrar las detecciones, y que **Species** y **Call type** vienen siempre en mayúscula y del vocabulario cerrado. Las coordenadas de frecuencia se obtienen invirtiendo la escala mel con la que se normalizaron las cajas (ecuación 2.4).

Que la salida tenga esta forma no es un detalle de implementación: es lo que separa a este sistema de la alternativa habitual. BirdNET y HOWLish entregan una probabilidad por segmento (Kahl et al., 2021; Campos et al., 2025) y los *sound event bounding boxes* y YOHO, límites temporales (Ebberts et al., 2024; Venkatesh et al., 2022); aquí se entrega tiempo, frecuencia, especie, tipo de llamada y confianza, en el archivo que el analista ya usa (Escobar-Amado et al., 2024).

Tabla 5.16: Columnas de la tabla de salida

Columna	Contenido
Selection	Correlativo desde 1, como exige Raven
View, Channel	Spectrogram 1, 1: la vista y el canal en los que Raven dibuja
Begin Time (s), End Time (s)	Lados temporales de la caja, en segundos desde el inicio del archivo
Low Freq (Hz), High Freq (Hz)	Lados de frecuencia, en hercios
Species	Código de especie en mayúscula (LW)
Call type	Código del tipo de llamada en mayúscula (CS)
Score	Confianza del modelo en $[0, 1]$; sólo en tablas del modelo

5.5.3. Demostración

El modelo final se aplicó sobre una grabación de la partición de prueba, que no participó del entrenamiento ni de la selección del *checkpoint*: `20240516_083055.wav`, de




Figura 5.16: Flujo de inferencia

35,2 segundos, con 14 anotaciones del equipo repartidas entre **sb/pcc**, **sb/ppc**, **sb/spc**, **sm/cc**, **sm/sc**. La inferencia corrió en CPU, que es la condición más desfavorable y la que tendría un analista sin GPU, y produjo una tabla con las 10 columnas de la Tabla 5.16 y una fila por detección. La Tabla 5.17 recoge sus primeras filas.

Tabla 5.17: Primeras filas de la tabla de salida

Sel.	Begin Time (s)	End Time (s)	Low Freq (Hz)	High Freq (Hz)	Species	Call type	Score
1	0,34	1,15	3 157	4 511	SM	PC	0,32
2	1,51	1,57	584	2 953	SM	CC	0,28
3	2,29	2,45	5 912	9 220	SB	PPC	0,18
4	2,57	3,00	6 218	9 921	SB	PPC	0,51
5	2,92	3,50	3 748	5 094	SM	PC	0,65
6	4,69	4,87	6 677	10 543	SB	PPC	0,52
7	5,51	5,68	7 471	12 723	SB	PPC	0,20
8	5,77	5,99	7 262	10 887	SB	PPC	0,19

Sobre esa grabación el modelo emite 55 detecciones al umbral 0,11. A $\text{IoU} \geq 0,3$ en coordenadas de la grabación entera, 13 de las 14 anotaciones del equipo tienen una detección encima, 15 de las 55 detecciones caen sobre una anotación y 13 de ellas llevan además la misma etiqueta. La Figura 5.17 superpone las dos capas, tal como se ven en Raven, sobre el tramo de 12 segundos que concentra más anotaciones. **Es un ejemplo, no una medición:** una grabación no es una muestra, y las métricas son las de la sección 5.4.

El archivo se abre en Raven sobre la grabación como una tabla de selección más, sin conversión ni herramienta añadida. La Figura 5.18 lo muestra sobre otra grabación de prueba, `20240117_162715.wav` de *Leontocebus weddelli*: Raven Lite carga `20240117_162715.detections.txt` como *Selection Table*, dibuja las seis detecciones como cajas en sus coordenadas de tiempo y frecuencia, las numera sobre el espectrogra-




Figura 5.17: Demostración sobre una grabación

ma y arrastra la columna **Species** a la tabla. A las columnas que produjo el modelo añade las que calcula por su cuenta (**Delta Time**, **Delta Freq**, **Avg Power Density**), igual que con una tabla anotada a mano. **Call type** y **Score** viajan en el archivo pero esta versión del programa no las muestra, de modo que el filtrado por confianza se hace fuera de Raven.




Figura 5.18: La tabla generada abierta en Raven

A partir de ahí el trabajo es el habitual: el analista oye cada caja, borra las que no correspondan, corrige las que estén mal encuadradas y guarda la tabla ya revisada. Ese es el circuito que el Capítulo 6 cronometra.

5.5.4. Verificación de RE2.4

El indicador exige dos cosas, y las dos quedan demostradas arriba:

1. **El *checkpoint* se carga sin claves incompatibles.** Los 708 tensores del archivo coinciden uno a uno con los del modelo reconstruido desde `architecture` y `hparams`, sin faltantes ni sobrantes (sección 5.5.1).
2. **La inferencia sobre un WAV produce un archivo tabulado con las columnas de Raven.** La Tabla 5.17 lo muestra: 55 filas con coordenadas tiempo-frecuencia, especie, tipo de llamada y puntuación, en las 10 columnas de la Tabla 5.16. Que esas columnas son las de Raven y no una imitación lo comprueba la Figura 5.18: el archivo se abre en el propio programa, sobre su grabación, y las detecciones quedan dibujadas sobre el espectrograma.

5.6. Código y modelo disponibles en un repositorio (RE2.5)

Resultado. El repositorio público <https://github.com/nhrot-fc/tesis-primate>, que contiene el código de curación, entrenamiento, evaluación e inferencia, las instrucciones de ejecución y el *checkpoint* del modelo final.

Cómo se alcanzó. Versionando el proyecto desde el inicio, no al entregarlo: 123 *commits* y una versión declarada en `pyproject.toml` (0.2.5). Cada cifra de este capítulo se rastrea a un *commit* (b895fe2), a un `meta.json` de caché y a un `best.pt`.

Medio de verificación. La URL del repositorio; esta sección es el índice que lleva de cada verbo del indicador al archivo que lo implementa.

5.6.1. Estructura

El repositorio separa el código del material que no cabe en él. La Figura 5.19 muestra el primer nivel: `src/` contiene el *pipeline* entero y `research/`, este documento con sus figuras. Las dos carpetas sin versionar son las que guardan datos del equipo de investigación y artefactos de decenas de gigabytes, que se reconstruyen con el código que sí está publicado.

```

tesis-primate/
  README.md      que es el proyecto y como se ejecuta
  pyproject.toml dependencias, extras y grupos; uv.lock las fija
  evaluation.sh  volcado + comparacion de todas las corridas
  Makefile       compila la tesis
  src/           el pipeline entero (figura 5.9)
  notebooks/     auditoria, curacion asistida, preentrenamiento
    con aves
  research/      la tesis: main.tex, capitulos/{tex, figures,
    notebook}
  docs/          requisitos del sistema y notas tecnicas
  data/ (no versionado) raw/, cleaned/, processed/, yolo/
  runs/ (no versionado) corridas: checkpoints, volcados,
    comparacion

```

Figura 5.19: Árbol del repositorio

El indicador de RE2.5 enumera lo que el repositorio debe permitir hacer. La Tabla 5.18 lleva cada uno de esos verbos al archivo que lo implementa y al resultado esperado que lo documenta.

Tabla 5.18: Ubicación de cada elemento del indicador

Qué	Dónde	Documentado en
Curación	src/prepare_annotations.py, src/data/annotations.py, src/data/species.py	RE1.1
Conjunto y partición	src/prepare_data.py, src/data/manifest.py, src/data/cache.py	RE1.2, RE1.3
Arquitecturas	src/models/	RE2.1
Entrenamiento	src/train.py, src/training/	RE2.2
Evaluación	src/dump_predictions.py, src/compare_models.py, src/evaluation/, evaluation.sh	RE2.1, RE2.3
Inferencia	src/detect.py, src/inference/	RE2.4
Instrucciones de ejecución	README.md, pyproject.toml, Listado 5.1	RE2.2
Modelo final	El <i>checkpoint</i> autocontenido de yolo26s_v3 con su operating_point.json	Sección 5.5.1

5.6.2. Qué contiene y qué no

El código, completo. Todo el *pipeline* tal como lo describe la sección 5.3, desde la lectura de las tablas de Raven hasta la escritura de la tabla de salida. No depende de nada que no esté declarado en `pyproject.toml` y fijado en `uv.lock`.

El modelo final, no las corridas. El artefacto que se publica es el *checkpoint* de `yolo26s_v3` (autocontenido, con su arquitectura, sus hiperparámetros, su vocabulario y el `meta.json` del caché con el que se entrenó (Tabla 5.8)) junto con su punto de operación. Las corridas completas, con sus `last.pt` y sus volcados, suman decenas de gigabytes y no aportan nada que el *checkpoint* elegido y las cifras de este capítulo no digan ya.

Las grabaciones y las anotaciones primarias, no. Pertenecen al equipo de investigación. El repositorio no las contiene ni las referencia por ubicación, y los pesos preentrenados de terceros (el AST de AudioSet, los de COCO) se resuelven desde su origen y conservan la licencia de su autor.

Fuera de alcance. La distribución del código y del modelo como producto (empaquetado para usuarios finales, versionado para terceros, licenciamiento y mantenimiento) no forma parte de esta tesis. El compromiso de este resultado, tal como lo enuncia su indicador, es que la URL permita localizar el código y los artefactos del modelo final, y eso es lo que la Tabla 5.18 verifica.

5.6.3. Verificación de RE2.5

El indicador pide que la URL permita localizar cuatro cosas, y las cuatro quedan localizadas en la Tabla 5.18: el código de curación, el de entrenamiento, el de evaluación y el de inferencia, cada uno con el resultado esperado que lo documenta; las instrucciones de ejecución, en el Listado 5.1; y los artefactos del modelo final, que son el *checkpoint* de `yolo26s_v3` y su punto de operación.

5.7. Discusión

Qué se obtuvo. Se implementó y se evaluó un detector que recibe un espectrograma y devuelve cajas tiempo–frecuencia con especie, tipo de llamada y confianza, y se lo

comparó con tres líneas base bajo un protocolo declarado antes de correr el experimento. Sobre las 7 598 ventanas de prueba, el modelo seleccionado recupera 0,811 de las 7 931 cajas anotadas $[0,787; 0,835]$ con precisión 0,665, al umbral que la validación eligió. Las cuatro configuraciones quedan dentro de un intervalo de 0,030 en esa magnitud y sus intervalos de confianza se solapan: la métrica primaria no las separa. La secundaria sí, y ordena al modelo seleccionado primero. De los 55 resultados que produce sobre una grabación de 35,2 segundos, el sistema entrega una tabla que el analista abre en su propia herramienta.

Qué significan. Tres lecturas, en orden de importancia para el problema.

La primera es que **el error está en encontrar y encuadrar, no en nombrar**. Entre 0,981 y 0,985 de los eventos localizados llevan la etiqueta correcta, y al menos 0,991 la especie correcta. La parte del problema que parecía más difícil (distinguir 25 pares de especie y tipo de llamada con dos órdenes de magnitud de desbalance) resultó ser la que el modelo resuelve. Para el uso asistido esto es una buena noticia con una consecuencia concreta: el revisor no tendrá que corregir etiquetas, tendrá que confirmar o descartar cajas, que es una operación mucho más rápida. Y para el diseño de un sistema futuro dice dónde invertir: en la detección y el encuadre, no en la cabeza de clasificación.

La segunda es que **la elección del punto de operación pesa más que la elección de la arquitectura**. A 3 000 propuestas por hora de audio las cuatro configuraciones cubren entre 0,793 y 0,807, pero mover el umbral de un solo modelo lo lleva de 0,52 a 0,91 dentro del mismo rango de carga. Esto reordena la prioridad del trabajo que queda: una vez que se tiene un detector razonable, el margen está en calibrarlo contra el presupuesto de revisión real, que es justamente lo que mide OE3.

La tercera es **un empate que no confirma la hipótesis de diseño**. Se esperaba que un extractor preentrenado en audio con una cabeza de conjuntos superara a los detectores de imagen preentrenados en COCO, y no lo hace: iguala a Faster R-CNN y queda tercera en la métrica secundaria. Decirlo así importa porque el experimento se declaró antes de correrlo y porque la alternativa (elegir a posteriori la métrica que favorezca a la propuesta) era posible: la propuesta gana en *recall* agnóstico sobre Faster R-CNN, gana en cuatro clases y tiene el mejor comportamiento en las dos clases que

se emiten en secuencia. Ninguna de esas tres observaciones sostiene una conclusión general.

Consistencia con la literatura. Los resultados concuerdan con la línea del Capítulo 3 en tres puntos y discrepan en uno.

Concuerdan en que **la detección bidimensional sobre el espectrograma es una formulación viable en bioacústica**: Escobar-Amado et al. (2024) reportan con Faster R-CNN sobre llamadas de foca, y Airale et al. (2025) y González et al. (2025) con detectores de la familia YOLO, cifras del mismo orden que las de la Tabla 5.11 sobre repertorios de tamaño comparable. Concuerdan también en que **un umbral de IoU bajo es lo razonable cuando las fronteras del evento son borrosas** (Zhu and Sato, 2025): la Figura 5.12 muestra que incluso los pares que el protocolo cuenta como aciertos tienen un IoU mediano de alrededor de 0,78, lejos de lo que se exige en detección sobre imágenes naturales. Y concuerdan en que **la salida debe tener la forma que el analista ya usa**: la diferencia entre entregar una probabilidad por segmento (Kahl et al., 2021) y entregar una caja con especie, tipo de llamada y confianza es lo que permite abrir el resultado en Raven sin ningún paso intermedio.

Discrepan con Zhu and Sato (2025), que es el precedente directo de esta arquitectura: allí un AST autosupervisado con decodificador deformable supera a un Faster R-CNN residual, y aquí la combinación equivalente no supera a ninguna de las tres líneas base en la métrica secundaria. Las dos diferencias entre ambos trabajos (extractor autosupervisado frente a supervisado, y un dominio de una sola clase de sonido frente a 25 clases) son las que la ablación pendiente de la sección 5.4.7 debería separar. Este trabajo no refuta aquel resultado: muestra que no se traslada sin más a un repertorio de primates con desbalance fuerte.

Generalización. Qué de esto sobrevive fuera de este corpus.

Se generaliza, con bastante confianza, **la separación de los tres ejes como método de evaluación**. Es independiente del taxón y del repertorio, y su valor (saber si un agregado bajo se debe a detección o a clasificación) se vuelve mayor cuanto más clases tiene el problema. Se generaliza también **la lectura de cobertura frente a carga**: cualquier sistema de pre-anotación asistida compite contra un presupuesto de revisión, y el umbral compartido entre arquitecturas es un artefacto de calibración en todas partes, no sólo aquí.

Se generaliza con reservas **el hallazgo de que la clasificación es fácil**. Depende de que las clases sean acústicamente separables, y en este corpus lo son en buena medida porque la especie está determinada por la carpeta de origen (sección 4.3.2): un modelo que vea una grabación de una especie no anotada por el equipo no tiene por qué comportarse igual. Un corpus con varias especies simpátricas anotadas en la misma grabación pondría a prueba ese resultado.

No se generaliza **el empate entre arquitecturas**. Es el resultado de este material, con este presupuesto de entrenamiento y con recetas no igualadas; con diez veces más datos anotados, o con un programa de entrenamiento más largo para la propuesta, el orden podría ser otro. Tampoco se generalizan los umbrales elegidos, que son propiedades de cada *checkpoint* y no de la arquitectura.

Limitaciones. Cinco, ordenadas por cuánto comprometen las conclusiones.

1. **No hay techo de evaluación.** No se midió el acuerdo entre anotadores sobre una muestra del material, de modo que no se sabe cuánto del error que la Tabla 5.11 atribuye al modelo es en realidad desacuerdo entre humanos. Es la limitación más seria de todo el capítulo: sin ella no se puede decir si 0,811 está cerca o lejos de lo alcanzable. El Capítulo 6 la aborda parcialmente al hacer que un experto revise una muestra de predicciones.
2. **Las recetas no están igualadas y la ablación clave no está medida.** Las cuatro configuraciones usan el optimizador y las aumentaciones de su marco de trabajo, y las tres variantes que separarían el aporte del extractor del de la cabeza (extractor congelado, PCEN, cabeza de COCO sobre el mismo mel) están implementadas y sin correr. La comparación mide sistemas completos, que es lo que se declaró, pero no permite atribuir la diferencia a un componente.
3. **Las clases escasas no se evalúan de forma fiable.** 8 de las 25 clases tienen 60 cajas de prueba o menos, y sobre esas cifras un intervalo de confianza por clase sería tan ancho que no distinguiría nada. Las cifras por clase de la Tabla 5.14 son indicativas en la mitad inferior de la tabla, no concluyentes.
4. **Las dos clases de ventana están medidas con una vara distinta.** *as/hc*, *pt/dc* tienen cajas que ocupan la ventana entera, de modo que detectarlas equivale a clasificar la ventana; se reportan pero no entran en la mAP ni en el promedio

por clase. Aportan el 32,6 % de las cajas de prueba, y cualquier agregado que las incluya (como el *recall* global) está inflado por ellas.

5. **La prueba se midió una vez, por diseño, pero con una sola semilla.** El protocolo protege contra el sobreajuste a la partición de prueba, no contra la varianza de entrenamiento: no se sabe cuánto se movería cada cifra al reentrenar la misma configuración con otra semilla. Dado que las cuatro caben en 0,030, esa varianza podría ser del mismo orden que las diferencias que se reportan.

Capítulo 6

Tiempo de Revisión y Análisis de Errores (OE3)

6.1. Introducción

Este capítulo presenta los resultados alcanzados para el tercer objetivo específico:

OE3. Cuantificar la reducción del tiempo de revisión que aporta el sistema y caracterizar sus errores mediante revisión experta de una muestra de predicciones.

Los tres resultados comprometidos en la Tabla 1.6 ocupan una sección cada uno: la metodología de validación comparativa (RE3.1, sección 6.2), la medición comparativa del tiempo de revisión (RE3.2, sección 6.3) y el análisis cualitativo de errores y hallazgos (RE3.3, sección 6.4). Cada sección describe el resultado, cómo se alcanzó con los métodos y procedimientos del Capítulo 1, cómo reproducirlo, y la verificación y las mediciones con que se comprueba su indicador. La sección 6.5 discute los tres en conjunto.

El material de entrada es el modelo seleccionado en el Capítulo 5 y la partición de prueba construida en el Capítulo 4: OE3 no entrena ni vuelve a ajustar nada, mide lo que cuesta usar el sistema.

- 6.2. Metodología de validación comparativa
(RE3.1)
- 6.3. Medición comparativa del tiempo de revisión
(RE3.2)
- 6.4. Análisis cualitativo de errores y hallazgos
(RE3.3)
- 6.5. Discusión

Capítulo 7

Conclusiones

7.1. Implicaciones de los resultados

El trabajo deja dos cosas que no existían al empezar. La primera es un conjunto acústico utilizable: 19 213 anotaciones curadas bajo un vocabulario cerrado, de las que 17 495 forman un experimento de 25 clases particionado por grabación, con su ficha y sus limitaciones declaradas. La segunda es la evidencia de que la detección de cajas tiempo–frecuencia sobre espectrograma es viable en este dominio, y de que el cuello de botella no está donde se esperaba.

Esa es la implicación principal del Capítulo 5: las cuatro configuraciones comparadas no se separan en la métrica primaria, con intervalos de confianza solapados y un rango de 0,030 en *recall*, mientras que la clasificación de especie y tipo de llamada resulta casi resuelta sobre los pares emparejados. El problema difícil no era distinguir 25 clases con dos órdenes de magnitud de desbalance, sino encontrar y encuadrar el evento. Para el equipo de investigación la consecuencia es concreta: el analista no tendrá que corregir etiquetas, tendrá que corregir cajas.

La segunda implicación es metodológica. Al declarar la regla de decisión antes de entrenar, el experimento pudo cerrarse con un resultado que no favorece a la arquitectura propuesta sin que eso lo invalide, y al separar la medición en detección, encuadre y clasificación quedó visible qué parte del problema está resuelta y cuál no. Una sola cifra agregada habría escondido ambas cosas.

7.2. Cumplimiento de los resultados esperados

La Tabla 7.1 contrasta cada resultado esperado del Capítulo 1 con la sección que lo entrega y lo verifica contra su indicador.

Tabla 7.1: Cumplimiento de los resultados esperados

RE	Resultado	Verificado en	Estado
RE1.1	Protocolo de curación documentado	Sección 4.3.3	Cumplido
RE1.2	Conjunto curado y particionado	Sección 4.4.5	Cumplido
RE1.3	Ficha del conjunto derivado	Sección 4.5.10	Cumplido
RE2.1	Diseño, arquitectura y líneas base	Sección 5.2.5	Cumplido
RE2.2	<i>Pipeline</i> reproducible	Sección 5.3.6	Cumplido
RE2.3	Informe comparativo desagregado	Sección 5.4.9	Cumplido
RE2.4	Modelo final y salida a tabla de Raven	Sección 5.5.3	Cumplido
RE2.5	Repositorio con código y modelo	Sección 5.6	Cumplido

Los ocho resultados de OE1 y OE2 se entregan y se verifican contra su indicador. Uno lo hace con una desviación declarada en la sección correspondiente, no silenciada: la dimensión del decodificador y el número de consultas de la arquitectura propuesta difieren de los valores anunciados en RE2.1, y la sección 5.2.5 razona por qué.

7.3. Cumplimiento de los objetivos específicos

OE1. Cumplido. El Capítulo 4 entrega el protocolo, el conjunto particionado por grabación y la ficha, y mide cada uno contra su indicador: el protocolo conserva el 95,7 % de las filas crudas, la partición no comparte ninguna grabación entre subconjuntos y la ficha cubre los apartados comprometidos, incluidas las limitaciones que el propio material impone.

OE2. Cumplido. El Capítulo 5 implementa el detector, lo compara con tres líneas base bajo un protocolo único declarado de antemano y selecciona YOLO26s por la métrica secundaria, con 0,811 de *recall* y 0,620 de mAP en la partición de prueba, medida una sola vez. El modelo final se carga y produce una tabla que Raven abre sobre la grabación, y el repositorio contiene el código y el *checkpoint*.

7.4. Cumplimiento del objetivo general

7.5. La propuesta frente al problema central

El problema central del Capítulo 1 tiene dos predicados: se anota mucho menos de lo que se graba, y lo que se anota no obedece a un criterio único. La alternativa de solución ataca los dos, y lo hace por vías distintas.

Contra el déficit de consistencia actúa OE1. El vocabulario cerrado, el mapa de sinónimos y la regla que hace de la carpeta la fuente de verdad de la especie convierten un material escrito a mano, con decenas de grafías para la misma clase, en 25 clases con criterio único. No corrige el juicio del anotador, que es irrecuperable sin volver al audio, pero elimina la parte del desacuerdo que era de escritura y no de criterio, y deja marcado y conservado lo que no puede decidir.

Contra el déficit de caudal actúa OE2, y aquí conviene ser preciso sobre lo que el sistema es y lo que no. No sustituye al analista ni pretende hacerlo: la cabeza emite cajas con la forma exacta en que el equipo ya anota, y el analista las recibe en su propia herramienta para aceptarlas, corregirlas o borrarlas. Es pre-anotación asistida, y por eso el compromiso elegido privilegia la cobertura sobre la precisión: perder una vocalización cuesta más que descartar una propuesta falsa, porque el humano revisa la salida de todos modos.

7.6. Trabajo futuro

Lo que queda fuera no es una lista de deseos: son las limitaciones declaradas en las discusiones de los capítulos de objetivo, ordenadas por cuánto comprometen lo que aquí se afirma.

- **Medir el acuerdo entre anotadores.** Es la carencia más seria. Sin ella no hay techo de evaluación, y una parte del error que este trabajo atribuye al modelo podría ser desacuerdo humano.
- **Separar el extractor de la cabeza.** Las tres ablaciones que lo harían están implementadas y sin correr, de modo que la comparación entre configuraciones no puede atribuir la diferencia a un componente.

- **Reconstruir el evento largo.** Las clases de duración mayor que la ventana sobreviven fragmentadas, sin ningún mecanismo que las reagrupe antes de puntuarlas.
- **Cubrir el nivel de frase.** Las clases de frase quedan fuera por anidamiento jerárquico, y con ellas el nivel superior de la jerarquía vocal.
- **Cerrar el vocabulario con el repertorio de referencia.** Los pares fuera de vocabulario mezclan error tipográfico y subdivisión legítima, y no hay forma de separarlos sin una referencia del repertorio vocal de cada especie.

Apéndice A

Plan del Proyecto

A.1. Justificación y viabilidad

A.1.1. Justificación

La investigación es conveniente porque ataca directamente el cuello de botella descrito en el Capítulo 1: el análisis manual del audio recolectado. El monitoreo acústico pasivo con sensores de bajo costo permite recolectar a gran escala, pero ese potencial queda desaprovechado mientras el análisis siga siendo lento, costoso y laborioso. Un sistema de pre-anotación asistida hace que el monitoreo a gran escala resulte operativamente viable y permite que el tiempo experto se dedique a la interpretación ecológica en lugar de al procesamiento.

En el plano práctico, el proyecto reduce la infrautilización del material acústico acumulado y, con ella, la latencia entre la recolección y la generación de conocimiento. En el plano teórico, aborda dos vacíos confirmados de forma independiente por la revisión del Capítulo 3: la ausencia de modelos y de conjuntos de datos con anotación tiempo-frecuencia para primates neotropicales, y la falta de estrategias establecidas para el etiquetado jerárquico de especie y tipo de llamada sobre eventos detectados.

A.1.2. Beneficios esperados

- Reducir la carga de revisión por hora de audio analizada: menos material que inspeccionar para la misma cobertura de eventos.
- Poner en uso el audio ya grabado que hoy permanece sin anotar.
- Acortar la latencia entre la recolección y la obtención de resultados ecológicos.

- Disminuir el costo y el error humano asociados al análisis manual.
- Entregar una herramienta reutilizable, con código y pesos públicos, integrable al flujo de trabajo existente en Raven.

A.1.3. Viabilidad técnica

El proyecto no depende de ningún desarrollo previo inexistente. Las arquitecturas necesarias están disponibles y documentadas (He et al., 2016; Kahl et al., 2021; Nolasco et al., 2023); las herramientas son software libre de uso extendido (Tabla 1.10); los recursos de cómputo se cubren con acceso a GPU en la nube; los datos iniciales, aproximadamente 10 GB de grabaciones WAV capturadas con AudioMoth, con sus anotaciones de Raven, ya están entregados; y la metodología de trabajo (CRISP-DM) está establecida y es la que estructura el documento.

A.1.4. Viabilidad temporal

El cronograma es factible dentro del calendario académico, con dos puntos de tensión identificados. El primero es OE1: la curación y estandarización del conjunto es meticulosa y cualquier retraso ahí se propaga a todo lo que sigue. El segundo es OE2, que consume tiempo tanto de cómputo como de análisis humano en la experimentación. Juega a favor que no haya recolección de datos en campo: el material de partida ya existe.

A.1.5. Viabilidad económica

El grueso del software es de código abierto y sin costo. Los sensores ya están desplegados y su costo no recae sobre este proyecto. El desembolso real se concentra en cómputo en la nube y en servicios de almacenamiento; el resto del presupuesto es una valorización del tiempo dedicado, no un pago efectivo.

A.2. Definición y alcance del proyecto

A.2.1. Alcance

El proyecto desarrolla y evalúa un sistema de pre-anotación asistida que produce cajas tiempo–frecuencia etiquetadas sobre grabaciones de monitoreo acústico pasivo, para las ocho especies de la Tabla 2.2. El sistema debe cumplir tres tareas: localizar el

evento en tiempo y frecuencia, identificar la especie y clasificar el tipo de vocalización. Una parte central del alcance es la caracterización cuantitativa de su comportamiento operativo: el tiempo de revisión que cuesta una hora de audio con y sin la asistencia del sistema, la carga de propuestas que genera y la naturaleza de sus discrepancias. La medición cronometrada y la revisión experta de una muestra de predicciones están dentro del alcance y dependen de la disponibilidad del equipo de investigación, que es el riesgo R3 de la sección A.3.5. El proyecto recorre el ciclo completo de CRISP-DM, desde la preparación de los datos hasta el procesamiento de grabaciones nuevas.

A.2.2. Entregables y criterios de aceptación

Los entregables son los resultados esperados enumerados en la sección 1.4. La Tabla A.1 recoge el criterio de aceptación de cada uno: la condición verificable que permite declararlo terminado.

A.2.3. Exclusiones

- No se desarrolla un sistema de monitoreo en tiempo real desplegable en campo; el alcance es el procesamiento de grabaciones existentes.
- El análisis detallado de sonidos antropogénicos queda fuera del foco primario, más allá de su detección y categorización general.
- El estudio se limita a las ocho especies declaradas.
- No se desarrolla hardware de adquisición.
- No se realiza nueva recolección de datos en campo.
- **No se cubre la distribución ni el mantenimiento del conjunto de datos ni del modelo.** Las grabaciones y las anotaciones primarias pertenecen al equipo de investigación, y publicarlas, licenciarlas o sostenerlas como recurso de terceros son decisiones suyas y no de esta tesis. El repositorio que compromete RE2.5 contiene el código y los artefactos del modelo final; empaquetar, versionar para terceros o dar soporte queda fuera.

A.2.4. Limitaciones y restricciones

Limitaciones. La ausencia de conjuntos etiquetados a gran escala para primates neotropicales obliga a invertir un esfuerzo considerable en OE1, y la calidad de las ano-

Tabla A.1: Criterios de aceptación

Entreg.	Criterio de aceptación
RE1.1	El protocolo define reglas de sintaxis para las etiquetas de especie y tipo de llamada, y especifica el tratamiento de errores, duplicados e inconsistencias de las anotaciones originales.
RE1.2	Todas las anotaciones del conjunto final cumplen las reglas de RE1.1, y se entrega un manifiesto con la asignación de cada archivo de grabación a una partición.
RE1.3	La ficha describe la estructura de directorios, incluye un diccionario de datos por columna y declara transformaciones, sesgos y limitaciones conocidas.
RE2.1	El documento justifica la arquitectura propuesta y la línea base a partir del estado del arte, y fija la configuración e hiperparámetros iniciales de ambas.
RE2.2	El <i>pipeline</i> ejecuta el ciclo completo de entrenamiento, evaluación e inferencia, e incluye instrucciones de instalación y ejecución.
RE2.3	El informe presenta las métricas de los tres ejes para la propuesta y la línea base, discute los resultados y concluye con una recomendación justificada.
RE2.4	Los pesos del modelo se cargan sin error y un script de demostración produce predicciones en el formato de tabla de selección de Raven sobre un clip de prueba.
RE2.5	El repositorio público contiene el código del <i>pipeline</i> , los pesos del modelo final y las instrucciones para reproducir la inferencia.
RE3.1	La metodología, fechada antes de la evaluación, especifica el subconjunto de prueba, el punto de operación (confianza 0,5 y NMS IoU 0,3), el umbral IoU 0,5 que define un verdadero positivo, las métricas, el emparejamiento y el procedimiento de revisión de discrepancias.
RE3.2	Se reportan los minutos por hora de audio en condición manual y asistida sobre material comparable, con el orden de revisión declarado, y el tiempo de procesamiento del modelo por hora de audio.
RE3.3	El informe clasifica la muestra de predicciones de alta confianza en evento no anotado, ruido y error de encuadre, e incluye ejemplos sobre el espectrograma de aciertos, de errores comunes y de detecciones correctas ausentes de la referencia.

taciones manuales recibidas es subjetiva y variable. El entorno acústico amazónico es denso y presenta con frecuencia baja relación señal-ruido. La variabilidad intraespecífica de las vocalizaciones y su naturaleza graduada dificultan definir categorías discretas, y las llamadas superpuestas o de baja intensidad son especialmente difíciles de modelar. Los sensores de bajo costo añaden variabilidad entre dispositivos. Por último, sin revisión experta las predicciones de alta confianza situadas en regiones sin anotación (tipo D de la Tabla 1.7) no pueden clasificarse de forma concluyente entre eventos omitidos por la referencia y falsos positivos genuinos: esta tesis las caracteriza geométricamente y las reporta como una cantidad acotada, y deja su resolución como trabajo futuro condicionado a la disponibilidad del equipo de investigación.

Restricciones. El desarrollo está sujeto al calendario académico. El proyecto depende del conjunto de datos entregado y de la verificación de su calidad. El acceso a GPU limita la escala de la experimentación, en particular la búsqueda exhaustiva de hiperparámetros. El desarrollo, la implementación y la evaluación recaen sobre el autor, con la supervisión del asesor.

A.3. Planificación del proyecto

A.3.1. Estructura de desglose del trabajo

La estructura de desglose se organiza según las fases de CRISP-DM y los objetivos específicos. La Tabla A.2 resume los paquetes de trabajo y el entregable asociado a cada uno, y la Figura A.1 los dibuja en jerarquía: sólo se abren los tres paquetes que producen resultados esperados.

A.3.2. Cronograma

El cronograma se ajusta al calendario académico y se organiza en bloques que respetan las dependencias entre paquetes: la preparación de datos precede al modelado, el modelado precede a la evaluación, y la fijación del punto de operación precede a la medición del tiempo y al análisis de errores, porque ambos se realizan sobre las predicciones del modelo ya seleccionado en ese punto. La sesión de revisión con el equipo de investigación se agenda con holgura, porque alimenta a la vez la condición asistida de RE3.2 y la muestra resuelta de RE3.3.

Tabla A.2: EDT del proyecto

ID	Paquete	Contenido	Entregable
1	Gestión del proyecto	Planificación, seguimiento, comunicación con el asesor, gestión de riesgos y de la calidad, cierre	N/A
2	Comprensión de la investigación	Objetivos, formulación del problema de detección y criterios de éxito	N/A
3	Comprensión de los datos	Acceso al corpus, descripción del formato, análisis exploratorio y verificación de calidad	N/A
4.1	Limpieza y estandarización	Corrección de etiquetas, tratamiento de audios dañados	RE1.1
4.2	Curación del conjunto	Aplicación del protocolo, vocabulario cerrado, partición por grabación	RE1.2
4.3	Ingeniería de características	Preprocesamiento, representación tiempo–frecuencia, ventaneo, aumento de datos	N/A
4.4	Documentación del conjunto	Ficha del conjunto derivado	RE1.3
5.1	Diseño del detector	Arquitectura propuesta y línea base, con justificación	RE2.1
5.2	Implementación	<i>Pipeline</i> de entrenamiento, evaluación e inferencia	RE2.2
5.3	Publicación del código	Repositorio con código y pesos	RE2.5
6.1	Evaluación cuantitativa	Métricas por eje, comparación con la línea base, análisis de errores	RE2.3
6.2	Selección del modelo final	Modelo elegido y exportador a tabla de selección de Raven	RE2.4
6.3	Metodología de validación	Subconjunto de prueba, punto de operación, emparejamiento, métricas y protocolo de revisión experta	RE3.1
6.4	Medición del tiempo de revisión	Cronometraje de la revisión manual y asistida sobre material comparable, y costo de inferencia	RE3.2
6.5	Análisis de errores	Clasificación de las predicciones de alta confianza y ejemplos sobre el espectrograma	RE3.3
6.6	Revisión experta de la muestra	Resolución con el equipo de investigación de las predicciones sin anotación	RE3.2, RE3.3
7	Despliegue	Inferencia por lotes sobre grabaciones no vistas y generación de tablas de anotación	N/A
8	Documentación y difusión	Redacción de la tesis y preparación de la defensa	N/A




Figura A.1: EDT en árbol

A.3.3. Estimación de costos

Los costos se presentan en dólares estadounidenses y distinguen desembolso real de valorización. Las Tablas A.3 a A.6 detallan cada categoría, y la Tabla A.7 las consolida.

A.3.4. Lista de recursos

Personas. El tesista, responsable del desarrollo, la implementación y el análisis; y el asesor, que aporta guía, supervisión y validación experta.

Equipamiento. Equipo de desarrollo con GPU dedicada, almacenamiento externo para el conjunto de datos y sus derivados, y acceso a servidores con GPU para el entrenamiento.

Herramientas. Las de la Tabla 1.10, más el acceso a Raven para la validación cuantitativa de las predicciones.

Tabla A.3: Costos de equipos

Categoría	Descripción	USD
Almacenamiento externo	SSD de 512 GB para el conjunto de datos y sus derivados	150,00
Equipo de desarrollo	Laptop con GPU dedicada ^a	1 500,00
Cómputo en la nube	Instancia con GPU de 48 GiB de memoria, estimada por horas de uso	600,00
Subtotal		2 250,00

^a Equipo preexistente propiedad del tesista. No representa un desembolso del proyecto, pero sí un recurso valorizado.

Tabla A.4: Capital intelectual

Recurso	Horas	USD/h	Total USD
Tesista ^a	600	5,00	2 500,00
Asesor de tesis ^b	40	25,00	1 000,00
Subtotal			3 500,00

^a Valorización del tiempo dedicado; no implica un pago real.

^b Cubierto por la institución.

Tabla A.5: Costos de software y servicios

Software o servicio	Licencia	Meses	USD/mes	Total USD
Python, uv, Pandas, NumPy	Código abierto	12	0,00	0,00
PyTorch, torchaudio, Transformers	Código abierto	12	0,00	0,00
Visual Studio Code	Código abierto	12	0,00	0,00
Zotero	Gratuito	12	0,00	0,00
Raven Lite	Licencia de estudiante	12	0,00	0,00
Entorno de cómputo con GPU	Suscripción	12	9,99	119,88
Almacenamiento en la nube	Suscripción	12	1,67	20,00
Subtotal				139,88

Tabla A.6: Costos indirectos

Categoría	Descripción	Meses	Total USD
Internet	Conexión para investigación y acceso a la nube	12	480,00
Electricidad	Consumo del equipo y periféricos	12	360,00
Impresiones y otros	Materiales de estudio e impresiones	12	120,00
Subtotal			960,00

Tabla A.7: Resumen de costos

Categoría	Total USD
Equipamiento (hardware)	2 250,00
Recursos humanos (valorización)	3 500,00
Software y servicios	139,88
Costos indirectos	960,00
Total	6 849,88

A.3.5. Gestión de riesgos

La Tabla A.8 recoge los riesgos identificados con su probabilidad, impacto, severidad y las acciones previstas.

Tabla A.8: Riesgos del proyecto

Riesgo	Prob.	Sever.	Mitigación	Contingencia
R1. Calidad de los datos: anotaciones inconsistentes y audios dañados	Baja	Media	Validación cruzada de una muestra con el asesor; detección automática de archivos corruptos o vacíos	Excluir el material bajo umbral mínimo de calidad y documentar la inconsistencia como limitación
R2. Recursos de cómputo insuficientes	Baja	Media	Espectrogramas precalculados; <i>pipeline</i> de datos optimizado; planificación de las corridas largas	Reducir la complejidad de las configuraciones menos prometedoras; acotar la búsqueda de hiperparámetros; parada temprana
R3. Baja disponibilidad de revisores expertos para la validación	Media	Baja	Sesión de revisión agendada con holgura y con el material ya preparado; la muestra se dimensiona para que una sola sesión la resuelva	Reducir el tamaño de la muestra revisada y declarar de forma explícita la limitación de alcance de RE3.2 y RE3.3
R4. Falla del equipo de desarrollo	Alta	Media	Código, datos y documentos sincronizados en repositorio remoto; entorno replicable por archivo de configuración	Reinstalar el sistema, clonar el repositorio y recrear el entorno desde su especificación
R5. Incompatibilidad del entorno de ejecución	Media	Media	Requerimientos explícitos y versionados; contenedor de ejecución; versiones estables de las bibliotecas clave	Proveer un entorno preconfigurado listo para ejecutar; migrar a versiones compatibles
R6. Aumento del costo de cómputo en la nube	Baja	Baja	Desarrollo y depuración en recursos locales o gratuitos; uso eficiente de la GPU; priorización de experimentos	Reducir el alcance de la experimentación; solicitar créditos académicos; usar recursos de la universidad
R7. Retrasos por disponibilidad limitada del tesista	Alta	Alta	Cronograma con holgura basado en la EDT; bloques de tiempo protegidos; seguimiento semanal del avance	Replanificar al detectar la desviación; negociar reducción de alcance con el asesor; priorizar la ruta crítica

Bibliografía

- Airale, L., Pajot, A., and Linossier, J. (2025). NBM: an open dataset for the acoustic monitoring of nocturnal migratory birds in europe.
- Blumstein, D. T., Mennill, D. J., Clemins, P., Girod, L., Yao, K., Patricelli, G., Deppe, J. L., Krakauer, A. H., Clark, C., Cortopassi, K. A., Hanser, S. F., McCowan, B., Ali, A. M., and Kirschel, A. N. G. (2011). Acoustic monitoring in terrestrial environments using microphone arrays: applications, technological considerations and prospectus. *Journal of Applied Ecology*, 48(3):758–767.
- Bonet-Solá, D. and Alsina-Pagès, R. M. (2021). A comparative survey of feature extraction and machine learning methods in diverse acoustic environments. *Sensors*, 21(4):1274.
- Campos, R., Krofel, M., Rio-Maior, H., and Renna, F. (2025). Howlish: a cnn for automated wolf howl detection. *Remote Sensing in Ecology and Conservation*.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., and Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- Ebbers, J., Germain, F. G., Wichern, G., and Roux, J. L. (2024). Sound event bounding boxes.
- Escobar-Amado, C., Badiéy, M., and Wan, L. (2024). Computer vision for bioacoustics: Detection of bearded seal vocalizations in the chukchi shelf using YOLOV5. *IEEE Journal of Oceanic Engineering*, 49(1):133–144.
- Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daume III, H., and Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12):86–92.
- Gibb, R., Browning, E., Glover-Kapfer, P., and Jones, K. E. (2018). Emerging opportunities and challenges in passive acoustic monitoring. *Methods in Ecology and Evolution*, 9(5):1191–1201.
- González, S. S., Quiros, S. B., and Toledano, D. T. (2025). YOLO-based transfer learning for sound event detection using visual object detection techniques. *Applied Sciences*, 16(1).
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778.

- He, Y., Trigoni, N., and Markham, A. (2021). SoundDet: Polyphonic moving sound event detection and localization from raw waveform.
- Heinicke, S., Kalan, A. K., Wagner, O. J., Mundry, R., Lukashevich, H., and Kuhl, H. S. (2015). Assessing the performance of a semi-automated acoustic monitoring system for primates. *Methods in Ecology and Evolution*, 6(7):753–763.
- Jin, C., Kim, M., Jang, S., and Paeng, D.-G. (2022). Semantic segmentation-based whistle extraction of indo-pacific bottlenose dolphin residing at the coast of jeju island. *Ecological Indicators*, 137:108792.
- Kahl, S., Wood, C. M., Eibl, M., and Klinck, H. (2021). BirdNET: A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 61:101236.
- Kath, H., Serafini, P. P., Campos, I. B., Gouvêa, T. S., and Sonntag, D. (2024). Leveraging transfer learning and active learning for data annotation in passive acoustic monitoring of wildlife. *Ecological Informatics*, 82:102710.
- Kershenbaum, A., Blumstein, D. T., Roch, M. A., Akçay, Ç., Backus, G., Bee, M. A., Bohn, K., Cao, Y., Carter, G., Cašar, C., Coen, M., DeRuiter, S. L., Doyle, L., Edelman, S., Ferrer-i Cancho, R., Freeberg, T. M., Garland, E. C., Gustison, M., Harley, H. E., Huetz, C., Hughes, M., Hyland Bruno, J., Ilany, A., Jin, D. Z., Johnson, M., Ju, C., Karnowski, J., Lohr, B., Manser, M. B., McCowan, B., Mercado III, E., Narins, P. M., Piel, A., Rice, M., Salmi, R., Sasahara, K., Sayigh, L., Shiu, Y., Taylor, C., Vallejo, E. E., Waller, S., and Zamora-Gutiérrez, V. (2016). Acoustic sequences in non-human animals: a tutorial review and prospectus. *Biological Reviews*, 91(1):13–52.
- Koga, N., Bando, Y., and Imoto, K. (2024). LEAD dataset: How can labels for sound event detection vary depending on annotators? In *2024 Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*, pages 1–6. ISSN: 2640-0103.
- Leroy, E. C., Thomisch, K., Royer, J.-Y., Boebel, O., and Van Opzeeland, I. (2018). On the reliability of acoustic annotations and automatic detections of Antarctic blue whale calls under different acoustic conditions. *The Journal of the Acoustical Society of America*, 144(2):740–754.
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., and Zitnick, C. L. (2014). Microsoft coco: Common objects in context. In *Computer Vision – ECCV 2014*, pages 740–755.
- Lostanlen, V., Salamon, J., Farnsworth, A., Kelling, S., and Bello, J. P. (2019). Robust sound event detection in bioacoustic sensor networks. *PLOS ONE*, 14(10):e0214168.
- Meedeniya, D., Ariyaratne, I., Bandara, M., Jayasundara, R., and Perera, C. (2023). A survey on deep learning based forest environment sound classification at the edge. *ACM Computing Surveys*, 56(3):1–36.
- Nam, H., Kim, S.-H., Ko, B.-Y., and Park, Y.-H. (2022). Frequency dynamic convolution: Frequency-adaptive pattern recognition for sound event detection. pages 2763–2767.

- Nguyen Hong Duc, P., Torterotot, M., Samaran, F., White, P. R., Gérard, O., Adam, O., and Cazau, D. (2021). Assessing inter-annotator agreement from collaborative annotation campaign in marine bioacoustics. *Ecological Informatics*, 61:101185.
- Nolasco, I., Singh, S., Morfi, V., Lostanlen, V., Strandburg-Peshkin, A., Vidaña-Vila, E., Gill, L., Pamuła, H., Whitehead, H., Kiskin, I., Jensen, F. H., Morford, J., Emmerson, M. G., Versace, E., Grout, E., Liu, H., Ghani, B., and Stowell, D. (2023). Learning to detect an animal sound from five examples. *Ecological Informatics*, 77:102258.
- Pham, P., Li, J., Szurley, J., and Das, S. (2018). Eventness: Object detection on spectrograms for temporal localization of audio events.
- Politis, A., Adavanne, S., and Virtanen, T. (2020). A dataset of reverberant spatial sound scenes with moving sources for sound event localization and detection. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events 2020 Workshop (DCASE2020)*, pages 165–169.
- Stowell, D. (2022). Computational bioacoustics with deep learning: a review and roadmap. *PeerJ*, 10:e13152.
- Vellinga, W.-P. (2026). Xeno-canto - bird sounds from around the world.
- Venkatesh, S., Moffat, D., and Miranda, E. R. (2022). You only hear once: A YOLO-like algorithm for audio segmentation and sound event detection. *Applied Sciences*, 12(7):3293.
- Veselý, A. (2008). Problem tree: A problem structuring heuristic. *Central European Journal of Public Policy*, 2(2):68–80.
- Wood, L., Anderson, K., Gerstoft, P., Bell, R., Subbaraman, R., and Bharadia, D. (2022). Deep learning object detection approaches to signal identification.
- Zhu, X., Su, W., Lu, L., Li, B., Wang, X., and Dai, J. (2021). Deformable DETR: Deformable transformers for end-to-end object detection. In *International Conference on Learning Representations (ICLR)*.
- Zhu, Z. and Sato, Y. (2025). Sound event detection using time-frequency bounding boxes with a self-supervised audio spectrogram transformer. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events 2025 Workshop (DCASE2025)*, Barcelona, Spain.