

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS E INGENIERÍA



**Detección de vocalizaciones de primates
neotropicales mediante cajas tiempo–frecuencia
para la pre-anotación asistida de grabaciones de
monitoreo acústico pasivo**

Tesis para obtener el título profesional de
Ingeniero Informático que presenta:

Fernando Nelson Candia Aroni

Asesor:

Dr. Edwin Rafael Villanueva Talavera

Lima, 2026

Índice general

1. Generalidades	2
1.1. Problemática	2
1.1.1. Recolección de datos acelerada	2
1.1.2. Análisis lento e inconsistente	4
1.1.3. Investigaciones anteriores	4
1.1.4. Vacío y contribución	5
1.2. Árbol de problemas	7
1.2.1. Condiciones subyacentes	8
1.2.2. Problema central	8
1.2.3. Causas	9
1.2.4. Efectos	11
1.3. Objetivos	12
1.3.1. Objetivo general	12
1.3.2. Objetivos específicos	12
1.4. Resultados esperados	13
1.4.1. OE1: Protocolo y conjunto de datos curado	13
1.4.2. OE2: Detector y evaluación	15
1.4.3. OE3: Tiempo de revisión y análisis de errores	17
1.5. Trazabilidad	18
1.6. Métodos y procedimientos	18
1.6.1. Metodología CRISP-DM	18
1.6.2. Herramientas	23
1.6.3. Procedimientos y reproducibilidad	23
2. Marco Referencial	26
2.1. Marco Teórico	26
2.1.1. Formulación del problema de detección	26
2.1.2. El espectrograma y la asimetría de sus ejes	29
2.1.3. Detección de objetos sobre audio	30
2.2. Marco Conceptual	31
2.2.1. Paisaje sonoro	31
2.2.2. Eventos acústicos	32
2.2.3. Representaciones tiempo–frecuencia	33

2.2.4.	Detección de eventos sonoros	34
2.2.5.	Clasificación jerárquica	37
2.2.6.	Anotaciones inconsistentes	38
3.	Estado del Arte	41
3.1.	Metodología de la revisión	41
3.1.1.	Objetivos y preguntas de revisión	41
3.1.2.	Estrategia de búsqueda	42
3.1.3.	Criterios de inclusión y exclusión	42
3.2.	Resultados de la revisión	44
3.2.1.	P1: Estrategias de detección tiempo–frecuencia	44
3.2.2.	P2: Clasificación jerárquica fina	45
3.2.3.	P3: Mitigación de ruido y variabilidad entre sensores	45
3.2.4.	P4: Conjuntos de datos y aumento de datos	46
3.2.5.	P5: Transferencia de aprendizaje	46
4.	Curación del Conjunto de Datos (OE1)	49
4.1.	Análisis del conjunto original	49
4.1.1.	Material recibido y formato	49
4.1.2.	Defectos detectados	50
4.1.3.	Composición del conjunto curado	52
4.1.4.	Geometría de los eventos	54
4.1.5.	Sílabas y frases	55
4.2.	Protocolo de curación y estandarización (RE1.1)	57
4.2.1.	Carga y consolidación	57
4.2.2.	Normalización de etiquetas	58
4.2.3.	Saneamiento geométrico	59
4.2.4.	Vocabulario cerrado y selección del subconjunto	60
4.3.	Particionado y ventaneo (RE1.2)	60
4.3.1.	Partición por archivo de grabación	60
4.3.2.	El ventaneo y su defecto	63
4.3.3.	Densidad de eventos por ventana	63
4.3.4.	Representación y normalización de las cajas	64
4.4.	Revisión posterior del vocabulario	66
4.5.	Ficha del conjunto derivado (RE1.3)	67
5.	Detección, Evaluación y Utilidad Operativa (OE2 y OE3)	72
5.1.	Arquitectura propuesta y línea base (RE2.1)	72
5.2.	Pipeline de entrenamiento e inferencia (RE2.2)	77
5.3.	Protocolo de evaluación	77
5.4.	Resultados (RE2.3)	77
5.5.	Exportación a Raven (RE2.4)	77
5.6.	Publicación del código y del modelo (RE2.5)	77

A. Plan del Proyecto	80
A.1. Justificación y viabilidad	80
A.1.1. Justificación	80
A.1.2. Beneficios esperados	80
A.1.3. Viabilidad técnica	81
A.1.4. Viabilidad temporal	81
A.1.5. Viabilidad económica	81
A.2. Definición y alcance del proyecto	81
A.2.1. Alcance	81
A.2.2. Entregables y criterios de aceptación	82
A.2.3. Exclusiones	83
A.2.4. Limitaciones y restricciones	83
A.3. Planificación del proyecto	83
A.3.1. Estructura de desglose del trabajo	83
A.3.2. Cronograma	85
A.3.3. Estimación de costos	85
A.3.4. Lista de recursos	85
A.3.5. Gestión de riesgos	87

Índice de figuras

1.1. Ejemplo de anotación tiempo–frecuencia en Raven.	3
1.2. Tres formas de salida de un evento sonoro.	5
1.3. Árbol de problemas.	7
1.4. Material recibido por especie.	9
1.5. Fases de CRISP-DM del proyecto.	19
1.6. Criterio de IoU.	23
2.1. Segmentación tiempo–frecuencia	27
2.2. Cadena de la señal.	31
2.3. Compromiso STFT.	34
2.4. Escala mel.	34
2.5. PCEN frente a log-mel.	35
4.1. Archivo de anotaciones de Raven	49
4.2. Raven con una grabación anotada	50
4.3. Etiquetas únicas encontradas en la columna de especie.	51
4.4. Etiquetas únicas encontradas en la columna de tipo de llamada.	51
4.5. Advertencias emitidas durante la carga automatizada de las grabaciones.	51
4.6. Grabación con corrupción leve	52
4.7. Grabación con corrupción severa	52
4.8. Galería de llamadas.	53
4.9. Geometría de las clases	55
4.10. Duración frente a ancho de banda	56
4.11. Anidamiento frase-sílaba.	57
4.12. Pipeline de curación.	58
4.13. Partición por grabación.	62
4.14. Efecto del ventaneo.	64
4.15. Ventana de entrenamiento	65
4.16. Coordenadas de la caja.	66
4.17. Anotaciones por par tras la revisión	68
4.18. Cajas por clase y partición	69
4.19. Anotaciones alcanzables por el ventaneo	69
4.20. Cajas anotadas por ventana	70
5.1. Arquitectura propuesta.	72

5.2. Pirámide multiescala.	73
5.3. Capa del decodificador.	73
5.4. Muestreo deformable.	74
5.5. Pipeline de entrenamiento.	74
5.6. Emparejamiento húngaro.	74
5.7. Pipeline de inferencia.	75
5.8. Umbral de confianza.	75
5.9. Recall por clase.	76
5.10. Detecciones cualitativas.	77
5.11. Matriz de confusión.	78
5.12. Distribución de IoU.	78
5.13. Ablación acumulada.	79
5.14. Línea de tiempo de detecciones.	79
5.15. Previsualización de la tabla de Raven.	79
A.1. EDT en árbol.	85

Índice de tablas

1.1. Resumen por especie	3
1.2. Vacío del problema	6
1.3. Disponibilidad en Xeno-canto	6
1.4. IOV de OE1	14
1.5. IOV de OE2	16
1.6. IOV de OE3	17
1.7. Trazabilidad del planteamiento	18
1.8. Fases de CRISP-DM y objetivos	19
1.9. Métricas de evaluación	22
1.10. Stack técnico: pipeline	24
1.11. Stack técnico: desarrollo	25
2.1. Arquitecturas frente a requisitos	36
2.2. Especies de primates consideradas en el proyecto	38
2.3. Repertorio por especie	39
3.1. Cadenas de búsqueda	42
3.2. Criterios de inclusión y exclusión	43
4.1. Composición del vocabulario curado por especie	53
4.2. Variación de tamaño de las llamadas anotadas	54
4.3. Clases del subconjunto de experimento	61
4.4. Composición de las particiones tras el ventaneo	62
4.5. Anotaciones que el ventaneo de 3s vuelve inalcanzables	63
4.6. Parámetros de preprocesamiento	65
A.1. Criterios de aceptación	82
A.2. EDT del proyecto	84
A.3. Costos de equipos y hardware	86
A.4. Capital intelectual	86
A.5. Costos de software y servicios	86
A.6. Costos indirectos	87
A.7. Resumen de costos	87
A.8. Riesgos del proyecto	88

Capítulo 1

Generalidades

1.1. Problemática

1.1.1. Recolección de datos acelerada

El monitoreo acústico pasivo (PAM) consiste en dejar grabadoras autónomas en el campo y registrar el sonido del ecosistema de forma continua. Frente a otros métodos de muestreo, los sensores acústicos no son invasivos, suelen ser omnidireccionales y ofrecen un área de detección mayor y menos restricciones taxonómicas que las cámaras trampa (Gibb et al., 2018). Permiten muestrear durante periodos largos con poco esfuerzo manual, lo que aumenta la probabilidad de detectar especies raras o poco vocales (Gibb et al., 2018), justamente el caso de los primates neotropicales de la Amazonía peruana, difíciles de observar de forma directa.

La aparición de sensores de bajo costo y código abierto está ampliando rápidamente el acceso a estas tecnologías y permite desplegar redes multisensor a escala (Gibb et al., 2018). El costo de grabar y almacenar cayó lo suficiente como para hacer viable la captura continua de audio (Stowell, 2022). El conjunto sobre el que trabaja esta tesis lo ilustra: 3 355 grabaciones de ocho especies de primates, con una duración acumulada de 32,69 horas, de las cuales 2 820 grabaciones (26,36 horas) cuentan con anotaciones expertas. La composición por especie se detalla en la Tabla 1.1. Sobre ese material, el protocolo de curación del Capítulo 4 deja 19 029 anotaciones utilizables: es la magnitud que conviene retener para contrastarla, más adelante, con lo disponible públicamente.




Figura 1.1: Ejemplo de anotación tiempo–frecuencia en Raven.

Tabla 1.1: Resumen por especie

Especie (código)	Total		Con anotaciones	
	N.º	Horas	N.º	Horas
Mono ardilla boliviano (SB)	290	3,08	256	2,79
Mono aullador (AS)	808	7,57	779	7,27
Capuchino de cabeza grande (SM)	659	6,13	582	5,31
Mono nocturno (AA)	116	1,10	83	0,78
Mono araña peruano (AC)	561	6,07	383	3,62
Capuchino de cabeza chata (CC)	16	0,11	7	0,04
Tití de Toppin (PT)	375	3,35	320	2,82
Tamarino de Weddell (LW)	530	5,28	410	3,71
Total	3 355	32,69	2 820	26,36

1.1.2. Análisis lento e inconsistente

El cuello de botella habitual es la falta de tiempo-persona de analistas entrenados (Stowell, 2022), y recolectar anotaciones es el principal cuello de botella para construir estos métodos (Nguyen Hong Duc et al., 2021). El trabajo se hace a mano. El analista abre cada grabación, inspecciona el espectrograma, dibuja un recuadro alrededor de cada vocalización y le asigna una etiqueta. En detección de eventos sonoros, recolectar etiquetas fuertes a gran escala consume mucho tiempo, y en la mayoría de los casos varios trabajadores se reparten las anotaciones para construir un solo conjunto de datos (Koga et al., 2024).

Ese reparto introduce un segundo problema ya que la anotación manual es subjetiva, y resulta difícil cuantificar los sesgos ligados al nivel de conocimiento del analista (Gibb et al., 2018); estudios recientes muestran que la tarea genera errores específicos de cada anotador (Nguyen Hong Duc et al., 2021). Al comparar varios anotadores sobre el mismo audio, las etiquetas fuertes presentan variaciones grandes tanto en el tipo de evento como en los tiempos de inicio y fin, hasta el punto de que determinar una etiqueta única resulta difícil (Koga et al., 2024). En bioacústica marina, Leroy et al. (2018) encontraron menos del 50 % de acuerdo entre dos analistas, y también un acuerdo pobre de un mismo analista al anotar dos veces el mismo segmento.

La variación temporal en las etiquetas fuertes es inevitable, y afecta tanto al entrenamiento del modelo como a la evaluación de su desempeño (Koga et al., 2024). Esto significa que en proyectos donde se aplica PAM, una gran parte del audio queda sin anotar y las etiquetas anotadas son inconsistentes.

1.1.3. Investigaciones anteriores

Los sistemas más difundidos clasifican segmentos de duración fija. BirdNET identifica cientos de especies de aves puntuando ventanas cortas de audio (Kahl et al., 2021) y, en un caso más cercano al de esta tesis, HOWLish detecta aullidos de lobo con una precisión de 0,006 bajo un desbalance extremo, y aun así reduce unas 15 veces el tiempo del operador frente a anotar todo a mano (Campos et al., 2025). Ese resultado es relevante porque muestra que, cuando un humano revisa la salida, aceptar precisión baja a cambio de recall alto es una estrategia válida. Su limitación es la forma del resultado: una probabilidad por segmento, no un evento delimitado.

Una segunda línea sí devuelve eventos. Los *sound event bounding boxes* formalizan cada predicción como una cuádrupla de clase, tiempo de inicio, tiempo de fin y una puntuación global de confianza (Ebbers et al., 2024). Es un evento con extensión propia, pero esa extensión existe solo sobre el eje temporal.

La tercera línea trata el espectrograma como una imagen. La idea de partida es que los eventos acústicos se manifiestan como patrones bidimensionales de tiempo y frecuencia, con texturas y estructuras geométricas propias, análogos a los objetos que aparecen en imágenes naturales (Pham et al., 2018). El trabajo más cercano al de esta tesis es NBM, que publica anotaciones precisas de tiempo y frecuencia recolectadas por decenas de aficionados a las aves en Francia, junto con un modelo de detección de objetos de dos etapas adaptado a datos de audio (Airale et al., 2025).




Figura 1.2: Tres formas de salida de un evento sonoro.

1.1.4. Vacío y contribución

El vacío tiene dos ejes, y esta tesis se sitúa en el cruce (Tabla 1.2).

Tabla 1.2: Vacío del problema

	Tarea madura: detección temporal	Tarea poco explorada: cajas tiempo–frecuencia
Dominio con recursos (aves, mamíferos marinos, cánidos)	BirdNET, SEBB, YOHO	NBM (Airale et al., 2025), YOLOv5 en focas barbudas (Escobar-Amado et al., 2024)
Dominio sin recursos (primates neotropicales)	Heinicke et al. (2015), primates africanos	Vacío: esta tesis

Eje de dominio. Los sistemas maduros existen para aves, lobos y mamíferos marinos. Para primates neotropicales de la Amazonía no hay un conjunto público con anotaciones tiempo–frecuencia. La Tabla 1.3 lo documenta sobre el repositorio abierto de grabaciones de fauna más utilizado: para las ocho especies objetivo, Xeno-canto contiene 32 grabaciones en primer plano y poco más de una hora de audio en total, tres especies no tienen ninguna grabación, y ninguna de las disponibles incluye anotaciones tiempo–frecuencia.

Tabla 1.3: Disponibilidad de grabaciones de las especies objetivo en Xeno-canto

Especie	Grabaciones (primer plano)	Duración total
<i>Alouatta sara</i>	8	41:14
<i>Plecturocebus toppini</i>	13	19:20
<i>Ateles chamek</i>	4	03:42
<i>Saimiri boliviensis</i>	4	02:28
<i>Aotus azarae</i>	3	02:18
<i>Cebus cuscinus</i>	0	N/D
<i>Leontocebus weddelli</i>	0	N/D
<i>Sapajus apella macrocephalus</i>	0	N/D
Total	32	69:02

Consulta realizada el 19 de agosto de 2026 sobre el nombre científico de cada especie (Vellinga, 2026).

Eje de tarea. El vacío tampoco es solo de dominio. La investigación existente ha pasado por alto en gran medida el rango de frecuencia de los eventos; el SED temporal descarta información codificada en el dominio frecuencial, y por eso la detección precisa

de cajas tiempo–frecuencia puede asistir al investigador humano. Pese a esa relevancia, sigue siendo un área en gran medida inexplorada (Zhu and Sato, 2025).

En el cruce de ambos ejes se sitúa esta tesis, que desarrolla un protocolo de curación y estandarización sobre las anotaciones producidas por el equipo de investigación, y un detector que devuelve cajas tiempo–frecuencia con especie, tipo de llamada y confianza, concebido como herramienta de pre-anotación asistida.

1.2. Árbol de problemas

El árbol se estructura siguiendo el heurístico de análisis causa–efecto propuesto por Veselý (2008), y sirve de puente entre la brecha operativa descrita en la sección anterior y los objetivos de la investigación. Organiza el área temática en causas, problema central y efectos para ordenar el trabajo posterior, sin cuantificar las relaciones entre sus elementos.




Figura 1.3: Árbol de problemas.

1.2.1. Condiciones subyacentes

Dos condiciones enmarcan el problema sin ser causas sobre las que esta tesis pueda actuar. Se consignan aparte, siguiendo la recomendación de Veselý (2008) de ubicar fuera del eje causal aquello sin lo cual el problema no existiría o existiría de otra forma.

S1: Grabar se volvió barato, pero analizar no

Los sensores de bajo costo permiten desplegar redes de muchos micrófonos a escala (Gibb et al., 2018). La condición no es negativa en sí misma; es la que vuelve visible y creciente la distancia entre lo que se graba y lo que se llega a revisar.

S2: La unidad acústica no tiene una definición estable ni fronteras discretas

Las unidades acústicas pueden estar jerárquicamente anidadas, de modo que una secuencia de unidades puede considerarse ella misma una unidad y ser reemplazada por una etiqueta; se organizan en notas, trinos, sílabas, frases, motivos y cantos, y las definiciones de unidad varían ampliamente entre investigadores, incluso dentro de un mismo grupo taxonómico (Kershenbaum et al., 2016). A ello se suma que las unidades producidas por animales exhiben variación graduada en sus rasgos, mientras que la mayoría de métodos analíticos asume categorías discretas (Kershenbaum et al., 2016). La indefinición de granularidad es, entonces, anterior al anotador y no se resuelve entrenándolo mejor. Esta condición es la que justifica, más adelante, una curación metodológica explícita en lugar de una corrección de las anotaciones recibidas.

1.2.2. Problema central

El análisis del audio de monitoreo acústico pasivo no acompaña al ritmo de su recolección, y las anotaciones que sí se producen no son consistentes entre sí.

El enunciado tiene deliberadamente dos predicados, porque el problema tiene dos dimensiones que ninguna de las dos agota por separado: un déficit de *caudal* (se anota mucho menos de lo que se graba) y un déficit de *consistencia* (lo que se anota no obedece a un criterio único). Un planteamiento que solo recogiera el primero dejaría sin cubrir la causa C2 y el efecto E2; uno que solo recogiera el segundo no explicaría todo el audio que queda sin anotar.

Del lado de la recolección, el despliegue a escala es hoy accesible (S1). Del lado del análisis, la gran cantidad de audio que se acumula hace que un cuello de botella común sea la falta de tiempo-persona de analistas entrenados (Stowell, 2022). Conforme escala el número de grabadoras desplegadas, detectar señales acústicas en los paisajes sonoros registrados se vuelve un obstáculo logístico que limita la escalabilidad de los estudios de PAM (Campos et al., 2025).




Figura 1.4: Material recibido por especie.

1.2.3. Causas

C1: Hay pocas horas de analista experto disponibles

Los eventos sonoros requieren que un experto los anote con las etiquetas correctas, y ese tiempo experto suele escasear; la restricción se siente tanto en distinciones categóricas finas como en el monitoreo a gran escala, donde el volumen de datos excede con mucho las horas-persona disponibles (Stowell, 2022). En detección de eventos sonoros, recolectar etiquetas fuertes a gran escala consume mucho tiempo, y por eso varios trabajadores se reparten las anotaciones para construir un solo conjunto de datos (Koga et al., 2024). El reparto entre anotadores es la respuesta habitual a esta restricción, y es también el punto donde C1 y C2 se encuentran: alivia el caudal a costa de multiplicar los criterios en juego.

C2: Inconsistencia entre anotadores y dentro de un mismo anotador

La tarea es subjetiva y genera errores específicos de cada anotador (Nguyen Hong Duc et al., 2021), y los sesgos ligados al nivel de conocimiento del analista son difíciles de

cuantificar (Gibb et al., 2018). La magnitud está medida: menos del 50 % de acuerdo entre analistas, y acuerdo pobre de un mismo analista consigo mismo (Leroy et al., 2018); con 20 anotadores por clip, las etiquetas fuertes presentan variaciones grandes en tipo de evento y en tiempos de inicio y fin (Koga et al., 2024). Estudios previos no han encontrado soluciones suficientes, y la variación afecta tanto el entrenamiento como la evaluación (Koga et al., 2024).

Interesa subrayar que este desacuerdo es una propiedad medible de la tarea y no un defecto individual corregible: descansa sobre S2, que fija su piso. Reducirlo a cero no es un objetivo alcanzable, y cualquier propuesta metodológica debe trabajar con él en lugar de suponerlo ausente.

C3: La salida de los sistemas automáticos no sustituye el trabajo del analista

La automatización sería la vía natural para aliviar C1, pero su producto actual no es un reemplazo directo del insumo que el analista necesita. Esto ocurre por dos motivos distintos, uno de representación y otro de cobertura.

En cuanto a la representación, los sistemas basados en segmentos fijos entregan una probabilidad asociada a una rejilla, no un evento con extensión propia: BirdNET divide las grabaciones en fragmentos de 3 s y almacena las probabilidades por especie de cada segmento (Kahl et al., 2021), y HOWLish segmenta en ejemplos de 0,96 s y promedia las predicciones con una ventana móvil (Campos et al., 2025). Los sistemas que sí entregan eventos delimitados los definen solo sobre el eje temporal, sea como cuádruplas de clase, onset, offset y confianza (Ebbers et al., 2024), sea regresando los puntos de inicio y fin de cada clase (Venkatesh et al., 2022). La frecuencia, sin embargo, aporta información que el biólogo usa: las cajas predichas llevan información estadística embebida sobre la vocalización, como su duración, ancho de banda y frecuencia central (Escobar-Amado et al., 2024).

En cuanto a la cobertura, aun cuando la precisión es alta, los métodos del estado del arte fallan con regularidad al distinguir llamadas tenues, transitorias o parcialmente enmascaradas, produciendo tasas altas de falsos negativos (Gibb et al., 2018). Una salida automática incompleta no descarga al analista: lo obliga a revisar igual.

1.2.4. Efectos

Los efectos se organizan por actor afectado, siguiendo el criterio que Veselý (2008) ilustra en su tercer ejemplo, en lugar de asignar un efecto a cada causa. E1 y E2 son efectos directos; E3 se deriva de ambos.

E1: Para el equipo de investigación, el material grabado crece más rápido de lo que puede analizarse

El volumen de datos excede con mucho las horas-persona disponibles (Stowell, 2022), y la detección de señales en los paisajes sonoros registrados se convierte en un obstáculo logístico conforme escalan los despliegues (Campos et al., 2025). El efecto práctico es que el esfuerzo y el gasto de despliegue quedan inmovilizados en material sin procesar, y que la porción del material efectivamente anotada responde a la disponibilidad del analista antes que a un criterio de muestreo.

E2: Para el desarrollo metodológico, no hay una referencia confiable contra la cual medir el avance

La variación en las etiquetas fuertes no solo afecta el entrenamiento del modelo, sino que tiene un impacto significativo sobre la evaluación de su desempeño (Koga et al., 2024). En el terreno de las cajas tiempo–frecuencia, Zhu and Sato (2025) observan desplazamientos relativamente grandes de las cajas predichas frente a las anotadas, y concluyen que las fronteras de los eventos son borrosas y difíciles de determinar, por lo que fijar un umbral de IoU bajo es razonable. A la heterogeneidad se suma un faltante no aleatorio: las llamadas tenues o enmascaradas escapan a los métodos automáticos (Gibb et al., 2018), de modo que los eventos ausentes de la referencia son sistemáticamente los más difíciles. La consecuencia es que las cifras de desempeño reportadas son difíciles de comparar entre trabajos y tienden a describir mejor las condiciones fáciles que el problema completo.

E3: Para la ecología y la gestión, las preguntas se responden tarde o sobre muestras sesgadas

Efecto indirecto, derivado de E1 y E2. El PAM es cada vez más adecuado para programas de monitoreo orientados a objetivos, cuyos protocolos deben ser estandarizables, escalables y financieramente sostenibles (Gibb et al., 2018); sus beneficios incluyen el muestreo continuo con poco esfuerzo manual y una mayor probabilidad de detectar

especies raras o poco vocales (Gibb et al., 2018). Cuando el análisis no acompaña a la recolección, esas ventajas no se materializan: la ventaja de detección de lo raro se pierde por E1, y la confianza en lo que se reporta se erosiona por E2. En primates, Heinicke et al. (2015) ya habían señalado el costo de esta brecha al evaluar un sistema de monitoreo acústico en un ambiente de selva altamente ruidoso.

1.3. Objetivos

1.3.1. Objetivo general

OG. Desarrollar y evaluar un sistema de pre-anotación asistida que proponga cajas tiempo–frecuencia con especie y tipo de llamada sobre grabaciones de PAM de primates amazónicos, con el fin de reducir el tiempo de revisión experta.

El encuadre asistido cuenta con respaldo en la literatura. La inteligencia artificial no reemplaza la experiencia, y conforme estos sistemas se estandarizan asumen el papel de pares expertos con quienes se consulta y debate, sin desplazar el rol del experto ni el del trabajo colaborativo (Stowell, 2022). También tiene precedente cuantificado en primates. Heinicke et al. (2015) evaluaron un sistema de monitoreo acústico para cuatro especies de primates en el ambiente altamente ruidoso del Parque Nacional Tai, y reportan que, pese a una precisión aparentemente baja, la inversión de tiempo para remover manualmente los falsos positivos de la salida del sistema fue de apenas 3–5 % comparada con la de un humano recolectando y procesando los datos de vocalización.

El mismo patrón se repite fuera de primates: HOWLish recupera el 81,3 % de los eventos de aullido observados y ofrece una reducción de 15 veces en el tiempo del operador frente a la detección totalmente manual, y su tubería redujo 22 veces el volumen de datos que un operador debía procesar manualmente (Campos et al., 2025).

1.3.2. Objetivos específicos

Cada objetivo específico responde a una de las tres causas del árbol: OE1 a la inconsistencia del etiquetado (C2), OE2 a la forma de la salida (C3) y OE3 a la escasez de horas de analista (C1).

- OE1.** Definir un protocolo de curación y estandarización, y aplicarlo sobre las anotaciones entregadas por el equipo de investigación para construir un conjunto de datos consistente de cajas tiempo–frecuencia etiquetadas por especie y tipo de llamada.
- OE2.** Implementar y evaluar un detector que reciba un espectrograma y devuelva cajas tiempo–frecuencia con especie, tipo de llamada y confianza, comparándolo con una línea base establecida.
- OE3.** Cuantificar la reducción del tiempo de revisión que aporta el sistema y caracterizar sus errores mediante revisión experta de una muestra de predicciones.

1.4. Resultados esperados

1.4.1. OE1: Protocolo y conjunto de datos curado

Las grabaciones y las anotaciones primarias provienen del equipo de investigación. La contribución de esta tesis es la normalización, el particionado y la caracterización del conjunto derivado, no la anotación original.

RE1.1. Protocolo documentado: vocabulario cerrado de clases, mapa de sinónimos, reglas de descarte y criterio de partición. Las definiciones de unidad y las etiquetas semánticas varían ampliamente entre investigadores (Kershenbaum et al., 2016), lo que justifica cerrar el vocabulario, y los protocolos de monitoreo deben ser estandarizables (Gibb et al., 2018).

RE1.2. Conjunto curado y particionado por archivo de grabación, sin solapamiento entre particiones. La variación en las etiquetas fuertes impacta la evaluación (Koga et al., 2024), por lo que una partición que no infle artificialmente el resultado es condición para que las cifras sean interpretables.

RE1.3. Ficha del conjunto derivado: composición, desbalance, sesgos conocidos y limitaciones. Pese a la importancia de los datos para el aprendizaje automático, no existe un proceso estandarizado para documentar conjuntos de datos; las *datasheets* proponen documentar motivación, composición, proceso de recolección y usos recomendados, con el potencial de aumentar la transparencia y la rendición de cuentas (Geburu et al., 2021). La ficha distingue dos capas: el conjunto primario, producido por el equipo de investigación, y el conjunto derivado, producido por esta tesis.

Tabla 1.4: Resultados esperados, medios de verificación e indicadores objetivamente verificables de OE1

RE	Resultado	Medio de verificación	Indicador objetivamente verificable (IOV)
RE1.1	Protocolo de curación y estandarización documentado.	Documento del protocolo.	Define la normalización de columnas y etiquetas, el mapa de sinónimos, el descarte de ruido y cajas degeneradas, la corrección de pares imposibles, el recorte al límite de Nyquist y el tratamiento de registros fuera de vocabulario.
RE1.2	Conjunto acústico curado y particionado para el experimento.	Directorio <code>data/processed/</code> : etiquetas, metadatos y tres archivos <code>.pt</code> .	Los archivos procesados cargan sin error; <code>meta.json</code> registra la semilla, el criterio de selección, las exclusiones, la etiqueta usada y la normalización; el código divide por archivo de grabación con proporciones 60/22,5/17,5 y no por ventanas aisladas.
RE1.3	Ficha del conjunto derivado.	Capítulo de curación, README y metadatos del conjunto.	Describe las ocho especies, el vocabulario, la composición, el desbalance, el diccionario de campos, el ventaneo de 3 s con salto de 1,5 s, la normalización log-mel, las exclusiones y las limitaciones conocidas.

La decisión de excluir las clases de frase se apoya directamente en Kershenbaum et al. (2016): las unidades pueden estar jerárquicamente anidadas, de modo que una secuencia de unidades puede considerarse ella misma una unidad, y un detector de conjunto plano no puede representar esa relación.

1.4.2. OE2: Detector y evaluación

RE2.1. Documento de diseño: arquitectura propuesta y línea base, con justificación de ambas. Los eventos se manifiestan como patrones bidimensionales con texturas y estructuras geométricas propias, análogos a los objetos de imágenes naturales (Pham et al., 2018), y detectar un objeto implica tanto afirmar que una clase está presente como localizarla, localización que se representa típicamente mediante una caja delimitadora (Lin et al., 2014). La brecha de modalidad entre imagen y audio justifica sustituir los *backbones* preentrenados en imágenes (Zhu and Sato, 2025). Como precedentes de detección bidimensional en bioacústica se consideran Escobar-Amado et al. (2024) y Airale et al. (2025), y como línea base sobre espectrogramas, González et al. (2025).

RE2.2. Pipeline reproducible de entrenamiento, evaluación e inferencia. La pirámide multiescala corrige que las arquitecturas de tipo ViT y AST produzcan representaciones de escala única (Zhu and Sato, 2025).

RE2.3. Informe de evaluación desagregado en detección, encuadre y clasificación, con comparación contra la línea base. Un umbral de IoU bajo es razonable cuando las fronteras de los eventos son borrosas (Zhu and Sato, 2025), y el sesgo hacia el recall se justifica por el fallo sistemático de los métodos automáticos ante llamadas tenues o enmascaradas (Gibb et al., 2018).

RE2.4. Modelo final y exportador a tabla de selección de Raven. Las cajas llevan información estadística embebida útil para el analista, como la duración, el ancho de banda y la frecuencia central (Escobar-Amado et al., 2024).

RE2.5. Repositorio público con código y pesos del modelo.

El contraste que sostiene RE2.4 es directo: BirdNET y HOWLish entregan probabilidad por segmento (Kahl et al., 2021; Campos et al., 2025), los *sound event bounding boxes* y YOHO entregan límites temporales (Ebberts et al., 2024; Venkatesh et al., 2022),

Tabla 1.5: Resultados esperados, medios de verificación e indicadores objetivamente verificables de OE2

RE	Resultado	Medio de verificación	Indicador objetivamente verificable (IOV)
RE2.1	Diseño experimental, arquitectura propuesta y línea base.	Documento de diseño y módulo de arquitecturas.	Especifica la arquitectura AST-Deformable-DETR implementada, con dimensión 128, 64 consultas y 3 niveles, sus hiperparámetros, y define la comparación con la línea base declarada.
RE2.2	Pipeline reproducible de entrenamiento, evaluación e inferencia.	Scripts de datos, entrenamiento, evaluación e inferencia; módulos de <code>src/pipelines/</code> ; <code>pyproject.toml</code> y manual técnico.	El pipeline genera los splits procesados, entrena desde un conjunto de configuración, evalúa un checkpoint y ejecuta inferencia sobre un WAV; las dependencias y comandos de ejecución están declarados.
RE2.3	Informe comparativo de resultados.	Informe de experimentación y archivos de métricas.	Reporta, como mínimo, recall, precisión, F1, IoU medio, AP a IoU 0,25 y 0,5, recall por clase y matriz de confusión; separa detección, encuadre y clasificación y justifica la selección del modelo.
RE2.4	Modelo final cargable y demostración funcional.	Checkpoint <code>.pth</code> , <code>labels.json</code> y ejecución de <code>src/infer.py</code> .	El checkpoint se carga sin claves incompatibles y la inferencia sobre un WAV produce un archivo tabulado con las columnas de Raven, incluidas coordenadas tiempo–frecuencia, especie, tipo de llamada y puntuación.
RE2.5	Código y modelo disponibles en un repositorio.	Repositorio de control de versiones.	La URL del repositorio permite localizar el código de curación, entrenamiento, evaluación e inferencia, junto con las instrucciones de ejecución y los artefactos del modelo final que se hayan decidido publicar.

y esta tesis entrega la tupla completa de tiempo, frecuencia, especie, tipo de llamada y confianza.

1.4.3. OE3: Tiempo de revisión y análisis de errores

Tabla 1.6: Resultados esperados, medios de verificación e indicadores objetivamente verificables de OE3

RE	Resultado	Medio de verificación	Indicador objetivamente verificable (IOV)
RE3.1	Metodología de validación comparativa.	Documento de metodología y protocolo de revisión experta.	Especifica el subconjunto de prueba, el punto de operación (confianza 0,5 y NMS IoU 0,3), el umbral IoU 0,5 para verdadero positivo, las métricas, el emparejamiento y el procedimiento para revisar discrepancias y eventos potencialmente omitidos.
RE3.2	Medición comparativa del tiempo de revisión.	Informe de validación, registros de tiempo y medición de inferencia.	Reporta minutos por hora de audio en condición manual y asistida, describe el material comparable y el orden de revisión, y presenta el tiempo de procesamiento del modelo por hora de audio. No fija un porcentaje de ahorro antes de medirlo.
RE3.3	Análisis cualitativo de errores y hallazgos.	Informe de análisis y espectrogramas anotados.	Clasifica una muestra de predicciones de alta confianza en evento no anotado, ruido y error de encuadre, e incluye ejemplos visuales de aciertos, errores comunes y detecciones correctas ausentes de la anotación de referencia.

RE3.1. Protocolo de la prueba: material, punto de operación, procedimiento y métricas, siguiendo el marco de tubería para identificación automatizada de sonidos (Gibb et al., 2018).

RE3.2. Medición del tiempo de revisión asistida frente a anotación manual sobre material comparable. Heinicke et al. (2015) reportan que en primates la remoción manual de falsos positivos tomó 3–5 % del tiempo frente a la recolección y el procesamiento humanos, y Campos et al. (2025) reportan una reducción de 15 veces

en tiempo de operador y de 22 veces en volumen de audio a revisar. Son los dos precedentes metodológicos de esta medición.

RE3.3. Informe de revisión experta de falsos positivos de alta confianza, clasificados en evento no anotado, ruido o error de encuadre. Los métodos automáticos fallan con llamadas tenues o enmascaradas (Gibb et al., 2018), lo que implica la existencia de eventos válidos fuera del *ground truth*; la variabilidad intra-analista (Leroy et al., 2018) apunta en la misma dirección desde el lado humano.

1.5. Trazabilidad

La relación entre las causas del problema, sus efectos y los productos comprometidos se resume en la Tabla 1.7. En la práctica, OE1 aborda la heterogeneidad del etiquetado, OE2 la representación funcional de los eventos, y OE3 la utilidad operativa del sistema dentro del flujo de trabajo del analista.

Tabla 1.7: Trazabilidad entre causas, efectos, objetivos y resultados esperados

Causa	Efecto	Objetivo	Resultados esperados
C1: Velocidad	E1	OE3	RE3.1, RE3.2, RE3.3
C2: Consistencia	E2	OE1	RE1.1, RE1.2, RE1.3
C3: Forma de la salida	E1, E2	OE2	RE2.1, RE2.2, RE2.3, RE2.4, RE2.5
E1, E2	E3	OG	Sistema de pre-anotación asistida integrado

1.6. Métodos y procedimientos

1.6.1. Metodología CRISP-DM

El desarrollo se organiza siguiendo CRISP-DM (*Cross-Industry Standard Process for Data Mining*), un marco iterativo, independiente de la industria y de la herramienta, que proporciona una hoja de ruta general para proyectos de minería de datos (Chapman et al., 2000). Su estructura cíclica, desde la comprensión del problema hasta el despliegue de la solución, se ajusta a un proyecto de investigación aplicada en el que la comprensión de los datos, la experimentación con modelos y la evaluación continua se realimentan




Figura 1.5: Fases de CRISP-DM del proyecto.

entre sí. La Tabla 1.8 resume la correspondencia entre las seis fases, los objetivos específicos y los capítulos de este documento.

Tabla 1.8: Fases de CRISP-DM y objetivos

Fase	Contenido en este proyecto	Objetivo	Capítulo
1. Comprensión del negocio	Árbol de problemas, objetivos y criterios de éxito	N/A	1
2. Comprensión de los datos	Análisis exploratorio y verificación de calidad de las anotaciones recibidas	OE1	4
3. Preparación de datos	Curación, vocabulario cerrado, particionado y ventaneo	OE1	4
4. Modelado	Detector de cajas tiempo–frecuencia y línea base	OE2	5
5. Evaluación	Métricas por eje, análisis de errores y tiempo de revisión	OE2, OE3	5
6. Despliegue	Inferencia por lotes y exportación a tabla de selección de Raven	OE2	5

Fase 1: Comprensión del negocio o de la investigación.

Convierte el conocimiento del dominio y los objetivos del proyecto en una definición formal del problema de minería de datos (Chapman et al., 2000). Esa traducción es el contenido de las secciones anteriores de este capítulo: la brecha operativa se estructura como árbol de problemas y de ahí derivan el objetivo general, los objetivos específicos

y los resultados esperados. Los criterios de éxito son a la vez técnicos, relacionados con el desempeño en detección, encuadre y clasificación, y operativos, vinculados con la reducción efectiva del tiempo de revisión experta, como recomienda el marco para asegurar que el resultado sea útil y no solo correcto.

Fase 2: Comprensión de los datos.

Los datos primarios son grabaciones en formato WAV muestreadas a 44,1 kHz, capturadas con dispositivos AudioMoth y entregadas por el equipo de investigación junto con sus anotaciones. Cada especie llega en una carpeta con grabaciones de duración heterogénea y un archivo de texto delimitado por tabulaciones producido con Raven Pro, en el que cada fila registra tiempo de inicio y fin, frecuencia mínima y máxima, amplitud, calidad, etiqueta de especie y etiqueta de tipo de llamada. La fase comprende el análisis exploratorio visualización de espectrogramas, distribución de clases, distribución de duraciones y rangos de frecuencia, junto con la verificación de calidad de los archivos de audio corruptos, errores tipográficos y etiquetas inconsistentes. El Capítulo 4 desarrolla ambos.

Fase 3: Preparación de datos.

Comprende la limpieza y normalización de etiquetas sobre un vocabulario cerrado, el preprocesamiento del audio, el cálculo de la representación tiempo–frecuencia, la segmentación de las grabaciones largas en ventanas de duración fija con solapamiento, y el aumento de datos mediante adición de ruido de fondo del propio entorno, desplazamiento de tono, estiramiento temporal y enmascaramiento de bloques de tiempo o frecuencia sobre el espectrograma. Aquí se resuelve la comparación entre log-mel y PCEN anunciada en la sección 2.2.3, bajo el criterio allí declarado.

Fase 4: Modelado.

La forma de la salida no está en discusión: el sistema debe emitir la tupla completa de la ecuación (2.1), y esa exigencia excluye de antemano toda arquitectura cuya cabeza produzca una probabilidad por trama o por segmento. Lo que se compara, por tanto, no son familias de arquitectura sino dos configuraciones que sí satisfacen la exigencia: la arquitectura propuesta sobre un extractor de audio con cabeza de detección y una línea base de detector sobre espectrogramas (González et al., 2025).

La regla de decisión se fija antes de entrenar: gana la configuración con mayor valor de la métrica principal definida en la Fase 5, medida sobre la partición de *validación*; la partición de prueba se reserva para reportar el desempeño de la configuración ya elegida y no participa de la elección. La implementación se realiza en PyTorch con código modular, separando la definición de la arquitectura, el bucle de entrenamiento y las utilidades.

Fase 5: Evaluación.

Los modelos entrenados se evalúan sobre la partición de prueba y los resultados se leen contra los criterios de éxito de la Fase 1. El análisis no se agota en una cifra agregada: identifica qué clases se detectan mejor y peor, qué tipos de error predominan, entre ellos la confusión entre especies acústicamente próximas, los falsos positivos por ruido y los errores de localización en tiempo o en frecuencia, y acompaña las cifras con ejemplos visualizados sobre el espectrograma.

Reportar varias métricas sin jerarquía permitiría elegir a posteriori la que favorezca al modelo preferido. Para evitarlo, la Tabla 1.9 asigna a cada una un rol fijado de antemano.

La **métrica principal** es el *recall* a nivel de evento *agnóstico a la clase*, con un umbral de IoU bidimensional de 0,5 y un umbral de confianza de 0,5. Que sea agnóstico a la clase no es un descuido: la sección 4.1.4 muestra que la geometría separa especies pero no tipos de llamada dentro de una misma especie, de modo que localizar y etiquetar son problemas de dificultad distinta, y mezclarlos en una sola cifra oculta cuál de los dos falla. El *recall* manda porque el sistema es de pre-annotación asistida y un humano revisa su salida.

El **criterio de selección de *checkpoint*** es una $F\text{-}\beta$ con $\beta = 3$, que pondera el *recall* nueve veces más que la precisión, y es la traducción operativa del requisito enunciado con el objetivo general: perder una vocalización cuesta más que revisar un falso positivo. Para que ese sesgo no degenera en proponer indiscriminadamente, junto a él se reporta el cociente **FP/TP al punto de operación**, que es literalmente la carga de revisión que el experto asume por cada acierto y la magnitud que conecta esta fase con OE3.

El encuadre se puntúa aparte, con el IoU medio sobre los pares ya emparejados y la precisión media a varios umbrales de IoU. El barrido incluye umbrales bajos porque

las fronteras del evento son borrosas incluso entre anotadores (Zhu and Sato, 2025), de modo que exigir un solapamiento alto mediría el acuerdo con un borde que el propio anotador no reproduce.

Tabla 1.9: Métricas de evaluación y rol asignado a cada una

Métrica	Definición	Rol
<i>Recall</i> por evento, agnóstico a la clase	Proporción de eventos anotados recuperados por alguna predicción cuyo solapamiento con la caja anotada supera IoU 0,5, al umbral de confianza 0,5. No exige que la clase sea correcta.	Principal
F- β con $\beta = 3$	Media armónica ponderada de precisión y <i>recall</i> que pesa el segundo nueve veces más que la primera.	Selección de <i>checkpoint</i>
FP/TP al punto de operación	Falsos positivos por cada verdadero positivo: la carga de revisión que el experto asume por cada acierto.	Costo de revisión (OE3)
IoU medio del encuadre	Solapamiento medio entre la caja predicha y la anotada, sobre los eventos ya emparejados. Mide encuadre, no detección.	Encuadre
Precisión media a varios umbrales de IoU	Precisión media agnóstica a la clase, evaluada en un barrido de umbrales de solapamiento desde exigencias laxas hasta estrictas.	Encuadre
Acierto sobre pares emparejados	Exactitud de la etiqueta de especie y tipo de llamada, condicionada a que la detección sea correcta.	Clasificación
Desempeño por clase	<i>Recall</i> individual para cada par de especie y tipo de llamada, con la causa atribuida a cada caída.	Diagnóstico

Fase 6: Despliegue.

En un proyecto de investigación el despliegue consiste en aplicar el modelo final a un volumen de grabaciones que no participaron del entrenamiento ni de la evaluación, y en producir con ellas tablas de anotación automáticas que el analista pueda abrir directamente en Raven. El artefacto es un *pipeline* de inferencia que recibe un directorio de audio, aplica exactamente el mismo preprocesamiento del entrenamiento, obtiene las predicciones crudas, ejecuta el posprocesamiento y escribe la tabla de selección en el formato esperado.




Figura 1.6: Criterio de IoU.

1.6.2. Herramientas

Cada herramienta se justifica por el requisito que satisface y por la alternativa que se descarta, no por sus virtudes generales. La Tabla 1.10 recoge las que intervienen en el recorrido del dato y la Tabla 1.11 las que sostienen el desarrollo. Donde no hay alternativa real, se dice.

1.6.3. Procedimientos y reproducibilidad

Las fases anteriores describen qué se hace con los datos y por qué. Esta subsección recoge únicamente lo operativo que no pertenece a ninguna fase en particular porque atraviesa todas: cómo se custodia el material, cómo se registran los experimentos y qué garantiza que un número reportado pueda volver a obtenerse.

Custodia del material primario. Los audios y sus anotaciones se mantienen bajo una estructura de directorios fija que no se edita nunca a mano. Toda transformación se produce por script a partir de ella y escribe en un directorio derivado distinto. Esa separación es la que permite reconstruir el conjunto de trabajo desde cero cada vez que el protocolo de curación cambia, y la que impide que una corrección puntual quede sin registro.

Registro de experimentos. Cada corrida queda asociada a un identificador de configuración y a un *commit* del repositorio. El bucle de entrenamiento registra los hiperparámetros, guarda *checkpoints* de forma periódica y evalúa sobre validación a intervalos fijos. Los scripts de evaluación son independientes de los de entrenamiento:

Tabla 1.10: Herramientas del *pipeline*, de la curación a la inferencia

Herramienta	Función en el <i>pipeline</i>	Por qué esta y no la alternativa
Python 3.12	Lenguaje de todo el sistema	R y MATLAB carecen de implementaciones de referencia de detectores de objetos, que es el componente que no se va a reimplementar
Pandas	Consolidación, limpieza y particionado de las anotaciones tabulares	Procesar los archivos de Raven con scripts <i>ad hoc</i> no deja registro reproducible de qué filas se descartaron y por qué
NumPy	Representación en memoria del audio y de las cajas antes de pasar a tensores	Sin alternativa práctica: es la interfaz común entre SoundFile, PyTorch y Matplotlib
SoundFile y soxr	Lectura por bloques de las grabaciones y remuestreo a 44,1 kHz	Permiten leer solo la ventana pedida de un archivo de una hora, en lugar de cargarlo entero en memoria
torchaudio	Cálculo del espectrograma mel que consume el modelo	Librosa devuelve arreglos de NumPy y obligaría a convertir en cada lote; aquí la transformada entrega tensores que el PCEN entrenable recibe directamente
PyTorch	Definición, entrenamiento y evaluación del detector	Las implementaciones de referencia de detectores están mayoritariamente en PyTorch, y portarlas a otro marco no se justifica
Transformers	Carga del <i>backbone</i> AST preentrenado en AudioSet	Entrenar un transformador de espectrogramas desde cero excede los datos disponibles; la biblioteca aporta los pesos y la interpolación del <i>embedding</i> posicional
Raven Pro / Lite	Origen de las anotaciones y destino de las predicciones exportadas	Sin alternativa: es la herramienta del analista, y su formato de tabla de selección es un requisito de RE2.4, no una elección de diseño

Tabla 1.11: Herramientas de desarrollo, inspección y reproducibilidad

Herramienta	Función	Por qué esta y no la alternativa
uv	Entorno virtual, resolución de dependencias y archivo de bloqueo	Instalar con <i>pip</i> sin bloqueo deja libres las versiones transitivas, y sin ellas el entorno de una corrida antigua no se reconstruye igual
Matplotlib	Figuras del análisis exploratorio y de los resultados	Sin alternativa que aporte algo distinto dentro del mismo ecosistema
PyQt6 y pyqtgraph	Visor interactivo que superpone espectrograma, anotación y predicción sobre la misma grabación	Raven no muestra la salida del modelo junto a la anotación, y una figura de Matplotlib no sostiene el desplazamiento continuo sobre una hora de audio
Ruff, ty y pytest	Formato, análisis estático y pruebas del código	Las pruebas cubren la conversión entre sistemas de coordenadas de caja, donde un error silencioso desplazaría todas las métricas sin fallar
Git	Versionado del código y de la configuración de cada experimento	Sin alternativa: es la condición para asociar un resultado reportado a un estado exacto del código

cargan un *checkpoint* existente y recalculan las métricas, de modo que reproducir una cifra publicada no exige reentrenar.

Respaldo y portabilidad. El código y la configuración se sincronizan en un repositorio remoto, y el entorno de ejecución se declara en un archivo de dependencias versionado, para que la falla del equipo de desarrollo o la ejecución en una máquina distinta no supongan rehacer trabajo. La gestión de la bibliografía se centraliza en Zotero a lo largo de todo el proceso.

La planificación que ordena todo lo anterior en el tiempo, mediante la estructura de desglose del trabajo, el cronograma, el presupuesto y la gestión de riesgos, se recoge en el Anexo A, fuera del cuerpo, porque no aporta al argumento científico y en el hilo del documento lo interrumpiría.

Capítulo 2

Marco Referencial

2.1. Marco Teórico

2.1.1. Formulación del problema de detección

El problema se plantea en dos niveles. El nivel de la *grabación* es el que le interesa al analista y define el producto; el nivel de la *ventana* es el que consume el modelo y define su entrada y su salida. Separarlos es necesario porque ninguna arquitectura actual procesa una hora de audio de una sola vez, y confundirlos oscurece qué predice realmente un detector.

Nivel de grabación

El sistema recibe un conjunto de grabaciones $G = \{g_1, g_2, \dots, g_M\}$. Cada grabación g_k es una señal de audio $x(t)$ en formato WAV, muestreada a $F_s = 44,1$ kHz, de duración D_k que puede llegar a la hora. Para cada una el sistema debe devolver una lista de eventos $E_k = \{e_1, e_2, \dots, e_{N_k}\}$, cuyo cardinal N_k no se conoce de antemano y donde cada evento es la tupla

$$e_i = (t_{\text{ini}}^{(i)}, t_{\text{fin}}^{(i)}, f_{\text{mín}}^{(i)}, f_{\text{máx}}^{(i)}, y^{(i)}, p^{(i)}). \quad (2.1)$$

$(t_{\text{ini}}, t_{\text{fin}})$ Instantes de inicio y fin del evento, en segundos desde el comienzo de la grabación, con $0 \leq t_{\text{ini}} < t_{\text{fin}} \leq D_k$.

$(f_{\text{mín}}, f_{\text{máx}})$ Banda de frecuencia que ocupa el evento, en hercios, con $0 \leq f_{\text{mín}} < f_{\text{máx}} \leq F_s/2$. Es la componente que distingue esta formulación de la detección de eventos sonoros puramente temporal.

y Etiqueta tomada de un vocabulario cerrado $Y = \{y_1, \dots, y_L\}$ cuyos elementos son pares de especie y tipo de llamada. La sección 2.2.5 justifica por qué la etiqueta es un par plano y no dos niveles predichos por separado; las proyecciones $\pi_{\text{esp}}(y)$ y $\pi_{\text{tipo}}(y)$ recuperan cada nivel cuando se lo necesita.

p Confianza en $[0, 1]$ asignada por el modelo, que ordena las predicciones y define el punto de operación de la revisión asistida.

Las cuatro primeras componentes definen una caja rectangular sobre el plano tiempo–frecuencia; las dos restantes la etiquetan y la puntúan. La Figura 2.1 muestra el resultado sobre un espectrograma.




Figura 2.1: Segmentación de audio en rangos de tiempo y frecuencia sobre un espectrograma. Cada rectángulo corresponde a una tupla de la ecuación (2.1).

Nivel de ventana

La grabación se recorta en ventanas de duración fija T_w , tomadas cada H segundos con $H < T_w$, de modo que ningún evento quede siempre partido por un borde. Cada ventana se convierte en un espectrograma mel $X \in \mathbb{R}^{F \times T}$, con F bandas de frecuencia y T tramas temporales, y ese tensor es la entrada del modelo.

El detector es una función de parámetros θ que a cada ventana le asigna un conjunto de tamaño fijo

$$f_\theta(X) = \left\{ (\hat{b}_q, \hat{\pi}_q) \right\}_{q=1}^Q, \quad \hat{b}_q \in [0, 1]^4, \quad \hat{\pi}_q \in [0, 1]^{L+1}, \quad (2.2)$$

donde Q es un número de consultas fijado por la arquitectura, independiente del contenido de la ventana y mayor que la cantidad de eventos que cabe esperar en ella. Cada consulta produce una caja $\hat{b}_q = (c_x, c_y, w, h)$ en coordenadas normalizadas al recuadro de la ventana — centro, ancho y alto, los cuatro en $[0, 1]$ — y una distribución $\hat{\pi}_q$ sobre $Y \cup \{\emptyset\}$, en la que $\emptyset$ es la clase «sin objeto» que absorbe las consultas sobrantes. El número de eventos no se predice: resulta de cuántas consultas eligen una clase de Y por encima del umbral de confianza.

Esta es la formulación de *predicción de conjuntos*: la salida no es una rejilla puntuada ni una secuencia, sino un conjunto sin orden, y durante el entrenamiento cada anotación de la ventana se asigna a exactamente una consulta mediante un emparejamiento biyectivo, mientras que el resto se supervisa hacia $\emptyset$. De ahí que dentro de la ventana no haya anclas ni supresión de no máximos.

Del marco normalizado al marco físico

Lo que emite el modelo no son segundos ni hercios sino fracciones de la ventana, y la conversión no es simétrica entre los dos ejes. En tiempo es afín: si la ventana empieza en t_0 ,

$$t_{\text{ini}} = t_0 + \left(c_x - \frac{w}{2}\right)T_w, \quad t_{\text{fin}} = t_0 + \left(c_x + \frac{w}{2}\right)T_w. \quad (2.3)$$

En frecuencia no lo es, porque el eje vertical del espectrograma está en escala mel. Con $m(\cdot)$ la función que convierte hercios a mel y $[f_{\text{lo}}, f_{\text{hi}}]$ los extremos del banco de filtros, la coordenada normalizada $u \in [0, 1]$ vuelve a hercios mediante

$$\varphi(u) = m^{-1}\left(m(f_{\text{lo}}) + u[m(f_{\text{hi}}) - m(f_{\text{lo}})]\right), \quad (2.4)$$

y entonces $f_{\text{mín}} = \varphi(c_y - h/2)$ y $f_{\text{máx}} = \varphi(c_y + h/2)$. La consecuencia práctica es que una caja de altura constante en el marco normalizado cubre una banda mucho más ancha en la parte alta del espectro que en la baja.

De las ventanas a la grabación

Como las ventanas se solapan, una misma vocalización puede predecirse en dos o tres de ellas, y una vocalización más larga que T_w solo puede predecirse por partes. Las predicciones de toda la grabación se llevan al marco común, se agrupan por clase y se depuran por supresión de no máximos, de modo que la lista E_k contenga un evento por vocalización. Ese es el punto en el que el nivel de ventana devuelve el control al nivel de grabación, y también el punto en el que el ventaneo deja su huella: la sección 4.3 documenta qué eventos quedan fuera de alcance por ser más largos que la ventana.

2.1.2. El espectrograma y la asimetría de sus ejes

La señal de audio es unidimensional, pero los eventos de interés se distinguen por cómo se distribuye su energía entre frecuencias a lo largo del tiempo. La transformada de Fourier de tiempo corto (STFT) recupera esa estructura: divide la señal en tramas solapadas, aplica una ventana a cada una y calcula su espectro. La magnitud del resultado es el espectrograma, una matriz $X \in \mathbb{R}^{F \times T}$ cuyos parámetros, como el tamaño de ventana, el salto entre ventanas y el tipo de ventana, fijan el compromiso entre resolución temporal y resolución frecuencial.

Las transformaciones que se aplican sobre esa matriz, como la escala mel, la compresión logarítmica y la normalización de energía por canal, y el criterio con el que se elige entre ellas se tratan en la sección 2.2.3, donde corresponden al eslabón de la cadena en que aparece esa decisión.

Interesa aquí una asimetría del espectrograma que conviene explicitar porque condiciona el diseño del detector. Tratarlo como una imagen es útil, pero sus dos ejes no son equivalentes: una traslación en tiempo preserva el significado del patrón, mientras que una traslación en frecuencia lo cambia: un mismo contorno desplazado media octava es otra vocalización, o ninguna. Los patrones espectro-temporales de los eventos sonoros dependen de la banda de frecuencia en que ocurren, de modo que la convolución bidimensional estándar, equivariante a traslación en ambos ejes, no es adecuada para el eje frecuencial (Nam et al., 2022). La consecuencia práctica es que el modelo debe conservar de forma explícita la posición en frecuencia en lugar de descartarla.

2.1.3. Detección de objetos sobre audio

Una vez que el sonido se representa como una matriz tiempo–frecuencia, la tarea de la ecuación (2.1) coincide con la de la detección de objetos en visión por computadora: afirmar que una clase está presente y localizarla, localización que se representa típicamente mediante una caja delimitadora (Lin et al., 2014). La analogía no es superficial. Los eventos acústicos se manifiestan como patrones bidimensionales de tiempo y frecuencia, con texturas y estructuras geométricas propias, análogos a los objetos que aparecen en imágenes naturales (Pham et al., 2018), y el encuadre trasciende la bioacústica hacia el análisis de señales en general (Wood et al., 2022).

Familia R-CNN. Los detectores de dos etapas proponen primero regiones candidatas y luego las clasifican y refinan. Su aplicación a espectrogramas está documentada en bioacústica marina, donde las cajas predichas llevan información estadística embebida sobre la vocalización, como su duración, ancho de banda y frecuencia central, directamente utilizable por el analista (Escobar-Amado et al., 2024). NBM adapta un detector de dos etapas a datos de audio y lo acompaña de anotaciones precisas en tiempo y frecuencia recolectadas por aficionados (Airale et al., 2025).

Familia YOLO. Los detectores de una etapa predicen clase y caja en una sola pasada sobre una rejilla, lo que los hace más rápidos y más simples de entrenar. Su uso sobre espectrogramas está reportado como línea base competitiva (González et al., 2025). En audio, la idea de regresar directamente los límites del evento en lugar de clasificar tramas aparece también en YOHO, que convierte la detección en una regresión de los puntos de inicio y fin de cada clase (Venkatesh et al., 2022).

Familia DETR y transformadores. Los detectores basados en atención eliminan las anclas y la supresión de no máximos, y formulan la detección como la predicción directa de un conjunto de objetos emparejado con las anotaciones. Su adaptación al audio es reciente: SoundDet trata el audio crudo como una señal espacio-temporal y detecta eventos móviles sobre ella (He et al., 2021), y Ebbers et al. (2024) formalizan la salida como cuádruplas de clase, inicio, fin y confianza, aunque manteniéndola sobre el eje temporal.

Cajas frente a máscaras. Una alternativa a la caja es la segmentación semántica, que asigna una etiqueta a cada celda tiempo–frecuencia y describe con más fidelidad

los contornos de una vocalización (Jin et al., 2022). Esta tesis opta por la caja por dos razones: es la forma en que el analista anota en Raven, y por tanto la única para la que existe una referencia disponible; y es la que se exporta sin pérdida a una tabla de selección. Una máscara exigiría reanotar el corpus completo.

2.2. Marco Conceptual

Los conceptos que siguen no se presentan por área temática sino siguiendo el recorrido de la señal, desde que el animal vocaliza hasta que el analista recibe una etiqueta revisable. Cada eslabón de ese recorrido pierde algo o introduce una ambigüedad, y es esa pérdida la que crea la necesidad del eslabón siguiente. El orden de las subsecciones es, por tanto, el orden en que aparecen los problemas.



Figura 2.2: Cadena de la señal.

2.2.1. Paisaje sonoro

La bioacústica estudia el sonido en los seres vivos. En este proyecto se aplica a través del monitoreo acústico pasivo, que despliega grabadoras autónomas para capturar el paisaje sonoro de un ecosistema sin intervenir en él (Blumstein et al., 2011). Lo que la grabadora registra no es la vocalización sino la suma de todo lo que llega al micrófono, y en un entorno como la Amazonía esa suma tiene tres componentes:

Biofonía. Los sonidos de origen biológico. Incluye la señal de interés las vocalizaciones de primates y también el coro de insectos, anfibios y aves, que ocupa las mismas bandas durante horas seguidas.

Geofonía. Los sonidos de origen físico: viento, lluvia, movimiento de la vegetación. Su energía se reparte sobre bandas amplias y su carácter es o bien cuasi-estacionario o bien de ráfaga.

Antropofonía. Los sonidos de origen humano: motosierras, disparos, motores. No solo interfieren con la señal, sino que son en sí mismos un indicador de presión sobre el ecosistema (Blumstein et al., 2011).

A ello se suma la atenuación: el animal está a una distancia desconocida del sensor, de modo que la misma vocalización llega unas veces nítida y otras apenas por encima del fondo. El archivo resultante contiene, entonces, una señal mezclada, atenuada y de relación señal-ruido variable dentro de una misma grabación. La pregunta que abre el eslabón siguiente es qué hay que buscar dentro de esa mezcla, es decir, qué constituye exactamente un evento.

2.2.2. Eventos acústicos

La vocalización se produce por el flujo de aire desde los pulmones, que hace vibrar las cuerdas vocales en la laringe y actúa como fuente sonora primaria; el tracto vocal supralaríngeo, formado por la faringe y las cavidades oral y nasal, filtra esa fuente y fija sus características finales: frecuencia fundamental, distribución de armónicos, amplitud, duración y timbre.

La consecuencia de esa estructura fuente-filtro es la que interesa aquí. La frecuencia fundamental queda determinada por la geometría y la tensión de las cuerdas vocales, y las resonancias del tracto vocal concentran la energía en un conjunto acotado de bandas. Un evento no es, por tanto, un instante con una etiqueta: es una región del plano tiempo-frecuencia con un límite inferior y un límite superior de frecuencia que dependen de la anatomía de quien vocaliza. La banda que ocupa una especie es una propiedad física de su aparato fonador, no una convención de dibujo del anotador. Esa es la razón por la que la caja tiempo-frecuencia de la ecuación (2.1) es la representación adecuada del evento, y no un rectángulo elegido por comodidad: los cuatro números que la definen tienen referente físico.

La misma estructura explica dos hechos que reaparecen más adelante. El primero es que distintas especies tienden a separarse por banda, lo que hace de la frecuencia una característica discriminante y no un dato accesorio. El segundo es que la producción

vocal en primates no humanos es en gran medida innata y ligada a estados internos, con control cortical limitado, pero admite variabilidad intraespecífica, incluidos dialectos, firmas individuales y variación según el contexto, que amplía el rango de formas que el detector debe reconocer como la misma clase.

El evento existe, entonces, como región bidimensional. El problema es que la señal grabada es unidimensional: hay que recuperar esa estructura antes de poder buscarla.

2.2.3. Representaciones tiempo–frecuencia

La transformada de Fourier de tiempo corto recupera la dimensión que falta: divide la señal en tramas solapadas y calcula el espectro de cada una, con lo que produce una matriz $X \in \mathbb{R}^{F \times T}$ en la que el eje vertical es frecuencia y el horizontal, tiempo. Sobre ella se aplican dos transformaciones habituales: la escala mel, que reagrupa las bandas según una progresión aproximadamente logarítmica, y la compresión logarítmica de la magnitud a decibelios. El resultado, el espectrograma log-mel, es la entrada estándar en detección de eventos sonoros.

Esta transformación es la bisagra del planteamiento: convierte un problema de audio en un problema de análisis de imágenes, y con ello habilita el uso de las técnicas de visión por computadora descritas en la sección 2.1.1 y siguientes.

La elección de la representación no es un trámite. La compresión logarítmica no es la única opción. La normalización de energía por canal (PCEN) combina control adaptativo de ganancia y compresión de rango dinámico, y en detección bioacústica de campo fue el contribuyente principal a la mejora de precisión sobre la línea base log-mel (Lostanlen et al., 2019). El criterio que decide entre ambas no es esa cifra sino una condición del ruido: la ventaja de PCEN proviene de estimar y descontar un fondo que varía lentamente respecto de la escala temporal del evento. El coro de insectos amazónico cumple esa condición, pues es cuasi-estacionario durante minutos, pero la lluvia y las ráfagas de viento no la cumplen, y sobre ellas el control de ganancia puede atenuar la propia vocalización junto con el fondo.

Dado que el corpus contiene ambos regímenes, esta tesis no da por establecida la superioridad de ninguna de las dos representaciones: las compara bajo un criterio declarado de antemano: el *recall* de eventos de baja relación señal-ruido al punto de operación fijado en la sección 1.6, y adopta la que lo maximice. Declarar el criterio antes

de medir es lo que impide elegir después la representación que favorezca al resultado obtenido.

Queda así una imagen en la que el evento es visible. Falta el mecanismo que lo localice dentro de ella.




Figura 2.3: Compromiso STFT.




Figura 2.4: Escala mel.

2.2.4. Detección de eventos sonoros

La detección de eventos sonoros (SED) consiste en identificar la presencia de un evento y localizar sus límites sobre la representación tiempo–frecuencia. La distinción decisiva dentro de esta tarea, que además constituye el concepto central de esta tesis, es la *forma de la salida*, porque no todas las formulaciones que se llaman SED devuelven un evento.




Figura 2.5: PCEN frente a log-mel.

Salida por segmento fijo. El sistema divide la grabación en fragmentos de duración constante y emite una probabilidad por fragmento y clase. Lo que devuelve es una rejilla puntuada, no un evento: el inicio y el fin de la vocalización quedan cuantizados al tamaño del fragmento, y su banda de frecuencia sencillamente no se estima.

Salida temporal delimitada. El sistema devuelve el instante de inicio y el de fin de cada evento, con su clase y su confianza. Es ya un evento con extensión propia, pero esa extensión existe solo sobre el eje temporal: descarta $f_{\min}$ y $f_{\max}$, que la subsección anterior estableció como magnitudes físicas del aparato fonador.

Salida tiempo–frecuencia. El sistema devuelve la tupla completa de la ecuación (2.1). Es la única de las tres formas que coincide con lo que el analista produce a mano en Raven y, por tanto, la única que puede sustituir su insumo en lugar de complementarlo.

Esta gradación es exactamente la causa C3 del árbol de problemas del Capítulo 1: la salida de los sistemas automáticos no sustituye el trabajo del analista porque su representación es más pobre que la del evento anotado. El marco conceptual la enuncia aquí como propiedad de la tarea; la sección 1.1.4 la usó como argumento de posicionamiento.

El problema impone seis exigencias, y cada familia de la literatura responde a una de ellas. Presentarlas en orden cronológico no dice nada; presentarlas por la exigencia que satisfacen permite decidir, y así las ordena la Tabla 2.1. Las vocalizaciones de primates se organizan en secuencias cuya identidad depende del orden y del espaciado de sus unidades, lo que explica por qué el contexto largo aparece como exigencia propia y no como un refinamiento del reconocimiento local.

Tabla 2.1: Cada exigencia del problema y la familia de arquitecturas que la resuelve

Exigencia	Familia	Qué aporta y dónde se queda corta
Reconocer un patrón espectro-temporal local	Redes convolucionales	Aplican filtros sobre vecindades del espectrograma y superan con claridad a los detectores por energía o por flujo espectral, pero una red simple carece de robustez frente a la variabilidad del ruido (Lostanlen et al., 2019)
Sostener el contexto a lo largo de una frase	Convolucionales recurrentes	Añaden capas recurrentes sobre las características convolucionales; fueron la arquitectura predominante en las primeras ediciones de los desafíos de localización y detección de eventos sonoros (Politis et al., 2020)
Ganar profundidad sin degradación	Conexiones residuales	Permiten entrenar redes muy profundas sin pérdida de desempeño (He et al., 2016); BirdNET, referencia en identificación de aves, emplea una arquitectura de esa familia (Kahl et al., 2021)
Modelar dependencias a larga distancia sin recurrencia	Transformadores	Autoatención y procesamiento paralelo; el <i>Audio Spectrogram Transformer</i> aparece como innovación en detección bioacústica de pocos ejemplos (Nolasco et al., 2023), pero produce representaciones de una sola escala
Preservar la posición en frecuencia	Ninguna de las anteriores por sí sola	La convolución bidimensional estándar es equivariante a traslación en ambos ejes, propiedad deseable en tiempo y errónea en frecuencia; corregirlo exige adaptar el filtro a la banda (Nam et al., 2022)
Emitir $f_{\min}$ y $f_{\max}$	Cabezas de detección de objetos	Única salida que coincide con la tupla de la ecuación (2.1); es la familia descrita en la sección 2.1.3

El criterio de descarte es la forma de la salida, no el desempeño reportado. Una arquitectura solo es candidata a arquitectura final si su cabeza puede emitir $f_{\min}$ y $f_{\max}$. Bajo esa regla, las cuatro primeras familias de la Tabla 2.1 quedan descartadas *como sistema completo*, porque su formulación habitual termina en una probabilidad por trama o por segmento; ninguna queda descartada *como extractor de características*, que es el papel en el que siguen siendo pertinentes. La cabeza que sí satisface la exigencia es la de los detectores de objetos descritos en la sección 2.1.3, y por eso la arquitectura de esta tesis combina un extractor de audio con una cabeza de detección, en lugar de adoptar una de las cuatro familias tal como se emplean en la literatura de SED.

Localizado el evento, queda el problema de nombrarlo.

2.2.5. Clasificación jerárquica

La etiqueta que el analista necesita contiene dos niveles anidados, la especie y, dentro de su repertorio, el tipo de llamada. Las unidades acústicas se agrupan en notas, trinos, sílabas, frases, motivos y cantos, y pueden estar jerárquicamente anidadas: una secuencia de unidades puede considerarse ella misma una unidad y ser reemplazada por una etiqueta única (Kershenbaum et al., 2016).

El conjunto de especies sobre el que se define el primer nivel es el de la Tabla 2.2. Los códigos de dos letras de la última columna son los que se emplean en el resto del documento.

El segundo nivel de la etiqueta se define dentro de cada especie, sobre el vocabulario de la Tabla 2.3. Los repertorios están desbalanceados, de modo que los 41 pares posibles no se reparten de forma pareja entre las ocho especies, y esa asimetría es la que condiciona la elección del esquema de clasificación.

Un mismo código puede designar llamadas distintas en especies distintas: **sc** es *squeak* en AA y AC, *shriek* en SB y *squeal* en SM. Por eso la unidad de etiquetado en el resto del documento es siempre el par, escrito **especie/tipo**, y nunca el código de llamada por sí solo.

Ante esa estructura caben tres esquemas. La *clasificación plana* crea una clase por cada par y trata la jerarquía como inexistente. El enfoque *local por nodo padre* entrena un clasificador de especie y, debajo, un clasificador de tipo por cada especie. El *modelo global jerárquico* aprende la estructura completa de una vez. Esta tesis adopta

Tabla 2.2: Especies de primates consideradas en el proyecto

Nombre común (inglés)	Nombre común (español)	Nombre científico	Código
Weddell's saddle-back tamarin	Tamarino de Weddell / pichico de vientre anaranjado	<i>Leontocebus weddelli</i>	LW
Toppin's titi monkey	Tití de Toppin / huicoco	<i>Plecturocebus toppini</i>	PT
Shock-headed capuchin	Capuchino de cabeza chata / machín blanco	<i>Cebus cuscinus</i>	CC
Peruvian spider monkey	Mono araña peruano / maquisapa	<i>Ateles chamek</i>	AC
Night monkey	Mono nocturno / musmuqui	<i>Aotus azarae</i>	AA
Large-headed capuchin	Capuchino de cabeza grande / machín negro	<i>Sapajus apella macrocephalus</i>	SM
Bolivian red howler	Mono aullador rojo boliviano / coto mono	<i>Alouatta sara</i>	AS
Bolivian squirrel monkey	Mono ardilla boliviano / fraile	<i>Saimiri boliviensis</i>	SB

la clasificación plana sobre un vocabulario cerrado de pares: los esquemas jerárquicos exigen un número mínimo de ejemplos en cada nodo hijo, y el desbalance del corpus deja varios pares con demasiados pocos como para sostener un clasificador propio. El Capítulo 4 documenta esa composición y cierra el vocabulario en consecuencia.

Queda un supuesto implícito en todo lo anterior: que la etiqueta de referencia contra la cual se entrena y se mide es un dato fijo. No lo es.

2.2.6. Anotaciones inconsistentes

Un sistema supervisado se entrena y se evalúa contra anotaciones humanas, de modo que las propiedades de esas anotaciones forman parte del planteamiento y no del apartado de limitaciones. Tres conceptos las describen.

Etiqueta fuerte y etiqueta débil. Una etiqueta *débil* declara que una clase está presente en algún lugar de la grabación, sin decir dónde; es lo que ofrecen los repositorios grandes de audio de fauna. Una etiqueta *fuerte* delimita el evento: aporta sus fronteras además de su clase. El material de esta tesis es de etiqueta fuerte y bidimensional, pues delimita también en frecuencia, lo que lo hace más informativo y, a la vez, más costoso

Tabla 2.3: Tipos de llamada admitidos en cada especie, con el código que aparece en la anotación

Especie	Tipos de llamada (código: nombre)	N.º
AA <i>Aotus azarae</i>	gc: <i>gulp</i> ; hm: <i>hoot</i> ; sc: <i>squeak</i>	3
AC <i>Ateles chamek</i>	chc: <i>chitter</i> ; gc: <i>growl</i> ; cc: <i>contact</i> ; whc: <i>whinnie</i> ; sc: <i>squeak</i> ; bc: <i>bark</i>	6
AS <i>Alouatta sara</i>	hc: <i>howl</i> ; bc: <i>bark</i>	2
CC <i>Cebus cuscinus</i>	cc: <i>contact</i>	1
LW <i>Leontocebus weddelli</i>	cc: <i>contact</i> ; cs: <i>contact syllable</i> ; aa: <i>aerial alarm</i> ; ta: <i>terrestrial alarm</i> ; sqc: <i>squeal</i> ; phc: <i>phee</i> ; tr: <i>trino</i> ; tf: <i>trino fast</i> ; tt: <i>trino transition</i> ; tj [†] : sin denominación; vc: <i>visual contact</i>	11
PT <i>Plecturocebus toppini</i>	dc: <i>duet</i> ; ac: <i>alarm</i> ; bp [†] : <i>bellow phrase</i> ; pp [†] : <i>pant phrase</i> ; sqc [†] : <i>squeal</i>	5
SB <i>Saimiri boliviensis</i>	pcc: <i>peep contact</i> ; ppc: <i>play peep</i> ; lpc: <i>long peep</i> ; spc: <i>spit</i> ; sc: <i>shriek</i>	5
SM <i>Sapajus macrocephalus</i>	cc: <i>contact</i> ; acc: <i>aggressive contact</i> ; sc: <i>squeal</i> ; pc: <i>purr</i> ; whc: <i>whistle</i> ; hic: <i>hip</i> ; fc: <i>food</i> ; fs: <i>food syllable</i>	8
Total		41

[†] Categorías sin nombre establecido en la literatura del repertorio, acuñadas por el equipo de anotación. El Capítulo 4 documenta cuáles de ellas sobreviven al vocabulario cerrado y cuáles se descartan por ser unidades de nivel de frase.

de producir y más expuesto a desacuerdo, porque hay más decisiones que tomar por evento.

Acuerdo entre anotadores y consigo mismo. El acuerdo *inter-anotador* mide cuánto coinciden dos analistas que anotan el mismo audio; el *intra-anotador*, cuánto coincide un mismo analista consigo mismo al anotar dos veces el mismo segmento. Ambos son bajos en bioacústica: se ha medido menos del 50 % de acuerdo entre dos analistas y también un acuerdo pobre de un analista consigo mismo (Leroy et al., 2018), y la tarea genera errores específicos de cada anotador (Nguyen Hong Duc et al., 2021). Con veinte anotadores por clip, las etiquetas fuertes muestran variaciones grandes tanto en el tipo de evento como en los tiempos de inicio y fin (Koga et al., 2024).

Frontera borrosa del evento. El desacuerdo anterior no se reparte de forma uniforme: se concentra en los bordes. Una vocalización no empieza ni termina en un instante definido, sino que emerge del fondo y se desvanece en él, y lo mismo ocurre en frecuencia con los armónicos superiores. En detección de cajas tiempo–frecuencia se observan desplazamientos relativamente grandes entre la caja predicha y la anotada, de lo que se concluye que las fronteras de los eventos son borrosas y difíciles de determinar (Zhu and Sato, 2025).

Estos tres conceptos son la formulación conceptual de la causa C2 del árbol de problemas, y de ellos se siguen dos decisiones metodológicas que sin ellos parecerían arbitrarias. La primera es el **umbral de IoU bajo**: exigir un solapamiento alto entre la caja predicha y la anotada mediría el acuerdo con un borde que el propio anotador no reproduce, de modo que un umbral exigente penalizaría al modelo por no replicar ruido de etiquetado (Zhu and Sato, 2025). La segunda es el **sesgo hacia el *recall***: si el *ground truth* está sistemáticamente incompleto, porque las llamadas tenues o enmascaradas escapan tanto al método automático como al analista fatigado (Gibb et al., 2018), una parte de los falsos positivos de alta confianza son en realidad eventos válidos ausentes de la referencia, y el sistema, concebido para que un humano revise su salida, debe favorecer no perderlos. El Capítulo 5 retoma ambas decisiones al fijar el protocolo de evaluación.

Capítulo 3

Estado del Arte

3.1. Metodología de la revisión

3.1.1. Objetivos y preguntas de revisión

La revisión busca identificar y evaluar el estado del arte en técnicas de aprendizaje profundo aplicables a una solución automatizada que produzca anotaciones detalladas, que incluyen localización tiempo–frecuencia, identificación de especie y clasificación del tipo de vocalización, sobre grabaciones de monitoreo acústico pasivo de primates amazónicos. Se organiza en torno a cinco preguntas:

- P1.** ¿Qué estrategias de aprendizaje profundo han obtenido mejores resultados en la detección tiempo–frecuencia de vocalizaciones en grabaciones de monitoreo acústico pasivo capturadas en entornos ruidosos?
- P2.** ¿Qué estrategias han obtenido mejores resultados en la clasificación jerárquica fina de los eventos detectados, identificando de forma simultánea la especie y el tipo específico de vocalización?
- P3.** ¿Qué técnicas de procesamiento resultan más efectivas para mitigar el ruido ambiental y la variabilidad propia de sensores de bajo costo como AudioMoth?
- P4.** ¿Qué conjuntos de datos públicos existen con vocalizaciones etiquetadas, qué formatos de anotación emplean, y qué estrategias de aumento de datos compensan mejor la escasez y el desbalance de clases?

P5. ¿Cómo se adaptan mediante transferencia de aprendizaje los modelos preentrenados en audio general o en bioacústica de aves a las tareas de detección (P1) y clasificación jerárquica (P2)?

3.1.2. Estrategia de búsqueda

La búsqueda se ejecutó sobre dos bases indexadas. Scopus cubre publicaciones seriadas de más de cinco mil editores en 140 países e incorpora una herramienta de búsqueda asistida que agrupa los artículos relacionados con una consulta. Web of Science aporta herramientas de visualización sobre la relevancia y las tendencias de las revistas dentro de sus categorías temáticas. La Tabla 3.1 recoge las cadenas empleadas y el número de documentos recuperado en cada motor.

Tabla 3.1: Cadenas de búsqueda y documentos recuperados por motor

Motor	Cadena de búsqueda	Docs.
Scopus	TITLE-ABS-KEY (<i>deep learning</i> OR <i>neural network*</i> OR <i>artificial intelligence</i> OR <i>transformer*</i> OR <i>machine learning</i>) AND TITLE-ABS-KEY (<i>sound event detection</i> OR <i>acoustic event detection</i> OR <i>audio event localization</i> OR <i>bioacoustic detection</i>) AND TITLE-ABS-KEY (<i>biodiversity</i> OR <i>wildlife</i> OR <i>animal vocalizations</i> OR <i>primates</i> OR <i>anthropogenic noise</i> OR <i>forest monitoring</i> OR <i>ecological monitoring</i>)	33
Web of Science	TS = (mismos tres bloques de términos, unidos por AND)	6
Total		39

Los tres bloques combinan técnica, tarea y dominio de aplicación. El asterisco es el comodín de truncamiento de ambos motores.

3.1.3. Criterios de inclusión y exclusión

Los resultados se cribaron con los criterios de la Tabla 3.2. Dos de ellos hacen el trabajo principal de filtrado y merecen explicitarse: el criterio de detección de eventos descarta los trabajos que solo clasifican la grabación completa sin localizar nada dentro de ella, y el criterio de clasificación jerárquica descarta los clasificadores binarios o de un solo nivel taxonómico. Son precisamente los dos ejes en los que se sitúa el vacío descrito en la sección 1.1.4.

Tabla 3.2: Criterios de inclusión y exclusión aplicados a los resultados

Criterio	Inclusión	Exclusión
Temporalidad	Publicaciones de 2020 en adelante	Anteriores a 2020
Calidad	Revistas Q1 o conferencias de alto impacto	Revistas no indexadas o de cuartiles inferiores
Enfoque	Técnicas de aprendizaje profundo	Aprendizaje automático clásico sin componente profundo
Análisis de señal	Análisis tiempo–frecuencia	Análisis exclusivamente temporal o frecuencial
Dominio	Bioacústica, con preferencia por mamíferos y primates	Reconocimiento de voz humana sin transferencia al dominio
Entorno	Entornos naturales ruidosos, preferentemente tropicales	Entornos exclusivamente de laboratorio
Detección	Métodos que localizan el evento en tiempo y frecuencia	Métodos que clasifican la grabación completa
Clasificación	Clasificación multinivel de especie y tipo de vocalización	Clasificadores binarios o de un solo nivel
Desbalance	Técnicas para desbalance de clases y escasez de datos	Métodos que exigen grandes volúmenes etiquetados
Evaluación	Métricas completas de precisión, <i>recall</i> y F1	Trabajos sin evaluación cuantitativa
Idioma	Inglés o español	Otros idiomas

3.2. Resultados de la revisión

Ninguno de los trabajos recuperados evalúa arquitecturas de aprendizaje profundo para la detección y clasificación de vocalizaciones de primates en el contexto amazónico. Los resultados que siguen se apoyan, por tanto, en la extrapolación desde dominios bioacústicos adyacentes pero más desarrollados, sobre todo la detección de aves y la localización de eventos sonoros, que enfrentan desafíos análogos de ruido ambiental, variabilidad entre sensores y escasez de datos etiquetados (Lostanlen et al., 2019; Meedeniya et al., 2023).

3.2.1. P1: Estrategias de detección tiempo–frecuencia

Las redes convolucionales son la base de los sistemas que operan sobre espectrogramas. Un modelo convolucional de arquitectura relativamente simple ya supera de forma clara a métodos tradicionales como el flujo espectral o los detectores basados en energía, aunque adolece de falta de robustez y de generalización ante la variabilidad del ruido (Lostanlen et al., 2019). Las redes convolucionales recurrentes añaden capas recurrentes para modelar dependencias temporales más largas y fueron la arquitectura predominante en las ediciones iniciales de los desafíos de localización y detección de eventos sonoros (Politis et al., 2020). Las variantes residuales facilitan el entrenamiento de redes más profundas sin degradación (He et al., 2016), y son la base de BirdNET (Kahl et al., 2021).

Los transformadores aparecen como innovación arquitectónica en detección bioacústica de pocos ejemplos, si bien la mayoría de sistemas exitosos de ese desafío siguieron usando redes convolucionales (Nolasco et al., 2023). En detección con salida bidimensional, el trabajo relevante sustituye los *backbones* preentrenados en imágenes por representaciones nativas de audio y añade una pirámide multiescala, precisamente porque las arquitecturas de tipo transformador de espectrograma producen representaciones de una sola escala (Zhu and Sato, 2025).

Del lado de la representación de entrada, la normalización de energía por canal fue el contribuyente principal a la mejora de precisión sobre la línea base de espectrograma log-mel (Lostanlen et al., 2019), y también la representación mayoritaria entre los sistemas exitosos del desafío de detección con pocos ejemplos (Nolasco et al., 2023).

La elección de la representación resultó, en esos trabajos, tan determinante como la elección de la arquitectura (Bonet-Solá and Alsina-Pagès, 2021).

3.2.2. P2: Clasificación jerárquica fina

La revisión no identificó estrategias diseñadas y evaluadas explícitamente para la clasificación jerárquica fina que asigna de forma simultánea la especie y el tipo de vocalización. La literatura recuperada se concentra en tres tareas vecinas pero distintas: la detección de eventos, que localiza sin etiquetar en detalle (Lostanlen et al., 2019; Politis et al., 2020); la clasificación de especie, multiclase o multietiqueta, que identifica qué especies están presentes BirdNET reconoce 984 especies de aves (Kahl et al., 2021), y Kath et al. (2024) entrenan clasificadores lineales sobre *embeddings* para anuros; y la clasificación de eventos ya detectados en un conjunto plano de clases predefinidas (Politis et al., 2020).

La necesidad de distinguir tipos de llamada o sílabas se reconoce como un desafío de clasificación de grano fino en bioacústica, pero se enuncia como problema abierto y no como capacidad demostrada (Nolasco et al., 2023). Este es, en la revisión, el hueco más nítido y el que sostiene el eje de tarea de la sección 1.1.4.

3.2.3. P3: Mitigación de ruido y variabilidad entre sensores

Ningún trabajo recuperado prueba técnicas específicamente sobre ruido amazónico, pero varios abordan el ruido ambiental heterogéneo y la variabilidad entre sensores en despliegues de monitoreo acústico pasivo. Dos resultados son directamente aplicables.

El primero es la normalización de energía por canal como preprocesamiento del espectrograma: al combinar compresión de rango dinámico y control adaptativo de ganancia, suprime el ruido estacionario y realza los eventos transitorios, y con sus parámetros ajustados a entornos exteriores ruidosos produce distribuciones de magnitud consistentes y cuasi-gaussianas entre sensores distintos (Lostanlen et al., 2019). El segundo son las redes adaptativas al contexto, que procesan en una rama auxiliar estadísticas espectrales resumidas a largo plazo, mediante percentiles del espectrograma, y adaptan el modelo a las condiciones de cada punto de monitoreo, mejorando la robustez frente a la variabilidad espacial del ruido (Lostanlen et al., 2019). Ambas

técnicas resultaron complementarias: su combinación fue lo que produjo detección robusta a escala de red de sensores.

3.2.4. P4: Conjuntos de datos y aumento de datos

Los conjuntos públicos disponibles se concentran de forma abrumadora en aves: BirdVox, Xeno-canto y la Macaulay Library. Fuera de ese taxón, la revisión identificó AnuraSet para anuros, la base de Watkins para mamíferos marinos y los conjuntos de DCASE para sonidos generales. No se encontró ningún conjunto público a gran escala etiquetado específicamente para vocalizaciones de primates, lo que confirma por una segunda vía el eje de dominio de la sección 1.1.4.

En cuanto a formatos, los eventos localizados en tiempo se distribuyen típicamente como archivos delimitados con tiempo de inicio, tiempo de fin y etiqueta de clase (Nolasco et al., 2023); en tareas de localización se añade la dirección de llegada (Politis et al., 2020); y en repositorios grandes como Xeno-canto lo habitual son etiquetas débiles de presencia o ausencia a nivel de grabación completa (Kahl et al., 2021). Ninguno de esos formatos registra la banda de frecuencia del evento.

Frente a la escasez y al desbalance, las técnicas reportadas son la adición de ruido de fondo realista, el desplazamiento de tono, el estiramiento temporal, el enmascaramiento de bloques de tiempo o frecuencia sobre el espectrograma y el entrenamiento con mezcla de ejemplos (Kahl et al., 2021; Lostanlen et al., 2019; Politis et al., 2020). El sobremuestreo de clases minoritarias es la respuesta habitual al desbalance, mientras que el aprendizaje sensible al costo fue probado sin mejora apreciable (Kahl et al., 2021). Cuando los ejemplos etiquetados son muy escasos, las redes prototípicas permiten adaptarse a clases nuevas con apenas cinco ejemplos (Nolasco et al., 2023).

3.2.5. P5: Transferencia de aprendizaje

La transferencia de aprendizaje es la estrategia central cuando los datos etiquetados son limitados (Kath et al., 2024). El hallazgo más útil de la revisión es que la proximidad del dominio de origen importa más que el tamaño del modelo: BirdNET, entrenado en aves, transfiere mejor a la clasificación de anuros que modelos entrenados en audio general o en imágenes (Kath et al., 2024). Eso lo posiciona como candidato razonable para transferir a primates.

Sobre el método de adaptación, la revisión distingue dos rutas. La extracción de características usa el modelo preentrenado como extractor fijo y entrena un clasificador simple sobre sus *embeddings*; la penúltima capa de BirdNET resultó particularmente efectiva en esa función (Kath et al., 2024). El ajuste fino reentrena parcial o totalmente los pesos con los pocos datos de la tarea objetivo, y exige cuidado para no sobreajustar (Nolasco et al., 2023). Ninguno de los trabajos documenta la adaptación de estos modelos a la detección con salida bidimensional ni a la clasificación jerárquica de primates.

Detección y robustez (P1, P3). No se identificó ningún estudio que aplique y evalúe modelos de aprendizaje profundo a la detección tiempo–frecuencia de primates amazónicos. La literatura de dominios vecinos sí ofrece estrategias trasladables: las arquitecturas convolucionales y convolucionales recurrentes como base (Lostanlen et al., 2019; Politis et al., 2020), las variantes residuales y los transformadores para secuencias largas (He et al., 2016; Nolasco et al., 2023), y, frente a la variabilidad del ruido, la normalización de energía por canal junto con las redes adaptativas al contexto, cuya combinación resultó la más efectiva a escala de red de sensores (Lostanlen et al., 2019).

Clasificación jerárquica (P2). No se hallaron estrategias explícitamente diseñadas y evaluadas para asignar de forma conjunta especie y tipo de vocalización. Existen enfoques de clasificación multietiqueta sobre *embeddings* preentrenados (Kath et al., 2024), pero la tarea jerárquica específica sigue requiriendo desarrollo propio.

Datos y anotaciones (P4). Se confirma la ausencia de conjuntos públicos a gran escala etiquetados para primates y adecuados para aprendizaje profundo: el esfuerzo de la comunidad se concentra en aves. Los formatos de anotación de uso común registran tiempo de inicio, tiempo de fin y clase (Nolasco et al., 2023), y descartan la banda de frecuencia, lo que significa que incluso los conjuntos disponibles no servirían como referencia para la tarea de esta tesis sin reanotación.

Transferencia (P5). La transferencia desde dominios cercanos es la respuesta más viable a la escasez de datos etiquetados, con evidencia de transferencia exitosa de aves a otros taxones (Kath et al., 2024; Nolasco et al., 2023). Queda abierto cómo aplicarla cuando la salida deseada no es una etiqueta por segmento sino una caja tiempo–frecuencia, que es exactamente el problema que aborda el Capítulo 5.

Los dos ejes del vacío descrito en la sección 1.1.4 quedan confirmados de forma independiente por esta revisión: no hay trabajo publicado sobre primates neotropicales

en este contexto (eje de dominio) y no hay estrategias establecidas para la salida bidimensional con etiquetado jerárquico (eje de tarea). El cruce de ambos ejes es la posición que ocupa esta tesis.

Capítulo 4

Curación del Conjunto de Datos (OE1)

4.1. Análisis del conjunto original

4.1.1. Material recibido y formato

El material de partida son ocho carpetas, una por especie. Cada carpeta contiene grabaciones en formato WAV muestreadas a 44,1 kHz, capturadas con dispositivos AudioMoth desplegados en el bosque, junto con sus anotaciones en archivos de texto generados con Raven. La Figura 4.1 muestra un archivo de anotaciones tal como se recibe.

Selection	View	Channel	Begin Time (s)	End Time (s)	Low Freq (Hz)	High Freq (Hz)	Inband Power (dB FS)	Species	Call type	Rating	Reference
1	Spectrogram	1	1.336330093	1.865888854	7560.000	10080.000	-46.04	LW	CS C		
2	Spectrogram	1	4.441470101	4.971028862	7560.000	10080.000	-67.83		noise		1
3	Spectrogram	1	1.950136839	2.449607034	7766.599	10801.822	-41.65	LW	CS B		
4	Spectrogram	1	4.558815508	5.058285703	7766.599	10801.822	-70.12		noise		3
5	Spectrogram	1	2.527837305	3.057396066	8212.955	10444.737	-41.20	LW	CS B		
6	Spectrogram	1	4.868727738	5.398286499	8212.955	10444.737	-78.54		noise		5
7	Spectrogram	1	3.135626338	3.611025680	8034.413	10266.194	-40.34	LW	CS B		
8	Spectrogram	1	4.637045780	5.112445122	8034.413	10266.194	-75.00		noise		7
9	Spectrogram	1	3.767486223	4.182708433	7588.057	9552.024	-41.43	LW	CS B		
10	Spectrogram	1	5.016161711	5.431383921	7588.057	9552.024	-68.79		noise		9
11	Spectrogram	1	1.320278575	4.166656916	7422.772	10588.366	-42.46	LW	CC B		
12	Spectrogram	1	4.407365444	5.719457935	7422.772	10588.366	-67.57		noise		11

Figura 4.1: Archivo de anotaciones de una grabación, con las columnas diferenciadas por color. El formato es un archivo de texto delimitado por tabulaciones que Raven lee y escribe directamente.

Las anotaciones se crean y editan sobre la grabación en Raven (Figura 4.2). El analista dibuja una región rectangular sobre el espectrograma y el software deriva de ella el rango de frecuencias, los tiempos de inicio y fin, y la amplitud. Las columnas de

especie y tipo de llamada se escriben a mano, y son justamente las que concentran los problemas descritos a continuación.




Figura 4.2: Raven durante el procesamiento de una grabación junto con sus anotaciones. Cada caja del espectrograma corresponde a una fila del archivo de la Figura 4.1.

4.1.2. Defectos detectados

Un análisis exploratorio sobre el conjunto reveló cinco problemas que impiden usar el material directamente para entrenamiento.

Inconsistencias de etiquetado. Una misma clase aparece escrita de múltiples formas. El prototipo inicial de este trabajo, restringido a la sílaba de contacto del tamarino de Weddell, ya encontró en la columna de tipo de llamada el conjunto de valores distintos {CS, CS_u, CS_{uuuuuu}A, contact syllable, CC, contact call, noise, noise_{uuu}, noise|, noises, AA, A, B, C, TA}: cuatro grafías para una única clase, tres para el descarte por ruido y un encabezado de columna que unas veces es Call type y otras Call Type. Las Figuras 4.3 y 4.4 muestran los valores únicos encontrados en cada una de las dos columnas manuales sobre el corpus completo.

Integridad de los archivos. La carga automatizada de las grabaciones produce advertencias sobre archivos de audio dañados (Figura 4.5), que interrumpen el proceso si no se manejan de forma explícita. La corrupción se manifiesta como bloques de ceros en la señal y admite grados: la Figura 4.6 muestra un caso leve y la Figura 4.7 uno en

```

print("\nEspecies únicas en el dataset:")
print("-----")
for i, specie in enumerate(raw_annotations["specie"].unique(), 1):
    print(f"{i}. {specie}")
✓ 0.0s

Especies únicas en el dataset:
-----
1. CC
2. PT
3. nan
4. LW
5. 8
6. -
7. PTD
8. LW
9. L
10. }
11. AS
12. AC
13. AC
14. SW
15. AA
16. AN
17. SN
18. #
19. AS-----AS
20. SB

```

Figura 4.3: Etiquetas únicas encontradas en la columna de especie.

```

print("Tipos de llamadas únicas en el dataset:")
print("-----")
for i, call in enumerate(raw_annotations["call_type"].unique(), 1):
    print(f"{i}. {call}")
✓ 0.0s

Tipos de llamadas únicas en el dataset:
-----
1. CC
2. nan
3. BP
4. PP
5. AC
6. DC
7. SQC
8. D
9. CHC
10. CS
11. noise
12. AA
13. A
14. B
15. TA
16. C
17. CS
18. CS      A
19. noise
20. contact call
21. contact syllable
22. TT
23. TR
24. VC
25. TJ
26. TC
27. noise|
28. noises

```

Figura 4.4: Etiquetas únicas encontradas en la columna de tipo de llamada.

el que la mayor parte del archivo es inutilizable. El origen probable son cortes durante la transferencia o fallos del medio de almacenamiento.

```

Procesando 2674 archivos de audio...
=====
⚠ ADVERTENCIA en 20240117_060129.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240117_163024.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240207_102952.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240214_102327.wav: Anotaciones exceden duración del audio (7.65s > 6.87s)
⚠ ADVERTENCIA en 20240214_102452.wav: Anotaciones exceden duración del audio (5.92s > 5.13s)
⚠ ADVERTENCIA en 20240214_102634.wav: Anotaciones exceden duración del audio (13.15s > 13.11s)
⚠ ADVERTENCIA en 20240415_114228.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240429_104951.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240504_080326.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240510_065700.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240510_071046.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240516_081806.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240516_081815.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240530_110626.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240621_074433.wav: Anotaciones exceden duración del audio (30.69s > 27.25s)
⚠ ADVERTENCIA en 20240805_091140.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240805_091302.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154436.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154640.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154724.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240809_154800.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240813_092636.wav: El espectrograma contiene ceros.
⚠ ADVERTENCIA en 20240815_170844.wav: El espectrograma contiene ceros.

```

Figura 4.5: Advertencias emitidas durante la carga automatizada de las grabaciones.

Discrepancias entre especie y carpeta. La etiqueta de especie escrita en la anotación no siempre coincide con el código de la carpeta contenedora, lo que obliga a decidir cuál de las dos fuentes prevalece antes de consolidar nada.




Figura 4.6: Grabación con corrupción leve




Figura 4.7: Grabación con corrupción severa

Frecuencias por encima de Nyquist. Algunas cajas declaran una frecuencia superior mayor que el límite de Nyquist de la señal (22 050 Hz a 44,1 kHz de muestreo), un valor que no puede corresponder a energía observable en la grabación.

Variabilidad en la unidad de análisis. La granularidad de las anotaciones no es uniforme. En unos casos el analista etiquetó sílabas individuales y en otros delimitó una secuencia completa con una sola caja. No se trata de un error de anotación sino de la manifestación directa del anidamiento jerárquico de las unidades acústicas (Kershenbaum et al., 2016) descrito en el Capítulo 2; la subsección 4.1.5 lo cuantifica.

4.1.3. Composición del conjunto curado

Tras aplicar el protocolo de la sección 4.2, el conjunto queda en **19 029 anotaciones sobre ocho especies, repartidas en 65 pares distintos de especie y tipo de llamada**. De esos 65 pares, 41 pertenecen al vocabulario declarado para el dominio y concentran 18 693 anotaciones; los 24 restantes, que suman 336 registros (el 1,8 %), quedan fuera del vocabulario y se marcan para revisión en lugar de descartarse en silencio. La Tabla 4.1 resume el reparto por especie.

Dos propiedades de esa tabla gobiernan el resto del capítulo. La primera es que **el vocabulario es desigual entre especies**: LW aporta once tipos de llamada distintos sobre 4 103 anotaciones, mientras que CC aporta un único tipo con 29. La segunda es que **la distribución dentro de una especie es tan sesgada como la distribución entre especies**: en SM, el par **sm/acc** cuenta con 8 anotaciones frente a las 2 040 de **sm/cc**, un factor de $255\times$ dentro de un mismo repertorio. La cola es larga: diez pares concentran el 74 % de las 19 029 anotaciones y el resto se reparte hasta pares con una sola.

Tabla 4.1: Composición del vocabulario curado por especie

Especie	Cód.	En vocabulario		Experimento	
		Tipos	Anotaciones	Clases	Anotaciones
<i>Leontocebus weddelli</i>	LW	11	4 103	1	2 282
<i>Sapajus macrocephalus</i>	SM	8	3 605	2	2 731
<i>Alouatta sara</i>	AS	2	3 309	2	3 309
<i>Ateles chamek</i>	AC	6	3 081	1	2 487
<i>Saimiri boliviensis</i>	SB	5	2 324	2	1 880
<i>Plecturocebus toppini</i>	PT	5	1 155	1	637
<i>Aotus azarae</i>	AA	3	1 087	1	799
<i>Cebus cuscinus</i>	CC	1	29	0	N/D
Total		41	18 693	10	14 125

Las 336 anotaciones restantes hasta 19029 corresponden a los 24 pares fuera de vocabulario, marcados para revisión.




Figura 4.8: Galería de llamadas.

4.1.4. Geometría de los eventos

Las llamadas anotadas son extraordinariamente desiguales en tamaño, y ese hecho condiciona todas las decisiones de diseño que siguen. La Tabla 4.2 lo mide sobre las 19 029 anotaciones.

Tabla 4.2: Variación de tamaño de las llamadas anotadas

	Mínimo	Máximo	Razón
Duración	0,034 s	73,3 s	2 134 ×
Ancho de banda	224 Hz	21 784 Hz	97×

La llamada más larga dura más de dos mil veces lo que la más corta. La magnitud se aprecia mejor por comparación: en COCO, la colección de imágenes con la que se evalúan habitualmente los detectores de objetos (Lin et al., 2014), los objetos mayores superan a los menores en un factor de entre 10 y 100. El problema que enfrenta este detector es, en ese eje, un orden de magnitud más severo que aquel para el que se diseñaron las arquitecturas que hereda.

La consecuencia inmediata es que **ninguna longitud de ventana única sirve para todas las clases**: una ventana capaz de contener un aullido de 73 s es demasiado gruesa para resolver un chirrido de 34 ms. La sección 4.3 documenta el compromiso adoptado y lo que cuesta.

La Figura 4.9 sitúa cada clase en duración y en banda de frecuencia, y hace visibles dos efectos a la vez. Las **especies se separan en buena medida por banda**: AS ocupa aproximadamente entre 25 y 1 410 Hz (percentiles 1 y 99), mientras que **lw/cs** nunca aparece anotada por debajo de 3 687 Hz. Los **tipos de llamada dentro de una misma especie no se separan**: en LW, la familia de trinos junto con vc y cs comparten banda y duración casi por completo.

Esa disociación tiene una consecuencia metodológica directa, y es la que sostiene el protocolo de evaluación del Capítulo 5: si la geometría distingue especies pero no tipos de llamada, entonces *localizar* y *etiquetar* son problemas de dificultad distinta y no deben puntuarse con una sola cifra. De ahí que la detección se entrene de forma agnóstica a la clase y la clasificación se evalúe por separado.

La Figura 4.10 desglosa la geometría par por par y revela un problema distinto del desbalance: **ac/bc** (coeficiente de variación del ancho de banda 0,60) y **sm/fs** (0,63) se




Figura 4.9: Dónde vive cada clase en tiempo y en frecuencia. Las especies ocupan bandas distintas; los tipos de llamada de una misma especie se solapan casi por completo. La figura abarca los pares del vocabulario curado con suficientes anotaciones para caracterizarlos, un conjunto más amplio que las diez clases del experimento (Tabla 4.3) y que corresponde al vocabulario ampliado de la sección 4.4.

parten cada uno en dos nubes claramente separadas en el plano duración $\times$ ancho de banda, mientras que **sb/ppc** (0,47) es una única mancha difusa. Que una etiqueta cubra dos nubes disjuntas sugiere que agrupa dos variantes de llamada que el vocabulario actual no distingue. Es un hallazgo sobre el esquema de anotación, no sobre el modelo. Son, además, las clases con peor *recall* en la evaluación del Capítulo 5.

4.1.5. Sílabas y frases

Una *frase* es una secuencia de *sílabas*, y los expertos anotan ambas: el 94,2 % de las frases **lw/cc** contienen al menos una sílaba **lw/cs**, y el 96,8 % de las frases **sm/fc** contienen una sílaba **sm/fs**. El mismo tramo de audio lleva, por tanto, una caja grande y varias cajas pequeñas dentro de ella.

El detector no puede representar esa relación. Devuelve una lista plana de cajas, y el emparejamiento durante el entrenamiento asocia cada anotación verdadera con exactamente una predicción, sin manera de expresar que “esta caja contiene a aquella”. Conservar ambos niveles equivaldría a pedir al modelo que informe dos veces el mismo sonido, como si fueran dos eventos no relacionados superpuestos. Es la consecuencia operativa del anidamiento jerárquico que Kershenbaum et al. (2016) describen como




Figura 4.10: Duración frente a ancho de banda, un panel por par del vocabulario curado. En gris, todas las clases; en color, la del panel. Las nubes partidas de *ac/bc* y *sm/fs* indican una etiqueta única que cubre dos variantes de llamada.

propiedad general de las unidades acústicas animales: una secuencia de unidades puede ella misma considerarse una unidad. Las dos clases de frase se excluyen, en consecuencia, antes del entrenamiento.




Figura 4.11: Anidamiento frase-sílaba.

4.2. Protocolo de curación y estandarización (RE1.1)

El protocolo se implementa como un *pipeline* programático, no como una corrección manual del material recibido. La distinción importa: un protocolo ejecutable puede volver a aplicarse sobre los datos primarios cada vez que sus reglas cambian, y deja registro de qué se descartó y por qué.

4.2.1. Carga y consolidación

El primer paso recorre la estructura de directorios, lee cada archivo de anotación y los unifica en una única tabla. Para cada archivo:

Emparejamiento con el audio. Solo se carga el archivo de anotación que tiene una grabación homónima junto a él. Un archivo de texto huérfano no aporta nada entrenable y su presencia suele indicar un error de transferencia.

Normalización de nombres de columna. Los encabezados originales se convierten a un formato programático uniforme; `Begin Time (s)` pasa a `begin_time_s`, y de




Figura 4.12: Pipeline de curación.

forma análoga el resto. Esto resuelve de una vez la alternancia entre `Call type` y `Call Type` observada en el material crudo.

Descarte de columnas no utilizadas. Se eliminan las columnas de selección, vista, canal, referencia y desplazamiento de archivo, que corresponden al estado interno de Raven y no al evento.

Enriquecimiento con metadatos. Se añaden la ruta de la grabación de origen y el directorio contenedor, que preserva la especie declarada por la organización del corpus.

Los errores de lectura se capturan y se registran, de modo que un archivo dañado o un directorio vacío se omitan sin detener el proceso.

4.2.2. Normalización de etiquetas

Sobre la tabla consolidada se aplican, en este orden, las siguientes reglas.

Normalización tipográfica. Toda etiqueta se reduce a minúsculas y a caracteres alfanuméricos separados por guion bajo. Este único paso absorbe la mayoría de las

variantes observadas, como espacios en blanco al final, mayúsculas inconsistentes y caracteres residuales, sin necesidad de enumerarlas.

Mapa de sinónimos. Un diccionario explícito unifica las variantes que la normalización tipográfica no captura, por ser errores de escritura o abreviaturas alternativas y no diferencias de formato: `noises` a `noise`, `cs_a` a `cs`, `whinnie` a `whc`, `tca` y `tac` a `ta`, `contact` a `cc`, `chcj` a `chc`, `php` a `phc`, `sqr` a `sqc`, y `tc` a `tr`. Al mapa se suma, por especie, la traducción del nombre legible del tipo de llamada a su código `contact syllable` a `cs`, de modo que las anotaciones escritas en prosa converjan con las escritas en código.

Descarte de ruido. Las anotaciones cuyo tipo de llamada, ya normalizado, es `noise` se eliminan: marcan la ausencia de evento, no un evento.

Corrección de pares imposibles. Un pequeño conjunto de correcciones explícitas resuelve pares que no existen en el repertorio de la especie y cuya intención es inequívoca; por ejemplo, `aa/hc` se corrige a `aa/hm`, dado que `AA` no tiene llamada de aullido pero sí de ululato.

Ante una discrepancia entre la especie escrita en la anotación y el código de la carpeta contenedora, prevalece la carpeta. El criterio no es arbitrario: el directorio es un dato estructural, fijado una vez por sesión de campo, mientras que la columna de especie se teclea en cada fila y es donde se observaron los errores de la Figura 4.3.

4.2.3. Saneamiento geométrico

Las coordenadas de la caja se validan de forma independiente de la etiqueta:

Recorte a Nyquist. La frecuencia superior se recorta a 22 050 Hz. Por encima de ese límite no hay energía observable en una señal muestreada a 44,1 kHz, de modo que un valor mayor es un error de anotación y no una propiedad del evento.

Descarte de cajas degeneradas. Se eliminan las anotaciones de duración inferior a 10 ms y las de ancho de banda nulo o negativo. Una caja sin área no define una región y no puede emparejarse con ninguna predicción.

Características derivadas. Se calculan la duración y el ancho de banda de cada caja, que son las magnitudes sobre las que se construye el análisis de la sección 4.1.4.

4.2.4. Vocabulario cerrado y selección del subconjunto

El vocabulario admisible se declara de forma explícita como el conjunto de pares (especie, tipo de llamada) válidos del dominio, no como aquello que aparezca en los datos. Cerrar el vocabulario es la respuesta a la condición subyacente S2 del árbol de problemas: las definiciones de unidad y las etiquetas semánticas varían ampliamente entre investigadores, incluso dentro de un mismo grupo taxonómico (Kershenbaum et al., 2016), de modo que sin una lista fija la misma señal recibe etiquetas distintas según quién la anote.

Los pares que caen fuera del vocabulario, 24 pares que suman 336 registros, no se eliminan: se marcan con una bandera de revisión. La diferencia es deliberada. Un par fuera de vocabulario puede ser un error de escritura no previsto o un tipo de llamada legítimo aún no incorporado, y solo el equipo de investigación puede distinguir uno de otro. Descartarlos en silencio destruiría esa evidencia.

Sobre el vocabulario se recorta el subconjunto de experimento en dos pasos:

1. Se excluyen las dos clases de frase, **lw/cc** y **sm/fc**, por la razón de anidamiento de la sección 4.1.5.
2. Se conservan los pares con al menos 500 anotaciones, umbral por debajo del cual una clase no sostiene ni entrenamiento ni evaluación por clase.

El resultado son las **10 clases y 14 125 anotaciones** de la Tabla 4.3, distribuidas sobre siete de las ocho especies: CC no alcanza el umbral con su única llamada de 29 anotaciones y queda fuera del experimento, aunque permanece en el conjunto curado.

4.3. Particionado y ventaneo (RE1.2)

4.3.1. Partición por archivo de grabación

El conjunto se divide en entrenamiento, validación y prueba en proporción 70/10/20, con semilla fijada para que la partición sea reproducible. La división se hace **por archivo de grabación**: todas las anotaciones de una misma grabación caen en la misma partición, y ninguna ventana cruza particiones.

La alternativa de repartir anotaciones o ventanas sueltas no es un descuido hipotético. El prototipo inicial de este trabajo la cometió: barajaba los clips de 0,5s y los repartía por índice, con lo que dos ventanas solapadas procedentes de la misma anotación podían

Tabla 4.3: Clases del subconjunto de experimento y clases de frase excluidas

Clase	Tipo de llamada	Anot.	Rol
ac/bc	Ladrado	2 487	Experimento
lw/cs	Sílaba de contacto	2 282	Experimento
sm/cc	Llamada de contacto	2 040	Experimento
as/bc	Ladrado	1 909	Experimento
as/hc	Aullido	1 400	Experimento
sb/ppc	Llamada de juego	1 151	Experimento
aa/gc	Llamada de trago	799	Experimento
sb/spc	Llamada de escupido	729	Experimento
sm/fs	Sílaba de comida	691	Experimento
pt/dc	Dueto	637	Experimento
lw/cc	Llamada de contacto	536	Excluida: contiene sílabas
sm/fc	Llamada de comida	126	Excluida: contiene sílabas
Total expe- rimento		14 125	

lw/cc supera el umbral de 500 y habría entrado en el experimento; se retira por anidamiento (sección 4.1.5), no por escasez. *sm/fc* no alcanza el umbral, pero se consigna aquí porque su exclusión responde al mismo criterio y porque *sm/fs*, que sí está en el experimento, vive dentro de ella.

quedar una en entrenamiento y otra en prueba. Sobre esa partición el clasificador alcanzaba un 99 % de exactitud, una cifra que no medía generalización sino memoria: el 91,2 % de los clips eran negativos, de modo que un predictor constante “sin llamada” ya obtenía 91,2 %. Dado que la variación en las etiquetas fuertes afecta por sí sola a la evaluación (Koga et al., 2024), no añadir además fuga de datos es la condición mínima para que las cifras resulten interpretables.

La Tabla 4.4 recoge la composición resultante.

Tabla 4.4: Composición de las particiones tras el ventaneo

Partición	Grabaciones	Ventanas	Cajas
Entrenamiento	1 166	8 022	16 674
Validación	166	1 043	2 183
Prueba	335	2 490	5 343
Total	1 667	11 555	24 200

Hay más cajas que anotaciones porque una misma anotación puede caer en dos ventanas consecutivas: la ventana de 3 s avanza 1,5 s.

El balance entre clases se conserva a lo largo de las tres particiones, con un rango de cajas de entrenamiento que va de 3 273 para **1w/cs** a 320 para **as/hc**. Ese último número llama la atención: **as/hc** tiene 1 400 anotaciones en la Tabla 4.3 y, sin embargo, aporta menos cajas que clases con la mitad de anotaciones. La razón es estructural y se documenta a continuación.



Figura 4.13: Partición por grabación.

4.3.2. El ventaneo y su defecto

Las grabaciones tienen duración variable y el detector consume entradas de tamaño fijo, de modo que cada grabación se segmenta en ventanas de 3 s que avanzan 1,5 s. Una anotación se asigna a una ventana solo si al menos la mitad de su duración cae dentro de ella.

Esa regla tiene una consecuencia que conviene enunciar sin rodeos: **ningún evento de más de 6 s puede asignarse a ninguna ventana**, porque no existe posición de la ventana en la que la mitad de su duración quepa dentro. El efecto se concentra en las dos clases de eventos largos y elimina **1 514 anotaciones, el 10,7 % del subconjunto de experimento**, antes de que el entrenamiento comience (Tabla 4.5).

Tabla 4.5: Anotaciones que el ventaneo de 3 s vuelve inalcanzables

Clase	Anotaciones	Inalcanzables (> 6 s)	Fracción perdida
as/hc	1 400	1 147	82 %
pt/dc	637	367	58 %
Total	2 037	1 514	74 %

Ninguna otra clase del experimento pierde una fracción apreciable. Un 13,5 % adicional del subconjunto excede los 3 s de la ventana y sobrevive únicamente como caja recortada al borde.

Este defecto se documenta aquí, y no en el apartado de limitaciones, porque determina la lectura de los resultados por clase del Capítulo 5: el *recall* de **as/hc** y **pt/dc** está acotado por el preprocesamiento antes de que intervenga ninguna decisión de arquitectura. Es la manifestación concreta del rango de $2134\times$ en duración de la Tabla 4.2: la ventana de 3 s acomoda ocho de las diez clases y sacrifica las dos restantes. Su corrección Una segunda longitud de ventana para las clases largas, o un criterio de solapamiento relajado con cajas recortadas al borde, es el principal pendiente de esta etapa.

4.3.3. Densidad de eventos por ventana

Conviene registrar cuántas anotaciones coinciden en una misma ventana de 3 s: la mediana es 2 y el máximo observado, 11. Es una propiedad del conjunto derivado, pero




Figura 4.14: Efecto del ventaneo.

se consigna aquí porque el Capítulo 5 la usa para dimensionar el número de predicciones simultáneas que el decodificador debe sostener.

4.3.4. Representación y normalización de las cajas

Cada ventana se transforma en un espectrograma log-mel con los parámetros de la Tabla 4.6. Log-mel es la representación con la que se construye el conjunto evaluado; la comparación contra la normalización de energía por canal anunciada en la sección 2.2.3 está pendiente, y su implementación ya existe en el repositorio pero no se ha medido bajo el criterio declarado allí. La columna de justificación registra qué falla con el ajuste alternativo, que es la información que permite revisar un parámetro sin repetir el experimento que lo fijó.

Las cajas se normalizan al formato de centro, ancho y alto en el intervalo $[0, 1]$, con el eje de frecuencia mapeado a través de la misma escala mel que produce la imagen. La consecuencia es que una caja significa lo mismo en el espacio de píxeles que sobre la pantalla del analista: el rectángulo que el modelo predice es directamente el rectángulo que Raven dibuja, sin reinterpretación. La Figura 4.15 muestra una ventana de entrenamiento tal como el modelo la recibe.

Tabla 4.6: Parámetros de preprocesamiento y motivo de cada elección

Parámetro	Valor	Justificación
Ventana / salto	3,0 s / 1,5 s	Acomoda 8 de las 10 clases; el costo son las dos clases largas de la Tabla 4.5
Solapamiento mínimo	0,5	Un evento entra en una ventana solo si la mitad de su duración cae dentro
Longitud de ventana STFT	1 024 (23 ms)	Más corta que los eventos más breves: 34 ms el mínimo, 81 ms la mediana de sm/cc
Puntos de la FFT	4 096	Relleno con ceros: densifica la rejilla de frecuencia sin tocar la resolución temporal
Salto STFT	400 (9 ms)	Produce 331 tramas por ventana
Bandas mel	128	Lo que espera el extractor preentrenado; 256 no dio ganancia medible
Rango de frecuencia	25 Hz – 22 050 Hz	Un techo de 16 kHz truncaba la mitad de las cajas de sb/spc , cuya frecuencia superior media es 16 110 Hz




Figura 4.15: Una ventana de entrenamiento: espectrograma log-mel de 3 s con los parámetros de la Tabla 4.6 y las cajas objetivo superpuestas en el marco normalizado. Las once cajas **sb/spc** de este clip son el caso más denso observado en todo el conjunto.




Figura 4.16: Coordenadas de la caja.

4.4. Revisión posterior del vocabulario

La configuración descrita hasta aquí, con diez clases y un umbral de 500 anotaciones, es la que se evalúa en el Capítulo 5, y todas las cifras de desempeño de esta tesis corresponden a ella. Esta sección documenta una revisión posterior del vocabulario, motivada por dos limitaciones que la propia ficha del conjunto derivado había registrado.

Qué motivó la revisión. La primera limitación es de cobertura: con el umbral en 500, veintinueve tipos de llamada que sí pertenecen al vocabulario del dominio quedaban sin usar, y una especie completa, CC, fuera del experimento. La segunda es de granularidad, y proviene del análisis geométrico de la sección 4.1.4: la familia de trinos de LW (**tr**, **tj**, **tt** y **tf**) comparte banda y duración casi por completo, de modo que mantenerlos como cuatro clases distintas obliga al detector a separar lo que la geometría no separa, y reparte entre cuatro etiquetas escasas un material que como clase única sí alcanza masa suficiente.

Qué cambió. Tres modificaciones sobre la selección, ninguna sobre el protocolo de curación de la sección 4.2:

1. El umbral de selección baja de 500 a 100 anotaciones por par.
2. Los cuatro tipos de trino de LW se fusionan en una clase única, **lw/trino**.
3. Se añade **sb/pcs** a los pares excluidos.

El resultado son **19 042 anotaciones sobre 54 pares distintos, de los cuales 25 superan el umbral y concentran el 92 % del material** (Figura 4.17), frente al 74 % que cubrían las diez clases anteriores. La cobertura del experimento pasa de siete especies a las ocho.

Qué mejora y qué no. La ampliación resuelve la cobertura pero no toca las dos causas estructurales que este capítulo documentó. El desbalance no desaparece: se traslada al nuevo umbral, y entre la clase mayoritaria y las que apenas lo superan sigue habiendo más de un orden de magnitud (Figura 4.18). Y el defecto de ventaneo permanece intacto, porque no depende del vocabulario sino de la longitud de la ventana: **as/hc** sigue perdiendo el 82 % de sus anotaciones y **pt/dc** el 58 %, con tres clases más aportando pérdidas menores (Figura 4.19). La corrección de ese defecto sigue siendo el principal pendiente de la etapa.

Una consecuencia menos evidente afecta al dimensionado del decodificador. Al incorporar clases de eventos más aislados, la densidad por ventana baja: la mediana de cajas por ventana de 3 s pasa de 2 a 1, aunque el máximo se mantiene en 11 (Figura 4.20). El presupuesto de predicciones simultáneas que fija el Capítulo 5 sigue siendo válido, porque se dimensiona sobre el máximo y no sobre la mediana.

El conjunto derivado bajo esta configuración está construido, pero el detector no se ha entrenado ni evaluado sobre él. Los resultados del Capítulo 5 corresponden a las diez clases, y extenderlos a las veinticinco es trabajo pendiente: no basta con reentrenar, porque buena parte de las clases incorporadas tiene menos cajas de entrenamiento que la más escasa de las diez actuales, y el análisis por clase deberá distinguir entre una caída atribuible al modelo y una atribuible a la escasez de la clase.

4.5. Ficha del conjunto derivado (RE1.3)

La documentación del conjunto sigue la estructura de las *datasheets* para conjuntos de datos, que proponen registrar motivación, composición, proceso de recolección, transformaciones aplicadas y usos recomendados, con el propósito de aumentar la transparencia y la rendición de cuentas (Geburu et al., 2021). La ficha distingue de forma explícita dos capas de responsabilidad.

Conjunto primario. Las grabaciones y las anotaciones originales, producidas por el equipo de investigación. La ficha documenta su origen, el equipo de captura, la




Figura 4.17: Anotaciones por par de especie y tipo de llamada tras la revisión del vocabulario. Las 25 clases por encima del umbral de 100 concentran el 92 % de las 19042 anotaciones; la cola larga llega hasta pares con una sola.




Figura 4.18: Cajas por clase y partición bajo el vocabulario ampliado. El balance se preserva entre particiones; el desbalance entre clases se mantiene, ahora sobre veinticinco.




Figura 4.19: Fracción de anotaciones que cada clase puede aportar bajo el ventaneo de 3 s, con el vocabulario ampliado. El defecto no depende del vocabulario: as/hc y pt/dc siguen perdiendo la mayor parte de su material.




Figura 4.20: Cajas anotadas por ventana de 3 s bajo el vocabulario ampliado: mediana 1, máximo 11.

frecuencia de muestreo y el procedimiento de anotación en Raven, pero no reclama su autoría.

Conjunto derivado. El resultado de aplicar el protocolo de la sección 4.2: normalización de etiquetas, vocabulario cerrado, saneamiento geométrico, selección del subconjunto, partición por archivo de grabación y ventaneo. Esta capa sí es contribución de esta tesis, y la ficha registra cada transformación junto con lo que descarta.

La ficha declara además, como limitaciones conocidas del conjunto derivado:

- Las 1 514 anotaciones inalcanzables bajo el ventaneo de 3 s (Tabla 4.5), y el 13,5 % adicional que sobrevive recortado al borde de la ventana.
- Las dos clases de frase excluidas por anidamiento (sección 4.1.5), que dejan sin cubrir el nivel superior de la jerarquía vocal.
- Los 29 tipos de llamada en vocabulario que no alcanzan el umbral de 500 anotaciones y quedan fuera del experimento, entre ellos la única clase de CC, que hace que el conjunto de experimento cubra siete especies y no ocho; la sección 4.4 documenta la revisión que responde a esta limitación.
- Los 24 pares fuera de vocabulario (336 registros) pendientes de revisión por el equipo de investigación.
- La heterogeneidad geométrica de **ac/bc**, **sm/fs** y **sb/ppc** (Figura 4.10), que sugiere etiquetas que agrupan variantes distintas de llamada.

- La ausencia de una medición de acuerdo entre anotadores, que impide separar el error del modelo del techo impuesto por la propia tarea.

Capítulo 5

Detección, Evaluación y Utilidad Operativa (OE2 y OE3)

5.1. Arquitectura propuesta y línea base (RE2.1)




Figura 5.1: Arquitectura propuesta.




Figura 5.2: Pirámide multiescala.




Figura 5.3: Capa del decodificador.




Figura 5.4: Muestreo deformable.




Figura 5.5: Pipeline de entrenamiento.




Figura 5.6: Emparejamiento húngaro.



Figura 5.7: Pipeline de inferencia.




Figura 5.8: Umbral de confianza.




Figura 5.9: Recall por clase.




Figura 5.10: Detecciones cualitativas.

- 5.2. Pipeline de entrenamiento e inferencia (RE2.2)
- 5.3. Protocolo de evaluación
- 5.4. Resultados (RE2.3)
- 5.5. Exportación a Raven (RE2.4)
- 5.6. Publicación del código y del modelo (RE2.5)




Figura 5.11: Matriz de confusión.




Figura 5.12: Distribución de IoU.




Figura 5.13: Ablación acumulada.




Figura 5.14: Línea de tiempo de detecciones.

La tabla de selección que abre el analista

primeras 10 de 36 detecciones de 20240219_103940.wav · columnas exactas de Raven más la de score, que ordena la revisión

Selection	View	Channel	Begin Time (s)	End Time (s)	Low Freq (Hz)	High Freq (Hz)	Species	Call type	Score
1	Spectrogram 1	1	0.252	0.604	849.9	2461.9	AC	BC	0.983
2	Spectrogram 1	1	1.591	2.274	294.3	4719.6	AC	BC	0.518
3	Spectrogram 1	1	6.479	6.760	177.1	18123.3	SB	SPC	0.948
4	Spectrogram 1	1	6.914	7.071	6213.7	9734.5	SB	PPC	0.556
5	Spectrogram 1	1	7.797	7.883	6329.8	11010.3	SB	PPC	0.966
6	Spectrogram 1	1	7.798	8.017	101.4	17137.2	SB	SPC	0.583
7	Spectrogram 1	1	8.455	8.600	38.2	17021.2	SB	SPC	0.673
8	Spectrogram 1	1	8.763	9.007	602.6	20983.5	SB	SPC	0.612
9	Spectrogram 1	1	9.010	9.362	5829.1	11412.6	SB	PCC	0.851
10	Spectrogram 1	1	9.011	9.136	6736.6	10595.5	SB	PPC	0.723

Figura 5.15: Previsualización de la tabla de Raven.

Apéndice A

Plan del Proyecto

A.1. Justificación y viabilidad

A.1.1. Justificación

La investigación es conveniente porque ataca directamente el cuello de botella descrito en el Capítulo 1: el análisis manual del audio recolectado. El monitoreo acústico pasivo con sensores de bajo costo permite recolectar a gran escala, pero ese potencial queda desaprovechado mientras el análisis siga siendo lento, costoso y laborioso. Un sistema de pre-anotación asistida hace que el monitoreo a gran escala resulte operativamente viable y permite que el tiempo experto se dedique a la interpretación ecológica en lugar de al procesamiento.

En el plano práctico, el proyecto reduce la infrautilización del material acústico acumulado y, con ella, la latencia entre la recolección y la generación de conocimiento. En el plano teórico, aborda dos vacíos confirmados de forma independiente por la revisión del Capítulo 3: la ausencia de modelos y de conjuntos de datos con anotación tiempo–frecuencia para primates neotropicales, y la falta de estrategias establecidas para el etiquetado jerárquico de especie y tipo de llamada sobre eventos detectados.

A.1.2. Beneficios esperados

- Reducir el tiempo de revisión experta por hora de audio analizada.
- Poner en uso el audio ya grabado que hoy permanece sin anotar.
- Acortar la latencia entre la recolección y la obtención de resultados ecológicos.
- Disminuir el costo y el error humano asociados al análisis manual.

- Entregar una herramienta reutilizable, con código y pesos públicos, integrable al flujo de trabajo existente en Raven.

A.1.3. Viabilidad técnica

El proyecto no depende de ningún desarrollo previo inexistente. Las arquitecturas necesarias están disponibles y documentadas (He et al., 2016; Kahl et al., 2021; Nolasco et al., 2023); las herramientas son software libre de uso extendido (Tabla 1.10); los recursos de cómputo se cubren con acceso a GPU en la nube; los datos iniciales, aproximadamente 10 GB de grabaciones WAV capturadas con AudioMoth, con sus anotaciones de Raven, ya están entregados; y la metodología de trabajo (CRISP-DM) está establecida y es la que estructura el documento.

A.1.4. Viabilidad temporal

El cronograma es factible dentro del calendario académico, con dos puntos de tensión identificados. El primero es OE1: la curación y estandarización del conjunto es meticulosa y cualquier retraso ahí se propaga a todo lo que sigue. El segundo es OE2, que consume tiempo tanto de cómputo como de análisis humano en la experimentación. Juega a favor que no haya recolección de datos en campo: el material de partida ya existe.

A.1.5. Viabilidad económica

El grueso del software es de código abierto y sin costo. Los sensores ya están desplegados y su costo no recae sobre este proyecto. El desembolso real se concentra en cómputo en la nube y en servicios de almacenamiento; el resto del presupuesto es una valorización del tiempo dedicado, no un pago efectivo.

A.2. Definición y alcance del proyecto

A.2.1. Alcance

El proyecto desarrolla y evalúa un sistema de pre-anotación asistida que produce cajas tiempo–frecuencia etiquetadas sobre grabaciones de monitoreo acústico pasivo, para las ocho especies de la Tabla 2.2. El sistema debe cumplir tres tareas: localizar el evento en tiempo y frecuencia, identificar la especie y clasificar el tipo de vocalización.

Una parte central del alcance es la comparación cuantitativa del tiempo de revisión asistida frente al análisis manual. El proyecto recorre el ciclo completo de CRISP-DM, desde la preparación de los datos hasta el procesamiento de grabaciones nuevas.

A.2.2. Entregables y criterios de aceptación

Los entregables son los resultados esperados enumerados en la sección 1.4. La Tabla A.1 recoge el criterio de aceptación de cada uno: la condición verificable que permite declararlo terminado.

Tabla A.1: Criterios de aceptación

Entreg.	Criterio de aceptación
RE1.1	El protocolo define reglas de sintaxis para las etiquetas de especie y tipo de llamada, y especifica el tratamiento de errores, duplicados e inconsistencias de las anotaciones originales.
RE1.2	Todas las anotaciones del conjunto final cumplen las reglas de RE1.1, y se entrega un manifiesto con la asignación de cada archivo de grabación a una partición.
RE1.3	La ficha describe la estructura de directorios, incluye un diccionario de datos por columna y declara transformaciones, sesgos y limitaciones conocidas.
RE2.1	El documento justifica la arquitectura propuesta y la línea base a partir del estado del arte, y fija la configuración e hiperparámetros iniciales de ambas.
RE2.2	El <i>pipeline</i> ejecuta el ciclo completo de entrenamiento, evaluación e inferencia, e incluye instrucciones de instalación y ejecución.
RE2.3	El informe presenta las métricas de los tres ejes para la propuesta y la línea base, discute los resultados y concluye con una recomendación justificada.
RE2.4	Los pesos del modelo se cargan sin error y un script de demostración produce predicciones en el formato de tabla de selección de Raven sobre un clip de prueba.
RE2.5	El repositorio público contiene el código del <i>pipeline</i> , los pesos del modelo final y las instrucciones para reproducir la inferencia.
RE3.1	El protocolo especifica el material de prueba, el punto de operación, el umbral de IoU que define un verdadero positivo y el procedimiento de revisión experta, incluyendo el control del efecto de aprendizaje.
RE3.2	Se reporta el tiempo de revisión en ambas condiciones sobre material comparable, junto con el tiempo de procesamiento del modelo por hora de audio.
RE3.3	El informe clasifica la muestra de falsos positivos de alta confianza en evento no anotado, ruido y error de encuadre, con ejemplos visualizados sobre el espectrograma.

A.2.3. Exclusiones

- No se desarrolla un sistema de monitoreo en tiempo real desplegable en campo; el alcance es el procesamiento de grabaciones existentes.
- El análisis detallado de sonidos antropogénicos queda fuera del foco primario, más allá de su detección y categorización general.
- El estudio se limita a las ocho especies declaradas.
- No se desarrolla hardware de adquisición.
- No se realiza nueva recolección de datos en campo.

A.2.4. Limitaciones y restricciones

Limitaciones. La ausencia de conjuntos etiquetados a gran escala para primates neotropicales obliga a invertir un esfuerzo considerable en OE1, y la calidad de las anotaciones manuales recibidas es subjetiva y variable. El entorno acústico amazónico es denso y presenta con frecuencia baja relación señal-ruido. La variabilidad intraespecífica de las vocalizaciones y su naturaleza graduada dificultan definir categorías discretas, y las llamadas superpuestas o de baja intensidad son especialmente difíciles de modelar. Los sensores de bajo costo añaden variabilidad entre dispositivos.

Restricciones. El desarrollo está sujeto al calendario académico. El proyecto depende del conjunto de datos entregado y de la verificación de su calidad. El acceso a GPU limita la escala de la experimentación, en particular la búsqueda exhaustiva de hiperparámetros. El desarrollo, la implementación y la evaluación recaen sobre el autor, con la supervisión del asesor.

A.3. Planificación del proyecto

A.3.1. Estructura de desglose del trabajo

La estructura de desglose se organiza según las fases de CRISP-DM y los objetivos específicos. La Tabla A.2 resume los paquetes de trabajo y el entregable asociado a cada uno.

Tabla A.2: EDT del proyecto

ID	Paquete	Contenido	Entregable
1	Gestión del proyecto	Planificación, seguimiento, comunicación con el asesor, gestión de riesgos y de la calidad, cierre	N/A
2	Comprensión de la investigación	Objetivos, formulación del problema de detección y criterios de éxito	N/A
3	Comprensión de los datos	Acceso al corpus, descripción del formato, análisis exploratorio y verificación de calidad	N/A
4.1	Limpieza y estandarización	Corrección de etiquetas, tratamiento de audios dañados	RE1.1
4.2	Curación del conjunto	Aplicación del protocolo, vocabulario cerrado, partición por grabación	RE1.2
4.3	Ingeniería de características	Preprocesamiento, representación tiempo–frecuencia, ventaneo, aumento de datos	N/A
4.4	Documentación del conjunto	Ficha del conjunto derivado	RE1.3
5.1	Diseño del detector	Arquitectura propuesta y línea base, con justificación	RE2.1
5.2	Implementación	<i>Pipeline</i> de entrenamiento, evaluación e inferencia	RE2.2
5.3	Publicación del código	Repositorio con código y pesos	RE2.5
6.1	Evaluación cuantitativa	Métricas por eje, comparación con la línea base, análisis de errores	RE2.3
6.2	Selección del modelo final	Modelo elegido y exportador a tabla de selección de Raven	RE2.4
6.3	Protocolo de la prueba de tiempo	Material, punto de operación, procedimiento y métricas	RE3.1
6.4	Medición del tiempo de revisión	Revisión asistida frente a anotación manual	RE3.2
6.5	Revisión experta de errores	Clasificación de una muestra de falsos positivos de alta confianza	RE3.3
7	Despliegue	Inferencia por lotes sobre grabaciones no vistas y generación de tablas de anotación	N/A
8	Documentación y difusión	Redacción de la tesis y preparación de la defensa	N/A



Figura A.1: EDT en árbol.

A.3.2. Cronograma

El cronograma se ajusta al calendario académico y se organiza en bloques que respetan las dependencias entre paquetes: la preparación de datos precede al modelado, el modelado precede a la evaluación, y la medición de tiempo de revisión precede al análisis de errores, porque se realiza sobre las predicciones del modelo ya seleccionado.

A.3.3. Estimación de costos

Los costos se presentan en dólares estadounidenses y distinguen desembolso real de valorización. Las Tablas A.3 a A.6 detallan cada categoría, y la Tabla A.7 las consolida.

A.3.4. Lista de recursos

Personas. El tesista, responsable del desarrollo, la implementación y el análisis; y el asesor, que aporta guía, supervisión y validación experta.

Equipamiento. Equipo de desarrollo con GPU dedicada, almacenamiento externo para el conjunto de datos y sus derivados, y acceso a servidores con GPU para el entrenamiento.

Tabla A.3: Costos de equipos y hardware

Categoría	Descripción	USD
Almacenamiento externo	SSD de 512 GB para el conjunto de datos y sus derivados	150,00
Equipo de desarrollo	Laptop con GPU dedicada ^a	1 500,00
Cómputo en la nube	Instancia con GPU de 48 GiB de memoria, estimada por horas de uso	600,00
Subtotal		2 250,00

^a Equipo preexistente propiedad del tesista. No representa un desembolso del proyecto, pero sí un recurso valorizado.

Tabla A.4: Valorización del capital intelectual

Recurso	Horas	USD/h	Total USD
Tesista ^a	600	5,00	2 500,00
Asesor de tesis ^b	40	25,00	1 000,00
Subtotal			3 500,00

^a Valorización del tiempo dedicado; no implica un pago real.

^b Cubierto por la institución.

Tabla A.5: Costos de software, licencias y servicios en la nube

Software o servicio	Licencia	Meses	USD/mes	Total USD
Python, uv, Pandas, NumPy	Código abierto	12	0,00	0,00
PyTorch, torchaudio, Transformers	Código abierto	12	0,00	0,00
Visual Studio Code	Código abierto	12	0,00	0,00
Zotero	Gratuito	12	0,00	0,00
Raven Lite	Licencia de estudiante	12	0,00	0,00
Entorno de cómputo con GPU	Suscripción	12	9,99	119,88
Almacenamiento en la nube	Suscripción	12	1,67	20,00
Subtotal				139,88

Tabla A.6: Costos indirectos

Categoría	Descripción	Meses	Total USD
Internet	Conexión para investigación y acceso a la nube	12	480,00
Electricidad	Consumo del equipo y periféricos	12	360,00
Impresiones y otros	Materiales de estudio e impresiones	12	120,00
Subtotal			960,00

Tabla A.7: Resumen de costos

Categoría	Total USD
Equipamiento (hardware)	2 250,00
Recursos humanos (valorización)	3 500,00
Software y servicios	139,88
Costos indirectos	960,00
Total	6 849,88

Herramientas. Las de la Tabla 1.10, más el acceso a Raven para la validación cualitativa de las predicciones.

A.3.5. Gestión de riesgos

La Tabla A.8 recoge los riesgos identificados con su probabilidad, impacto, severidad y las acciones previstas.

Tabla A.8: Riesgos del proyecto, mitigación y contingencia

Riesgo	Prob.	Sever.	Mitigación	Contingencia
R1. Calidad de los datos: anotaciones inconsistentes y audios dañados	Baja	Media	Validación cruzada de una muestra con el asesor; detección automática de archivos corruptos o vacíos	Excluir el material bajo umbral mínimo de calidad y documentar la inconsistencia como limitación
R2. Recursos de cómputo insuficientes	Baja	Media	Espectrogramas precalculados; <i>pipeline</i> de datos optimizado; planificación de las corridas largas	Reducir la complejidad de las configuraciones menos prometedoras; acotar la búsqueda de hiperparámetros; parada temprana
R3. Baja disponibilidad de revisores expertos para la validación	Media	Media	Contactar a los revisores con antelación; protocolo de revisión breve y de carga acotada	Validación interna con el asesor, declarada de forma transparente como limitación del estudio
R4. Falla del equipo de desarrollo	Alta	Media	Código, datos y documentos sincronizados en repositorio remoto; entorno replicable por archivo de configuración	Reinstalar el sistema, clonar el repositorio y recrear el entorno desde su especificación
R5. Incompatibilidad del entorno de ejecución	Media	Media	Requerimientos explícitos y versionados; contenedor de ejecución; versiones estables de las bibliotecas clave	Proveer un entorno preconfigurado listo para ejecutar; migrar a versiones compatibles
R6. Aumento del costo de cómputo en la nube	Baja	Baja	Desarrollo y depuración en recursos locales o gratuitos; uso eficiente de la GPU; priorización de experimentos	Reducir el alcance de la experimentación; solicitar créditos académicos; usar recursos de la universidad
R7. Retrasos por disponibilidad limitada del tesista	Alta	Alta	Cronograma con holgura basado en la EDT; bloques de tiempo protegidos; seguimiento semanal del avance	Replanificar al detectar la desviación; negociar reducción de alcance con el asesor; priorizar la ruta crítica

Bibliografía

- Airale, L., Pajot, A., and Linossier, J. (2025). NBM: an open dataset for the acoustic monitoring of nocturnal migratory birds in europe.
- Blumstein, D. T., Mennill, D. J., Clemins, P., Girod, L., Yao, K., Patricelli, G., Deppe, J. L., Krakauer, A. H., Clark, C., Cortopassi, K. A., Hanser, S. F., McCowan, B., Ali, A. M., and Kirschel, A. N. G. (2011). Acoustic monitoring in terrestrial environments using microphone arrays: applications, technological considerations and prospectus. *Journal of Applied Ecology*, 48(3):758–767.
- Bonet-Solá, D. and Alsina-Pagès, R. M. (2021). A comparative survey of feature extraction and machine learning methods in diverse acoustic environments. *Sensors*, 21(4):1274.
- Campos, R., Krofel, M., Rio-Maior, H., and Renna, F. (2025). Howlish: a cnn for automated wolf howl detection. *Remote Sensing in Ecology and Conservation*.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., and Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- Ebbers, J., Germain, F. G., Wichern, G., and Roux, J. L. (2024). Sound event bounding boxes.
- Escobar-Amado, C., Badiey, M., and Wan, L. (2024). Computer vision for bioacoustics: Detection of bearded seal vocalizations in the chukchi shelf using YOLOV5. *IEEE Journal of Oceanic Engineering*, 49(1):133–144.
- Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daume III, H., and Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12):86–92.
- Gibb, R., Browning, E., Glover-Kapfer, P., and Jones, K. E. (2018). Emerging opportunities and challenges in passive acoustic monitoring. *Methods in Ecology and Evolution*, 9(5):1191–1201.
- González, S. S., Quiros, S. B., and Toledano, D. T. (2025). YOLO-based transfer learning for sound event detection using visual object detection techniques. *Applied Sciences*, 16(1).
- He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778.

- He, Y., Trigoni, N., and Markham, A. (2021). SoundDet: Polyphonic moving sound event detection and localization from raw waveform.
- Heinicke, S., Kalan, A. K., Wagner, O. J., Mundry, R., Lukashevich, H., and Kuhl, H. S. (2015). Assessing the performance of a semi-automated acoustic monitoring system for primates. *Methods in Ecology and Evolution*, 6(7):753–763.
- Jin, C., Kim, M., Jang, S., and Paeng, D.-G. (2022). Semantic segmentation-based whistle extraction of indo-pacific bottlenose dolphin residing at the coast of jeju island. *Ecological Indicators*, 137:108792.
- Kahl, S., Wood, C. M., Eibl, M., and Klinck, H. (2021). BirdNET: A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 61:101236.
- Kath, H., Serafini, P. P., Campos, I. B., Gouvêa, T. S., and Sonntag, D. (2024). Leveraging transfer learning and active learning for data annotation in passive acoustic monitoring of wildlife. *Ecological Informatics*, 82:102710.
- Kershenbaum, A., Blumstein, D. T., Roch, M. A., Akçay, Ç., Backus, G., Bee, M. A., Bohn, K., Cao, Y., Carter, G., Cašar, C., Coen, M., DeRuiter, S. L., Doyle, L., Edelman, S., Ferrer-i Cancho, R., Freeberg, T. M., Garland, E. C., Gustison, M., Harley, H. E., Huetz, C., Hughes, M., Hyland Bruno, J., Ilany, A., Jin, D. Z., Johnson, M., Ju, C., Karnowski, J., Lohr, B., Manser, M. B., McCowan, B., Mercado III, E., Narins, P. M., Piel, A., Rice, M., Salmi, R., Sasahara, K., Sayigh, L., Shiu, Y., Taylor, C., Vallejo, E. E., Waller, S., and Zamora-Gutiérrez, V. (2016). Acoustic sequences in non-human animals: a tutorial review and prospectus. *Biological Reviews*, 91(1):13–52.
- Koga, N., Bando, Y., and Imoto, K. (2024). LEAD dataset: How can labels for sound event detection vary depending on annotators? In *2024 Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*, pages 1–6. ISSN: 2640-0103.
- Leroy, E. C., Thomisch, K., Royer, J.-Y., Boebel, O., and Van Opzeeland, I. (2018). On the reliability of acoustic annotations and automatic detections of Antarctic blue whale calls under different acoustic conditions. *The Journal of the Acoustical Society of America*, 144(2):740–754.
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., and Zitnick, C. L. (2014). Microsoft coco: Common objects in context. In *Computer Vision – ECCV 2014*, pages 740–755.
- Lostanlen, V., Salamon, J., Farnsworth, A., Kelling, S., and Bello, J. P. (2019). Robust sound event detection in bioacoustic sensor networks. *PLOS ONE*, 14(10):e0214168.
- Meedeniya, D., Ariyaratne, I., Bandara, M., Jayasundara, R., and Perera, C. (2023). A survey on deep learning based forest environment sound classification at the edge. *ACM Computing Surveys*, 56(3):1–36.
- Nam, H., Kim, S.-H., Ko, B.-Y., and Park, Y.-H. (2022). Frequency dynamic convolution: Frequency-adaptive pattern recognition for sound event detection. pages 2763–2767.

- Nguyen Hong Duc, P., Torterotot, M., Samaran, F., White, P. R., Gérard, O., Adam, O., and Cazau, D. (2021). Assessing inter-annotator agreement from collaborative annotation campaign in marine bioacoustics. *Ecological Informatics*, 61:101185.
- Nolasco, I., Singh, S., Morfi, V., Lostanlen, V., Strandburg-Peshkin, A., Vidaña-Vila, E., Gill, L., Pamuła, H., Whitehead, H., Kiskin, I., Jensen, F. H., Morford, J., Emmerson, M. G., Versace, E., Grout, E., Liu, H., Ghani, B., and Stowell, D. (2023). Learning to detect an animal sound from five examples. *Ecological Informatics*, 77:102258.
- Pham, P., Li, J., Szurley, J., and Das, S. (2018). Eventness: Object detection on spectrograms for temporal localization of audio events.
- Politis, A., Adavanne, S., and Virtanen, T. (2020). A dataset of reverberant spatial sound scenes with moving sources for sound event localization and detection. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events 2020 Workshop (DCASE2020)*, pages 165–169.
- Stowell, D. (2022). Computational bioacoustics with deep learning: a review and roadmap. *PeerJ*, 10:e13152.
- Vellinga, W.-P. (2026). Xeno-canto - bird sounds from around the world.
- Venkatesh, S., Moffat, D., and Miranda, E. R. (2022). You only hear once: A YOLO-like algorithm for audio segmentation and sound event detection. *Applied Sciences*, 12(7):3293.
- Veselý, A. (2008). Problem tree: A problem structuring heuristic. *Central European Journal of Public Policy*, 2(2):68–80.
- Wood, L., Anderson, K., Gerstoft, P., Bell, R., Subbaraman, R., and Bharadia, D. (2022). Deep learning object detection approaches to signal identification.
- Zhu, Z. and Sato, Y. (2025). Sound event detection using time-frequency bounding boxes with a self-supervised audio spectrogram transformer. In *Proceedings of the Detection and Classification of Acoustic Scenes and Events 2025 Workshop (DCASE2025)*, Barcelona, Spain.